

好的，这是根据你提供的Audio-Omni论文PDF翻译的中文版本。我已严格按照要求，去除了参考文献部分，并完整保留了原文的结构、所有内容、公式、表格和图表示意，其中“token”一词根据指示未作翻译。

Audio-Omni: 将多模态理解扩展到通用的音频生成与编辑

ZEYUE TIAN, 香港科技大学, 中国香港特别行政区 BINXIN YANG, 微信视觉团队, 腾讯公司, 中国 ZHAOYANG LIU, 香港科技大学, 中国香港特别行政区 JIEXUAN ZHANG, 北京大学, 北京, 中国 RUIBIN YUAN, 香港科技大学, 中国香港特别行政区 HUBERY YIN, 微信视觉团队, 腾讯公司, 中国 QIFENG CHEN, 香港科技大学, 中国香港特别行政区 CHEN LI*, 微信视觉团队, 腾讯公司, 中国 JING LYU, 微信视觉团队, 腾讯公司, 中国 WEI XUE*, 香港科技大学, 中国香港特别行政区 YIKE GUO, 香港科技大学, 中国香港特别行政区

图1. Audio-Omni框架及其能力概览。(顶部) 我们的解耦架构通过一个特征投影器，将用于理解的冻结MLLM与用于音频合成的可训练DiT连接起来。(中间) 模型在理解、生成和编辑方面统一能力的展示。(底部) 从MLLM继承而来的显著涌现能力展示。

多模态模型的最新进展推动了音频理解、生成和编辑领域的快速发展。然而，这些能力通常由专门的模型处理，使得开发一个能够无缝整合所有三项任务的真正统一框架仍待探索。虽然一些开创性工作已探索统一音频理解和生成，但它们通常局限于特定领域。为解决此问题，我们引入了Audio-Omni，这是首个端到端框架，统一了通用声音、音乐和语音领域的生成与编辑，并集成了多模态理解能力。我们的架构协同了一个用于高层推理的冻结多模态大语言模型（MLLM）和一个用于高保真合成的可训练扩散Transformer（DiT）。为克服音频编辑中关键的数据稀缺问题，我们构建了AudioEdit，一个包含超过一百万个精心策展编辑对的大规模新数据集。大量实验表明，Audio-Omni在一系列基准测试中取得了最先进的性能，超越了先前的统一方法，同时实现了与专门专家模型相当或更优的性能。在其核心能力之外，Audio-Omni展现出显著的继承能力，包括知识增强的推理生成、上下文生成和用于音频生成的零样本跨语言控制，突显了朝着通用生成式音频智能的一个有前景的方向。代码、模型和数据集将公开发布在 <https://zeyuet.github.io/Audio-Omni>。

CCS概念: 计算方法 → 人工智能；机器学习；计算机图形学。

附加关键词和短语: 音频生成，多模态学习，扩散模型，统一模型，音频编辑

1 引言

多模态学习的最新进展催生了在单一模型中集成理解与生成的统一框架趋势，并在视觉领域如图像 [Chen et al. 2025b; Jiao et al. 2025; Ma et al. 2025; Pan et al. 2025] 和视频 [Liu et al. 2025a; Wei et al. 2025] 的理解与生成方面取得了显著进展。然而，音频领域仍相对探索不足。

与视觉模态不同，音频涵盖三个具有显著分布差异的不同领域：通用声音、音乐和语音。虽然已做出一些努力来统一音频理解和生成，但它们仍局限于特定领域，如以语音为中心的模型 [Al et al. 2025; An et al. 2024] 或仅限于通用音频和音乐的模型 [Liu et al. 2024a; Tian et al. 2025b]，未能覆盖完整的音频频谱。其他系统依赖于基于工具的集成 [Huang et al. 2024a]，缺乏端到端优化。与此同时，现有的音频编辑模型 [Manor and Michaeli 2024; Wang et al. 2023b] 专为编辑而设计，无法扩展到理解或生成，使得统一所有三项能力成为一个开放的挑战。

为解决这些局限性，我们引入了Audio-Omni，一个统一了跨完整音频领域频谱的音频理解、生成和编辑的框架。我们采用了解耦设计：一个冻结的多模态大语言模型（MLLM）作为推理核心，而一个可训练的扩散Transformer（DiT）负责处理和编辑。保持MLLM冻结保留了其丰富的多模态知识，这反过来赋予了生成模块超越其明确训练范围的能力。为有效连接这两个组件，我们设计了一种混合条件机制，将输入解耦为两个互补的流：一个高层语义流，结合MLLM特征和用于语音合成的文本嵌入，通过交叉注意力注入以提供指令性指导；以及一个低层信号流，融合梅尔频谱图和视频同步特征，与输入噪声拼接以提供精确的时间控制。这种分离是在单一框架内掌握声音、音乐和语音的多样化需求的关键。

训练一个具有此规模的统一模型需要一个全面且多样化的数据集。指令引导音频编辑进展的一个关键障碍是缺乏任何大规模的公开数据集。为填补这一空白，我们精心设计了一个流程来构建AudioEdit，一个用于此任务的大规模、高质量数据集。通过结合真实世界数据挖掘与可扩展程序化合成的系统化流程创建，AudioEdit包含超过100万个严格策展的样本，涵盖添加、移除、提取和风格迁移等编辑任务。在此数据集上训练使我们的模型具备了强大的编辑能力。

大量实验验证了我们统一设计的有效性。Audio-Omni在理解、生成和编辑任务上均优于先前的统一模型，并在多项任务上与专门专家模型持平或超越。在这些核心结果之外，生成模块自然继承了冻结MLLM的能力，包括用于基于推理生成的世界知识、用于音频条件合成的上下文学习，以及用于跨语言控制的多语言理解。

总之，我们的主要贡献如下：

我们提出了Audio-Omni，这是首个统一了跨通用声音、音乐和语音领域的音频理解、生成和编辑的框架。其核心是一个解耦架构，通过一个混合条件机制桥接冻结的MLLM与可训练的DiT，以解耦语义和信号级别的控制。我们引入了AudioEdit，一个大规模、高质量的数据集，其用于指令引导音频编辑的精细流程涵盖了广泛的任務，以促进该领域的未来研究。大量实验表明，Audio-Omni优于先前的统一模型，并在广泛的任務上取得了与专门专家模型相比具有竞争力或更优的结果。此外，Audio-Omni在生成方面展现出显著的继承能力，例如知识增强生成和跨语言控制，突显了通向智能且通用的生成式音频系统的一条路径。

2 相关工作

音频领域的专门模型。近年来，音频处理领域取得了显著进展，特别是随着大规模预训练模型的出现。对于音频理解，大量工作已产生能够处理跨所有三个音频领域复杂任务的强大模型 [Chu et al. 2024, 2033; Ghosh et al. 2025; Kong et al. 2024; Tang et al. 2024]。与理解中全面的领域覆盖相比，生成模型通常更加专门化。在通用音频领域，像 [Evans et al. 2024; Ghosal et al. 2023; Huang et al. 2023; Majumder et al. 2024] 这样的著名文生音频模型已展示了从文本描述进行高保真合成的能力，而其他方法则探索了以视频为条件的生成 [Cheng et al. 2025; Liu et al. 2025c, 2024b; Xing et al. 2024]。类似地，在音乐领域，像 [Chen et al. 2024; Copet et al. 2024; Deng et al. 2024; He et al. 2024; Melechovsky et al. 2024; Yinghao et al. 2024; Yuan et al. 2025, 2024] 这样的模型擅长文生音乐，并且专门的研究也涉及了视频到音乐的生成 [Lin et al. 2024; Su et al. 2023; Tian et al. 2025c; Xie et al. 2025a]。语音领域拥有自己丰富的研究版图，包括强大的文语转换（TTS）系统 [Chen et al. 2025a; Deng et al. 2025; Du et al. 2024] 和支持如语音转换（VC） [Peng et al. 2024; Wang et al. 2023a] 等复杂变换的模型。虽然一些近期模型展示了处理多模态条件或跨多个领域生成音频的能力 [Liu et al. 2025b; Rong et al. 2025; Tian et al. 2025a; Wang et al. 2025a]。与此同时，音频编辑领域仍待充分探索，很大程度上是由于缺乏大规模的指令引导数据集。现有方法分为两大类。无需训练、零样本的方法适配预训练模型，但往往难以保持非目标内容和遵循精确指令 [Manor and Michaeli 2024]。基于训练的方法，如 [Lan et al. 2025; Tao et al. 2025; Wang et al. 2023b]，构建了合成数据流程，但引入了显著的领域差距，因为其混合独立音频段的策略无法捕捉真实世界编辑场景的声学复杂性。

统一多模态模型。近期，多模态研究的一个主要趋势是开发旨在单一框架内处理理解和生成的统一模型。这种统一在视觉领域取得了显著成功，像 [Chen et al. 2025b; Jiao et al. 2025; Ma et al. 2025; Pan et al. 2025] 这样的模型实现了统一的图像理解和生成，而其他模型则将这些能力扩展到视频领域 [Liu et al. 2025a; Wei et al. 2025]。一些框架甚至支持跨不同模态的生成，如文本、图像、音频和视频 [Lu et al. 2024; Wu et al. 2024; Zhan et al. 2024]。在音频领域，一些开创性工作 [Al et al. 2025; An et al. 2024; Huang et al. 2024b; Liu et al. 2024a] 也朝着这个统一目标迈进。然而，它们存在关键局限性。一些方法依赖于通过工具调用来编排独立的专家模型 [Huang et al. 2024b]，这缺乏端到端优化的优势。其他模型虽然更加集成，但通常关注音频领域的有限子集，如仅语音 [Al et al. 2025; An et al. 2024] 或仅音乐生成 [Liu et al. 2024a]，未能提供真正通用的解决方案。为解决这些不足，我们提出了Audio-Omni，这是首个统一了跨所有通用声音、音乐和语音领域的理解、生成和编辑的框架。我们的方法提供了一个内聚的端到端解决方案，克服了专门模型的碎片化和现有统一工作的领域局限性。

3 音频编辑数据集构建

表1. 我们提出的音频编辑数据集AudioEdit的统计信息。

任务类型|数据来源|训练样本|测试样本

添加 真实数据 50K 500 合成数据 150K -	移除 真实数据 50K 500 合成数据 150K -	提取 真实数据 50K 500 合成数据 150K - 风格迁移 真实数据 500K 500 总计 1,100K 2,000
-----------------------------	-----------------------------	---

推进指令引导音频编辑的一个障碍是缺乏大规模配对数据集。虽然开创性工作如 [Lan et al. 2025; Tao et al. 2025; Wang et al. 2023b] 提出了合成流程，但它们依赖混合独立音频段的做法引入了与真实世界音频（其中声音是整合的）显著的领域差距。此外，这些方法在复杂的音频风格迁移等任务上常常失败，难以将声学风格与时间结构和音高等核心内容属性解耦。为解决这些局限性，我们引入了AudioEdit，一个通过集成真实世界数据挖掘与可扩展合成的新型混合流程构建的大规模数据集。

如图2所示，我们的流程具有两个互补的分支，以生成兼具真实世界声学保真度和大规模多样性的数据集。**真实数据分支**从真实世界数据集VGGSound [Chen et al. 2020]中挖掘真实的编辑对。首先，我们采用强大的MLLM (Gemini 2.5 Pro) 来识别每个源音频片段中的主要发声对象类别。然后，我们部署SAM-Audio [Shi et al. 2025]，一个最先进的音频分割模型，基于识别出的类别执行源分离。此步骤将源音频解耦为一个包含指定对象音频的目标音轨和一个相应的残差音轨。随后，所有分离出的音轨经过严格的多阶段过滤以确保质量。从超过54万个带有类别标签的样本开始，我们应用VAD¹过滤（保留约 $\sim 347K$ 对），然后进行基于CLAP [Elizalde et al. 2023]的语义对齐（保留约 $\sim 50K$ 对，总体保留率约为 9.2%）。在子集上进行的人工验证达到了约 83% 的一致性，确认了流程质量。此过程为添加、移除和提取任务生成了高质量的源-目标对。对于风格迁移，我们通过提示Gemini生成语义相关但不同的关键词（提示模板见附录1.1）来扩展过滤后的目标，然后再次应用CLAP过滤，产生约 500K 对。我们使用ZETA [Manor and Michaeli 2024] 将每个目标转换为新风格，同时保持时间结构和音高，然后将转换后的音频与残差音轨混合以形成最终编辑输出。同时，我们的**合成数据分支**通过使用Scaper工具包 [Salamon et al. 2017] 程序化生成声景来确保规模和多样性。这是通过将来自ESC-50 [Piczak 2015] 的前景事件随机混合到来自AudioCaps [Kim et al. 2019] 的10秒背景中实现的，应用随机化参数包括起始时间、信噪比 (0-3 dB)、音高偏移 (-3 到 +3 半音) 和时间拉伸因子 (0.8-1.2)。此自动化过程高效地产生了大量带有精确标注的数据，用于我们的添加、移除和提取任务。

通过这个精心设计的混合流程，我们构建了AudioEdit，一个用于指令引导音频编辑的大规模、高质量数据集。AudioEdit总共包含超过100万个样本，涵盖添加、移除、提取和风格迁移音频编辑任务，详细统计信息见表1。

4 方法

在本节中，我们描述Audio-Omni的架构及其训练策略。

4.1 预备知识

修正流 (Rectified Flow)。我们的生成主干建立在修正流 [Liu et al. 2022] 的框架之上，这是一类强大的生成模型。与通常遵循随机路径的传统扩散模型不同，修正流通过建模噪声和数据之间的直线轨迹来简化生成过程。这条轨迹通过一个常速度场 $\mathbf{v} = \mathbf{x}_1 - \mathbf{x}_0$ 连接随机噪声样本 $\mathbf{x}_1 \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$ 和数据样本 $\mathbf{x}_0$ 。该常微分方程 (ODE) 对时间变量 $t \in [0, 1]$ 定义为：

$$\frac{d\mathbf{x}_t}{dt} = \mathbf{v}. \quad (1)$$

沿此线性路径在任何时间 t 的解由插值给出：

$$\mathbf{x}_t = (1 - t)\mathbf{x}_0 + t\mathbf{x}_1. \quad (2)$$

一个神经网络，记为 $v_\theta(\mathbf{x}_t, t, c)$ ，被训练来预测这个速度场 $\mathbf{v}$ ，其条件为带噪状态 $\mathbf{x}_t$ 、时间 t 和一组条件信号 c 。在推理期间，生成从 $t = 1$ 时的随机噪声样本 $\mathbf{x}_1$ 开始，使用数值求解器将方程1中的ODE反向求解到 $t = 0$ ，由 v_θ 的预测引导。 v_θ 的训练目标在第4.3节中详述。

4.2 模型架构

如图3所示，我们的Audio-Omni框架建立在一个解耦架构之上，该架构包含一个用于理解的冻结MLLM和一个用于通用音频生成与编辑的可训练DiT主干。

理解模块。我们的理解模块是一个预训练并冻结的MLLM，它作为我们框架的主要推理和理解核心。它处理多样化的输入集，包括文本指令 ($\mathbf{T}_{\text{in}}$)、音频波形 ($\mathbf{A}_{\text{in}}$) 和视频 ($\mathbf{V}_{\text{in}}$)，这些输入由其各自的编码器进行token化。MLLM在我们的框架中扮演双重角色。对于理解任务，它直接基于多模态输入生成文本响应。对于生成任务，其关键功能是为生成模块产生一个强大的条件信号。为此，我们提取其倒数第二层（即第二到最后一层的隐藏状态）的隐藏状态，因为我们凭经验发现，与最后一层相比，这为下游生成任务提供了更具泛化性和更丰富的语义表征（见第5.4节）。我们将此多模态特征记为 $\mathbf{F}_{\text{mm}} \in \mathbb{R}^{L_{\text{mm}} \times D_{\text{mm}}}$ 。

生成模块。生成模块由一个以修正流目标训练的DiT主干组成，用于合成最终的音频波形。该模块以两个不同的特征流为条件，使其能够处理广泛的任務。

第一个流，我们称之为**高层语义特征**，为合成过程提供主要的指令信号。此流通过将来自MLLM的多模态特征 $\mathbf{F}_{\text{mm}}$ 与用于语音相关任务的转录衍生特征 $\mathbf{F}_{\text{trans}}$ 拼接而成：

$$\mathbf{c}_{\text{high}} = \text{Concat}(\mathbf{F}_{\text{mm}}, \mathbf{F}_{\text{trans}}). \quad (3)$$

特征 $\mathbf{F}_{\text{trans}}$ 由转录编码器产生，其对输入转录 $\mathbf{T}_{\text{trans}}$ （用于TTS/VC任务）执行字符级编码。具体来说，它首先将文本转换为字符嵌入序列，然后由基于ConvNeXtV2的架构处理。

第二个流，称为**低层信号特征**，提供对编辑和同步任务至关重要的具体的、时间对齐的参考。此流通过拼接来自参考音频和视频同步信号的特征形成：

$$\mathbf{c}_{\text{low}} = \text{Concat}(\mathbf{F}_{\text{sync}}, \mathbf{F}_{\text{mel}}). \quad (4)$$

梅尔频谱图特征 $\mathbf{F}_{\text{mel}}$ 由梅尔编码器从参考音频 $\mathbf{A}_{\text{ref}}$ （用于编辑）或语音提示 $\mathbf{S}_{\text{prompt}}$ （用于语音转换）中提取。同步特征 $\mathbf{F}_{\text{sync}}$ 由预训练的Synchformer [lashin et al. 2024] 模型从输入视频 $\mathbf{V}_{\text{in}}$ 中提取。

图3. Audio-Omni框架。我们的框架采用了解耦设计，具有两个不同的条件流来引导可训练的DiT主干。高层语义特征流提供全局性的指令指导。它通过拼接来自冻结MLLM的特征（MM特征）与来自可训练转录编码器的字符级嵌入形成。低层信号特征流为编辑和同步提供精确的时间指导。它结合了来自Synchformer和梅尔编码器的特征。这两个流通过不同的机制注入DiT：高层流作为交叉注意力的上下文，低层流则与输入噪声和时间嵌入拼接。

这两个条件流通过针对其属性定制的不同机制注入DiT主干。**高层语义特征** ($\mathbf{c}_{\text{high}}$) 通过交叉注意力作为上下文注入，允许模型在生成过程的每一步灵活地查询抽象指令。相比之下，**低层信号特征** ($\mathbf{c}_{\text{low}}$) 首先通过元素级加法与时间嵌入融合，然后将此组合信号与VAE编码的带噪音频隐变量 ($\mathbf{x}_t$) 拼接，形成DiT的主要输入。这种拼接提供了强大的逐帧指导，确保了编辑和同步任务的精确对齐。DiT主干随后处理此复合输入以预测速度场，其最终的去噪隐变量输出被传递给VAE解码器以重建音频波形。

4.3 训练目标

我们使用基于修正流目标的单一统一损失函数端到端地训练我们的Audio-Omni。对于每个训练样本，我们的目标是训练网络 v_θ 来预测常速度 $\mathbf{v} = \mathbf{x}_1 - \mathbf{x}_0$ ，其中 $\mathbf{x}_0$ 是目标音频的VAE编码隐变量， $\mathbf{x}_1$ 是来自 $\mathcal{N}(\mathbf{0}, \mathbf{I})$ 的随机噪声样本。遵循标准的RF训练流程，我们首先从均匀分布 $\mathcal{U}(0, 1)$ 中采样一个随机时间步 t 。该时间步用于创建插值的隐状态 $\mathbf{x}_t = (1 - t)\mathbf{x}_0 + t\mathbf{x}_1$ 。然后训练目标是最小化网络预测速度与真实速度 $\mathbf{v}$ 之间的均方误差。损失函数 $\mathcal{L}$ 定义为：

$$\mathcal{L} = \mathbb{E}_{t \sim \mathcal{U}(0,1), \mathbf{x}_0, \mathbf{x}_1, \mathbf{c}} [\|v_\theta(\mathbf{x}_t, t, \mathbf{c}) - (\mathbf{x}_1 - \mathbf{x}_0)\|^2] \quad (5)$$

其中 $\mathbf{c}$ 代表给定训练样本可用的全部条件信号。

5 实验

5.1 实现细节

模型架构。对于MLLM，我们使用预训练的Qwen2.5-Omni-3B模型 [Xu et al. 2025]，它以5 fps处理输入视频，以16 kHz处理音频。我们从其倒数第二层提取特征作为主要的语义条件。DiT主干是一个Transformer架构，深度为36层，隐藏维

度为2048，注意力头数为32。整个模型总共约有79亿参数，其中30.5亿（DiT和条件器）是可训练的。我们的条件模块包括一个Synchformer [Iashin et al. 2024]，从25 fps的视频中提取同步特征；一个梅尔编码器，计算100维的梅尔频谱图（44.1 kHz, FFT大小1024, hop 256）；以及一个由四个ConvNeXtV2块组成的转录编码器，用于字符级文本编码。最终音频由采用自 [Evans et al. 2024] 的预训练VAE进行编码和解码。

数据集。训练数据来源及其规模总结在附录表A4中。

训练细节。我们训练DiT主干和所有可学习条件模块约80k步，总批次大小为5120。我们使用AdamW优化器，学习率为 $5e-5$ ， $\beta_1 = 0.9$ ， $\beta_2 = 0.999$ ，权重衰减为 $1e-3$ 。整个模型使用修正流目标（方程5）端到端训练。为增强语音转换和语音编辑能力，我们在训练期间遵循 [Chen et al. 2025a] 对语音提示采用掩码策略。具体来说，我们随机掩码提示的梅尔频谱图的20%到75%，迫使模型从部分声学信号推断全局说话人音色，同时使用完整的转录重建整个话语。此方案对于开发模型稳健的零样本语音克隆和内容编辑能力至关重要。

推理细节。在推理时，我们使用数值ODE求解器，以100步从随机噪声样本生成音频隐变量。对于条件生成，我们采用无分类器引导，引导尺度为6.0。

5.2 评估指标

为评估Audio-Omni，我们对其理解、生成和编辑能力采用了一套全面的指标。对于理解，我们在MMSU [Wang et al. 2025b] 和MMAU [Sakshi et al. 2024] 基准上报告分数以评估多任务推理。对于生成，我们使用PANNs [Kong et al. 2020] 嵌入上的KL散度、Inception Score (IS)、Fréchet Audio Distance (FAD) 和Fréchet Distance (FD) 来衡量分布相似性和质量。语音合成性能特别使用词错误率（WER）进行评估。对于编辑，我们使用对数谱距离（LSD）来衡量保真度和内容保持，并使用FAD来评估感知质量。

5.3 主要结果

在本节中，我们展示了Audio-Omni的定量和定性结果，评估其在理解、生成和编辑任务上相对于各种专门和统一模型的性能。

5.3.1 整体性能。如表2、表3和表4所示，Audio-Omni在理解、生成和编辑任务上展现出强大而全面的能力。

理解。得益于我们的解耦架构，Audio-Omni从冻结的MLLM核心继承了强大的理解能力，其音频编码器已在大规模音频相关数据上进行了预训练，使其在多领域音频任务上表现强劲 [Xu et al. 2025]。我们在MMSU（涵盖47个口语语言任务）和MMAU（评估跨声音、音乐和语音的27项推理技能）上进行了评估。如表2所示，Audio-Omni取得了强大的理解性能，优于大多数统一模型，并接近专用理解专家的水平。

生成与编辑。对于生成任务，Audio-Omni展现出最先进或极具竞争力的性能。我们在标准测试集上报告FAD：AudioCaps用于T2A，MusicCaps用于T2M，VGGSound用于V2A，以及V2M-bench用于V2M。对于语音合成，我们在Seed-TTS [Anastassiou et al. 2024] en基准上评估WER。在生成任务中，我们的模型展现出强大的整体性能，持续且显著地优于所有其他统一模型。值得注意的是，它在T2M和TTS上进一步超越了专门的专家模型。对于编辑，我们在我们提出的AudioEdit测试集上报告了四个任务（添加、移除、提取、风格迁移）的平均FAD和LSD。我们还报告了CLAP分数（在添加、提取和风格迁移上平均）以评估指令遵循。如表4所示，Audio-Omni在所有指标上均取得了最佳性能，每个任务的详细结果见附录表A3。

总之，表2、表3和表4验证了我们统一框架的有效性：Audio-Omni从冻结的MLLM继承了强大的理解能力，同时在生成和编辑任务上取得了最先进或极具竞争力的结果，表明一个单一的统一模型可以作为跨完整音频任务频谱的强大通才。

5.3.2 零样本跨语言文生音频生成。我们框架的一个显著能力是其零样本跨语言生成，这继承自冻结MLLM的多语言理解能力。如附录表A2所示，尽管Audio-Omni是在英语上训练的，但在多种语言（中文、西班牙语、德语、法语、日语）上仍保持了强劲的性能，其质量可与仅英语的专家模型相媲美。

5.3.3 继承能力与零样本能力。我们进一步突显Audio-Omni的几种代表性能力。前两种是继承自冻结MLLM的世界知识和上下文推理的涌现能力，而后两种由我们基于掩码的训练策略实现。我们在图4中定性地展示了这些能力。

图4. Audio-Omni能力的定性展示，包括 (a) 知识增强生成，(b) 上下文生成，(c) 零样本语音转换，和 (d) 零样本语音编辑。

知识增强生成。Audio-Omni成功处理需要外部世界知识知识密集型提示。例如，当被提示“用Jimi Hendrix演奏的乐器生成一段快乐的音乐。”时，它正确推断出乐器是电吉他，并合成相应的旋律，这是一项超出标准文生音频模型能力的任务。

上下文生成。我们的模型展示了强大的上下文学习能力。给定一段钢琴录音和指令“生成一段能营造紧张感的戏剧性电影级和弦进行”，它提取钢琴的音色并将其应用于新合成的乐曲中。

零样本语音转换与语音编辑。在语音训练期间，我们随机掩码说话人身份或语音内容，迫使模型从上下文中推断缺失的组件。这自然地在推理时实现了零样本语音转换和语音编辑，无需特定于任务的监督。

这些能力表明Audio-Omni超越了一个标准的多任务模型，展现出继承的智能和跨不同音频生成场景的灵活零样本控制。

5.4 消融研究

为验证我们的设计选择，我们在本节中进行了一系列消融研究，更多消融研究包含在附录1.3中。

数据集组成的消融研究。为评估我们数据源的影响，我们评估了三种训练配置：仅使用合成数据、仅使用真实世界数据，或混合使用两者。如表5所示，混合数据方法产生了最佳的整体性能。这表明了一种协同效应，合成数据提供了多样化编辑操作的广泛覆盖，而真实世界数据贡献了关键的声学真实感和保真度。值得注意的是，仅靠合成数据训练不足以实现对真实世界音频声学复杂性的稳健泛化。

条件注入策略的消融研究。我们进行了一项消融研究，以确定整合我们多模态条件的最佳方法。我们通过改变特征（包括多模态 (mm)、转录 (trans)、同步 (sync) 和梅尔频谱图 (mel)）如何传递给DiT主干（通过交叉注意力（上下文）或通道级拼接（Cat））来比较四种不同的注入策略。如表6所示，结果一致地证明了某种特定配置在所有任务中的优越性。该最优策略涉及提供高层条件（mm, trans）作为灵活的上下文，同时将低层条件（sync, mel）与输入噪声拼接。这一结果为未来关于最优统一音频生成条件策略的研究提供了洞见。

条件特征来源选择的消融研究。我们消融了四种从冻结MLLM提取条件特征的策略，在T2A和T2M任务上的结果如表7所示。这些方法包括使用最后一层 (-1) 嵌入、倒数第二层 (-2) 嵌入、MetaQuery（遵循 [Pan et al. 2025]，在输入序列后附加可学习token），以及查询机制（使用可学习token通过交叉注意力关注倒数第二层特征）。我们的结果表明，对于音频生成任务，使用来自倒数第二层的未经过滤的特征序列是最有效的条件策略。倒数第二层的优越性证实了最后一层过于专门化于文本预测，而倒数第二层保留了更丰富、未压缩的语义和声学细节。此外，复杂的查询机制被证明是有害的，这表明高保真音频合成对信息瓶颈敏感，并且最受益于直接访问密集特征。

表2. 多模态理解基准上的定量结果。

方法 MMSU↑ MMAU↑	
专门模型 Audio Flamingo3 [Goel et al. 2025]	61.40 72.42
Qwen2-Audio-Instruct [Chu et al. 2024]	53.27 57.40
Qwen2.5-Omni-3B [Xu et al. 2025]	56.83 63.30
统一模型 Ming-Omni [Al et al. 2025]	47.53 70.80
Unified-IO2 [Lu et al. 2024]	30.7 43.20
MuMuLLaMA [Liu et al. 2024a]	6.32 12.87
Audio-Omni	56.83 63.30

表3. 多模态生成基准上的定量结果。

方法 T2A_FAD↓ T2M_FAD↓ V2A_FAD↓ V2M_FAD↓ TTS_WER↓	
专门模型 Tango2 [Majumder et al. 2024]	3.20 - - -
MMAudio [Cheng et al. 2025]	4.71 - 2.04 - -
Stable-Audio-Open [Evans et al. 2024]	3.15 3.23 - - -
MusicGen [Copet et al. 2024]	- 3.94 - - -
VATT [Liu et al. 2024b]	- - 2.55 - -
AudioX [Tian et al. 2025a]	1.86 1.53 1.13 2.12 -
VidMuse [Tian et al. 2025c]	- - - 2.46 -
统一模型 Ming-Omni [Al et al. 2025]	- - - - -
Unified-IO2 [Lu et al. 2024]	7.81 3.17 - 21.63 -
MuMuLLaMA [Liu et al. 2024a]	- 5.89 - 52.25 -
Audio-Omni	1.86 1.94 1.71 1.58 1.77

FS-TTS [Chen et al. 2025a]|-|-|1.83 MaskGCT [Wang et al. 2024]|-|-|2.62 CosyVoice3 [Du et al. 2025]|-|-|2.46

表4. 音频编辑基准上的定量结果。

方法 AE_FAD↓ AE_LSD↓ CLAP↑				
专门模型	ZETA [Manor and Michaeli 2024]	3.81 3.80 0.30	SDEdit [Meng et al. 2021]	3.51 4.40 0.22
	MMEDIT [Tao et al. 2025]	3.95 4.05 0.15	统一模型	Audio-Omni 3.27 2.27 0.32

表5. 音频编辑训练数据集组成的消融研究。

设置|KL↓|IS↑|FD↓|FAD↓|LSD↓ 仅真实|1.27|5.54|20.69|2.67|1.84 仅合成|1.93|5.04|37.96|3.80|5.17 合成 + 真实 (Ours)|1.30|5.93|20.48|2.48|1.82

表6. 条件注入策略的消融研究。

上下文|拼接|T2A↓|V2A↓|TTS↓|AE↓ mm, trans, sync, mel|none|40.91|25.61|32.46|5.47 mm, trans, sync|mel|38.26|26.46|25.88|4.03 mm, trans|sync, mel|28.90|18.55|19.33|3.62 mm|trans, sync, mel|60.58|56.88|59.20|4.88

表7. 来自MLLM的条件特征来源的消融研究。

特征来源	T2A	T2M	IS↑	FD↓	IS↑	FAD↓	最后一层 (-1)	9.36	4.21	2.90	3.26	倒数第二层 (-2)	11.26	2.75	3.46	3.05
							MetaQuery	7.44	8.34	2.38	8.15	查询 (Query)	8.55	5.31	2.69	4.22

6 结论

在这项工作中，我们介绍了Audio-Omni，这是首个端到端框架，统一了跨完整声音、音乐和语音频谱的音频理解、生成与编辑。我们的解耦架构成功协同了用于高层推理的冻结MLLM与可训练的DiT，并由一个混合条件机制引导，该机制分离了高层语义和低层信号特征。为解决关键的数据瓶颈，我们还构建了AudioEdit，一个包含超过一百万个指令引导编辑的大规模数据集。大量实验表明，我们的单一统一模型不仅匹配或超越了专门专家模型的性能，而且还展现出显著的继承能力，包括知识增强推理和从MLLM继承的零样本跨语言控制。我们相信Audio-Omni提供了一个强大且可扩展的基线，突显了通向通用生成式音频智能的一条有前景的道路。

附录

1.1 数据集详情

我们的模型在混合多样化数据集上训练，详见附录表A4。每个任务的数据组成如下：

- **文生音频 (T2A)**：约 1400 小时，来自 AudioCaps [Kim et al. 2019]、WavCaps [Mei et al. 2024]、AudioSetCaps [Bai et al. 2025] 和 AudioTime [Xie et al. 2025b]。
- **视频生音频 (V2A)**：约 700 小时，来自 VGGSound [Chen et al. 2020] 和 AudioSet Strong [Hershey et al. 2021] 基准。
- **文生音乐 (T2M)**：约 17000 小时，结合了来自 V2M [Tian et al. 2025c] 和 MUCaps [Liu et al. 2024a] 的数据。
- **视频生音乐 (V2M)**：约 16000 小时，完全来自 V2M [Tian et al. 2025c] 数据集。
- **语音**：约 6000 小时，使用 AudioFLAN [Xue et al. 2025] 的英语子集。
- **音频编辑**：约 3000 小时，来自我们内部构建的 AudioEdit 数据集，方法论详见第3节。

风格迁移关键词生成。对于风格迁移数据构建，我们使用 Gemini 2.5 Pro 提示每个音频的原始关键词以生成语义相关但风格不同的目标关键词。提示模板为：“给定音频关键词 '[original_keyword]'，生成一个相关但不同的关键词用于风格迁移。”生成的候选词在通过 CLAP 过滤后，再用于指导 ZETA 进行风格变换。

1.2 更多比较结果

音频编辑任务的详细结果。表 A3 展示了在我们的 AudioEdit 基准上使用 FAD 和 LSD 对四个主要音频编辑任务的详细性能。Audio-Omni 在所有单独任务上均持续达到 SOTA 性能。

生成任务的详细结果。我们在表 A5 中提供了我们的模型在所有生成任务上使用多个评估指标的全面性能分解。该表展示了文生音频 (T2A)、文生音乐 (T2M)、视频生音频 (V2A)、视频生音乐 (V2M) 和文语转换 (TTS) 任务的 KL 散度、Inception Score (IS)、Fréchet Distance (FD) 和 Fréchet Audio Distance (FAD) 结果。

零样本跨语言文生音频生成。我们框架的一个显著继承能力是其零样本跨语言生成，直接继承自冻结 MLLM 的多语言理解能力。为评估这一点，我们使用 Gemini 将 AudioCaps 测试集翻译成中文 (CN)、西班牙语 (ES)、德语 (DE)、法语 (FR) 和日语 (JP)。如表 A2 所示，尽管 Audio-Omni 几乎完全是在英语上训练的，但在所有语言上均保持了强劲的性能。值得注意的是，从非英语提示（例如中文）生成的音频质量可与强大的、仅英语的专家模型相媲美。这一结果验证了我们的解耦架构有效地将 MLLM 的语言能力转移到了合成任务，弥合了生成音频中的语言差距。

表 A1. 不同编码器的消融研究。我们评估了不同编码器对文生音频 (T2A) 和视频生音频 (V2A) 任务的影响。

任务\编码器	KL↓	IS↑	FD↓	FAD↓
T2A T5	1.51	11.27	15.78	2.75
CLAP	1.81	9.64	16.58	1.84
Qwen	1.25	11.65	12.21	2.14
V2A CLIP	2.20	7.42	12.21	2.80
VideoMAE	2.29	6.58	14.72	3.06
Qwen	2.00	8.08	8.50	2.23

表 A2. 零样本跨语言文生音频生成结果。

方法\语言	KL↓	IS↑	FD↓	FAD↓
Tango2 [Majumder et al. 2024]	EN 1.11	10.37	12.22	3.20
AudioX [Tian et al. 2025a]	EN 1.34	12.09	11.83	1.86
MMAudio [Cheng et al. 2025]	EN 1.35	12.03	12.63	4.71
Stable-Audio-Open [Evans et al. 2024]	EN 2.01	10.37	29.01	3.15
Audio-Omni	EN 1.15	11.64	11.97	1.86
	CN 1.65	11.10	15.05	2.26
	ES 2.36	9.16	25.26	4.32
	DE 2.39	9.13	23.51	2.92
	FR 2.47	8.80	28.63	4.21
	JP 2.27	8.67	19.82	3.13

1.3 更多消融研究

统一 MLLM 编码器的作用。为验证我们对理解模块的选择，我们将冻结的 Qwen-Omni-3B (Qwen) MLLM 与专门的单模态编码器进行比较。对于 T2A，在 AudioCaps [Kim et al. 2019] 上评估，我们将其替换为文本编码器 (T5 [Raffel et al. 2020], CLAP [Elizalde et al. 2023])。对于 V2A，在 VGGSound [Chen et al. 2020] 上评估，我们将其与视觉编码器 (CLIP [Radford et al. 2021], VideoMAE [Tong et al. 2022]) 进行比较。如表 A1 所示，结果一致证明了使用统一 MLLM 的优越性，它在两项任务的所有指标上都显著取得了更好的性能。我们将此归因于 MLLM 更丰富的语义理解，更重要的是，其固有的联合处理多模态上下文的能力，捕捉了专门编码器本质上会忽视的跨模态关系。

1.4 人工评估

为补充我们的客观指标，我们与 20 位音频专业人士进行了一项综合人工评估研究。遵循先前音频生成工作中建立的评估协议 [Kreuk et al. 2022; Majumder et al. 2024; Tian et al. 2025a]，我们评估了生成输出相对于竞争基线的感知质量。对于每个任务 (T2A, T2M, V2A, V2M 和音频编辑)，我们随机选择 20 个测试样本，并以随机、匿名的方式呈现给评估者。评估者被要求在每个样本的两个关键维度上打分：整体质量 (OVL)，衡量通用的音频保真度和自然度；以及相关性 (REL)，评估输出与给定条件（文本提示、视频内容或编辑指令）的对齐程度。两个指标均采用 1 到 100 的评分尺度，分数越高表示性能越好。

如表 A6 所示，Audio-Omni 在所有评估任务上持续取得有竞争力或更优的评分，表明我们模型的输出在人类对质量和指令遵循的感知上表现良好。

表 A3. 音频编辑任务的详细结果。我们报告每个任务的 FAD/LSD 及其平均值。

方 法	添 加	移 除	提 取	风 格 迁 移	平均 FAD↓ LSD↓ FAD↓ LSD↓ FAD↓ LSD↓ FAD↓ LSD↓ ZETA [Manor and Michaeli 2024] 5.36 4.15 3.43 4.19 2.86 3.63 3.59 3.27 3.81 3.81 SDEdit [Meng et al. 2021] 4.22 4.18 2.16 4.46 4.51 4.31 3.14 4.63 3.51 4.40 MMEDIT [Tao et al. 2025] 5.30 3.55 2.08 4.41 4.54 3.88 3.88 4.35 3.95 4.05 Audio-Omni 2.78 2.32 3.68 1.91 3.52 2.04 3.11 2.82 3.27 2.27

表 A4. 跨任务的训练数据汇总。

任务 小时数 数据集			
T2A rowspan="4"="4" 1.4k AudioCaps [Kim et al. 2019] WavCaps [Mei et al. 2024] AudioSetCaps [Bai et al. 2025] AudioTime [Xie et al. 2025b]	V2A rowspan="4"="2" 0.7k IF-Caps [Tian et al. 2025a] AudioSet Strong [Hershey et al. 2021]	T2M rowspan="4"="2" 17k IF-Caps [Tian et al. 2025a] MUCaps [Liu et al. 2024a]	V2M rowspan="4"="2" 16k V2M [Tian et al. 2025c] MMTrail [Chi et al. 2024] 语音[6k Audio-FLAN (英语子集) [Xue et al. 2025] 编辑[3k AudioEdit (第3节)

表 A5. 多模态生成基准上使用多个指标的详细定量结果。

方法 KL↓ IS↑ FD↓ FAD↓			
文生音频 (T2A) Tango2 [Majumder et al. 2024] 1.11 10.37 12.22 3.20 MMAudio [Cheng et al. 2025] 1.35 12.03 12.63 4.71 Stable-Audio-Open [Evans et al. 2024] 2.01 10.37 29.01 3.15 Unified-IO2 [Lu et al. 2024] 2.72 5.44 37.95 7.81 AudioX [Tian et al. 2025a] 1.34 12.09 11.83 1.86 Audio-Omni 1.15 11.64 11.97 1.86	文生音乐 (T2M) Stable-Audio-Open [Evans et al. 2024] 1.51 2.94 36.33 3.23 MusicGen [Copet et al. 2024] 1.43 2.24 25.40 4.55 AudioX [Tian et al. 2025a] 1.02 3.54 10.63 1.53 MuMuLaMA [Liu et al. 2024a] 1.00 1.25 52.25 5.10 Unified-IO2 [Lu et al. 2024] 0.81 2.47 18.94 3.17 Audio-Omni 0.84 3.49 8.68 1.41	视频生音频 (V2A) MMAudio [Cheng et al. 2025] 1.97 14.95 6.18 2.04 VATT [Liu et al. 2024b] 1.40 10.02 11.71 2.55 AudioX [Tian et al. 2025a] 2.57 12.16 8.83 1.13 Audio-Omni 1.98 10.35 8.33 1.71	视频生音乐 (V2M) VidMuse [Tian et al. 2025c] 0.73 1.32 22.95 2.46 AudioX [Tian et al. 2025a] 0.69 1.34 23.96 2.12 MuMuLaMA [Liu et al. 2024a] 1.00 1.25 52.25 5.10 Audio-Omni 0.64 1.36 17.46 1.51

表 A6. 生成和编辑任务的人工评估结果。

任务 方法 OVL↑ REL↑				
T2A Tango2 [Majumder et al. 2024] 72.3 74.1 AudioX [Tian et al. 2025a] 81.5 83.2 Audio-Omni 78.6 83.5	T2M MusicGen [Copet et al. 2024] 70.8 72.5 AudioX [Tian et al. 2025a] 79.2 81.3 Audio-Omni 82.7 81.6	V2A MMAudio [Cheng et al. 2025] 80.2 81.8 AudioX [Tian et al. 2025a] 79.5 81.2 Audio-Omni 75.3 77.1	V2M VidMuse [Tian et al. 2025c] 73.5 75.2 AudioX [Tian et al. 2025a] 78.9 80.7 Audio-Omni 80.3 81.0	编辑 SDEdit [Meng et al. 2021] 68.4 70.2 ZETA [Manor and Michaeli 2024] 74.6 76.3 Audio-Omni 79.8 81.5

2 伦理声明

虽然Audio-Omni在音频理解、生成和编辑方面展示了强大的能力，但我们承认生成式音频技术相关的潜在伦理风险。诸如语音转换和语音合成等任务可能被滥用于创建深度伪造、冒充或传播虚假信息。为减轻这些风险，我们在访问模型之

前将要求用户接受负责任的条款，明确禁止恶意应用。我们鼓励社区开发稳健的音频水印和检测方法，并相信通过适当的保障措施，Audio-Omni可以成为创意表达和科学研究的宝贵工具。