

# AuK 技术报告：一个用于语音生成与编辑的开源基础模型

项目页面 [GitHub](#) [AuK](#) [AuK-Flash](#)

1. VAE联合训练 (p: Ming-uniAudio)
2. 混合流DiT, 先双后单
3. 先训生成, 再训编辑

## 摘要

generation-only warm-up

我们介绍了 AuK，一个开源基础模型，通过自然语言指令和音频上下文的统一接口，统一了语音生成与编辑。为支持这一广泛的能力集，我们构建了约 30.3 亿条指令-音频实例和 195 万小时的有效监督，涵盖五个任务家族：语音生成、内容编辑、增强与分离、副语言编辑和声学编辑。AuK 结合了一个用于语义条件的多模态大语言模型、一个在语音、通用音频和音乐上联合训练的 VAE 用于声学条件，以及一个混合修正流 Transformer，该 Transformer 先执行双流 MMDiT 块，然后执行统一单流 DiT 块进行生成。训练从仅生成热身开始，然后进行联合生成-编辑预训练。随后我们应用互补的后训练策略：针对开放式编辑的人类反馈偏好优化，以及针对语音生成的基于奖励的强化学习。为降低推理成本，我们进一步通过一致性初始化和任务路由的解耦 DMD 对模型进行蒸馏。所得的 AuK-Flash 执行 4 步推理，无需无分类器引导，在匹配条件下相比完整模型实现了 4.5× 的挂钟加速。实验表明，在零样本和指令控制的语音生成以及通用指令引导编辑方面具有领先性能，同时在信号级恢复任务上保持竞争力。我们发布了源代码和模型权重，以支持可复现性和进一步研究。

## 1 引言

最近的语音生成系统已从传统的文语转换发展到零样本语音克隆 [10, 12, 11, 6, 68, 86, 29, 1, 28, 51, 88]、指令控制合成 [22, 78, 23, 87, 19, 38, 24]，以及越来越灵活的语音编辑 [72, 73, 63, 65, 4, 3, 33]。然而在实际使用中，这些能力很少孤立出现。用户可能要求系统以描述的风格合成语音、替换话语的一部分、改变其情感或口音、插入非语言发声、分离说话人，或恢复退化音频。用单独的任务特定模型支持此类请求会碎片化用户体验并重复建模工作。这促使我们构建一个统一模型，能够解释自由形式指令并生成所请求的语音。

统一这些能力具有挑战性，原因有三。第一，它们的输出约束根本不同：生成创建新语音，内容编辑仅改变选定区域，副语言和声学编辑必须保留语言内容，而增强或分离必须仅保留指令指定的场景组件。第二，条件接口因任务而异。有些任务仅依赖文本，而其他任务需要对指令和源或参考音频进行联合推理。第三，监督和评估是异构的。识别准确率和说话人相似度为生成提供了可扩展的信号，但开放式编辑还依赖于对自然度、编辑强度、上下文适当性以及未指定属性保持的主观判断。现有的统一音频系统和编辑基准已开始暴露这一更广泛的问题 [72, 73, 44, 79]，但一个具有广泛任务覆盖、可扩展训练和高效推理的单一模型仍然难以实现。

我们介绍了 AuK，一个用于语音生成与编辑的统一基础模型。如图 2 所示，AuK 涵盖语音生成、低级声学控制、副语言转换、内容编辑以及信号增强或分离。我们通过一个通用接口来表述这些能力：自然语言指令和可选的音频上下文被映射到目标波形。AuK 结合了一个 MLLM 语义编码器、一个音频 VAE 和一个混合流 Transformer。MLLM [69] 编码纯文本或文本与参考音频的联合，并将分层隐藏状态聚合为语义条件。AuK-VAE 在语音、通用音频和音乐上联合训练，为参考条件和波形重建提供共享声学隐空间。双流 MMDiT [32] 块首先在语义流和声学流之间交换信息，同时保留它们不同的残差路径；随后的单流 DiT 块联合细化融合序列并预测目标隐变量的修正流速度。这种设计在同一主干内支持纯文本生成和参考条件编辑。

训练的组织旨在解决生成和编辑的不同需求。统一预训练从仅生成热身开始，然后使用共享流匹配目标联合优化生成和编辑任务。后训练包含两个互补阶段。对于编辑，由于任务完成是开放式的，且不存在足够广泛的偏好数据集或奖励模型，我们收集关于自由形式编辑请求的人类反馈，并执行基于流的偏好优化。对于生成，我们应用 Flow-GRPO，使用自动奖励来评估内容正确性、说话人相似度和指令风格一致性。最后，我们通过一致

性初始化和任务路由的解耦 DMD 对后训练模型进行蒸馏。所得的 AuK-Flash 执行 4 步、无 CFG 推理，在匹配条件下相比 32-NFE 教师模型实现了  $4.5\times$  的挂钟加速。

实验涵盖 AuK-VAE 重建、零样本和指令语音生成、通用指令引导语音编辑、语音增强、分离和超分辨率。在这些评估中，AuK 在语音生成和通用指令引导编辑基准上取得了领先性能，同时在信号级恢复任务上保持竞争力。AuK-Flash 在显著降低推理成本的情况下保留了广泛的生成和编辑能力。我们发布了源代码和模型权重，以促进开源社区和进一步研究。

## 2 数据构建

如图 3 所总结，我们将预训练语料组织为五个任务家族：语音生成、声学编辑、副语言编辑、内容编辑以及增强与分离。尽管目标不同，所有任务共享一个统一接口，由自然语言指令、可选输入音频和目标波形组成。这种表述允许单一模型从约 30.3 亿条指令-音频实例中学习生成、恢复、分离和编辑，总有效音频监督达 195 万小时。

### 2.1 语音生成

语音生成教会模型从文本合成自然、易懂且可控的语音。我们构建了两种互补的监督形式：以参考语音为条件的无转录零样本 TTS，以及由自由形式描述控制的指令 TTS。

**零样本 TTS。** 我们通过多阶段策展流程构建大规模双语语料。首先应用源分离和语音增强以提高信号质量，随后进行基于 MOS 的质量过滤、说话人身份验证，以及与多个 ASR 系统的交叉验证，以去除噪声或不一致的话语。

传统零样本 TTS 通常需要参考话语及其转录，使部署依赖额外的 ASR 系统。我们改为将零样本 TTS 表述为无转录的上下文学习。对于具有  $n$  个不同话语的说话人，我们枚举所有  $C_n^2$  个无序对，并将每对中的每个话语一次指定为声学提示、一次指定为合成目标，产生  $n \times (n - 1)$  个双向训练实例。每个实例仅包含提示语音和目标文本；从不提供提示转录。因此，在推理时，模型可以从完整参考话语或随机裁剪的片段克隆说话人，而无需转录。

1个说话人，n句话，产生 $n*(n-1)$ 个训练对，不提供文本使具有无转录TTS能力

**指令 TTS。** 我们从经过标准化预处理和质量控制的大规模双语语音集合中派生指令 TTS 语料。Qwen3-Omni [70] 为每个保留话语标注自由形式自然语言描述和结构化属性，涵盖性别、年龄、语速、清晰度、流畅度、发声状态、语调、响度、音色、音高、口音、情感和个性。我们将此描述与目标文本结合形成输入指令，并使用相应波形作为合成目标。由于不提供参考音频，所得对教会模型直接从表达性描述设计声音。

### 2.2 声学编辑

声学编辑教会模型控制低级说话属性，包括语速、音高和响度，同时保留语言内容、说话人身份以及所有非目标特征。我们使用确定性信号处理变换生成配对监督。

对于每个源话语，我们创建五个语速倍数 ( $0.5\times$ ,  $0.75\times$ ,  $1.25\times$ ,  $1.5\times$ , 和  $2.0\times$ 、六个响度偏移 ( $\pm 5$ ,  $\pm 10$  和  $\pm 15\text{dB}$ )，以及六个音高偏移 ( $\pm 1$ ,  $\pm 2$  和  $\pm 3$  半音) 的目标。语速使用保持音高的时间拉伸修改，音高使用保持时长的音高偏移修改，响度使用波形增益修改。每个变换后的波形与其源和一条指定属性及请求幅度的自然语言指令配对。我们验证每次变换，并在必要时应用峰值保护以防止削波。

### 2.3 副语言编辑

副语言编辑教会模型修改话语的表达方式，同时保留所说的内容。我们为情感、音色、口音、非语言发声和耳语风格编辑构建配对监督。

**情感编辑。** 我们从用于指令 TTS 的双语语音池构建情感编辑样本，以确保语音具有表现力。目标情感从八个类别中采样：愤怒、快乐、悲伤、恐惧、惊讶、厌恶、平静和兴奋。给定源转录和目标情感指令，Qwen3-TTS-CustomVoice [22] 首先合成一个表达性参考话语。然后 IndexTTS2 [86] 以原始话语为条件获取说话人特征，以合成参考为条件获取情感，同时转录保持不变。所得波形与源音频和自然语言编辑指令配对。

**音色编辑。** 我们采用 X-VC [85] 训练语料，该语料使用 SeedVC-Small [41] 构建。每组包含四个对齐的源-目标对，保留语言内容同时改变说话人音色。所有波形通过语音超分辨率增强，并标准化到 24kHz 采样率。Qwen3-Omni [70] 为每个目标波形生成自然语言音色描述，并将其纳入相应的编辑指令。

**去口音。** 我们从涵盖 13 个中文方言和地区口音类别的内部语料构建去口音对。对于每个带口音的源话语，CosyVoice2 [12] 首先使用源话语作为说话人提示，从独立采样的文本合成同说话人标准普通话参考。然后我们部分掩码源，并使用 OmniVoice [89] 以源转录和合成标准普通话参考为条件重建它。目标遵循标准普通话发音，同时保留源说话人的音色和韵律特征。

**非语言编辑。** 我们从公共数据集和具有异构人类和模型派生标注的内部数据集构建非语言编辑语料。我们将这些标注归一化为 39 种事件类型，涵盖生理声音、情感表达和话语发声。对于每个事件，Qwen3-ForcedAligner [59] 定位其时间跨度。我们掩码事件及其直接上下文，然后使用 F5-TTS [6] 重建一个无事件波形，同时保留周围语音、说话人身份和韵律。每个原始-重建对支持事件移除和插入，并带有指定事件类型和位置的自然语言指令。

**耳语：不使用声带振动的，类似悄悄话的**

**耳语风格转换。** 我们从包含平行正常和耳语音音的公共普通话语料构建正常到耳语对。我们仅保留正常和耳语转录满足  $WER = 0$  的对。所有录音重采样到 24kHz，正常语音输入按话语归一化到 RMS 目标 -24 dBFS，与更广泛语音训练语料的平均电平匹配。

## 2.4 内容编辑

内容编辑教会模型插入、删除或替换口语和歌唱内容，同时保留说话人身份、韵律、旋律以及编辑区域之外的声学上下文。我们为语音内容和歌词内容编辑构建配对监督。

**语音内容编辑。** 从高质量转录语音开始，我们使用大语言模型（LLM）生成操作特定的标注和用于插入、删除和替换的目标转录。每个操作独立应用，产生具有显式编辑类型和明确定义目标转录的示例。

我们通过局部掩码填充合成目标波形。Qwen3-ForcedAligner [59] 首先提供源波形和转录之间的词级对齐，允许将每个编辑跨度映射到其时间区间。我们仅掩码这些区间，并以掩码源波形和目标转录为条件，让 F5-TTS [6] 生成请求的内容。这种构建仅修改指定区域，同时保留其他地方的说话人身份、韵律和声学上下文。我们转录每个合成波形并与目标转录比较以进行质量控制，仅保留低词错误率的样本。

**歌词编辑。** 我们从高质量干声录音构建歌词编辑数据。每个录音被转录并在词级与其歌词对齐，之后 LLM 为局部编辑生成源-目标歌词对。中文替换保留字符数，并在拼音级别检查，而英文替换尊重完整词边界并保留词数。

然后 YingMusic-Singer-Plus [20] 合成目标人声。我们仅掩码与编辑歌词相关的隐区间，并以完整目标歌词和原始旋律为条件生成，保留歌手的音色、节奏、表达和周围声学细节。与语音内容编辑一样，我们转录每个合成人声并仅保留低词错误率的样本。

## 2.5 增强与分离

增强与分离训练模型根据自然语言请求转换复杂声学场景。给定相同的混合，指令决定哪些组件应被保留、移除、隔离或恢复，为语音增强、源提取、源移除和选择性编辑提供统一监督。

**语音增强。** 我们通过对质量过滤后的语音应用独立采样的退化来构建语音增强示例。候选非语音录音首先用 ASR 系统转录，包含可懂词的片段被丢弃，然后将剩余音频混合为持续背景噪声或局部声学事件。混响使用测量的房间脉冲响应和具有随机几何、混响时间、源位置和麦克风位置的模拟房间引入。我们还应用信道退化，包括带宽限制、削波、信号丢失、电话和扩音器染色、类水下滤波和直流偏移。随机化这些退化的类型、严重程度和组合可防止模型将指令与单一声学签名关联。

训练目标不限于完全干净的语音。除了恢复原始信号外，我们创建选择性目标，仅移除指令指定的损坏。例如，去噪目标可能保留混响，去混响目标可能保留环境声音，信道恢复目标可能保留所有无关场景属性。因此，模型学习到增强是指令依赖的：为一个请求移除的组件可能为另一个请求有意保留。

**多说话人分离。** 我们通过将多个说话人安排在共享时间线上并具有轮流、停顿、打断和部分或完全重叠来构建对话混合。说话人增益、时间放置、房间声学 and 可选背景干扰独立变化，产生比简单波形相加更接近自然对话的场景。

自然语言指令通过互补线索识别所需说话人，包括口语内容、说话顺序、相对响度或排他性时间戳。指令可以保留或移除一个说话人或一个说话人子集。我们还构建移除说话人同时保留场景噪声、混响和信道效应的目标。解决这些示例要求模型解释请求、定位相关源，并保留所有未明确针对的组件。

**音乐增强与分离。** 对于音乐数据，我们首先使用源分离模型获得对齐的人声和伴奏干声。伴奏被转录并与人声转录或歌词比较；具有大量文本重叠的歌曲被拒绝，以减少伴奏干声中的残留歌声。然后我们构建两种互补的监督形式。原生歌曲示例使用原始歌曲作为输入，时间对齐的干声裁剪作为目标，避免从分离音轨重建输入时产生的伪影。基于场景的示例结合语音、歌声和背景音乐，具有受控时序和增益，创建诸如音乐上说话、语音与歌声混合以及多个重叠歌手的混合。

所得指令请求口语语音、歌声、一组人声源，或按顺序或时间戳识别的歌手。这种设计将音乐处理转化为与对话分离相同的指令条件源选择问题，同时保留真实歌曲的声学复杂性。

---

## 3 模型设计

### 3.1 总体架构

图 4 显示了 AuK 的完整架构。它由三个互补角色的组件组成：MLLM 联合处理文本指令和音频上下文以产生多模态语义条件；预训练变分自编码器（VAE）将音频编码到保留细粒度声学信息的隐空间；FLUX 风格 [32] Transformer 主干促进语义和声学条件之间的交互与融合，同时预测目标声学隐变量。

在训练期间，我们根据输入音频可用性将任务分为两类。（1）有参考音频的任务（例如，零样本 TTS、内容编辑、语音增强和分离）。输入音频被发送到 MLLM 的音频编码器和 VAE 编码器。音频编码器向 LLM 提供音频表示，而文本用户指令直接提供给 LLM。同时，VAE 编码器将相同的输入音频转换为参考声学隐变量。语义条件、参考声学隐变量和带噪目标隐变量沿序列维度拼接。（2）无参考音频的任务（例如，指令 TTS）。用户指令直接提供给 LLM，不提供参考音频。

### 3.2 MLLM 语义条件

多模态语言模型的固定输出层可能无法为多样化的音频生成和编辑任务提供最优条件，因为不同深度的表示捕获互补的语言、声学和跨模态线索。为保留这些信息，AuK 使用 Qwen2.5-Omni [69] 作为其语义编码器，并聚合其分层隐藏状态。

令  $\mathbf{t}$  表示 token 化的用户指令， $\mathcal{E}_{\text{aud}}(\mathbf{x}_{\text{ref}})$  表示从可选参考波形提取的音频编码器。MLLM 第  $\ell$  层的隐藏状态为

$$\mathbf{h}^{(\ell)} = \begin{cases} \text{MLLM}^{(\ell)}(\mathbf{t}, \mathcal{E}_{\text{aud}}(\mathbf{x}_{\text{ref}})), & \text{with reference audio,} \\ \text{MLLM}^{(\ell)}(\mathbf{t}), & \text{otherwise.} \end{cases} \quad (1)$$

因此，音频条件任务联合编码指令和参考音频，而纯文本任务仅从指令派生语义表示。

分层表示被聚合为语义条件：

$$\mathbf{c}_{\text{sem}} = \sum_{\ell=1}^L w_{\ell} \cdot \text{LayerNorm}(\mathbf{h}^{(\ell)}), \quad (2)$$

其中  $L$  是 MLLM 层数， $w_{\ell}$  是第  $\ell$  层的无约束可学习标量。层归一化 [2] 在聚合前平衡跨层的表示尺度。所得的  $\mathbf{c}_{\text{sem}}$  结合了来自多个抽象层次的信息，并用作生成主干的语义条件。

### 3.3 VAE 声学条件与重建

我们采用流增强音频 VAE [77] 为参考音频条件和波形重建提供共享隐空间。其非因果编码器  $\mathcal{E}_{\text{enc}}$  将 24kHz 波形映射为 50Hz 的 64 维隐变量序列，而其因果解码器  $\mathcal{E}_{\text{dec}}$  将隐变量序列映射回音频。归一化流在 VAE 训练期间正则化隐分布。

对于参考波形  $\mathbf{x}_{\text{ref}}$ ，编码器产生后验参数和隐样本

$$(\mu_{\text{ref}}, \log \sigma_{\text{ref}}) = \mathcal{E}_{\text{enc}}(\mathbf{x}_{\text{ref}}), \quad \mathbf{z}_{\text{ref}} = \mu_{\text{ref}} + \epsilon \odot \sigma_{\text{ref}}, \quad \epsilon \sim \mathcal{N}(\mathbf{0}, \mathbf{I}). \quad (3)$$

声学条件是 VAE 编码器隐变量本身：

$$\mathbf{c}_{\text{ac}} = \begin{cases} \mathbf{z}_{\text{ref}}, & \text{if reference audio is available,} \\ \emptyset, & \text{otherwise.} \end{cases} \quad (4)$$

这里， $\mathbf{c}_{\text{ac}}$  是 VAE 空间中的未投影参考隐变量，仅在传递给主干时投影到 Transformer 隐藏维度，如公式 (5) 所述。在 VAE 训练期间，编码器-解码器对优化以重建输入波形。在生成期间，因果解码器  $\mathcal{E}_{\text{dec}}$  将所得目标隐变量转换为输出波形。VAE 架构和训练目标的详细描述见第 4.1 节。

### 3.4 Transformer 主干

AuK 的 Transformer 主干遵循 FLUX 风格 [32] 混合设计。其前  $M$  层是双流 MMDiT 块 [14]，后续  $N$  层是单流 DiT 块 [50]。流时间  $t \sim \mathcal{U}[0, 1]$  的正弦嵌入由 MLP 投影，并用于调制每个块。

**条件映射。** 语义条件、可选声学条件和带噪目标隐变量被映射到两个输入流：

$$\mathbf{s}^{(0)} = \mathcal{P}_{\text{sem}}(\mathbf{c}_{\text{sem}}), \quad \mathbf{a}^{(0)} = [\mathcal{P}_{\text{ref}}(\mathbf{c}_{\text{ac}}); \mathcal{P}_{\text{tgt}}(\mathbf{z}_t)]. \quad (5)$$

这里， $\mathbf{c}_{\text{sem}}$  是 MLLM 语义条件， $\mathbf{c}_{\text{ac}}$  是可选 VAE 参考隐变量， $\mathbf{z}_t$  是流时间  $t$  的带噪目标隐变量。算子  $\mathcal{P}_{\text{sem}}$  由线性投影和 RMSNorm 组成，而  $\mathcal{P}_{\text{ref}}$  和  $\mathcal{P}_{\text{tgt}}$  各由卷积位置嵌入和线性投影组成，如图 4 所示。

**双流 MMDiT 块。** 前  $M$  个块联合更新语义流和声学流：

$$(\mathbf{s}^{(M)}, \mathbf{a}^{(M)}) = \text{MMDiT}^M(\mathbf{s}^{(0)}, \mathbf{a}^{(0)}; \mathbf{e}_t). \quad (6)$$

这里， $\mathbf{e}_t$  是投影的流时间嵌入， $\text{MMDiT}^M$  表示  $M$  个 MMDiT 块的堆叠， $\mathbf{s}^{(M)}$  和  $\mathbf{a}^{(M)}$  是其语义和声学输出。每个块使用流特定的查询、键、值和残差投影。RoPE [61] 根据每个流的位置应用，然后将其注意力张量拼接以进行联合注意力，实现双向语义-声学交互，同时保留独立的残差路径。

**单流 DiT 块。** 更新后的流被拼接，并由后续  $N$  个 DiT 块处理以预测流速度：

$$\tilde{\mathbf{v}}_t = \mathcal{P}_{\text{out}} \left( \text{DiT}^N \left( [\mathbf{s}^{(M)}; \mathbf{a}^{(M)}]; \mathbf{e}_t \right)_{\text{tgt}} \right). \quad (7)$$

这里， $\text{DiT}^N$  表示  $N$  个 DiT 块的堆叠，下标  $\text{tgt}$  从其输出中选择目标隐变量位置， $\mathcal{P}_{\text{out}}$  是最终输出投影， $\tilde{\mathbf{v}}_t$  是预测的流速度。MMDiT 和 DiT 块均在 RoPE 之前应用基于 RMSNorm [76] 的 QK-Norm，并使用零初始化、时间条件的 AdaLN [50] 来调制其注意力和 SwiGLU 前馈网络 [57]。

## 4 模型训练

### 4.1 VAE 训练

AuK-VAE 被训练为提供紧凑隐空间，支持参考音频条件和高质量波形重建。我们描述其架构、训练数据和优化目标。

**架构配置。** AuK-VAE 操作于 24kHz 单声道波形。编码器首先用核大小 3 的卷积将波形投影到 12 通道，随后是六个下采样块，步长为 (2, 2, 2, 3, 4, 5)，通道宽度为  $12 \rightarrow 24 \rightarrow 48 \rightarrow 96 \rightarrow 192 \rightarrow 384 \rightarrow 768$ 。每个块包含一个步长卷积（核大小为步长的两倍）、六个核大小 3、膨胀率 (1, 2, 4, 8, 16, 32) 的残差单元，以及最终 LeakyReLU 激活。最终核大小 3 的卷积产生 128 通道，参数化 64 维后验均值和标准差。总下采样因子为 480，产生 50Hz 的隐帧率。所有编码器卷积使用权重归一化。

归一化流  $\mathcal{F}$  由四个残差耦合层与通道翻转交织组成，将后验样本  $\mathbf{z}$  映射为  $\mathbf{z}_p = \mathcal{F}(\mathbf{z})$  以进行隐正则化。流仅在 VAE 训练期间使用；声学条件和波形重建在原始隐空间  $\mathbf{z}$  中操作。

解码器遵循 BigVGAN [34]。核大小 7 的 3 帧前瞻卷积将隐表示投影到 1536 通道，之后所有卷积都是因果的。六个转置卷积块使用步长 (5, 4, 3, 2, 2, 2) 和两倍于步长的核，同时将通道宽度减小为  $1536 \rightarrow 768 \rightarrow 384 \rightarrow 192 \rightarrow 96 \rightarrow 48 \rightarrow 24$ 。每个块后跟一个抗混叠多周期组合模块，残差分支核大小为 {3, 7, 11}，膨胀率为 {1, 3, 5}。解码器使用逐通道 SnakeBeta 激活和最终核大小 7 的因果卷积重建波形。

**训练数据与设置。** 我们在约 300 万小时的语音、音乐和通用音频上训练 AuK-VAE 124 万次更新。三个域在实例级别以 6:3:1 的比例采样。所有波形重采样到 24kHz 并分割为 1.28 秒片段。

**训练目标。** 遵循 DAC [31]，我们使用多尺度对数梅尔重建损失  $\mathcal{L}_{\text{mel}}$ ，定义为  $\mathbf{x}$  和  $\hat{\mathbf{x}}$  的梅尔频谱图在多个分辨率下的  $\ell_1$  距离之和。我们使用窗口长度 {32, 64, 128, 256, 512, 1024, 2048}、跳跃大小 {8, 16, 32, 64, 128, 256, 512} 和梅尔频带数 {5, 10, 20, 40, 80, 160, 320} 以捕获短时声学细节和长程频谱结构。

为提高感知质量，我们应用对抗训练，使用周期 {2, 3, 5, 7, 11} 的多周期判别器 [30] 和多尺度 CQT 判别器 [18]。两个判别器族均使用最小二乘 GAN 目标 [45]；额外的  $\ell_1$  特征匹配损失  $\mathcal{L}_{\text{feat}}$  从中间表示计算。我们将变换后的后验  $q_\phi(\mathbf{z}_p | \mathbf{x})$  正则化 toward 标准高斯：

$$\mathcal{L}_{\text{KL}} = D_{\text{KL}}(q_\phi(\mathbf{z}_p | \mathbf{x}) \| \mathcal{N}(\mathbf{0}, \mathbf{I})). \quad (8)$$

完整生成器目标为

$$\mathcal{L}_{\text{VAE}} = \lambda_{\text{mel}} \mathcal{L}_{\text{mel}} + \lambda_{\text{adv}} \mathcal{L}_{\text{adv}} + \lambda_{\text{feat}} \mathcal{L}_{\text{feat}} + \lambda_{\text{KL}} \mathcal{L}_{\text{KL}}, \quad (9)$$

其中  $\mathcal{L}_{\text{adv}}$  是生成器侧最小二乘 GAN 损失。我们设置  $\lambda_{\text{mel}} = 15$ 、 $\lambda_{\text{adv}} = 1$ 、 $\lambda_{\text{feat}} = 2$  和  $\lambda_{\text{KL}} = 5$ 。判别器使用其对应的判别器目标单独优化。

## 4.2 统一预训练

统一预训练遵循两阶段课程。第一阶段仅使用生成任务建立基本语音生成能力，而第二阶段使用共享修正流目标、条件丢弃策略和任务混合联合优化生成和编辑。在两个阶段中，MLLM 语义编码器和音频 VAE 保持冻结；仅 Transformer 主干和层融合参数被更新。

**模型配置。** 主干包含 30 个 Transformer 层：10 个双流 MMDiT 块，随后是 20 个单流 DiT 块。每个块隐藏维度为 1536，24 个注意力头，头维度 64，SwiGLU 前馈网络中间维度 3072。主干包含约 15 亿参数，并采用 F5-TTS [6] 中使用的 RoPE 和卷积位置嵌入设计。

**训练课程。** 在第一阶段，我们仅训练语音生成任务 50k 次更新。这种仅生成热身启动在模型暴露于异构编辑目标之前建立稳定的文本到语音对齐和基本合成质量。第二阶段从此检查点初始化，并联合训练生成和编辑任务另外 600k 次更新。下面报告的五个家族采样混合适用于第二阶段。

**流匹配目标。** 令  $\mathbf{z}_1$  表示冻结 VAE 编码器产生的干净目标隐变量， $\mathbf{z}_0 \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$  表示高斯噪声。对于采样的流时间  $t \in [0, 1]$ ，我们构造线性插值和目标速度：

$$\mathbf{z}_t = (1 - t)\mathbf{z}_0 + t\mathbf{z}_1, \quad \mathbf{v}_t = \mathbf{z}_1 - \mathbf{z}_0. \quad (10)$$

模型从  $\mathbf{z}_t$ 、流时间嵌入以及可用的语义和声学条件预测  $\hat{\mathbf{v}}_t$ 。训练最小化有效、非填充隐帧上的掩码均方误差：

$$\mathcal{L}_{\text{FM}} = \frac{\|\mathbf{m} \odot (\hat{\mathbf{v}}_t - \mathbf{v}_t)\|_2^2}{\sum_i m_i}, \quad (11)$$

其中  $\mathbf{m}$  是有效性掩码。我们采样  $t = \sigma(u)$ ，其中  $u \sim \mathcal{N}(-0.8, 0.8^2)$ ，将训练偏向较小的  $t$ ，对应更接近高斯噪声端点的更噪声状态，同时保留整个轨迹上的支持。在推理时，学习到的速度场用确定性 ODE 求解器积分。

表 1：第二阶段预训练中五个任务家族的固定每批次采样概率。

| 任务家族  | 采样概率   |
|-------|--------|
| 语音生成  | 28.10% |
| 内容编辑  | 23.02% |
| 增强与分离 | 23.17% |
| 副语言编辑 | 21.75% |
| 声学编辑  | 3.96%  |

**条件丢弃与参考增强。** 为支持纯文本生成和参考条件任务的无分类器引导，我们应用分层条件丢弃。我们首先以概率 0.3 采样声学条件丢弃掩码。然后独立以概率 0.2 采样无条件掩码；当激活时，第二个掩码覆盖第一个决策并丢弃声学 and 语义条件。所得训练示例在同一目标下覆盖完全条件、纯文本和无条件配置。

推理时的参考音频在零样本 TTS 等任务中时长可能变化很大。为降低对训练期间观察到的参考长度的敏感性，我们以概率 0.5 将零样本 TTS 参考裁剪为 3 秒到其原始长度之间均匀采样的时长。

**任务混合与动态批处理。** 在第二阶段，我们将第 2 节中的五个任务家族实现为固定的每批次采样概率，总结在表 1 中。话语长度从 1 到 35 秒，并使用动态长度分桶批处理分组。每个加速器最多处理 10,000 个 50Hz 的隐帧或每微批次 24 个话语，以先达到的限制为准。所得全局批次最多包含 6,144 个话语，对应跨 GPU 每个优化器步骤约 14 小时音频。

**优化。**我们在 256 个 GPU 上使用 DeepSpeed ZeRO-2 和 bf16 精度训练，无 CPU offload。梯度裁剪到全局范数 1.0。我们使用融合 AdamW,  $\beta = (0.9, 0.95)$ ，峰值学习率  $1 \times 10^{-4}$ ，在前 2,000 次更新中线性预热，然后保持恒定。模型权重的指数移动平均在 100 次更新后启用，衰减 0.9999，每 10 次更新刷新；EMA 检查点用于评估和发布。

### 4.3 后训练

后训练包含两个互补阶段。首先，编辑偏好优化使用人类反馈将多样化的编辑行为与任务完成和感知质量的主观判断对齐。其次，生成强化学习使用自动奖励模型改进零样本和指令遵循语音生成。两个阶段仅更新 Transformer 主干；Qwen2.5-Omni 编码器和音频 VAE 保持冻结。

#### 4.3.1 编辑偏好优化

**人类偏好数据。**编辑任务比生成任务由更主观的标准评判。结果是否可接受通常取决于难以量化的自然度、转换程度和上下文适当性判断，不同于语音生成中的内容正确性和说话人相似度，后者可由单一自动指标可靠测量。此外，对于我们覆盖的多样化编辑任务，既不存在足够广泛的偏好数据集，也不存在现成的奖励模型。因此，我们直接收集人类反馈并使用偏好学习优化编辑行为。

对于每个编辑指令，我们从预训练模型采样 10 或 20 个候选输出。标注者在三级序数尺度  $s_i \in \{0, 1, 2\}$  上对每个候选评分，分别对应失败、部分完成和成功完成。所有 20 个候选获得相同评分的组被丢弃，因为它们不提供偏好信号。过滤后，数据集包含 818 个信息组和 9,080 个已评分候选。

**基于流的 DPO 分数。**遵循 Diffusion-DPO [66]，我们定义隐式偏好分数，来自策略相对于冻结参考模型在流匹配误差上的改进。尽管候选波形从独立噪声轨迹生成，DPO 损失在组内使用共享噪声样本  $\mathbf{z}_0$  和流时间  $t$  重新评估候选，隔离归因于候选目标隐变量的差异。冻结参考预测在每个微批次内缓存。

**序数列表式目标。**我们使用 LiPO [42] 的列表式公式优化序数反馈，其中  $R_i^{\text{pref}}$  是上述隐式偏好分数。令  $\mathcal{I}_q^+$  和  $\mathcal{I}_q^-$  表示关系  $q \in \{1 \sim 0, 2 \sim 0, 2 \sim 1\}$  的较高和较低评分候选集， $\Delta R_{ij} = R_i^{\text{pref}} - R_j^{\text{pref}}$  表示对  $(i, j)$ 。每个偏好对由标签平滑逻辑损失  $\epsilon = 0.05$  惩罚，分两级减少：首先在每个关系内平均，然后以置信权重跨关系组合：

$$\mathcal{L}_q = \frac{1}{|\mathcal{I}_q^+||\mathcal{I}_q^-|} \sum_{i \in \mathcal{I}_q^+} \sum_{j \in \mathcal{I}_q^-} \ell(\Delta R_{ij}), \quad \mathcal{L}_q = \frac{\sum_{q \in \mathcal{A}_g} \omega_q \mathcal{L}_q}{\sum_{q \in \mathcal{A}_g} \omega_q}, \quad (12)$$

其中  $\mathcal{A}_g$  是组  $g$  中存在的评分关系集， $\omega_{2 \sim 0} = 1$ ，其他关系权重为 0.5。这种两级减少使组的贡献仅取决于  $\omega_q$ ，与偏好对数量和组大小无关。策略和冻结参考均从统一预训练检查点初始化。我们训练此阶段 104 次优化器更新，并将其作为阶段终点。

#### 4.3.2 生成强化学习

生成强化学习改进两个具有不同奖励结构的任务家族。对于零样本 TTS，我们使用现成的 ASR 和说话人验证模型优化内容正确性和说话人相似度。对于指令 TTS，我们使用专用风格一致性模型优化与请求说话风格的一致性。第二阶段还缓解编辑导向偏好优化引入的生成质量权衡。

**提示构建。**我们从训练集构建 10,000 个零样本提示的冻结池，包含 5,000 个中文和 5,000 个英文示例。参考按 1-4 秒、4-8 秒和 8-15 秒的时长范围分层。遵循 FlowTTS-GRPO [67]，我们用包含局部词重复、稀疏多词重复或整句重复的困难文本增强池，每个与原始参考波形配对。对于指令遵循 TTS，我们按其可控维度对指令分类，并评估基础模型在每个维度上的风格一致性。在此诊断指导下，我们故意过采样模型最弱的维度，并策展额外的 5,000 个指令遵循提示池，使优化压力集中在模型最不可靠的地方。

**Flow-GRPO 优化。** 遵循 Flow-GRPO [40]，我们将采样重新表述为具有相同边际分布的 SDE，沿去噪轨迹产生高斯转移核。GRPO 组中的候选从不同噪声轨迹生成，提供相对策略优化所需的探索。遵循 MixGRPO [36]，随机采样和梯度计算限制在轨迹前半部分低 SNR 区域的连续六步窗口内；其余步骤使用确定性 ODE 更新以限制方差和计算成本。策略目标遵循 GRPO [56] 的裁剪形式，并增加相对于冻结参考策略的 KL 惩罚，权重为  $\beta_{\text{KL}}$ 。

**奖励设计。** 对于零样本 TTS，内容正确性由现成语音识别模型判断。中文同音字引起的错误无法通过强化学习消除，因此我们区分容忍错误率  $E$  和严格错误率  $E^s$ 。同音字替换不表示发音失败，因此容忍率决定候选是否算完全正确，而严格率在已通过此检查的候选之间提供更细粒度排名信号，并与目标文本的负对数似然融合为内容分数  $R_i^{\text{content}}$ 。令  $\gamma \in [0, 1]$  表示两项之间的插值权重， $\tau > 0$  表示控制误差项敏感度的温度：

$$R_i^{\text{content}} = (1 - \gamma) \left( 1 + 4e^{-E_i^s/\tau} \right) + \gamma \left( 1 + 4e^{-\text{NLL}_i} \right). \quad (13)$$

说话人相似度测量为候选和参考音频的说话人嵌入之间的余弦相似度，其中  $\psi(\cdot)$  表示说话人编码器：

$$R_i^{\text{spk}} = \cos(\psi(y_i), \psi(y_{\text{ref}})). \quad (14)$$

为防止高说话人相似度补偿不正确内容， $R_i^{\text{content}}$  在整个候选组上标准化，而  $R_i^{\text{spk}}$  仅在满足  $E_i = 0$  的候选之间标准化。这种约束构造关闭了加权奖励融合中常见的奖励黑客路径 [67, 81]。

对于指令 TTS，专用风格一致性模型判断候选是否匹配请求属性。我们收集 30,000 个平衡的 1:1 正/负样本作为监督，并训练一个基于 Qwen2.5-Omni-7B [69] 构建的多模态奖励模型来复现风格一致性判断。在实践中，我们查询判断器  $V$  次并使用多数投票：

$$R_i^{\text{style}} = 111111 = 111111111111 > V/211111. \quad (15)$$

风格任务优势是 GRPO [56] 中使用的标准组级 z 分数。

**优化。** 我们从编辑偏好检查点初始化策略，每个提示采样  $G = 16$  个候选，并训练 500 次优化器更新。Rollout 使用 500 个采样步，无分类器引导 2.0，sway 系数  $-1.0$  和  $\lambda = 0.7$ 。我们使用 AdamW ( $\beta = (0.9, 0.95)$ )，权重衰减  $10^{-4}$ 、学习率  $5 \times 10^{-5}$  和梯度裁剪 1.0 进行优化。KL 系数初始化为  $\beta_{\text{KL}} = 0.12$ ，并按比例调整 toward 目标 KL  $\mathcal{D}^* = 10^{-3}$ ，区间为  $[0.08, 0.5]$ 。

## 5 模型加速

完整训练模型需要迭代流采样和无分类器引导 (CFG) [21]，使其在广泛的生成和编辑能力中推理成本高昂。因此，我们通过两个阶段将其蒸馏为四步、无 CFG 的学生模型：一致性初始化提供稳定的少步起点，任务路由的解耦 DMD 在保留分离能力的同时改进分布匹配。两个阶段使用与统一预训练相同分布的数据。完整训练模型在加速过程中作为教师。

**一致性初始化。** 遵循少步视频扩散蒸馏中在分布匹配阶段前初始化学生的常见做法 [82, 84, 35, 74]，我们从教师初始化学生，并在教师指导下执行轨迹级一致性蒸馏 [60]。学生被训练将任何噪声状态  $\mathbf{z}_t$  直接映射到其采样轨迹的端点  $\mathbf{z}_1$ ：对于相邻时间步  $t < t'$ ，冻结教师首先用单步 CFG 引导的速度步将  $\mathbf{z}_t$  推进到  $\mathbf{z}_{t'}$ ，然后匹配学生从  $\mathbf{z}_t$  和从  $\mathbf{z}_{t'}$  对  $\mathbf{z}_1$  的预测，后者带停止梯度，使梯度仅通过  $t$  处的预测流动。此阶段使学生适应少步流积分，产生具有初步四步生成和编辑能力的稳定初始化。我们还比较了其他轨迹级蒸馏初始化方法，包括 CausVid [74] 和 MeanFlow [17] 中使用的 ODE 回归。在匹配更新次数下，一致性初始化始终表现最佳。因此我们保留一致性蒸馏。

**带 APG 的解耦 DMD。** 第二阶段采用解耦 DMD [37]，其已在 Z-Image [75] 中大规模验证。解耦 DMD 将学生更新分为两个互补组件。CFG 增强 (CA) 将教师的条件引导转移给学生，而分布匹配 (DM) 将学生分布与教师分布对齐。两个组件在独立重新加噪的学生预测上评估，使引导转移和分布匹配不依赖于相同的噪声水平。

一致性检查点初始化学生和假分数模型，而冻结的后训练教师充当真实分数模型。我们观察到，直接在 CA 分支中使用教师 CFG 目标可能使少步学生暴露于过饱和预测，导致过冲和可听削波。因此，我们在该分支中用自适应投影引导 (APG) [55] 替代 CFG，它在保留指令遵循的同时抑制过度引导分量。

**任务路由的解耦 DMD。** 我们凭经验观察到，在所有任务上统一应用解耦 DMD 会降低多说话人和人声分离，一些学生输出回归到未处理的混合。我们将此行为归因于分布不匹配：重新加噪的错误分离输出可能落在教师的训练分布之外，导致教师场偏好全局合理但分离不足的音频。为保留分离能力，我们将分离示例路由到监督干净预测目标，并将它们从 DMD 更新的两侧排除。

对于任务标签为  $\tau_i$  的样本  $i$ ，令  $\hat{\mathbf{z}}_{1,i}$  表示学生的干净端点预测， $\mathbf{z}_{1,i}$  表示真实干净隐变量。路由目标为

$$\left(\mathcal{L}_{\theta}^{(i)}, \mathcal{L}_{\phi}^{(i)}\right) = \begin{cases} \left(\|\hat{\mathbf{z}}_{1,i} - \mathbf{z}_{1,i}\|_2^2, 0\right), & \tau_i \in \mathcal{S}, \\ \left(\mathcal{L}_{\text{DMD}}^{(i)}, \mathcal{L}_{\text{fake}}^{(i)}\right), & \tau_i \notin \mathcal{S}, \end{cases} \quad (16)$$

其中  $\mathcal{L}_{\theta}^{(i)}$  更新学生， $\mathcal{L}_{\phi}^{(i)}$  更新假分数模型。对于路由的分离示例，干净隐变量回归仅更新学生，而配对目标中的零将样本从假分数训练中排除。所有剩余示例使用解耦 DMD 学生损失  $\mathcal{L}_{\text{DMD}}^{(i)}$  和在线流匹配损失  $\mathcal{L}_{\text{fake}}^{(i)}$ ，使假分数模型与演变的学生分布保持一致。

**训练配置。** 两个阶段使用与统一预训练相同的数据分布和批次大小。我们在 256 个 GPU 上使用融合 AdamW 训练，恒定学习率  $10^{-5}$ ，全局梯度裁剪 1.0。一致性初始化运行 500 次更新；学生从教师初始化，教师目标使用 CFG 引导尺度 2.0。第二阶段从一致性检查点初始化学生和假分数模型，并冻结教师作为真实分数模型。我们执行 2,500 次学生更新，每次学生更新执行 5 次假分数更新。CA 分支使用 APG，引导尺度 4.0 和  $\eta = 0$ 。不引入额外的对抗判别器或对抗损失。

## 6 模型推理

推理流程包含两个阶段。对于自由形式用户请求，提示增强器 (PE) 识别任务，将请求重写为面向模型的指令，准备可选输入音频，并估计输出时长。所得指令和可选音频上下文然后传递给 AuK 进行条件流采样。已遵循支持格式的规范指令可以绕过 PE 并直接提供给模型。

### 6.1 提示增强器

自由形式请求的措辞可能差异很大，省略必需参数，或隐式引用输入音频。PE 提供任务感知接口，将这些请求转换为更接近训练分布的显式指令，同时保留所有用户指定内容。

**任务路由与指令重写。** 给定请求  $q$  和可选输入音频  $a$ ，PE 在有音频时获得 ASR 转录和语言预测。然后请求、音频和 ASR 上下文由能力强的语言模型 [64, 9, 48] 处理，以识别目标任务并提取其参数和控制参数。音频派生上下文有助于解析隐式引用、区分措辞相似的操作，并支持时长估计。

提取的参数根据训练中表示的范范围进行验证。口语或连续的语速、响度和音高描述映射到支持的离散值，而无效或不支持的请求在声学推理前被拒绝。PE 然后使用任务特定模板或策展指令表述渲染验证后的请求。用户提供的合成文本和替换内容被保留，而任务描述可以轻量重写或扩展。在语音生成需要时应用文本归一化。

**音频准备与时长估计。** 对于音频条件任务，PE 应用轻量级、任务相关预处理，包括前导和尾部静音处理、重采样，以及当输入分布与训练时不同时的简单电平归一化。这些操作标准化模型输入，而不改变应保留的内容。

PE 还在流采样前估计目标时长。令  $T_{\text{in}}$  为输入音频时长， $B(x)$  表示文本  $x$  的 UTF-8 字节长度，遵循 F5-TTS [6] 中使用的时长启发式。任务相关估计为

$$T_{\text{out}} = \begin{cases} T_{\text{in}} \frac{B(x_{\text{target}})}{B(x_{\text{source}})}, & \text{zero-shot TTS and content editing,} \\ \frac{T_{\text{in}}}{s}, & \text{speed editing with multiplier } s, \\ \kappa_{\epsilon} T_{\text{in}}, & \text{emotion editing,} \\ T_{\text{in}} + \Delta_{\text{nv}}, & \text{nonverbal editing,} \\ f_{\text{LLM}}(\hat{T}_{\text{base}}, d_{\text{style}}, x_{\text{target}}), & \text{instruct TTS,} \\ T_{\text{in}}, & \text{duration-preserving operations.} \end{cases} \quad (17)$$

情感因子  $\kappa_{\epsilon}$  和非语言偏移  $\Delta_{\text{nv}}$  从相应训练数据估计。对于指令 TTS，基础估计  $\hat{T}_{\text{base}} = \rho_{\ell} B(x_{\text{target}})$  使用语言相关字节率系数  $\rho_{\ell}$ ；语言模型然后使用请求风格和输出文本调整此估计。对于零样本 TTS， $x_{\text{source}}$  通过内部转录参考音频获得，因此不要求用户提供参考转录。对于语音和歌词内容编辑，时长使用目标与源内容之间的 UTF-8 字节长度比进行缩放。

## 6.2 推理策略与配置

当提供输入音频时，它被转换为单声道、重采样到 24kHz，并由 VAE 编码为声学参考。同时，MLLM 联合处理增强指令和输入音频以构造语义条件。对于纯文本生成，语义条件仅从指令派生，不使用声学参考。估计时长决定 VAE 速率 50Hz 下的目标隐变量长度。采样从该长度的高斯噪声开始，生成的隐变量由 VAE 解码为输出波形。

AuK 和 AuK-Flash 的所有评估时设置统一在表 2 中。两个变体使用相同的提示增强、音频准备、时长估计、隐表示和 VAE 解码器。完整模型使用其 EMA 检查点和无分类器引导，而 Flash 变体使用任务路由蒸馏检查点且不需要引导。

表 2：AuK 和 AuK-Flash 的推理配置。

| 配置      | AuK        | AuK-Flash |
|---------|------------|-----------|
| 检查点     | EMA 后训练    | 任务路由蒸馏    |
| 数值精度    | bfloat16   |           |
| ODE 求解器 | Euler      |           |
| 函数评估    | 32         | 4         |
| CFG 尺度  | 2.0        | 无         |
| Sway 系数 | -1.0       |           |
| 输出采样率   | 24 kHz     |           |
| VAE 隐空间 | 64 维，50 Hz |           |
| 挂钟加速    | 1.0×       | 4.5×      |

报告的 4.5× 加速比较了四步、无 CFG 的 AuK-Flash 采样器与 32-NFE、CFG-2.0 的 AuK 采样器，在相同硬件、输出时长和批次大小下。除非另有说明，这些配置用于相应的基准结果。

## 7 性能

我们从三个互补角度评估 AuK 和 AuK-Flash：重建保真度、语音生成和语音编辑。表 3 提供了与代表性系统的紧凑比较。

表 3：选定的语音生成、编辑、增强和分离基准摘要。每个块保留其原生指标。每列中显示系统的最佳结果以粗体显示。

| 任务     | 数据集                      | 先前 SOTA             | 指标                | 结果                                           |
|--------|--------------------------|---------------------|-------------------|----------------------------------------------|
| 生成能力   | Seed-TTS-Eval            | Qwen3-TTS           | WER↓              | en: 1.23, zh: 1.22, zh-hard: 6.76, avg: 3.07 |
|        |                          | Seed-TTS            |                   | 2.25, 1.12, 7.59, 3.65                       |
|        |                          | VoxCPM2             |                   | 1.84, 0.97, 8.13, 3.65                       |
|        |                          | <b>AuK-Flash</b>    |                   | 1.03, 1.10, 6.43, 2.85                       |
|        |                          | <b>AuK</b>          |                   | 1.02, 1.02, 5.91, 2.65                       |
|        | InstructTTSEval          | Qwen3-TTS           | SIM↑              | DSD-ZH: 0.717, DSD-EN: 0.770, 0.748, 0.745   |
|        |                          | Seed-TTS            |                   | 0.762, 0.796, 0.776, 0.778                   |
|        |                          | VoxCPM2             |                   | 0.753, 0.795, 0.753, 0.767                   |
|        |                          | <b>AuK-Flash</b>    |                   | 0.772, 0.814, 0.784, 0.790                   |
|        |                          | <b>AuK</b>          |                   | 0.788, 0.814, 0.782, 0.795                   |
| 通用语音编辑 | MMAE (Speech)            | Qwen3-TTS-VD        | ACC↑              | 81.10, 82.40                                 |
|        |                          | Mimo-Audio          |                   | 74.30, 77.60                                 |
|        |                          | MOSS-VoiceGenerator |                   | 80.00, 82.00                                 |
|        |                          | <b>AuK-Flash</b>    |                   | 78.80, 82.40                                 |
|        |                          | <b>AuK</b>          |                   | 83.37, 81.60                                 |
|        | SpeechEditBench          | Step-Audio-EditX    | IFR↑ / CR↑ / EMR↑ | 43.52, 77.27, 4.69                           |
|        |                          | Ming-UniAudio       |                   | 34.13, 76.01, 7.04                           |
|        |                          | <b>AuK-Flash</b>    |                   | 46.62, 86.41, 13.85                          |
|        |                          | <b>AuK</b>          |                   | 48.23, 88.11, 12.44                          |
|        | Ming-Freeform-Audio-Edit | Step-Audio-EditX    | ACC↑              | 16.50, 7.71, 20.13, 31.25, 22.89             |

| 任务      | 数据集           | 先前 SOTA         | 指标                                   | 结果                         |
|---------|---------------|-----------------|--------------------------------------|----------------------------|
|         |               | Ming-UniAudio   |                                      | 6.61, 10.46, 10.16, 14.28  |
|         |               | AuK-Flash       | WER↓                                 | 4.87, 3.34, 4.71, 4.84     |
|         |               | AuK             |                                      | 4.62, 3.09, 3.85, 3.96     |
|         |               | Ming-UniAudio   | ACC↑                                 | 86.21, 79.62, 71.14, 70.98 |
|         |               | AuK-Flash       |                                      | 92.01, 91.21, 84.00, 82.98 |
|         |               | AuK             |                                      | 91.95, 91.47, 85.47, 85.25 |
|         |               | Ming-UniAudio   | SIM↑                                 | 0.81, 0.82, 0.78, 0.77     |
|         |               | AuK-Flash       |                                      | 0.88, 0.89, 0.89, 0.89     |
|         |               | AuK             |                                      | 0.88, 0.88, 0.88, 0.88     |
|         |               | Ming-UniAudio   | no-edit WER↓                         | 6.55, 8.78, 20.41, 24.15   |
|         |               | AuK-Flash       |                                      | 5.01, 3.32, 16.55, 16.76   |
|         |               | AuK             |                                      | 4.77, 3.11, 15.84, 15.99   |
| 语音增强与分离 | DNS Challenge | Ming-UniAudio   | WER↓                                 | 5.01, 10.75                |
|         |               | AuK-Flash       |                                      | 2.40, 4.45                 |
|         |               | AuK             |                                      | 2.02, 3.48                 |
|         |               | Ming-UniAudio   | SIM↑                                 | 0.63, 0.54                 |
|         |               | AuK-Flash       |                                      | 0.79, 0.75                 |
|         |               | AuK             |                                      | 0.78, 0.74                 |
|         | CHiME-4       | SAM-Audio-Large | DNSMOS-OVRL↑ / UTMOS↑ / DWER↓ / SIM↑ | 3.29, 3.78, 9.67, 0.96     |
|         |               | AnyEnhance      |                                      | 3.41, 3.76, 7.71, 0.98     |
|         |               | RE-USE          |                                      | 3.38, 3.69, 3.31, 0.98     |
|         |               | AuK-Flash       |                                      | 3.38, 4.05, 2.93, 0.99     |
|         |               |                 |                                      |                            |
|         |               |                 |                                      |                            |

| 任务        | 数据集 | 先前 SOTA          | 指标                                     | 结果                      |
|-----------|-----|------------------|----------------------------------------|-------------------------|
|           |     | <b>AuK</b>       |                                        | 3.35, 3.86, 2.66, 0.99  |
| Libri2Mix |     | SAM-Audio-Large  | DNSMOS-OVRL↑ /<br>UTMOS↑ / WER↓        | 3.14, 3.38, 17.30       |
|           |     | AnyEnhance       |                                        | 3.19, 3.24, 27.41       |
|           |     | RE-USE           |                                        | 3.33, 3.44, 10.71       |
|           |     | <b>AuK-Flash</b> |                                        | 3.35, 3.91, 7.84        |
|           |     | <b>AuK</b>       |                                        | 3.28, 3.72, 7.98        |
| VCTK-SR   |     | AudiSR           | DNSMOS-OVRL↑ /<br>UTMOS↑ / WER↓ / SIM↑ | 3.24, 3.66, 9.34, 0.96  |
|           |     | MossFormer-2-SS  |                                        | 2.87, 2.84, 57.22, 0.86 |
|           |     | Sidon (Dialogue) |                                        | 3.08, 2.61, 51.79, 0.87 |
|           |     | <b>AuK-Flash</b> |                                        | 3.32, 4.03, 10.07, 0.96 |
|           |     | <b>AuK</b>       |                                        | 3.28, 3.87, 9.12, 0.96  |
|           |     | AudiSR           |                                        | 3.08, 3.13, 4.72, 0.92  |
|           |     | Resemble-Enhance |                                        | 3.18, 3.59, 15.94, 0.95 |
|           |     | <b>AuK-Flash</b> |                                        | 3.25, 4.05, 2.92, 0.96  |
|           |     | <b>AuK</b>       |                                        | 3.21, 3.93, 3.06, 0.97  |
|           |     |                  |                                        |                         |

7.1 VAE 重建结果

我们评估 AuK-VAE 在三个代表性音频域上的重建质量：语音、通用音频和音乐。具体来说，评估使用 Seed-TTS-Eval [1] 用于语音，从 AudioSet [16] 随机采样的 2,000 个片段用于通用音频，以及 MUSDB18-HQ [52] 测试集用于音乐。比较模型包括 MiniMax-H3-AudioVAE [46]、Ming-Omni-TTS [27]、Stable-Audio-3-SAME-L [49] 和 MMAudio-VAE [7]。重建保真度使用 PESQ、STOI、梅尔频谱图距离（Mel Dist）和多分辨率 STFT 距离（STFT）测量。

如表 4 所示，AuK-VAE 在所有三个域的所有四个指标上均取得最佳结果。这些结果表明 AuK-VAE 在语音、通用音频和音乐中一致地保留了感知质量、可懂度和频谱细节。

表 4：跨语音、通用音频和音乐的 VAE 重建质量比较。每个域内最佳和次佳结果分别以粗体和下划线显示。

| 域  | 测试集           | 方法                    | PESQ↑ | STOI↑ | Mel Dist↓ | STFT↓ |
|----|---------------|-----------------------|-------|-------|-----------|-------|
| 语音 | Seed-TTS-Eval | MiniMax-H3-AudioVAE   | 3.633 | 0.968 | 0.695     | 1.615 |
|    |               | Ming-omni-tts         | 2.583 | 0.926 | 1.014     | 1.923 |
|    |               | Stable-Audio-3-SAME-L | 2.969 | 0.951 | 0.954     | 1.819 |

| 域  | 测试集        | 方法                    | PESQ↑        | STOI↑        | Mel Dist↓    | STFT↓        |
|----|------------|-----------------------|--------------|--------------|--------------|--------------|
| 音频 | AudioSet   | MMAudio-VAE           | 2.696        | 0.937        | 0.619        | 1.627        |
|    |            | <b>AuK-VAE</b>        | <b>4.143</b> | <b>0.982</b> | <b>0.574</b> | <b>1.457</b> |
|    |            | MiniMax-H3-AudioVAE   | 2.835        | 0.792        | 0.766        | 2.119        |
|    |            | Ming-omni-tts         | 1.817        | 0.650        | 1.121        | 3.389        |
|    |            | Stable-Audio-3-SAME-L | 2.901        | 0.779        | 1.052        | 3.264        |
|    |            | MMAudio-VAE           | 2.455        | 0.770        | 0.635        | 2.216        |
| 音乐 | MUSDB18-HQ | <b>AuK-VAE</b>        | <b>3.833</b> | <b>0.900</b> | <b>0.571</b> | <b>1.842</b> |
|    |            | MiniMax-H3-AudioVAE   | 2.801        | 0.847        | 0.697        | 1.848        |
|    |            | Ming-omni-tts         | 1.634        | 0.708        | 0.941        | 2.315        |
|    |            | Stable-Audio-3-SAME-L | 3.051        | 0.876        | 0.701        | 1.795        |
|    |            | MMAudio-VAE           | 1.753        | 0.775        | 0.661        | 1.826        |
|    |            | <b>AuK-VAE</b>        | <b>3.884</b> | <b>0.927</b> | <b>0.525</b> | <b>1.721</b> |

7.2 生成能力

我们评估两种互补的生成能力：在 Seed-TTS-Eval [1] 上的零样本语音克隆和在 InstructTTSEval [25] 上的指令控制合成。Seed-TTS-Eval 测量英语、中文和中文困难文本子集上的语言准确率和说话人保持，而 InstructTTSEval 评估两种语言中对声学参数、描述性风格和角色扮演指令的控制。对于两个基准，推理仅使用基准特定指令模板和输出时长估计，不进行额外提示增强。我们运行每个评估三次并报告平均分数。

**零样本 TTS。** AuK 在比较系统中实现了最低的平均识别错误和最高的平均说话人相似度，平均错误为 2.65%，SIM 为 0.795。表 3 中的比较包括 Qwen3-TTS [22]、Seed-TTS [1] 和 VoxCPM2 [88]，而表 5 提供了更广泛的基线集。与平均识别错误最强的基线 Qwen3-TTS 相比，AuK 将错误从 3.07% 降至 2.65%。它还将平均 SIM 相对于该指标最强的基线 Seed-TTS 从 0.778 提高到 0.795。AuK-Flash 保持竞争力，平均识别错误为 2.85%，SIM 为 0.790。在 test-en 上，AuK 实现了最低 WER 1.02%；在 test-zh-hard 上，它获得了最低识别错误 5.91%，而 AuK-Flash 实现了最高 SIM 0.784。

**指令 TTS。** 在 DSD 划分上，AuK 实现了最佳中文准确率 83.37%，比 Qwen3-TTS-VD [22] 高出 2.27 个百分点。AuK-Flash 在英文 DSD 上达到 82.40%，与 Qwen3-TTS-VD 并列表 3 中总结系统的最佳结果。表 6 中的完整结果（还包括 Mimo-Audio [78] 和 MOSS-VoiceGenerator [24]）显示，完整模型在所有三个中文指标上均优于 Flash 变体，而 Flash 变体的主要优势是其更强的英文 DSD 结果。

7.3 编辑能力

我们以两种互补方式评估编辑相关能力。第一种测试模型能否执行自然语言编辑指令，同时保留请求更改之外的属性。第二种方式评估信号级处理，使用 DNS Challenge 2020 [53] 和 CHiME-4 [5] 进行增强，Libri2Mix [8] 进行双说话人分离，VCTK-SR [71] 进行语音超分辨率。

7.3.1 通用语音编辑

我们在三个互补基准上评估通用语音编辑。对于 MMAE [44]，我们使用其语音子集评估基于规则的指令遵循和保持。SpeechEditBench [79] 评估五个编辑类别的联合成功，而 Ming-Freeform-Audio-Edit [72] 提供语义和声学编辑的操作级评估。

**MMAE-Speech。** IFR 测量指令遵循规则的平均成功率，CR 测量与请求编辑无关的属性一致性，EMR 是满足所有指令遵循和一致性规则的样本百分比。AuK 实现了最高的 IFR 和 CR 分数，分别达到 48.23% 和 88.11%，而 AuK-Flash 实现了最高的 EMR 13.85%。相对于 IFR 和 CR 上最强的先前基线 Step-Audio-EditX [73]，AuK 将这两个指标分别提高了 4.71 和 10.84 个百分点。相对于 Ming-UniAudio [72]，AuK-Flash 将 EMR 从 7.04% 提高到 13.85%。这些结果表明，完整模型在平均指令遵循和保持方面表现更好，而 Flash 变体更频繁地同时满足所有评估规则。

**SpeechEditBench。** 在表 3 中包含的专用编辑模型中，AuK 在内容、情感、韵律和声学编辑方面取得最佳结果，而 AuK-Flash 在副语言编辑方面表现最佳。相对于 Ming-UniAudio，AuK 将内容编辑的联合成功率从 76.46% 提高到 91.83%，韵律编辑从 26.50% 提高到 71.33%。AuK-Flash 的副语言编辑得分为 39.25%，而 Step-Audio-EditX 为 31.25%。

**Ming-Freeform-Audio-Edit。** 该基准包含互补的语义和声学编辑轨道。对于语义编辑，摘要结果平均每个 Basic/Full 和中文/英文设置的删除、插入和替换。AuK 在所有四个设置中实现了最低的平均 WER 和无编辑 WER。在更具挑战性的 Full 设置下，与 Ming-UniAudio 相比，AuK 将中文平均 WER 从 10.46% 降至 3.09%，英文从 14.28% 降至 3.96%。它还将编辑准确率中文从 79.62% 提高到 91.47%，英文从 70.98% 提高到 85.25%。表 8 和表 9 中的操作级结果显示，这些增益扩展到删除、插入和替换。

对于声学编辑，摘要结果平均速度、音高和音量改变。与 Ming-UniAudio 相比，AuK 将中文平均 WER 从 5.01% 降至 2.02%，英文从 10.75% 降至 3.48%。相比之下，AuK-Flash 在中文和英文中分别实现了最高的平均 SIM 分数 0.79 和 0.75。表 10 中的操作级结果显示，AuK 在中音高和音量改变以及英文速度和音高改变方面实现了最低 WER。AuK-Flash 在所有六个语言-操作设置中实现了最高或并列最高的 SIM。总体而言，完整模型提供更低的平均识别错误，而 Flash 变体更好地保留说话人身份。

### 7.3.2 语音增强与分离

评估涵盖代表性任务特定系统，包括 Resemble-Enhance [54]、DaSheng [62]、MossFormer2-SS [83] 和 AudioSR [39]，以及统一或通用系统，如 Ming-UniAudio [72]、SAM-Audio-Large [58]、AnyEnhance [80]、RE-USE [15] 和 Sidon [47]。主要结果总结在表 3 中，完整指标报告在表 11 至 14 中。在这些任务中，DNSMOS 和 UTMOS 评估感知质量，dWER、WER 和 PER 测量语言保持，SIM 测量说话人身份保持。

**语音增强。** 在 DNS Challenge 上，AuK 实现了最低 dWER 2.66%，比 RE-USE 提高了 0.65 个百分点，而两个变体均实现了最高 SIM 0.99。AuK 在 CHiME-4 上也取得了有竞争力的结果，WER 为 7.98%，UTMOS 为 3.72。总体而言，这些结果表明 AuK 在语音增强中保持了强大的语言内容和说话人身份，同时在感知质量上具有竞争力。

---

## 8 结论

我们提出了 AuK，一个开源基础模型，通过共同的指令条件波形生成接口统一了语音生成与编辑。其训练语料涵盖五个任务家族，包含约 30.3 亿条指令-音频实例和 195 万小时的有效监督。多模态语言模型提供语义条件，在语音、通用音频和音乐上联合训练的音频 VAE 提供共享声学隐空间，而 FLUX 风格 Transformer 用于隐扩散。仅生成热身、联合生成-编辑预训练、针对开放式编辑的人类反馈偏好优化，以及针对生成的基于奖励的强化学习，共同使模型在这一异构能力集上对齐。任务路由蒸馏进一步产生 AuK-Flash，它以四步推理、无无分类器引导和  $4.5\times$  挂钟加速保留了广泛能力。

实验表明，在零样本和声音设计语音生成以及通用指令引导编辑方面具有领先性能，同时在语音恢复任务上具有竞争力。我们的定性观察还表明，统一训练能够实现跨话语、任务和语言的有用迁移。同时，对无约束编辑请求的稳健原理解释仍不完整，系统仍受益于显式任务路由和提示增强。未来工作应改进原生指令接地、组合泛化和可扩展对齐，以支持开放式音频转换，同时进一步降低推理成本。我们发布了源代码和模型权重，以促进未来开发和研究。

---

## 贡献

### 核心贡献者

Ziyang Ma, Zhikang Niu, Wenming Tu, Tianrui Wang, Ruiqi Yan, Junxi Liu, Yanru Huo

### 贡献者

工程与训练：Nickk Huang, Yang Liu, Qicong Xie, Zeyu Xie, Hui Wang, Haitao Li, Zixuan Jiang

数据与基础设施：Yalin Li, Jie Fang, Yifan Duan, Zeyue Tian, Guangzheng Li, Haina Zhu, Shuyi Wang, Jinwen Wang, Mingyu Cui, Tian Tan, Auden, Sen Liang

### 项目赞助与顾问

Steve Yves, Shan Yang, Liefeng Bo, Zilong Zheng, Kai Yu, Eng-Siong Chng, Xie Chen

### 致谢

Yushen Chen, Wenxi Chen, Feiteng Li, Qixi Zheng, Yiwei Guo, Guanrou Yang, Yipeng Kang, Shengpeng Ji, Yuzhe Liang, Peifan Chen, Qixiang Xu, Jiayi Liang, Jubin Zhang, Jiaxin Zhi, Shanyi Zhu, Yiru Fan, Pan Luo

---

（参考文献和附录已按用户要求省略。）