

好的，这是根据你提供的CosyEdit论文PDF翻译的中文版本。我已严格按照要求，去除了参考文献部分，并完整保留了原文的结构、所有内容、公式、表格和图表示意，其中“token”一词根据指示未作翻译。

CosyEdit: 从零样本文语转换模型中解锁端到端语音编辑能力

Junyang Chen^{1,†}, Yuhang Jia^{1,†}, Hui Wang¹, Jiaming Zhou¹, and Yong Qin^{1,*}¹ 南开大学计算机学院，中国天津 chenjunyang@mail.nankai.edu.cn, qinyong@nankai.edu.cn

摘要—自动语音编辑旨在根据文本指令修改语音内容，然而传统的级联系统依赖于显式的时间对齐和复杂的预处理。为解决这些局限性，我们提出了CosyEdit，一个从CosyVoice通过任务特定的后训练和互补训练范式适配而来的端到端语音编辑模型，它内化了文本-语音对齐，同时确保编辑前后语音的高度一致性。我们的4亿参数模型仅在我们精心策划的GigaEdit数据集的250小时监督数据上训练，即实现了可靠的语音编辑性能。广泛的评估表明，CosyEdit不仅优于几个十亿参数的语言模型基线，而且接近最先进的级联系统。这些结果表明，通过后训练从零样本文语转换模型中解锁稳健高效的语音编辑是可行的，为高质量语音编辑提供了一种高性价比的端到端解决方案。代码和音频样本可在 <https://cjl1018.github.io/CosyEditDemoPage/> 获取。

索引词—语音编辑，零样本文语转换，条件流匹配，后训练，上下文学习。

1. 引言

自动语音编辑旨在根据文本指令修改现有的语音录音，实现音频层面的直接插入、删除或替换，而无需重新录制。与主要关注保持说话人音色的零样本文语转换（TTS）不同，语音编辑进一步要求在编辑后保持未编辑区域的韵律和副语言一致性，同时确保整体流畅性。实现自然可靠的编辑需要解决两个核心挑战：（1）语音与文本之间精确的跨模态时间对齐，以及（2）对修改片段进行上下文一致的零样本生成。

早期的语音编辑系统通常依赖外部文本-语音对齐工具，如Montreal Forced Aligner (MFA) [1]，来建立语音和转录之间的时间对应关系（图1(a)，步骤(i)）。然后，系统通过比较目标文本和原始文本来识别文本编辑跨度（步骤(ii)），从对齐的文本跨度确定语音编辑边界（步骤(iii)），最后合成编辑后的片段以集成到保留的上下文中（步骤(iv)）。这种多阶段设计引入了大量的工程开销：每个阶段都需要专用工具和仔细的校准，并且早期阶段的对齐错误会通过流程传播，降低最终输出质量。

图1. 级联与端到端语音编辑的比较。斜体字符表示与文本未时间对齐的语音片段，而正体字符表示已建立对齐时间戳的片段。红色空矩形框表示待编辑的掩码语音token。

如表I总结，级联流程通常构建在非自回归（NAR）[2]-[5]或自回归（AR）[6], [7]架构上，各有其固有限制：NAR模型需要一个辅助时长预测器 [2], [5] 来避免编辑边界处的韵律不匹配，而AR模型在没有额外稳定措施的情况下容易出现采样不稳定性 [6] 和不自然的边界过渡 [7]。

近期语音语言模型（SLM）[8]-[10]的进展为端到端语音编辑引入了一种新范式。通过在统一的表示空间内内化文本-语音对齐，它们消除了对外部对齐模块的需求，并且本质上更易于在单次推理中支持任意编辑类型和跨度。尽管取得了这些进展，现有SLM的语音编辑能力在很大程度上是通用任务的副产品，缺乏专门为语音编辑量身定制的架构设计和训练目标。此外，这些模型通常设计有巨大的参数规模，并需要大规模训练，这对学术研究和实际部署来说都是难以承受的。

受这些观察的启发，我们探索了任务特定的后训练作为一种轻量级方式，将预训练的零样本文语转换模型适配于端到端语音编辑。我们的方法基于一个洞察：语音编辑与零样本文语转换共享核心能力，包括：（1）从文本生成自然语音的能力，（2）上下文学习能力，以及（3）时间对齐的潜力。基于此策略，我们引入了CosyEdit，一个从CosyVoice [11] 初始化并用仅250小时的任务特定监督编辑数据进行后训练的4亿参数模型。实验结果表明，CosyEdit在端到端语音编辑中取得了最先进的性能，并且与先进的级联系统相比仍具有高度竞争力。

我们的贡献有三个方面：

我们引入了一个从现有语音语料库构建监督式语音编辑数据集的通用流程，并构建了GigaEdit，一个涵盖多样声学条件和编辑类型的250小时编辑数据集。我们将以CosyVoice为代表的AR+NAAR零样本文语转换模型，通过语音编辑特定的自回归token建模范式、参考引导的流匹配和互补的混合上下文训练方案进行扩展，从而产生CosyEdit，一个仅需250小时后训练即可获得的端到端语音编辑模型。跨多个语音编辑基准的广泛评估表明，轻量级后训练是将零样本文语转换基础模型适配于语音编辑的一条实用且有效的途径。

表 I 语音编辑模型的比较

方法	架构	端到端	多编辑	参数量	数据	流畅语音	NAR	×	×	23.9M	585 h	VoiceCraft	AR	×	×	830M	10k h	SSR-Speech	AR	×	≤ 3	830M	10k h	Step-Audio-EditX	AR+NAAR	√	√	3B	200k h	MiMo-Audio	AR+NAAR	√	√	7B	100M h	Ming-UniAudio	AR+NAAR	√	×	16B	390k h	CosyEdit (ours)	AR+NAAR	√	√	400M	250 h
----	----	-----	-----	-----	----	------	-----	---	---	-------	-------	------------	----	---	---	------	-------	------------	----	---	-----	------	-------	------------------	---------	---	---	----	--------	------------	---------	---	---	----	--------	---------------	---------	---	---	-----	--------	-----------------	---------	---	---	------	-------

II. 提出的方法

与CosyVoice [11]类似，CosyEdit包含四个组件：一个文本编码器，一个 S^3 语音tokenizer，一个自回归（AR）大语言模型（LLM），和一个非自回归（NAR）条件流匹配（CFM）[12]模型。我们保留了原始的文本编码器和 S^3 tokenizer，同时通过任务特定的训练目标适配LLM，并重新设计了带有参考引导机制的CFM。此外，我们提出了两种互补的输入序列构建策略用于训练，以使模型更好地从TTS系统的刚性、合成韵律适应到现实世界的、野外的语音编辑场景。

A. 用于语音编辑的大语言模型

与将语音编辑视为以周围上下文为条件的掩码区域预测的级联语音编辑方法不同，我们将语音编辑重新表述为一个自回归离散语音token生成问题，其中文本-语音对齐隐式地内化在这个过程中。如图2(b)所示，我们使TTS模型联合以目标文本和原始语音为条件，其中原始语音提供上下文和声学信息，而目标文本指定所需的编辑。因此，我们设计LLM来建模以下序列：

$$[\mathbb{S}, \mathbf{v}, \overline{X}_{tar}, \mu_{ori}, \mathbb{T}, \mu_{tar}, \mathbb{E}], \quad (1)$$

其中 $\mathbb{S}$ 和 $\mathbb{E}$ 分别表示起始和结束token。向量 $\mathbf{v}$ 是使用预训练的说话人验证模型从原始语音 Y_{ori} 中提取的说话人嵌入。文本编码 $\overline{X}_{tar} = \{\bar{x}_u\}_{u \in [1:U]}$ 使用与CosyVoice相同的字节对编码（BPE）tokenizer和文本编码器生成：

$$\overline{X}_{tar} = \text{TextEncoder}(\text{BPE}(X_{tar})). \quad (2)$$

我们使用 S^3 tokenizer从原始语音和目标语音中提取离散的监督语义token：

$$\begin{aligned} \mu_{ori} &= \text{SpeechTokenizer}(Y_{ori}), \\ \mu_{tar} &= \text{SpeechTokenizer}(Y_{tar}). \end{aligned} \quad (3)$$

然后我们在原始语音token序列 μ_{ori} 和目标语音token序列 μ_{tar} 之间插入一个单一的过渡token $\mathbb{T}$ ，以标记条件上下文和自回归生成之间的边界。AR token语言模型的训练目标是：

$$\mathcal{L}_{LM} = -\frac{1}{N+1} \sum_{j=1}^{N+1} \log q(\mu_{\text{tar},j}), \quad (4)$$

其中 $N = |\mu_{\text{tar}}|$, $\mu_{\text{tar},N+1} = \mathbb{E}$ 是结束token, $q(\mu_{\text{tar},j})$ 表示第 j 个目标语义token在给定输入序列和教师强制下的前缀 $\mu_{\text{tar},1:j-1}$ 时的预测概率。

B. 引导的最优传输条件流匹配

CosyVoice中的流模型最初设计用于零样本文语转换,其主要目标是合成具有全局一致说话人音色的干净录音室质量语音。相比之下,语音编辑需要保持真实世界录音中超越说话人身份的复杂声学环境。为此,我们引入了引导OT-CFM (GOT-CFM),一种OT-CFM [13] 的参考引导变体。具体来说,我们在原始和目标梅尔频谱图的时间拼接上构建流匹配路径,其中从带噪到干净的原始梅尔频谱图的可观测轨迹作为显式的声学参考,以指导目标梅尔频谱图的流建模。这种设计允许流匹配模块访问完整的语音上下文。训练目标为:

$$\mathcal{L}_{GOT-CFM} = \mathbb{E}_{t,p_0(Z_0),q(Z_1)} \left| \omega_t(\phi_t^O T(Z_0, Z_1) | Z_1) - \nu_t(\phi_t^O T(Z_0, Z_1) | \theta) \right|, \quad (5)$$

其中

$$Z_0 = [M_{\text{ori}}^0, M_{\text{tar}}^0], \quad Z_1 = [M_{\text{ori}}, M_{\text{tar}}]. \quad (6)$$

这里, M_{ori}^0 和 M_{ori} 分别表示原始语音的带噪和干净梅尔频谱图, M_{tar}^0 和 M_{tar} 表示目标语音的相应部分。算子 $[\cdot, \cdot]$ 表示沿时间维度的拼接。插值路径 $\phi_t^{OT}(Z_0, Z_1)$ 随时间线性混合 Z_0 和 Z_1 , 而目标向量场 $\omega_t(\phi_t^{OT}(Z_0, Z_1) | Z_1)$ 提供了从带噪状态指向目标状态的恒定方向。

为构建引导概率密度路径,我们以完全揭示的原始梅尔频谱图 M_{ori} 和完全掩码的目标梅尔频谱图 $\tilde{M}_{\text{tar}}$ 为条件来调节模型。从 M_{ori}^0 到 M_{ori} 的已知轨迹作为一个引导,鼓励 M_{tar}^0 沿着类似的路径朝向 M_{tar} 。说话人嵌入 $\mathbf{v}$ 、语音token μ_Z , 以及 M_{ori} 和 $\tilde{M}_{\text{tar}}$ 的拼接被馈入神经网络,以匹配由 θ 参数化的向量场:

$$\begin{aligned} & \nu_t(\phi_t^{OT}(Z_0, Z_1) | \theta) \\ &= \text{NN}_{\theta} \left(\phi_t^{OT}(Z_0, Z_1), t; \mathbf{v}, \mu_Z, [M_{\text{ori}}, \tilde{M}_{\text{tar}}] \right), \end{aligned} \quad (7)$$

其中

$$\mu_Z = [\mu_{\text{ori}}, \mu_{\text{tar}}]. \quad (8)$$

C. 零样本和单样本上下文学习

为提高模型内化文本-语音对齐的能力,同时保持对局部编辑指令的敏感性,我们引入了两种互补的训练范式,即单样本上下文学习 (OICL) 和零样本上下文学习 (ZICL)。如图3所示,两种范式共享相同的自回归目标语音预测目标,区别仅在于是否提供显式的原始文本-语音对作为对齐上下文。

给定原始文本编码 $\bar{X}_{\text{ori}}$ 、目标文本编码 $\bar{X}_{\text{tar}}$ 、原始语音token μ_{ori} 和目标语音token序列 μ_{tar} , OICL的输入序列构建为

$$S_{\text{OICL}} = [\mathfrak{S}, \mathbf{v}, \bar{X}_{\text{ori}}, \bar{X}_{\text{tar}}, \bar{\Omega}, \mu_{\text{ori}}], \quad (9)$$

其中 $\bar{\Omega}$ 表示OICL中分隔文本和声学上下文的过渡token。以 S_{OICL} 为条件,模型被训练以自回归地预测 μ_{tar} 。

图3. ZICL和OICL的训练序列格式。

相比之下，ZICL有意从条件上下文中移除原始文本编码 $\overline{X}_{ori}$ ，并保留目标文本编码和原始语音token：

$$S_{ZICL} = [\mathcal{G}, \mathbf{v}, \overline{X}_{tar}, \mu_{ori}, \overline{\Omega}], \quad (10)$$

其中模型预测相同的目标语音token μ_{tar} 。为避免跨训练范式引入不一致的文本-语音关联，在ZICL中， μ_{ori} 被放置在 $\overline{\Omega}$ 之前，确保原始语音始终被视为条件上下文而非自回归目标前缀。

这两种范式呈现互补的权衡。OICL提供配对的原始文本和语音，提供精确的隐式时间对齐参考。然而，这种显式监督有引发捷径行为的风险，即模型过度依赖对齐线索，倾向于复制原始语音而非执行预期的编辑。相比之下，ZICL完全省略原始文本，迫使模型从目标文本和原始语音之间的差异推断编辑边界，从而加强编辑位置的指令遵循，但代价是失去直接的对齐监督。

为在保留保真度和编辑能力之间取得平衡，ZICL和OICL样本在训练期间以ZICL混合比例 λ 混合，得到复合目标

$$\mathcal{L} = \lambda \mathcal{L}_{ZICL} + (1 - \lambda) \mathcal{L}_{OICL}, \quad (11)$$

其中

$$\mathcal{L}_s = -\log P(\mu_{tar} | \mathcal{S}_s). \quad (12)$$

III. 实验

A. 实验设置

GigaEdit数据集。我们提出了一种数据构建流程，能够将现有的语音语料库转换为涵盖插入、删除和替换子任务的监督式语音编辑数据集。使用此流程，我们基于GigaSpeech-S [14] 构建了GigaEdit数据集。如图2(a)所示，我们将每个话语及其转录视为目标语音和目标文本，并使用MFA获取它们的时间对齐。然后我们为三种基本编辑类型构建数据：(1) 对于插入子任务，我们根据时间对齐随机移除目标语音的一些片段（移除长度 $< |X_{tar}|/2$ ），得到的缩短语音和转录作为原始语音和原始文本。(2) 删除子任务可视为插入任务的对称对应：我们应用与插入相同的流程，但交换原始和目标的角色。(3) 对于替换子任务，我们从目标语音中删除一个连续片段，将此片段分成两个不重叠的部分，并分别将每个部分插回删除位置以形成两个话语，这两个话语因此被用作一个替换对。

为提高对涉及多个编辑位置和多样化编辑操作的场景的泛化能力，我们将替换过程扩展到多编辑任务。在此变体中，我们从目标语音中随机删除多个不连续的片段，同时保持其余步骤与替换子任务相同。相应的转录对使用相同的过程生成，从而能够模拟混合的基本编辑类型。

训练细节。我们使用两块NVIDIA A800 GPU在GigaEdit数据集上训练CosyEdit。LLM和流模型均训练了16个epoch，学习率分别为 3×10^{-6} 和 1×10^{-4} 。在推理期间，我们使用OICL范式以获得更好的上下文利用。

B. 在RealEdit上的实验

我们在RealEdit [6] 上评估CosyEdit，这是一个具有挑战性的野外语音编辑基准，包含310个样本，具有多样且复杂的声学条件。

基线。级联和端到端语音编辑系统均被纳入基线。级联基线包括AR模型VoiceCraft [6]、SSR-Speech [7] 和NAR模型FluentSpeech [2]。端到端基线包括Step-Audio-EditX [8]、MiMo-Audio [9] 和Ming-UniAudio [10]。虽然Step-Audio-EditX和MiMo-Audio并非专门为语音内容编辑设计，但它们的大规模训练赋予了内容编辑任务一定

程度的泛化能力，使其成为相关的端到端基线。由于端到端模型通常重新生成整个话语，我们特别关注未编辑区域引入的修改是否在感知上明显。

图4. 不同ZICL比例 λ 下RealEdit上的WER和MCD

FluentSpeech使用LibriTTS [15] 训练的检查点，对多跨度情况进行顺序编辑。VoiceCraft遵循静音减少策略，生成五个输出并选择最短的。Step-Audio-EditX以克隆模式运行，进行零样本推理。MiMo-Audio以对话模式运行，使用SSR-Speech在RealEdit [6] 上生成的五个高质量编辑示例作为少样本前缀提示，并允许最多五次推理尝试以获得转录与目标文本匹配的输出。Ming-UniAudio通过基于规则的映射将编辑提示转换为自然语言指令，并对多跨度情况应用顺序编辑。

指标。客观指标包括词错误率（WER, %）和说话人相似度（SpkSIM, %），分别使用Whisper-medium.en [16] 和WavLM-TDCNN [17] 计算。感知质量使用两个神经MOS预测器估计，MOSNet [18] 和UTMOS [19]。我们还报告生成语音与原始语音之间的平均绝对误差MOS，记为 MAE_{MOSNet} 和 MAE_{UTMOS} 。对于端到端模型，我们使用梅尔倒谱失真（MCD [20]；越低越好）评估未编辑区域的一致性，通过动态时间规整（DTW）[21] 结合pymcd计算，以补偿在提取未编辑区域时强制对齐器引入的轻微时间错位。

对于主观评估，我们从RealEdit中每个编辑任务（插入、删除、替换和混合编辑）随机采样10个示例，总共40个样本，并为所有系统收集人工评分。我们引入了两个超越常规MOS的语音编辑特定指标：编辑MOS（EMOS）强调语义方面，包括编辑正确性、语音易懂度和边界自然度，而相似度MOS（SMOS）侧重于声学一致性，评估编辑区域中的音色相似性、韵律适当性以及未编辑区域的保持。十位听众在五点李克特量表上对每个样本进行评分。

ZICL混合比例的影响。图4展示了ZICL混合比例 λ 的影响。增加 λ 持续提高编辑准确性，WER从 6.87% 降至 4.45%，同时逐渐降低未编辑区域的保真度，反映为MCD从 4.80dB 增至 5.28dB。这一趋势验证了第II-C节讨论的OIICL和ZICL的互补作用。我们为所有后续实验选择 $\lambda = 0.4$ ，因为它在指令遵循和保真度保持之间提供了有利的平衡。

实验结果。表II比较了RealEdit基准上级联语音编辑流程和端到端模型。CosyEdit在WER和EMOS指标上均超越了所有基线，展示了其在复杂声学环境中合成准确稳健内容编辑的强大能力。在相对于真实值（原始语音）的声学一致性方面，如SpkSIM和SMOS指标所示，CosyEdit优于所有端到端基线，并超越了几个传统级联系统，接近SSR-Speech的性能。在感知质量方面，通过 MAE_{MOSNet} 和 MAE_{UTMOS} 测量，CosyEdit在端到端模型中实现了编辑前后最低的整体质量偏差，表明编辑后的语音保持了接近原始语音的合成质量。

消融研究。我们研究了LLM和Flow模块上语音编辑特定微调的效果，结果如表III所示。以零样本本文语转换模型CosyVoice为基线，添加LLM SFT略微增加了WER，从4.49增至5.33。详细分析表明，这主要是由于Whisper混淆了语音相似词的替换错误。重要的是，LLM SFT改善了未编辑区域的韵律一致性，使其节奏更符合野外原始语音，而非零样本本文语转换的录音室级节奏。这导致了更好的声学一致性，反映为MCD和MAE MOS的降低。SpkSIM也显示出适度增加，表明说话人音色保持有所改善。

相比之下，在GOT-CFM上的Flow SFT在所有客观指标上产生了一致的改进。主观检查表明，Flow微调主要增强了声学细节建模，导致语音相似词之间更清晰的区分和更忠实于原始语音的声学实现。LLM SFT和Flow SFT的增益是互补的且基本可加。结合两个组件得到最终的CosyEdit系统，它在编辑准确性、声学一致性和说话人保持之间实现了最佳的整体平衡。

感知透明性测试。为评估未编辑区域的感知变化，我们进行了一项感知透明性测试，让听众在原始语音和重建语音之间做出二元相同/不同判断。我们从RealEdit中随机选择40个话语，使用CosyEdit和CosyVoice的零样本本文语转换模式合成与原始语音语义相同的目标语音。此外，我们使用CosyVoice的HiFiT-GAN声码器 [22], [23] 作为上界，从原始语音的梅尔频谱图重建波形。五位听众评估他们是否能感知到重建语音与原始语音之间的任何差异，包括内容错误、说话人变化、韵律变化、音频质量和背景伪影，使用二元（相同/不同）评分方案。

如图5所示，CosyEdit达到 83.5% 的“相同”评分，显著高于CosyVoice零样本文语转换 (5.5%) 并接近HiFT-GAN上界 (94.0%)，展示了在保持与原始语音的感知相似性方面相对于零样本文语转换的明显改进。

表 II REALEDIT 上的语音编辑结果。粗体数字表示虚线分隔的每个模型组内的最佳结果。* 表示仅基于语音可懂度的评分。

方法	主观评估	WER ↓ SpkSIM ↑ MCD ↓ MOSNet MAE\(\text{MOSNet}\) UTMOS MAE\(\text{UTMOS}\) EMOS ↑ SMOS ↑ Ground Truth 6.06 - 3.34 - 3.38 - 4.21*																																																																							
		FluentSpeech	5.97	92.74	-	2.72	0.78	2.81	0.67	2.7	2.6	VoiceCraft	6.55	97.12	-	3.18	0.24	3.31	0.20	4.04	4.08	SSR-Speech	5.05	98.31	-	3.32	0.14	3.34	0.12	4.11	4.09	Step-Audio-	EditX	10.76	95.88	8.64	3.94	0.61	3.89	0.54	3.41	3.49	MiMo-	Audio	16.86	93.71	9.78	3.48	0.50	3.38	0.47	3.55	3.05	Ming-	UniAudio	9.98	96.70	5.36	3.13	0.33	3.18	0.30	3.79	3.84	CosyEdit	(ours)	4.50	97.34	4.94	3.19	0.29	3.30	0.25

表 III 组件消融研究

方法	WER ↓ SpkSIM ↑ MCD ↓ MAE\(\text{MOSNet}\) MAE\(\text{UTMOS}\)
CosyVoice	4.49 95.90 6.82 0.63 0.49 w/ LLM SFT 5.33 96.63 6.17 0.57 0.45 w/ Flow SFT 4.18 96.73 5.59 0.31 0.27
CosyEdit	4.50 97.34 4.94 0.29 0.25

图5. 感知透明性测试。听众判断重建语音在感知上是否与原始语音相同。

C. 在Ming-Freeform-Audio-Edit上的附加实验

我们进一步在Ming-Freeform-Audio-Edit [10] 基准的英语语义编辑子集上评估CosyEdit。与RealEdit相比，该数据集明确将编辑操作分类为插入、删除和替换，允许对每种类型进行单独分析。我们在基本子集和完整子集上报告结果。

基线。我们将CosyEdit与代表性语音编辑系统进行比较，包括VoiceCraft [6]、SSR-Speech [7] 和Ming-UniAudio [10]。所有基线均在RealEdit基准中使用的相同设置下进行评估。

指标。遵循基准协议，我们报告用于编辑正确性的WER、用于说话人保持的说话人相似度（SS）和用于感知语音质量的DNSMOS [24]。重要的是，与标准TTS评估中直接偏好更高DNSMOS不同，语音编辑要求生成的话语保持原始录音的声学质量，而非简单地最大化预测质量。因此，我们额外报告MAE_{DNSMOS} 来衡量生成语音与原始语音之间预测MOS的平均绝对偏差，其中较低的值表示编辑前后更好的质量一致性。

实验结果。表IV报告了在Ming-Freeform-Audio-Edit上的性能。CosyEdit在所有三种编辑类型上都表现出强大且稳定的性能。在编辑正确性方面，它在插入（2.83/2.85）和替换（2.61/2.56）上取得了第二好的WER，并在删除（5.69/5.95）上保持竞争力，大幅优于大型端到端基线Ming-UniAudio，这突显了任务特定后训练对于内容编辑相对于通用语音语言建模的有效性。

在声学方面，CosyEdit在说话人相似度（SS）上持续排名第二，在所有编辑类型上紧密接近SSR-Speech，表明其稳健地保持了说话人身份。MAE_{DNSMOS} 进一步证实，CosyEdit保持了比端到端基线更接近原始语音的感知质量，表现出更小的偏差。

虽然SSR-Speech取得了最佳性能，但其具有显式文本-语音对齐和局部重建的级联系统为内容保持编辑提供了有利的归纳偏置。相比之下，CosyEdit完全端到端运行，在推理时无需外部对齐工具或手动指定的编辑边界。总体而言，这些结果突显了准确性与简洁性之间的有利权衡。尽管CosyEdit未超越最强的级联系统，但它在单

一模型架构内提供了有竞争力的性能。这种轻量级后训练框架显著降低了训练成本，增强了部署便捷性，并最终在WER、说话人相似度和声学一致性方面实现了良好平衡的增益。

表 IV 在 MING-FREEFORM-AUDIO-EDIT 英文子集上的性能比较。MAE 表示生成语音与原始语音之间的 MAE DNSMOS，越低越好。红色和蓝色分别表示最佳和次佳系统结果。

编辑类型 模型			
	插入 Ground Truth - - -	删除 Ground Truth WER↓	替换 Ground Truth WER↓
	- 2.99 3.01 - -	basic full SS↑ basic	basic full SS↑ basic
	VoiceCraft 4.39 4.51 0.85	full DNSMOS basic	full DNSMOS basic
性能 WER↓	0.85 3.01 3.03 0.146	full MAE↓ basic full	full MAE↓ basic full
basic full SS↑	0.144 SSR-Speech 1.75	VoiceCraft - - - - 3.05	VoiceCraft - - - - 3.04
basic	2.03 0.94 0.94 3.06	3.03 - - SSR-Speech 5.22	3.05 - - SSR-Speech 3.13
full DNSMOS	3.06 0.139 0.128 Ming-	5.29 0.91 0.91 3.03	2.96 0.80 0.81 3.02
basic	UniAudio 6.49 7.84 0.80	3.02 0.136 0.134 Ming-	3.02 0.172 0.164 Ming-
full MAE↓ basic	0.80 3.04 3.04 0.168	UniAudio 14.79 24.37 0.77	UniAudio 8.10 7.95 0.89
full	0.167 CosyEdit 2.83	0.75 2.97 2.97 0.206	0.90 3.08 3.08 0.146
	2.85 0.86 0.86 3.10	0.204 CosyEdit 5.69	0.140 CosyEdit 2.61
	3.11 0.167 0.167	5.95 0.83 0.83 3.10	2.56 0.83 0.83 3.11
		3.09 0.161 0.164	3.13 0.156 0.146

IV. 结论

在本文中，我们提出了CosyEdit，一个端到端的语音编辑模型，它内化了时间对齐，在推理时消除了外部模块和复杂的预处理。我们没有从头训练大规模的语音语言模型，而是为AR+NAAR零样本文语转换模型引入了一个任务特定的后训练框架，实现了高效且高性价比的语音编辑适配。在250小时的GigaEdit数据集上微调后，CosyEdit优于最近的端到端基线，并接近最先进的级联系统。为支持负责任的使用，我们进一步强调了减轻语音深度伪造潜在滥用的重要性。为此，我们发布了代码和数据集，以促进水印和部分编辑音频检测的研究。未来的工作将侧重于多语言扩展、更细粒度的控制以及最小化未编辑区域的失真。