

好的，这是根据你提供的Ming-UniAudio论文PDF翻译的中文版本。我已严格按照要求，去除了参考文献部分，并完整保留了原文的结构、所有内容、公式、表格和图表示意，其中“token”一词根据指示未作翻译。

Ming-UniAudio: 基于统一表示、用于联合理解、生成与编辑的语音大语言模型

Inclusion AI, Ant Group*

*完整作者名单见贡献部分（第10节）。

现有的语音模型在理解和生成任务对token表示的要求上存在冲突。表示上的这种差异阻碍了语音语言模型执行基于指令的自由形式编辑。为解决这一挑战，我们引入了一个新颖的框架，统一了语音理解、生成和编辑。我们统一模型的核心是一个统一的连续语音分词器 Ming-Tok-Audio，这是首个有效整合语义和声学特征的连续分词器，使其同时适用于理解和生成任务。基于这个统一的连续音频分词器，我们开发了语音语言模型 Ming-UniAudio，在生成和理解能力之间取得了平衡。Ming-UniAudio 在 ContextASR 基准的12项指标中的8项上创下了新的最先进（SOTA）记录。值得注意的是，对于中文语音克隆，它取得了极具竞争力的 Seed-TTS-WER 0.95。利用这个基础模型，我们进一步训练了一个专用的语音编辑模型 Ming-UniAudio-Edit，这是首个仅由自然语言指令引导、无需时间戳条件即可处理语义和声学修改的、实现通用自由形式语音编辑的语音语言模型。为严格评估编辑能力并为未来研究奠定基础，我们引入了 Ming-Freeform-Audio-Edit，首个为基于指令的自由形式语音编辑量身定制的全面基准，涵盖多样化的场景和跨越语义正确性、声学质量和指令对齐的评估维度。我们开源了连续音频分词器、统一基础模型和基于自由形式指令的编辑模型，以促进统一的音频理解、生成和操作的发展。

日期：2025年10月16日 项目主页：链接 代码：<https://github.com/inclusionAI/Ming-UniAudio> 模型：<https://huggingface.co/inclusionAI>

1 引言

大语言模型（LLMs）（Brown et al., 2020; Yang et al., 2025）的快速突破显著提升了语音基础模型在理解（Chu et al., 2023; Wu et al., 2025a）和生成（Wang et al., 2023; Du et al., 2024a; Jia et al., 2025）两方面的能力。这些进展使得对口语的更准确和细粒度理解，以及更流畅自然的语音输出成为人机交互（Xu et al., 2025b）的关键。在语音表示方面，理解和生成任务提出了根本不同的要求：理解受益于紧凑的、以语义为中心的编码，而生成则需要丰富的、高质量的声学细节。因此，大多数现有的语音语言模型采取了两种架构折衷之一：要么为理解和生成维护独立的表示（Xu et al., 2025b; KimiTeam et al., 2025），要么两者都依赖离散token（Defossez et al., 2024; Xiaomi, 2025; Huang et al., 2025a）。前一种方法，即分离表示，给编辑带来了根本性的挑战，因为用于理解和生成的分离表示阻止了解释指令和合成修改后音频所需的无缝工作流（Le et al., 2023）。而后一种方法，即离散表示，由于量化而遭受语音细节的损失。在语音任务方面，目前还没有单一模型能够使用自由形式指令对输入语音执行语义和声学编辑。相比之下，多轮编辑在图像领域已经得到了很好的证明，例如 GPT-4o 和 Gemini-Image-Flash 2.5（OpenAI, 2024; Google, 2025）。为调和理解和生成任务对表示的不同要求，我们提出了一种基于 VAE 的连续音频分词器，统一了语义和声学表示。此外，我们引入了一种新颖的能力，即自由形式语音编辑，它实现了细粒度且高质量的语音操作。然而，构建这样一个统一系统需要解决几个基本挑战，我们详述如下。

- **不一致的表示：理解 vs. 生成：**一个主要障碍在于语音理解和生成对表示的不同需求。理解任务，如自动语音识别（ASR）和情感分析，主要需要高层语义信息。相比之下，语音生成（例如，文语转换、语音

转换) 要求对细粒度声学细节 (包括韵律、音色和语调) 进行忠实重建。在单一表示中调和它们不同的需求是非常具有挑战性的, 常常导致模型在一个方面表现出色而牺牲另一方面。

- **不同的训练目标:** 在理解和生成的联合训练中, 存在几个挑战。这两个任务的优化目标不同, 并且它们呈现出不同级别的训练难度。此外, 生成任务通常需要更多的训练迭代。因此, 确定理解和生成任务之间的训练比例以使两者同时达到最优性能, 尤其是在多阶段训练设计下, 仍然是一个紧迫的问题。
- **语音编辑的局限性:** 现有的语音编辑方法通常是受限的。许多方法需要复杂的多阶段流程, 或在一组有限的预定义操作 (例如, 去噪、速度改变) 上运行。扩展到更复杂的“自由形式”编辑提出了进一步的挑战。语义内容修改 (例如, 插入、删除、替换) 通常需要时间戳条件来指定编辑位置。缺乏真正由指令引导的自由形式编辑能力限制了当前语音编辑工具的实用性和可访问性。

为解决这些问题, 我们提出了 Ming-UniAudio, 一个旨在实现统一语音理解、生成和自由形式编辑的新颖框架。我们的主要贡献如下。

- **统一的连续语音分词器:** 我们引入了一种新颖的统一连续语音分词器, 它建立在变分自编码器 (VAE) 框架之上, 并使用纯粹的因果Transformer架构实现。该分词器统一了语义和声学表示, 通过多阶段训练和来自LLM的语义蒸馏进行优化。它同时提取高维统一特征 Z_{uni} 作为LLM的通用接口, 以及用于高质量生成至关重要的低维声学潜在向量 Z_{latent} 。此外, 该潜在向量可以通过语义模块转换为高维统一特征, 从而与LLM的理解和生成任务形成一个完整的闭环。
- **用于生成和理解的统一语音语言模型:** 我们预训练了一个端到端的统一语音语言模型, 能够使用单个LLM主干进行理解和生成。该模型包含一个逐token扩散头, 它以LLM的隐藏状态和预测的语义序列为条件, 确保高质量和自然的语音合成。
- **指令引导的自由形式语音编辑:** 据我们所知, 这是首个完全基于自由形式自然语言指令实现真正通用语音编辑框架的工作。该框架实现了全面编辑, 涵盖语义内容修改 (插入、删除、替换) 和声学属性调整 (去噪、速度/音高/音量、方言/情感转换等), 无需用户指定明确的编辑区域。我们提出了 Audio-Edit-Benchmark, 首个开源的自由形式评估集, 包含三种语义和五种声学类型的编辑任务, 以评估模型的编辑性能。

2 相关工作

2.1 语音分词器

语音分词对于表示连续语音信号至关重要。声学token, 如 SoundStream (Zeghidour et al., 2021) 或 EnCodec (Défossez et al., 2022), 擅长保持高重建质量, 但往往缺乏丰富的语义信息, 这可能导致发音稳定性受损 (Wang et al., 2023)。相反, 语义token, 如 HuBERT、Whisper 和 CosyVoice (Hsu et al., 2021; Radford et al., 2023a; Du et al., 2024b), 富含语义内容但倾向于丢失声学细节。因此, 需要一个单独的扩散模型来将这些token转换为梅尔频谱图并注入音色、韵律和风格等声学特征。为解决上述问题, SpeechTokenizer (Zhang et al., 2023) 使用知识蒸馏来整合语义和声学特征, 而 Step Audio Tokenizer (Huang et al., 2025a) 试图通过交错语义和声学token来解决这个问题。然而, 它们的离散性质使其对于基于理解的任务 (如语音识别) 来说不是最优的。受计算机视觉中 MingTok-Vision (Huang et al., 2025b) 工作的启发, 我们提出了一个基于VAE的连续分词器, 具有统一的语义和声学表示, 提供了比离散方法更好的性能。这种统一方法表明, 未来实现无缝、自由形式的语音编辑现在是可行的。这一能力意义重大, 因为它弥合了理解和生成之间的关键差距。

2.2 统一的语音理解与生成模型

近期努力旨在构建用于语音理解和生成的统一模型。KimiAudio (KimiTeam et al., 2025) 提出了一种音频分词器，它将语义音频token与来自 Whisper (Radford et al., 2023a) 编码器的连续声学向量连接起来，以增强感知能力并输出离散语义token。DualSpeechLM (Wang et al., 2025c) 提出了一种双token建模范式，使用专用的 USToken 用于输入和声学token用于输出。其他模型如 SpeechGPT (Zhang et al., 2024) 和 Moshi (Defossez et al., 2024) 探索了不同的策略，通常依赖于大规模配对数据或在真正统一表示方面存在局限性。我们的统一分词器提供了一种更内在且连续的语义和声学信息表示，这对生成和理解任务都有效。此外，我们用于生成的逐token自回归扩散头被假设能比离散token后接句子级扩散模块产生更高的生成质量，这已由 DitAR (Jia et al., 2025) 和 VibeVoice (Peng et al., 2025) 证明。

2.3 指令引导的语音编辑

语音编辑领域已经看到增长，特别是随着指令引导方法的出现。VoiceBox (Le et al., 2023) 引入了一种基于流匹配的非自回归编辑范式。然而，它依赖像 MFA 这样的对齐模型来指定编辑区域，这在实践场景中增加了操作开销。InstructSpeech (Huang et al., 2024) 代表了一个重大进步，采用三元组数据构建、多任务学习和多步推理来实现基于指令的编辑。然而，当给出自由形式指令时，仍然需要时间戳对齐机制来定位指定区域。其他模型，如 VoiceCraft (Peng et al., 2024) 和 EditTS (Tae et al., 2021)，通常在真正“自由形式”能力方面存在限制，要么需要显式的区域掩码，要么仅限于特定类型的编辑。此外，副语言任务，包括情感和口音转换，要求语音LLM具备强大的理解能力。我们的框架通过仅基于自然语言指令实现全面、无约束的编辑，直接解决了这个问题。

3 模型架构

3.1 统一的连续分词器

我们统一的流式分词器是 Ming-UniAudio 的基石，旨在通过同时以可流式方式提取语义和声学特征，解决理解和生成之间的表示不一致问题。

3.1.1 设计原则与基本原理

图2 MingTok-Audio的整体框架

我们的模型设计遵循三个核心原则，旨在为理解和生成任务创建统一的表示。

连续表示：开发理解和生成任务的统一模型的一个主要挑战在于它们偏好的输入表示的不同性质。理解任务显然受益于能更好捕获细微语义信息的连续特征。相反，最先进的语音生成模型通常依赖离散token，当与流匹配和声码器等框架结合时，提供了一种有效的建模方法。为构建一个真正统一的架构，单一且连贯的表示是必要的。由于语义碎片化等问题，离散token对于理解任务不是最优的。此外，近期工作如 DitAR (Jia et al., 2025) 已证明VAE的连续潜在表示在生成质量上可以优于离散token。因此，我们采用基于VAE的分词器，为所有下游任务生成连续且统一的表示。

低维和高维表示的联合建模：这种统一表示 (Z_{uni}) 提出了一个核心的维度挑战。一方面，理解任务需要为LLM提供高维、语义丰富的输入。另一方面，诸如流匹配的生成框架在处理高维数据时常常面临可扩展性挑战，使得低维潜在（例如，32或64维）成为建模的更易处理的选择。为弥合这个维度差距，我们的分词器旨在明确链接低维和高维空间。这是通过一个语义模块实现的，该模块将紧凑的潜在变量 Z_{latent} 映射到其语义更丰富的对应物 Z_{uni} ，然后将其确立为LLM的输入。这种架构优势地使所有任务都能在丰富的高维空间中操作，同时利用紧凑潜在进行生成的高效性。

- **语义对齐与声学重建的联合优化：**我们的统一表示使用同时针对语义对齐和声学重建的联合目标进行优化。(1) **与预训练LLM的语义对齐。**为用语义丰富 Z_{uni} ，我们使用冻结的LLM作为指导。通过判别任务

通过LLM反向传播梯度来训练分词器，这迫使 Z_{uni} 与LLM的语义空间对齐。(2) **声学重建**。对于生成任务， Z_{uni} 保留足够的底层声学细节至关重要。我们使用 Z_{uni} 作为重建解码器的输入，承担语音重建任务。这个重建目标迫使 Z_{uni} 编码用于精确信号重建的细粒度声学细节。通过联合优化这两个目标， Z_{uni} 成为一个单一的表示，同时编码用于理解的丰富语义和用于生成的细粒度声学。

3.1.2 分词器架构

我们的分词器，详见图2a，是一个完全基于Transformer的架构，专为高效率而设计。它完全不含卷积，由三个核心模块组成：编码器、语义模块和解码器。

- **编码器**：编码器处理原始音频输入并将其编码到潜在空间，遵循类似于 TS3-Codec (Wu et al., 2025b) 的策略。我们将原始波形重塑为2D张量，然后将每个帧向量投影到模型的隐藏维度 (d_{model})。随后，我们采用单向Transformer来捕获上下文信息。其最终隐藏状态被投影到 $2 \times d_{\text{latent}}$ 向量以获得VAE的高斯潜在分布。
- **语义模块**：为获得用于下游理解和生成训练的联合表示，我们引入了一个基于预训练 Whisper large-v3 (Radford et al., 2023b) 编码器构建的语义模块。我们通过移除其卷积层来适配这个编码器，使其能够直接从我们的VAE的低维声学潜在 Z_{latent} 处理到高维统一特征 Z_{uni} 。
- **解码器**：解码器通过两阶段过程从 Z_{uni} 重建波形。首先，一个单向Transformer将 Z_{uni} 映射到中间频谱表示。随后，一个受 Vocos (Siuzdak, 2023) 启发的合成头预测完整的复数频谱图（幅度和相位），以便通过逆短时傅里叶变换（iSTFT）进行最终合成。

3.2 统一的语音语言模型

如图3所示，我们统一语音语言模型的核心是一个解码器-only的LLM主干。该架构设计用于处理组合的token序列，无缝集成文本token与 Ming-Tok-Audio 产生的连续统一语音token Z_{uni} 。模型的通用性通过多头设计实现，其中不同任务由专门的输出模块处理。这个统一框架允许单个模型在理解、合成和操作之间切换，条件取决于特定的输入格式和指令提示。

- **理解任务**：LLM的最终隐藏状态由文本头投影，以自回归地生成目标文本序列。
- **生成任务**：隐藏状态被馈送到逐token扩散头以合成音频。
- **编辑任务**：在“理解-然后-合成”范式中利用整个架构，模型首先处理源音频和文本指令以生成中间表示（例如，思维链），然后逐token扩散头合成最终的编辑后音频。

图3 Ming-UniAudio的模型架构

4 统一分词器：方法与训练

为有效获得用于语音理解和生成的统一表示，我们为所提出的架构设计了一个三阶段训练方法。

4.1 三阶段训练范式

4.1.1 声学重建训练

在第一阶段，我们训练一个声学分词器，由编码器和解码器组成，以学习音频波形的高质量表示。此过程通过混合VAE-GAN目标进行优化，遵循 X-codec 框架 (Ye et al., 2024)。如图2b (S0) 所示，总体训练目标由两个主要损失函数组成，一个用于判别器 (D)，一个用于生成器 (G)。判别器损失 $\mathcal{L}_D$ 旨在区分所有子判别器上的真实音频和重建音频。生成器损失 $\mathcal{L}_G$ 是一个复合目标，旨在确保重建的准确性和感知的自然度。如公式1所示，

$$\mathcal{L}_G = \lambda_{\text{rec}}\mathcal{L}_{\text{rec}} + \lambda_{\text{adv}}\mathcal{L}_{\text{adv}} + \lambda_{\text{fm}}\mathcal{L}_{\text{fm}} + \lambda_{\text{kl}}\mathcal{L}_{\text{KL}} \quad (1)$$

其中组成部分包括：(1) 多尺度梅尔频谱图重建损失 ($\mathcal{L}_{\text{rec}}$) 以确保感知音频质量；(2) 对抗性损失 ($\mathcal{L}_{\text{adv}}$) 通过欺骗判别器来增强音频自然度；(3) 判别器特征上的特征匹配损失 ($\mathcal{L}_{\text{fm}}$) 以稳定GAN训练；以及 (4) KL散度损失 ($\mathcal{L}_{\text{KL}}$) 以正则化VAE的潜在空间。

4.1.2 语义特征蒸馏

我们使用预训练的 Whisper large-v3 编码器的权重初始化语义模块，借助其强大的语义先验。为使该模块从原始的梅尔频谱图输入适配到我们模型的声学潜在输入，我们采用语义蒸馏，其中仅训练语义模块，如图2b (S1) 所示。如公式2定义， Z_{semantic} 是原始冻结 Whisper 编码器的输出。

$$\mathcal{L}_{\text{distill}} = \text{MSE}(Z_{\text{uni}}, Z_{\text{semantic}}) \quad (2)$$

4.1.3 与LLM的统一分词器训练

遵循第3.1.1节概述的方法，我们执行一个用于语义对齐和语音重建的联合训练阶段。在此阶段，我们仅更新语义模块的参数，迫使 Z_{uni} 同时捕获丰富的语义内容和详细的声学特征。与声学重建训练阶段不同，此阶段的训练仅由梅尔频谱图重建损失引导，因为我们发现在此阶段包含GAN损失会对语义学习产生负面影响。

$$\mathcal{L}_{\text{align}} = - \sum_{t=1}^T \log P(y_t | Z_{\text{uni}}, y_{<t}) \quad (3)$$

$$\mathcal{L} = \lambda_{\text{align}}\mathcal{L}_{\text{align}} + \lambda_{\text{rec}}\mathcal{L}_{\text{rec}} \quad (4)$$

4.2 实验设置

4.2.1 数据与评估指标

我们的模型在约390,000小时的语音数据（16kHz）的庞大且多样化的语料库上训练，普通话和英语的比例为1:1平衡。在评估中，我们在公开的 Seed-TTS-Eval (Anastassiou et al., 2024a) 基准上报告结果。为全面评估我们提出的统一分词器的性能，我们采用了几个广泛使用的客观指标。(1) 短时客观可懂度 (STOI)；(2) 感知语音质量评估 (PESQ)；(3) 说话人相似度 (SPK SIM)。

4.2.2 训练配置

我们的统一分词器通过将 16kHz 音频分割成320个样本的非重叠帧来处理，结果得到 50Hz 的帧率，在所有层中使用滑动窗口注意力（窗口大小 = 32）。我们的模型总共有13.5亿参数。我们按照第4.1节提出的三阶段训练范式训练我们的分词器。每个阶段的具体配置详见表1。

表1 统一连续语音分词器的训练配置

训练阶段	学习率	训练步数	可训练模块	目标
声学分词器训练	$1e-4$	200k	编码器+解码器	$\mathcal{L}_G = 15\mathcal{L}_{\text{rec}} + \mathcal{L}_{\text{adv}} + \mathcal{L}_{\text{feat}} + 1e-4\mathcal{L}_{\text{KL}}$
语义特征蒸馏	$1e-4$	200k	语义模块	$\mathcal{L} = \mathcal{L}_{\text{distill}}$
统一分词器训练	$1e-4$	200k	语义模块	$\mathcal{L} = 2\mathcal{L}_{\text{align}} + \mathcal{L}_{\text{rec}}$

4.3 评估

4.3.1 语音重建性能

表2 不同声学分词器的重建性能比较。

系统	帧率	SEED-ZH	SEED-EN	PESQ↑	SIM↑	STOI↑	PESQ↑	SIM↑	STOI↑	MingTok-Audio
		(ours)	50	4.21	0.96	0.98	4.04	0.96	0.98	MiMo-Audio-Tokenizer
		(2025)	25	2.71	0.89	0.93	2.43	0.85	0.92	GLM4-Voice-Tokenizer
		(2024)	12.5	1.06	0.33	0.61	1.05	0.12	0.60	Baichuan-Audio-Tokenizer
		(2025b)	12.5	1.84	0.78	0.86	1.62	0.69	0.85	XY-Tokenizer
		(2025)	12.5	2.27	0.77	0.90	2.14	0.82	0.90	Mimi Défossez et al.
		(2024)	12.5	2.05	0.73	0.89	2.01	0.77	0.89	XCodec2.0
		(2025)	50	2.19	0.80	0.92	2.37	0.82	0.93	BigCodec
		(2024)	80	2.26	0.81	0.92	2.22	0.80	0.91	

为验证我们统一分词器在生成方面的能力，我们在下游TTS任务上评估了其性能。 Z_{uni} 作为LLM的输入，并采用逐token流匹配头进行生成建模。结果如表3所示。我们基于统一分词器的连续特征TTS，尽管使用相同的训练数据和模型规模，仍显著优于我们之前的离散token模型 Ming-lite-omni。这一结果突显了统一表示在生成任务上的优越性。

系统	Seed-zh WER(%)	Seed-zh SIM	Seed-en WER(%)	Seed-en SIM	Seed-TTS	Anastassiou et al. (2024b)	Ming-Omni-Lite Inclusion et al. (2025)	MingTok-Audio-TTS
	1.12	0.80	2.25	0.76	1.69	0.68	4.31	0.51
	1.04	0.75	1.54	0.68				

5.1 统一预训练的方法论洞察

- **表示的稳定性：**语音分词器 MingTok-Audio 在下游理解和生成任务上独立验证时，能够取得强大性能。这表明 MingTok-Audio 的统一表示 Z_{uni} 固有地富含语义和声学信息。然而，这两个任务在数据量、训练步数和学习率方面存在差异。稳定的表示对这两个任务都是基础。但是，解冻所有参数（即全量微调）很容易导致特征漂移，导致理解和生成之间的性能不平衡。因此，冻结分词器并选择无参数的token压缩模块，尤其是在初始训练阶段，对于保持分词器语义和声学表示的稳定性至关重要。
- **表示的闭环流动：**语义和声学特征必须能够在整个训练过程中以闭环方式流动。否则，可能会出现表示偏差，使模型性能偏向特定任务。至关重要的是，在分词器的语义模块、LLM的适配器、token压缩器和逐token流匹配头等模块中，语义和声学信息都能自由传递。这防止了表示在任何阶段在理解和生成目标之间摇摆，我们称之为“表示混淆”。
- **联合训练：**具有不同收敛步数、训练数据量和难度级别的任务必须合理调度。理解任务的性能通常与消耗的token数量正相关。相反，使用自回归模型和逐token扩散头的语音生成性能通常与迭代步数相关。

因此，为高效利用计算资源并使理解和生成任务同时达到最优性能，应采用特定策略。

5.2 实现细节

整体架构采用一个168亿参数的混合专家（MoE）大语言模型（28亿激活）进行自回归生成，如图3所示。

音频token压缩是最有影响力的策略之一。在音频分词器从输入音频生成高维特征之后，有多种方法可以将特征序列下采样到LLM所需的输入帧率。除了对相邻token进行操作的时序池化方法（如公式5所示），另一种方法（交叉注意力压缩器）涉及使用Transformer模块将块中的信息聚合到[CLS] token中。

$$Z'_{\text{uni}}[i] = \text{Pooling}(Z_{\text{uni}}[pi : (p + 1)i]) \quad \text{for } i = 0, \dots, \left\lfloor \frac{l_{\text{uni}}}{p} \right\rfloor - 1 \quad (5)$$

其中 l_{uni} 是 Z_{uni} 的长度。为研究两种方法的影响，我们进行了一项研究，结果如表4所示。显然，池化策略取得了显著更好的结果。这表明下采样过程本身不需要高度复杂的映射。尽管如此，仍需要高效准确地传输原始特征，以最大化下游模块可用的信息。

表4 下采样策略的性能比较。两个实验均在 Qwen-0.5B 上进行。

配置	理解 WER(%)↓	生成 WER(%)↓ SIM↑ aishell1 aishell2-ios Fleurs-zh LS-clean LS-other Voxpopuli-
		en AVG Seed-zh Seed-en AVG 基线 (池化) 3.23 3.62 5.53 2.26 6.02 10.41 5.18 8.07 10.61 22.07 基线 (交叉注意力) 5.69 7.05 6.95 3.64 10.06 13.97 7.89 8.88 10.48 21.89

语义模块冻结：在预训练早期，语义模块的输出特征分布在理解和生成任务的训练过程中可能发生显著变化，导致收敛不稳定或收敛速度较慢。对这一现象的对比实验见表5和图5a。可以观察到，当语义模块未冻结时，理解和生成任务的性能均显著恶化，且收敛速度更慢。这表明理解和生成任务之间存在明显的表示不一致。

扩散头初始化：为加速统一语音语言模型的收敛，我们旨在验证用已在生成任务上训练的参数初始化扩散头是否能带来更好的结果。因此，我们以单任务方式使用相同的训练设置训练了一个基于 Qwen-0.5B 的模型，并在大规模训练开始前加载其权重。我们在 Qwen-0.5B 上评估了这一策略的性能，结果见表5和图5b。在理解任务性能几乎没有下降的情况下，生成任务的性能显著提高。此外，具有扩散头初始化的基线配置实现了约为消融实验2.0倍的收敛速度。

连续token的停止标准：与受益于特殊 token 的离散分词器不同，我们的模型需要一个额外的停止检测器。我们给LLM附加了一个线性层，在每一帧执行二元分类。为避免对尾部标注的强依赖，我们提出了一种弱监督训练策略。（1）每个话语的最后一帧被标记为正样本（停止）；（2）然后忽略最后一帧的前三帧（300毫秒）以最小化VAD错误的影响；（3）在剩余帧中，选择具有最高停止分数的一帧作为负样本。这种方法保持了正负样本的平衡，并在线挖掘了最难的负样本。停止头使用交叉熵损失训练，缩放因子为0.01。

表5 几种训练策略的性能比较。

配置	理解 WER(%)↓	生成 WER(%)↓ SIM↑ aishell1 aishell2-ios Fleurs-zh LS-clean LS-other Voxpopuli-en AVG Seed-zh Seed-en AVG 基线 2.29 3.32 4.26 2.28 6.04 7.91 4.35 4.62 10.58 8.43 + 任务分布 = 1:3 2.38 3.33 4.39 2.33 5.90 8.29 4.44 3.18 10.60 5.54 + 任务分布 = 1:4 2.47 3.43 4.35 2.40 6.13 8.13 4.49 3.20 10.60 5.75 - 语义模块冻结 4.02 4.54 7.21 2.81 7.81 14.78 6.86 8.11 10.60 22.49 - 扩散头初始化 2.36 3.33 4.22 2.27 5.92 7.92 4.34 10.02 10.51 12.64 基线 420k 步 1.62 3.08 4.33 1.76 4.91 8.46 4.03 2.27 10.63 6.59 + 退火 1.47 2.82 4.06 1.59 4.39 8.37 3.78 1.97 10.64 6.05

5.3 数据策展与处理

我们模型的性能依赖于大规模、多样化的训练数据集。我们从两个主要来源编译数据：公开可用的音频数据集和一个包含网络爬取录音和合成音频的内部收藏。

为确保数据质量和相关性，我们实施了一个多阶段预处理流程。首先，对所有数据应用严格的清洗过程，特别是对质量差异显著的网络爬取音频。其次，认识到理解和生成等不同任务有不同要求，我们执行任务特定的过滤。这种定制化方法使我们能够创建高质量的、带标注的数据子集，针对广泛的语音相关任务进行优化，为训练我们的统一模型奠定坚实基础。

图4 音频数据处理流程概览。

5.4 训练

大规模训练阶段：此阶段旨在为LLM提供足够的大规模数据以建立其基本的对齐能力。在此阶段，模型训练了200,000步，理解和生成任务的训练步数比例为1:3。在整个训练过程中，音频分词器中语义模块的参数保持冻结。

退火阶段：此阶段的目的是使用更高质量的数据和更小的学习率进行退火，从而稳定模型参数，同时进一步提高整体性能。所有其他训练配置与前一阶段保持一致。

全量微调阶段：此阶段在前一阶段的基础上，继续使用解冻的语义模块参数进行训练。同时，适度增加生成任务训练的比例，旨在进一步提高生成任务的性能，同时最小程度地影响理解任务的性能。

表6 不同阶段的训练配置。LR代表学习率。Und代表理解。Gen代表生成。

超参数	预训练	大规模训练	退火	全量微调	LR (语义模块)	冻结	冻结	1e-5	LR (其他)	1e-4	1e-5	1e-5	LR调度器	恒定
	恒定	恒定	批次大小 (理解)	5500 token	5500 token	5500 token	批次大小 (生成)	2000 token	2000 token	2000 token	步数比例 (理解:生成)	1:3	1:3	1:6
	预热步数	3000	0	0	AdamW	eps	1e-5	1e-5	1e-8	训练数据	时长(h)	(理解:生成)	400k:800k	370k:370k
	370k:370k	370k:370k												

图5 语义模块冻结和扩散头初始化的消融研究损失曲线。

6 基于指令的自由形式语音编辑

6.1 基于指令编辑的统一范式

语音编辑是一项同时对理解和生成能力要求都很高的任务。利用 Ming-UniAudio 模型在理解和生成方面的强大基础能力，我们探索了基于自由形式指令的语音编辑的训练范式、数据构建方法和评估指标。统一语音理解和生成的核心挑战源于表示的根本不一致。理解任务依赖于连续的、语义丰富的特征，而最先进的生成模型通常依赖离散token。虽然对合成有效，但这些离散token牺牲了细粒度的声学信息，进而降低了理解任务的性能。这迫使采用碎片化的方法：对理解使用连续token，对生成使用离散token。结果是两种不同的分词方案从根本上阻碍了开发真正统一、高质量的表示。

基于预训练的、连续且统一的分词器 Ming-Tok-Audio，以及预训练的、统一了理解和生成任务的语音LLM Ming-UniAudio，我们的方法能够使用单一、统一的表示实现高质量的语音理解和语音生成。这种架构完美地符合语音编辑任务所需的“理解-然后-合成”范式，如图6所示。最终，我们的模型支持各种编辑任务。每个任务对应的输入和输出格式详见表7。据我们所知，这是首个能够遵循人类指令而无需时间戳对齐等额外操作的语音编辑模型。

表7 各种语音编辑任务及其任务形式的总结。

类型|任务|输入|输出

语义|删除|源语音，删除单词 'hello'...|CoT文本，目标语音 插入|源语音，插入单词 'hello'...|CoT文本，目标语音 替换|源语音，将单词 'hello' 替换为 'world'|CoT文本，目标语音

声学|去噪|源语音，对音频进行去噪|目标语音 速度改变|源语音，将速度调整为1.5|目标语音 音高改变|源语音，将音高偏移3个步长|目标语音 音量改变|源语音，将音量调整为1.5|目标语音 方言转换|源语音，将语音口音改为成都话|目标语音

我们根据以下原则设计了基于自由形式指令的编辑训练方案：

- **全局 vs. 局部**：语义和声学编辑任务呈现出基本的局部与全局差异。语义编辑通常是局部的：它在特定区域内修改内容，同时要求周围音频（内容、音色、韵律）保持不变。编辑后的片段还必须与其上下文保持声学一致性。相比之下，声学编辑（例如，口音转换、去噪）通常是全局的，改变整个话语的声学特征，同时保留原始文本。这种差异需要不同的建模方法。
- **定位然后修改**：鉴于其局部性质，语义编辑任务需要一个两阶段过程：首先定位目标片段，然后执行修改，我们将其表述为语义任务的思维链。
- **互补任务的联合训练**：许多训练任务可以被视为互补对，例如去噪与添加背景音乐，以及文本添加与删除。因此，多任务联合训练预计将通过利用这些互补关系来增强整体模型性能。

基于这些原则，我们提出了一个无缝集成语义理解和声学合成的统一生成模型。为解决“全局 vs. 局部”的差异，我们的模型在统一的表示 (Z_{uni}) 上操作以进行内容操作，并使用逐token扩散头进行高质量生成，兼顾局部语义编辑和全局声学变化。对于语义任务中的“定位然后修改”原则，我们将该过程表述为一个指令引导的序列到序列变换：模型首先自回归地生成一个目标语义序列，有效地执行“思维链”推理以确定编辑内容和位置。

声学任务：我们为广泛的声学编辑任务设计了一个统一范式。这些包括副语言修改（如情感和方言转换）、物理属性调整（如速度、音高和音量），以及其他任务（如去噪和添加背景音）。该框架接受输入音频和指令，直接产生编辑后的音频输出。关键的是，它避免生成任何文本或其他语义输出，这使其能够灵活地适应各种类型的输出音频。这种范式展现出强大的鲁棒性，并在各种内容保持的编辑任务中表现异常出色，其中底层文本内容保持不变。

语义任务：对于语义编辑任务，我们采用指令遵循格式，使我们能够有效利用预训练模型理解和执行指令的能力。数据构建如下：

$$\text{SourceSpeech}_{z_{\text{uni}}} + \text{Instruction}_{\text{text}} \rightarrow \text{CoT}_{\text{text}} + \text{TargetSpeech}_{z_{\text{latent}}}$$

我们引入了几项关键创新以实现自由形式的指令遵循：

- **用于文本引导的CoT**：我们引入了一个思维链（CoT）(Wei et al., 2023) 步骤，其中模型首先生成编辑后语音的目标文本。这个中间文本输出显著提高了最终合成音频的发音准确性和指令遵循能力。
- **显式编辑定位**：在CoT文本中插入一个特殊的 [MASK] token，明确划定了编辑区域。这为模型提供了精确的位置线索，引导其聚焦于目标修改片段，并增强其位置感知能力。
- **编辑区域的加权损失**：为优先学习新内容的复杂合成，对编辑后的音频段应用更高的损失权重。此策略将这些区域与未编辑区域区分开来，而未编辑区域的重建可以通过从源音频复制来简化。

6.2 指令调优数据

我们通过以下方法（如图7所示）构建语音编辑训练数据集：

- 插入：**此任务涉及在指定位置插入内容，该位置可以由文本索引或相对于特定单词的位置（即在其之前或之后）定义。训练对通过包含一个移除了某部分的音频段作为输入，以及原始完整音频作为目标来构建。
- 删除：**作为插入的对偶任务，此任务旨在移除指定内容。我们通过将随机音频片段插入到干净录音中来合成输入。目标是原始的、未修改的音频，从而训练模型移除该片段。
- 替换：**此任务旨在将音频的一段替换为不同的内容。我们通过将原始音频的一段移动到同一录音中另一个不同的、非重叠的位置来构建输入。目标是原始的、未修改的音频，训练模型恢复被覆盖的部分。
- 去噪：**带噪输入通过使用 MUSAN (Snyder et al., 2015) 数据集的噪声增强干净音频生成。目标是原始的、干净的音频。
- 速度和音高改变：**我们使用开源工具处理音频以改变其速度和音高。处理后的音频作为训练目标，以原始音频和指令作为输入。
- 方言转换：**我们构建了一个普通话-方言平行语料库。为丰富说话人多样性，我们进一步应用语音转换（VC）为训练数据生成了超过1,000种不同的音色。

图6 Ming-UniAudio 与开源语音LLM在理解、生成和编辑任务上的比较。

6.3 Freeform-Audio-Edit 基准

我们构建了 Ming-Freeform-Audio-Edit，首个用于语义和声学任务、无需时间戳条件的通用自由形式语音编辑基准，包括语音内容插入/删除/替换、情感/口音转换、速度/音高/音量改变等。

6.3.1 语义测试集

用于语义语音编辑任务的公共基准很少，这阻碍了不同方法的直接比较。此外，现有的评估集主要设计用于基于区域的模型。据我们所知，Ming-Freeform-Audio-Edit 是首个为自由形式语音编辑模型构建的基准。

数据集构建：我们从 seed-tts 测试集中选择了896个中文和655个英文样本。对于每个音频片段，首先将其随机分配到三个任务之一：删除、插入或替换。接下来，我们获取其转录，并利用LLM为分配的任务生成自然语言指令和对应的编辑后文本。最后，LLM生成的编辑后文本经过人工验证，以确保其与给定指令的预期结果一致。

数据集统计：删除、插入和替换任务的指令大致可分为两类：基于索引的，指定对位置 i 到 j 的内容进行操作；以及基于内容的，针对特定的字符或单词进行编辑。

在我们的初始版本中，编辑指令对于中文和英文音频都是用英文编写的，并且它们的措辞相对有限（见附录C中 Ming-Freeform-Audio-Edit 的示例）。我们将其称为基本版本；此基本版本的数据集统计信息如表8所示。

表8 Ming-Freeform-Audio-Edit 基本语义测试集的数据集统计。

指令	中	英文	删除 插入 替换 删除 插入 替换	基于索引 92 65 29 47 79 29	基于内
类型	文	容	78 105 130 133 81 150	总计 170 170 159 180 160 179	

为更好地将编辑指令与真实用户表达对齐，我们构建了这些测试集的第二个版本，称为完整版本。除了增加每个任务的测试示例数量外，我们在使用LLM生成指令时特意强调指令的自然性和多样性。此外，我们的初步实验显示，三个任务难度不同，替换被证明是最具挑战性的。因此，我们在测试集中增加了替换任务的比例，以确保更严格的评估。完整版数据集的详细统计信息见表9。

表9 Ming-Freeform-Audio-Edit 完整语义测试集的数据集统计。

指令	中	英文	删除 插入 替换 删除 插入 替换	基于索引 186 180 361 381 100 67	基于内
类型	文	容	95 110 289 62 99 189	总计 281 290 325 200 199 256	

6.3.2 声学测试集

数据集构建：声学测试集的构建过程与语义测试集类似：音频来自 seed-tts 测试集，LLM生成特定任务的编辑指令。与语义测试集不同，不需要文本标签，因此省去了人工验证步骤。

数据集统计：Ming-Freeform-Audio-Edit 中声学测试集每个任务的测试样本数量见表10。

任务类型|中文|英文 情感转换|84|72 速度改变|50|50 音高改变|50|50 音量改变|50|50 方言转换|250|-

表10 Ming-Freeform-Audio-Edit 声学测试集的数据集统计。

6.3.3 评估指标

对于语义编辑任务，我们报告 WER 和 SIM，分别评估语音的易懂度和说话人相似度，遵循 seed-tts (Anastassiou et al., 2024b)。此外，我们定义 ACC 和 no-edit WER 来衡量编辑区域内的音频编辑准确性和编辑区域外的音频 WER。对于声学编辑任务，评估指标因具体任务而异。具体来说，对于语音去噪任务，我们使用 DNSMOS (Reddy et al., 2022) 来评估增强语音的质量。该分数范围为0到5，分数越高表示音频质量越好。对于其余任务，我们主要采用 WER 和 SIM 作为评估标准。我们还报告速度改变的相对时长误差（RDE）和音量改变的相对幅度误差（RAE）；较低的数值表示更接近目标规格。

7 结果与分析

7.1 理解

如表11所示，Ming-UniAudio 在几个公开基准上取得了与领先开源模型相当的性能。值得注意的是，由于其专门的多方言训练，它在我们的内部方言测试集上显著优于现有模型。

此外，该模型展示了强大的利用上下文信息的能力，其在 ContextASR Bench (Wang et al., 2025a) 上的表现证明了这一点。根据表12的结果，Ming-UniAudio 在12个子任务中的8个上取得了SOTA性能。这表明在轮对话和热词增强等现实场景中具有强大的稳健性潜力。

表11 在各种音频基准数据集上的ASR性能比较。最佳结果以粗体显示。

数据集 模型	理解 ASR Kimi-Audio KimiTeam et al. (2025) 2.56 1.28 31.93 41.49 6.69 60.64 Qwen2.5 Omni Xu et al. (2025a) 2.75 1.80 29.31 10.39 7.61 32.05 Qwen2 Audio Chu et al. (2023) 2.92 1.60 25.88 7.59 7.77 31.73 Ming-UniAudio 2.84 1.62 9.80 5.51 5.46 14.65
性能 aishell2-ios LS-clean Hunan Guangyue Chuanyu Shanghai	

表12 ContextASR Bench (Wang et al., 2025a) 上的上下文ASR性能比较。最佳结果以粗体显示。

数据集|模型

性能	Speech-English Dialogue-English Speech-Mandarin Dialogue-Mandarin	理解 Context ASR Qwen2-Audio Chu et al. (2023) 11.49 27.27 35.08 13.99 33.02 32.92 9.92 24.10 30.02 7.00 22.76 26.17
	WER NE-WER NE-FNR WER NE-WER NE-FNR WER NE-WER NE-FNR	Baichuan-Audio Li et al. (2025a) 7.52 15.87 4.55 5.66 10.01 3.64 2.16 6.65 2.35 2.96 11.48 3.94 Kimi-Audio KimiTeam et al. (2025) 2.90 6.68 8.01 4.67 13.50 11.31 1.95 11.13 15.28 2.90 15.91 16.68 Baichuan-Omni-1.5 Li et al. (2025c) 8.16 17.69 6.53 9.91 14.40 5.54 2.98 8.39 4.71 5.00 16.83 7.84 Qwen2.5-Omni-3B Xu et al. (2025a) 3.99 17.80 9.69 4.83 14.36 12.85 2.13 10.55 14.11 3.12 15.07 15.17 Qwen2.5-Omni-7B Xu et al. (2025a) 3.96 17.38 8.72 5.32 11.83 9.24 1.84 9.80 12.19 2.40 14.06 13.17 Ming-UniAudio 4.00 3.56 3.69 5.34 8.73 2.53 1.58 5.98 2.40 3.04 9.50 1.48

7.2 生成

如表13所示，Ming-UniAudio 在语音生成方面展示了强大的整体性能。在语音可懂度方面，以词错误率（WER）衡量，它在中文上取得了比较模型中最优的结果（0.95），在英文上也保持高度竞争力。虽然在音色相似度（SIM）方面还有进一步提升的空间，但该模型持续产生高度易懂的语音，这是我们工作的主要关注点。

表13 语音生成基准数据集上的性能比较。最佳结果以粗体显示。

数据集 模型		生成 Seed-TTS Anastassiou et al. (2024b) 1.12 0.80 2.25 0.76 FireRedTTS Guo et al. (2024) 1.51 0.65 3.82 0.53 FireRedTTS-Z Xie et al. (2025) 1.14 0.736 1.95 0.65 DiTAR Jia et al. (2025) 1.02 0.753 1.69 0.74 F5-TTS Chen et al. (2024) 1.56 0.74 1.83 0.65
性能 Seed-zh	WER(%) Seed-zh	CosyVoice 2 Du et al. (2024c) 1.45 0.75 2.57 0.65 CosyVoice 3-1.5B Du et al. (2025) 1.12 0.78 2.21 0.72 MiMo-Audio Xiaomi (2025) 1.96 - 5.37 - Qwen2.5-Omni-7BRL Xu et al. (2025a) 1.42 0.75 2.33 0.64 Qwen3-Omni-30B-A3B-Instruct Xu et al. (2025b) 1.07 - 1.39 - Ming-UniAudio 0.95 0.70 1.85 0.58
	SIM Seed-en	
	WER(%) Seed-en	
	SIM	

7.3 编辑

表14总结了我们的编辑任务的客观结果。总体而言，Ming-UniAudio 在广泛的语义和声学操作中展示了强大且多功能的编辑能力。

语义编辑：Ming-UniAudio-Edit 的一个关键特性是它能够基于自然语言指令执行自由形式的语义编辑。由于大多数现有的开源模型缺乏此能力，直接比较是有限的。然而，我们的内部分析揭示了几项关键性能趋势：

- **强大的任务性能：**它在核心任务上取得了高准确率，包括插入任务 **79.31%**（WER=3.89）和替换任务 **76.62%**（WER=4.56）。
- **稳健的泛化能力：**模型显示出对不同指令复杂性的稳健泛化能力，这通过基本版和完整版之间一致的表现得以证明。
- **语言和任务变化：**中文任务的性能持续优于英文，很可能由于更大、更高质量的训练集。在语义任务中，插入产生了最低的WER，受益于更连贯的训练目标。

声学编辑：它在语音转换任务中表现出色，特别是在方言转换中取得了高风格一致性和语义稳定性，同时在音量和速度改变方面也取得了强劲的结果。相比之下，音高改变对说话人相似度提出了挑战，可能由于目标数据

质量。在 DNS Challenge 测试集 (Reddy et al., 2020) 上，其 DNSMOS 分数（3.26 OVRL）与通用模型和专用方法相比具有很强的竞争力，验证了我们的统一方法。

表14 Ming-Freeform-Audio-Edit 上的性能比较。最佳结果以粗体显示。

数据集 模型 性能			
删除-基本	插入-基本	替换-基本	DNS Challenge 模型类型 DNSMOS
删除-完整 Ming- UniAudio WER(%)	插入-完整 Ming- UniAudio WER(%)	替换-完整 Ming- UniAudio WER(%)	OVRL DNSMOS SIG DNSMOS BAK
zh en	zh en	zh en	FullSubNet Hao et al.
11.89 14.85	3.42 6.63	4.52 8.99	(2021) 2.93 3.05 3.51 Inter-Subnet Chen
22.92 27.60 ACC	3.89 7.592 ACC	4.56 7.64 ACC zh	et al. (2023) 2.98 3.17 3.15 CDiffUSE Lu
zh en	zh en	en	et al. (2022) 2.84 3.57 3.52 SGMSE
100 82.22	80 71.43	78.62 59.78	Richter et al. (2023) 3.11 3.47 3.41
82.92 85 SIM zh	79.31 62.31 SIM	76.62 65.62 SIM	StoRM Lemerancier et al.
en	zh en	zh en	(2023) 3.15 3.54 3.69 GenSE Yao et al.
0.78 0.76	0.83 0.79	0.82 0.78	(2025) 3.43 3.65 4.18 MiMo-Audio
0.81 0.74 no-edit	0.83 0.79 no-edit	0.83 0.77 no-edit	Xiaomi (2025) 3.30 3.56 4.10 Ming-
WER(%) zh en	WER(%) zh en	WER(%) zh en	UniAudio 3.26 3.59 3.97
11.49 24.26	3.52 17.70	4.63 19.28	
17.50 35.21	4.10 18.84	4.75 18.39 方言转	
		换 Ming-	
		UniAudio WER(%)	
		8.93 ACC	
		0.50 SIM	
		0.66 速度改	
		变 Ming-	
		UniAudio WER(%)	
		zh en	
		5.88 17.53 SIM zh	
		en	
		0.66 0.57 RDE(%)	
		zh en	
		6.36 5.92 音高改	
		变 Ming-	
		UniAudio WER(%)	
		zh en	
		7.45 13.37 SIM zh	
		en	
		0.36 0.24 音量改	
		变 Ming-	
		UniAudio WER(%)	
		zh en	
		1.71 1.35 SIM zh	
		en	
		0.86 0.80 RAE(%)	
		zh en	

14.9 | 11.7 添加声

音|Ground Truth

Ming-

UniAudio|WER(%)

3.68

3.59 SIM

-

0.78 DNSMOS

OVRL

2.12

2.46

8 结论

通过对音频分词器进行多阶段训练，涵盖重建、特征蒸馏和语义蒸馏，我们为语音理解和生成开发了一个连续的联合表示。在联合训练任务中，我们的模型取得了与领先开源模型相当的性能，特别是在语音生成的语义稳定性方面达到了最先进的（SOTA）结果。

9 未来工作

本报告概述了我们的技术方法和初步结果。以下，我们总结了计划在不久的将来进行的几个方向。

语义蒸馏：改进大语言模型蒸馏以增强理解性能。 **指令跟随生成：**我们认为这一能力是实现更高级的通用基于指令的语音编辑的关键先决条件。 **更多模态：**集成图像和视频模态以实现多模态理解和生成。

10 贡献者

作者按名字字母顺序排列。

Ant Inclusion Al Jingdong Chen Xuezhi Wang Canxiang Yan Jun Zhou Yi Yuan Chunxiang Jin Kaimeng Ren Yifei Wu Dawei Huang Ming Yang Yongjie Lyu Haibing Yu Mingxue Yang Zhengyu He Han Peng Qiang Xu Zhihao Qiu Hui Zhan Qin Zhao Zhiqiang Fang Jie Gao Ruijie Xiong Ziyuan Huang Jing Peng Shaoxiong Lin