

好的，这是根据你提供的MMEDIT论文PDF翻译的中文版本。我已严格按照要求，去除了参考文献部分，并完整保留了原文的结构、所有内容、公式、表格和图表示意，其中“token”一词根据指示未作翻译。

# MMEDIT: 基于音频语言模型的多类型音频编辑统一框架

Ye Tao<sup>1,2</sup>, Wen Wu<sup>2</sup>, Chao Zhang<sup>2</sup>, Mengyue Wu<sup>1</sup>, Shuai Wang<sup>3</sup>, Xuenan Xu<sup>1,2</sup><sup>1</sup> 人工智能教育部重点实验室, X-LANCE实验室, 上海交通大学  
<sup>2</sup> 上海人工智能实验室 <sup>3</sup> 南京大学

**摘要**——文本引导的音频编辑需要在严格保留非目标内容的同时修改特定的声学事件。尽管最近取得了进展，现有方法仍然存在根本性局限：大多数方法局限于基本操作（例如，添加和移除），而现实场景则需要更广泛的任务。此外，该范式中的标准架构通常将文本和音频处理解耦，限制了模型将指令与特定声学上下文对齐的能力。为克服这些约束，我们提出了MMEdit，一个由ALM驱动的统一音频编辑框架。我们系统地扩展了任务定义，以涵盖全面的操作范围，包括添加、替换、移除、重排序和属性修改。此外，我们构建了一个可扩展的合成流程，以生成具有细粒度事件级标注的大规模配对数据。为捕获复杂的编辑语义，我们将Qwen2-Audio编码器与基于MMDiT的生成器集成，实现了精确的跨模态对齐和局部编辑。实验表明，我们的方法在编辑定位准确性、稳健的指令遵循以及未编辑区域的高保真度方面均表现优越。项目页面可通过 Project Page 访问。

**索引词**——音频编辑，扩散模型，多模态模型

## I. 引言

随着生成式建模的快速发展，现代文生音频（TTA）系统[1]-[3]现在能够从自然语言提示中生成高保真、多样化且与文本对齐的声音。与从头合成音频的TTA不同，文本引导的音频编辑（TTE）旨在根据用户提供的文本指令修改现有音频信号的特定区域，同时保持其余内容不变[4]。这种范式为用户提供了一种更直观、更高效的方式，通过自然语言实现对音频内容的细粒度控制，而不是依赖手动波形编辑或专家后处理。自从AUDIT[4]引入该任务以来，音频编辑已吸引了越来越多的研究兴趣[5]-[8]。

现有TTE研究大致可分为免训练和基于训练两类范式。免训练方法通常通过反转去噪过程来适配预训练的基于扩散的TTA模型，以重建潜在噪声并在新的文本条件下重新生成音频。PPAE[5]和AudioEditor[7]是代表性方法。尽管无需额外训练，但这些方法严重依赖扩散反转，导致推理成本高，并且对完整描述或手工掩码有很强的依赖，限制了它们对复杂编辑任务的适用性。关键的是，反转和后续再生成的机制可能会损害对原始结构和细粒度细节的保真度。

相比之下，基于训练的框架显式地对配对数据中学习指令条件生成模型。AUDIT[4]通过训练潜在扩散模型开创了这一范式。Paissan等人[8]探索了嵌入空间中的提示插值和微调，而RFM-Editing[9]引入了修正流匹配以提高效率。与免训练反转相比，这种范式提供了更好的保真度和更快的推理速度。

尽管取得了这些进展，音频编辑的进展在数据资源和模型设计两方面都面临挑战。在数据方面，真实编辑对很少可用，因此现有研究依赖小规模或手动合成的数据集来模拟编辑操作[4], [7]。然而，先前的合成流程通常采用简单的混合策略，事件级可控性有限，导致仅覆盖基本编辑类型（即添加和移除），因此无法反映全面的现实操作范围。缺乏开放且统一的基准进一步加剧了挑战，导致不同研究之间的评估不一致和可重复性有限。在模型设计方面，大多数现有工作依赖纯文本编码器来处理指令。文本指令和源音频之间的交互仅限于生成模型中的交叉注意力机制。然而，在复杂的音频场景中，精确编辑特定事件不仅需要解释指令，还需要在源音频中定位该事件，而纯文本语义编码器固有的缺乏这种能力。因此，这种解耦的、后期融合的设计通常不足以实现对复杂编辑指令的上下文感知理解。

为解决这些局限性，我们提出了MMEdit，一个由音频语言模型驱动的统一框架，用于通用的、遵循指令的音频编辑。首先，我们系统地将编辑范围扩展到六种代表性操作：添加、移除、替换、响度调整、重排序和速度修改，以更好地适应现实应用。我们由此开发了一个可扩展的流程，生成了超过一百万个训练样本，并提炼出一个高质量、人工验证的评估基准。尽管某些操作可以通过单事件音频中的信号处理工具实现，但现实声景中的事件重叠使得事件特定的编辑变得困难。因此，我们将它们整合到一个统一的编辑模型中，以学习跨操作的共享音频编辑能力。此外，MMEdit利用音频语言模型（ALM）来联合处理指令和音频内容。这种统一处理实现了精确的跨模态对齐，使模型能够在特定的声学上下文中精确解释指令。ALM编码器与基于MMDiT[10]的生成器集成，以生成高保真音频。我们的主要贡献总结如下：

**全面的任务定义：**我们系统地将编辑范围扩展到涵盖六种代表性操作，更好地反映现实需求。

**可扩展的数据流程和统一的基准：**我们开发了一个合成生成流程，可生成具有细粒度事件级标注的大规模配对数据。为促进可重复性，我们首次建立并开源了一个TTE评估基准。

**ALM驱动的架构和优越的性能：**MMEdit将ALM编码器与MMDiT相结合，增强了模型理解复杂编辑指令以进行精确编辑的能力。大量实验表明，MMEdit在遵循编辑指令和保持未编辑内容完整性方面显著优于现有基线。

## II. 数据流程

为促进可扩展的训练和评估，我们构建了一个包含超过一百万个音频编辑对的大规模合成数据集。每个对表示为一个三元组（指令，源音频，编辑后音频）。构建流程如图1所示，包括三个阶段：片段策展、音频合成和指令合成。

### A. 音频片段策展

现有的TTE研究（如AUDIT）通常通过组合整个音频片段及其完整的全局描述来合成训练对。然而，为了实现更精确和可解释的编辑（例如指定事件时间和出现次数），需要更细的粒度。我们首先在音频-描述语料库AudioCaps[11]上执行事件级分割和定位。具体来说，受AudioTime[12]启发，我们使用LLM将每个描述分解为单事件描述。然后，这些描述由文本到音频定位（TAG）模型[13]进行时间戳标注以确定事件边界，仅保留非重叠的片段并裁剪为基本音频单元用于后续合成。最后，为保证语义对齐，我们计算文本标签和提取片段之间的CLAP分数[14]，并丢弃相似度分数低于0.3的对。

为模拟具有丰富上下文变化的真实场景，我们将音频组件分为前景（F）和背景（B）声音。前景片段通常由来源于我们策展片段和AudioTime数据集的短时声学事件组成。相反，背景片段来源于全长AudioCaps录音和长时长区间，捕获持续的环境上下文。这种区分提供了对事件空间和语义层次结构的显式控制，为以下编辑任务定义奠定了基础。

## B. 编辑任务定义与合成

在解耦的前景和背景组件的基础上，我们系统地定义了六种代表性编辑操作，以模拟现实世界的声学操作。我们将每种操作表述为应用于前景和背景流的变换函数，由参数控制。

图1：构建流程和示例。(1) 使用TAG模型和CLAP过滤从AudioCaps中提取干净的事件级片段；(2) 模拟前景-背景合成并记录元数据；(3) 为每个编辑任务生成基于模板的指令。

1. **添加**：此任务将新的声学元素引入现有音频片段。它涵盖三种典型设置： $(B \rightarrow F + B)$ ， $(F \rightarrow F + B)$  和  $(F + B \rightarrow F + F' + B)$ 。这些变体捕获了现实音频中常见的合成模式。

在我们的符号中， $F_n$  表示第  $n$  个前景事件，而  $F'$  和  $B'$  分别表示新的前景和背景组件。为在技术上实现这些合成过程，我们利用Scaper工具包[15]进行可编程声景合成和增强。这允许对信噪比（SNR）、事件时序和动态混合进行精确控制。这种统一公式在每个类别内容纳了多种子类型，为多样化的音频编辑场景提供了一个灵活且可扩展的框架。

2. **移除**：此任务移除特定的声音组件，同时保留音频的其余部分。它包括移除局部化的前景或背景事件： $(F + B \rightarrow B)$ ， $(F + B \rightarrow F)$ ， $(F + F' + B \rightarrow F + B)$ 。
3. **替换**：此任务将目标声音事件替换为另一个，同时保持其在原始音频片段中的时间出现： $(F + B \rightarrow F' + B)$  或  $(F + B \rightarrow F + B')$ 。
4. **重排序**：此任务改变多个事件的时间顺序，而不改变其内容： $(F_1 + F_2 \rightarrow F_2 + F_1)$  和  $(F_1 + F_2 + B \rightarrow F_2 + F_1 + B)$ 。
5. **响度调整**：此任务调节选定事件源的相对幅度以模拟强调或衰减，同时保持所有其他属性不变： $(F + B \rightarrow F' / \downarrow + B)$ 。
6. **速度修改**：此任务调整声音事件的播放速度，同时保持所有其他属性不变： $(F + B \rightarrow F \times \alpha + B)$ ，其中缩放因子  $\alpha$  控制速度。

鉴于音频编辑指令的结构化性质，我们为每种编辑类型设计了多样的提示模板，纳入了用于事件类型、时间戳和出现次数等可变参数的特异性槽位。然后，我们通过用细粒度元数据填充这些槽位来构建相应的文本指令，以模拟真实的用户命令。通过扩展此流程，我们构建了一个包含超过一百万个三元组的大规模训练语料库，总计约2500小时的音频。为确保可靠的评估标准，我们通过严格的筛选和人工验证进一步策展了一个高质量的基准。我们将此基准和生成流程公开，以促进可重复的研究和公平的比较。每个编辑任务的详细统计信息见表。

## III. MMEDIT

在本节中，我们介绍MMEdit，一个为遵循指令的音频编辑设计的通用框架。与先前依赖交叉注意力来桥接模态的解耦设计不同，MMEdit集成了一个ALM来联合处理指令和音频以实现深度对齐，并结合一个基于MMDiT[10]的主干进行高保真生成。这种设计实现了更精确的跨模态对齐，使模型能够在特定的声学上下文中解释指令。如图2所示，MMEdit由三个主要组件组成：用于潜在音频表示的波形变分自编码器（VAE）[16]、用于跨模态理解的基于音频语言模型（ALM）的编码器，以及在潜在空间中进行生成的基于MMDiT的主干。

表 I MMEDIT 数据统计。跨编辑任务的训练样本和基准分布。

划分|添加|移除|替换|重排序|响度|速度 训练|260k|230k|250k|150k|100k|100k 基准|700|500|300|500|300|200

### A. 多模态理解

通用编辑能力的关键在于模型深入理解源音频内容和文本指令之间交互的能力。我们没有依赖纯文本编码器（例如T5）进行指令理解，而是使用Qwen2-Audio[17]作为多模态编码器，以获得更具代表性的语义特征来引导编辑。Qwen2-Audio可以联合处理源音频  $\mathbf{x}_{in}$  和指令  $\mathbf{y}$ ，产生固有的跨模态对齐表示：

$$\mathbf{H} = \mathcal{E}_{\text{Qwen}}(\mathbf{x}_{in}, \mathbf{y}) \in \mathbb{R}^{L_q \times D_q}. \quad (1)$$

从H中，我们导出两个互补的条件信号：

- **全局上下文**： $\mathbf{c}_{\text{global}} = \text{AvgPool}(\mathbf{H})$ ，总结编辑的整体意图。
- **细粒度特征**： $\mathbf{H}_{\text{seq}} = \mathbf{H}$ ，提供事件级时间线索，使主干能够通过联合注意力执行精确定位。

这种双粒度条件，受MMDiT启发，受益于提供全局摘要和细粒度局部细节作为互补的条件信号。

图2：所提出的MMEdit框架的整体架构。该模型利用强大的Qwen2-Audio进行音频和指令的联合理解，生成高层多模态表示H。然后，MMDiT主干在以H和源音频潜在  $z_{in}$  为条件的情况下，从高斯潜在预测音频潜在  $z_0$ 。最后，VAE解码器将  $z_0$  转换为编辑后的音频。

### B. MMDiT 主干架构

为在复杂的多模态引导下有效处理复合输入，我们基于Stable Diffusion 3中提出的MMDiT架构构建，并通过允许音频潜在与多模态指令嵌入H交互来将其适配于音频编辑。

1. **通过自适应调制的全局条件**：来自ALM的全局上下文  $\mathbf{c}_{\text{global}}$  与扩散时间步  $t$  融合。得到的向量在每个Transformer块之前通过自适应层归一化（AdaLN）[18]调制整个网络，作为生成的全局语义引导。

2. **MMDiT块设计**: 主干由堆叠的  $N_{\text{joint}}$  个联合块和随后的  $N_{\text{single}}$  个单一块组成。在每个联合块中, 音频潜在和多模态指令嵌入沿序列维度拼接, 并由共享的自注意力层处理。这种联合注意力机制使音频潜在能够直接关注指令嵌入, 实现事件级的、文本引导的编辑。在联合块之后, 单一块仅使用自注意力在音频潜在内部操作。单一块专注于细化时间连续性和频谱连贯性, 确保编辑后的音频在声学上保持自然, 并且未编辑区域以高保真度保留。

## C. 用于音频编辑的潜在扩散

给定一个编辑对, 我们将源波形表示为  $x_{in}$ , 目标波形表示为  $x_0$ 。两者都被映射到预训练VAE的潜在空间中, 该VAE直接对原始波形进行操作:

$$z_{in} = \mathcal{E}_{VAE}(x_{in}), \quad z_0 = \mathcal{E}_{VAE}(x_0) \in \mathbb{R}^{C \times L}, \quad (2)$$

其中  $\mathcal{E}_{VAE}$  是预训练VAE的编码器。

在训练期间, 我们遵循标准的DDPM[19]公式。对于随机采样的时间步  $t \in \{1, \dots, T\}$ , 目标潜在  $z_0$  的带噪版本  $z_t$  通过下式获得:

$$z_t = \sqrt{\bar{\alpha}_t} z_0 + \sqrt{1 - \bar{\alpha}_t} \epsilon, \quad \epsilon \sim \mathcal{N}(0, I), \quad (3)$$

其中  $\bar{\alpha}_t$  是前向扩散系数  $\alpha_t$  的累积乘积, 这些系数构成噪声时间表, 指定每个扩散步骤中保留了多少信号。

编辑的一个关键困难是仅修改请求的事件, 同时保持输入音频的其余结构。为向去噪器暴露未编辑的参考, 我们沿通道维度将带噪潜在与源音频潜在在拼接:

$$\tilde{z}_t = z_t \oplus z_{in} \in \mathbb{R}^{2C \times L}, \quad (4)$$

其中  $\oplus$  表示通道级拼接。MMDiT主干随后预测速度:

$$\hat{v} = v_{\theta}(\tilde{z}_t, t, \mathbf{c}_{global}, \mathbf{H}_{seq}), \quad (5)$$

其中

$$v = \sqrt{\bar{\alpha}_t} \epsilon - \sqrt{1 - \bar{\alpha}_t} z_0, \quad \epsilon \sim \mathcal{N}(0, I). \quad (6)$$

我们使用速度预测目标训练模型:

$$\mathcal{L}_{diff} = \mathbb{E}_{z_0, \epsilon, t, z_{in}} [\|v - v_{\theta}(\tilde{z}_t, t, \mathbf{c}_{global}, \mathbf{H}_{seq})\|_2^2]. \quad (7)$$

在训练期间, 文本指令被随机掩码以学习无条件生成, 而源音频潜在始终馈送给模型。在推理期间, 我们使用DDIM[20]采样器和无分类器引导, 其中引导的噪声估计公式为  $\tilde{\epsilon} = \epsilon_{uncond} + w(\epsilon_{cond} - \epsilon_{uncond})$ 。最后, VAE解码器将去噪后的潜在转换为编辑后的音频。

## IV. 实验

### A. 训练设置

MMEdit在第II节介绍的合成编辑对以及从AudioCaps构建的额外文生音频风格对上训练。在初步实验中, 我们观察到混入TTA数据(从无编辑的描述生成)能显著提高编辑输出的感知质量。在整个训练过程中, Qwen2-Audio编码器和VAE保持冻结, 而MMDiT主干使用AdamW优化器训练80个epoch。

### B. 基线与评估

我们将MMEdit与两个代表性的音频编辑系统AUDIT和AudioEditor进行比较, 因为它们是唯一与我们设置相似的公开可用模型。注意, 两者仅支持添加、移除和替换操作。由于AudioEditor操作于源-目标描述对, 我们将每个编辑指令重写为完整的句子目标描述, 以符合其要求的输入格式。为全面评估性能, 我们报告合成对上的基于参考的客观指标, 以及真实录音上的基于平均意见分数(MOS)的主观指标。

- 客观评估**: 在合成测试集上, 我们报告对数谱距离(LSD)、Fréchet音频距离(FAD)、Fréchet距离(FD)和KL散度, 以测量频谱和分布差异, 同时报告Inception Score (IS) [2]以评估感知质量和多样性。
- 主观评估**: 为减轻合成数据中潜在偏差, 我们在60个真实AudioCaps录音的策展子集上进行了听力测试, 并配以手动设计的指令。由于没有可用的真实编辑后音频, 我们依赖人类判断。对于所有任务, 我们邀请十位大学水平的评分者按照明确的指示进行主观评分。每个编辑样本在1-5李克特量表上沿两个维度进行评分: 相关性(R-MOS), 衡量系统遵循编辑指令的准确程度; 以及保真度(F-MOS), 衡量原始音频中未编辑区域的保持程度, 且不引入非预期的伪影或失真。

表II 定量比较。我们报告合成测试集上的客观指标(LSD, FAD, FD, KL, IS)和真实录音上的主观MOS评分。↓表示越低越好, 而↑表示越高越好。注意 AudioEditor 和 AUDIT 不支持重排序、响度或速度操作。

编辑类型|模型|LSD ↓|FAD ↓|FD ↓|KL ↓|IS ↑|R-MOS ↑|F-MOS ↑

|                                                     |                                                |                                                    |                                               |                                                   |                                              |
|-----------------------------------------------------|------------------------------------------------|----------------------------------------------------|-----------------------------------------------|---------------------------------------------------|----------------------------------------------|
| 添加                                                  | AUDIT 1.96 22.65 224.57 32.07 35.05 0.279 2.67 | 移除                                                 | AUDIT 3.43 24.13 830.46 2.45 64.67 2.84 1.82  | 替换                                                | AUDIT 2.85 3.14 528.12 2.20 93.60 2.84 3.75  |
| AudioEditor 1.98 23.12 523.35 1.99 310.49 2.79 3.25 | MMEdit 1.61 40.82 615.53 1.24 78.34 4.34 4.09  | AudioEditor 3.78 5.74 731.37 2.01 310.02 2.70 2.70 | MMEdit 2.89 60.67 813.08 0.69 09.18 3.90 4.30 | AudioEditor 2.62 2.83 431.99 1.76 47.90 2.70 2.70 | MMEdit 2.56 0.94 619.06 1.76 06.08 3.73 4.19 |
|                                                     |                                                |                                                    |                                               | 重排序                                               | MMEdit 2.35 3.07 91.32 8.39 1.63 81.3 4.40   |
|                                                     |                                                |                                                    |                                               | 响度                                                | MMEdit 1.31 0.44 78.52 0.25 26.32 4.43 4.35  |
|                                                     |                                                |                                                    |                                               | 速度                                                | MMEdit 1.20 0.47 98.63 0.27 35.57 3.88 4.18  |

### C. 主要结果与分析

表II总结了在所有任务的合成测试集上的定量结果。在所有模型都支持的三个任务中，MMEdit除IS外一致取得了最佳结果，表明编辑后的输出更接近真实目标。相比之下，AUDIT显示出明显更高的距离和散度值，表明样本保真度下降，与真实值的对齐较弱。AudioEditor取得了最高的IS，而MMEdit达到了略低但有竞争力的值，AUDIT则落后于两者。这一结果是预期的，因为AudioEditor作为一个基于反转的框架运行，建立在TTA生成主干之上。由于每个编辑操作都需要触发主干的完整生成过程，它固有地促进了再合成的更多样性，从而产生更高的IS。相反，这种对整体再生成的依赖解释了其在面向相似度的指标上表现较差的原因，表明与MMEdit相比，其保持源音频未编辑内容的能力有所降低。

如表II详细所示，在真实AudioCaps片段上的主观结果也证实了MMEdit的优越性。MMEdit在R-MOS上持续得分高于3.7，表明其强大的指令遵循能力。这一优势在F-MOS上更为明显，其中MMEdit展示了卓越的未编辑区域保持能力。这一结果通过针对两个基线的配对  $t$  检验 ( $p < 0.001$ ) 进一步验证。值得注意的是，尽管IS很高，AudioEditor获得了明显较低的主观分数，表明其为最大化多样性而进行了更激进的修改，代价是破坏了未编辑内容。

此外，MMEdit通过执行重排序、响度和速度调整等复杂操作展示了稳健的泛化能力——这些任务现有基线无法支持。这些结果决定性地突显了我们框架的优越性：与先前工作相比，MMEdit在分布保真度和生成多样性之间实现了更有利的平衡。

D. 消融研究

我们研究了ALM编码器、扩散主干架构和无分类器引导策略[21]的各自贡献。

1. **ALM编码器的影响：**为评估多模态ALM的关键作用，我们通过将Qwen2-Audio编码器替换为纯文本编码器（Flan-T5[22]）进行消融研究，保持其他组件不变。如表III所示，尽管纯文本变体 ( $w/T5$ ) 取得了更高的IS，但保真度指标的下降表明纯文本编码器无法捕获源音频的复杂声学线索。相比之下，Qwen2-Audio通过联合编码指令和源音频贡献了更丰富的跨模态信息，使得比纯文本编码器更准确和感知连贯的编辑成为可能。
2. **主干架构的影响：**我们进一步评估了我们的MMDiT主干相对于普通DiT变体（记为  $w/DiT$ ）的优势。该变体采用标准的DiT结构，仅通过交叉注意力层注入  $\mathbf{H}$ 。如表III所示，该变体在所有指标上均不及完整的MMEdit框架。这一结果表明，基于浅层交叉注意力的条件可能无法充分利用多模态条件。相反，MMDiT主干通过其联合注意力机制提供了一种更有效的方式来整合这些线索。

表 III 指令编码器和生成主干的消融研究。

|    |    |    |     |     |     |        |        |       |        |        |        |        |      |        |        |        |        |        |      |             |        |        |        |        |      |
|----|----|----|-----|-----|-----|--------|--------|-------|--------|--------|--------|--------|------|--------|--------|--------|--------|--------|------|-------------|--------|--------|--------|--------|------|
| 方法 | 客观 | 主观 | FD↓ | KL↓ | IS↑ | R-MOS↑ | F-MOS↑ | w/ T5 | [6.29] | [1.25] | [9.10] | [3.36] | 3.63 | w/ DiT | [4.77] | [1.08] | [8.72] | [3.80] | 4.05 | MMEdit (完整) | [4.72] | [0.83] | [8.83] | [4.05] | 4.23 |
|----|----|----|-----|-----|-----|--------|--------|-------|--------|--------|--------|--------|------|--------|--------|--------|--------|--------|------|-------------|--------|--------|--------|--------|------|

图3. 引导尺度和条件掩码的影响。

3. **引导尺度和条件掩码的分析：**我们最后研究了无分类器引导（CFG）尺度  $w$  以及训练无条件生成的掩码策略的影响。一个关键的设计选择在于训练无条件生成的策略。我们探索了两种策略：（1）掩码音频：同时丢弃文本指令和源音频潜在；（2）无掩码音频：仅丢弃文本指令，同时保留源音频潜在。

如图3所示，无掩码在所有方面都显著优于掩码。其理论依据是，与纯生成不同，编辑任务要求保持源音频的底层结构。通过在不条件分支中保留源潜在，引导方向被驱动为聚焦于文本指定的语义修改，而不是从头重建音频。结果表明，过大的尺度会过度扭曲源音频，而太小的尺度则导致编辑不足。尺度  $w = 5.0$  在保持和编辑强度之间实现了最有利的权衡。

V. 结论

在本文中，我们提出了MMEdit，一个由ALM驱动的框架，专为通用的文本引导音频编辑而设计。通过构建具有细粒度事件级标注的可扩展合成流程，我们系统性地编辑范围扩展到涵盖六种不同的任务。我们提出的架构协同了Qwen2-Audio多模态编码器与基于MMDiT的主干，有效地弥合了高层语义理解与精确声学操作之间的差距。大量实验表明，MMEdit显著优于现有基线，在保持未编辑区域高保真度的同时，实现了优越的指令遵循和编辑定位。然而，在生成多样性和细粒度时间对齐方面仍存在局限性，特别是对于复杂的重叠事件，我们将此留作未来的工作。我们希望这项工作能为未来音频编辑系统的研究提供一个坚实且可重复的基础。