

好的，这是根据你提供的UNISON论文PDF翻译的中文版本。我已严格按照要求，去除了参考文献部分，并完整保留了原文的结构、所有内容、公式、表格和图表示意，其中“token”一词根据指示未作翻译。

UNISON: 通过深度LLM融合的统一声音生成与编辑框架

Zhaoqing Li¹, Haoning Xu¹, Jingran Su², Yaofang Liu³, Zhefan Rao⁴, Huimeng Wang¹, Jiajun Deng¹, Tianzi Wang¹, Zengrui Jin⁵, Rui Liu⁶, Haoxuan Chi^{4*}, Xunying Liu¹¹ 香港中文大学, ²香港理工大学, ³香港城市大学, ⁴香港科技大学, ⁵清华大学, ⁶华为香港研究院 {zqli, xyliu}@se.cuhk.edu.hk

摘要

我们提出了UNISON，一个潜在的扩散框架，在单一模型中统一了语音生成、声音生成和音频编辑。单个模型处理文生音频、文语转换、零样本说话人克隆、混合语音与声音生成、场景级音频编辑、场景内语音编辑以及定时时间组合，所有这些任务共享同一组权重。我们的架构具有两个核心设计：（1）逐层深度LLM融合，通过学习的投影将冻结的MLLM中均匀采样层的隐藏状态注入到对应的MM-DiT块中，提供深度匹配的语义条件，相比于单层基线提高了指令遵循能力；（2）一个统一的多任务架构，其中任务身份仅通过通道级掩码编码，源音频通过VAE编码的通道拼接提供。训练通过一个在线的GPU端多任务数据合成流程以及任务同质化批处理和两阶段课程来稳定。凭借621M-732M的可训练参数，UNISON在评估领域取得了与任务专家模型竞争或超越的结果，同时比类似的统一系统小约4×。音频样本可在以下网址获取：

<https://lizhaoqing.github.io/UNISON-demo/>

1 引言

一个实用的音频生成系统应处理多样化的任务：从文本描述生成音效，以目标说话人的声音合成清晰的语音，从录音中插入或移除特定的声学事件，以及按时间结构组成声景。目前，这些任务通常由在孤立数据集上使用不同条件流程训练的专门模型来处理。这种碎片化增加了部署复杂性，并阻止了跨任务知识迁移——特别是在生成和编辑之间，它们的主要区别在于是否存在源信号。

图1: UNISON概览。单个流匹配模型处理文生音频、零样本文语转换、性别控制、音频场景编辑和定时时间组合。所有任务共享相同的架构和权重，仅通过任务掩码通道和可选的源潜在在拼接来区分。

近期工作已朝着统一系统发展。AudioBox (Vyas et al., 2023) 通过带上上下文掩码的流匹配统一了语音和声音生成。MMAudio (Cheng et al., 2025) 使用MM-DiT主干在视频-音频和文本-音频数据上进行了联合训练。AudioOmni (Tian et al., 2026) 将任务覆盖扩展到包括编辑和多领域合成，而UniSonate (Qiang et al., 2026a) 通过音素驱动的MM-DiT统一了TTS、音乐和音效生成。尽管取得了这些进展，两个基本限制仍然存在：（1）由于任务特定的辅助模块导致的不一致的潜在空间。尽管这些系统旨在统一，但大多数仍然依赖异构组件来处理不同任务——用于参考音频的独立梅尔编码器，用于TTS的专用音素前端，用于编辑与生成的单独条件流，或专用的时长预测器。这些辅助模块碎片化了潜在空间：每个任务都在一个略有不同的表征机制中运行，限制了跨任务知识迁移并使训练流程复杂化。一个真正统一的系统应该将所有任务路由通过相同的编码器、相同的潜在空间和相同的前向传递，任务身份被最小程度地编码。（2）丢弃层次化语义的浅层文本条件。大多数现有系统的一个共同设计选择是在生成主干上以单层文本表征（通常是T5、CLAP或MLLM的最终隐藏状态）为条件，该表征被相同地馈送到所有DiT层。对Transformer语言模型的探测研究表明，表征是按层次组织的：较低层主要编码词汇和句法信息，而较高层捕获更抽象的语义内容 (Tenney et al., 2019; Clark et al., 2019)。仅将最终层嵌入馈送到生成模型会丢弃这种层次结构，可能限制了对组合复杂的音频提示（同时指定说话人属性、声学事件和时间结构）的指令遵循能力。

为解决这些问题，我们提出了UNISON，其贡献如下：

一个统一的生成与编辑多任务架构，带有高效的在线训练流程。我们设计了一个架构，其中所有任务（包括语音和声音的生成与编辑）共享完全相同的VAE、DiT主干和前向传递。任务身份由与音频潜在在拼接的单个掩码通道编码；源/参考音频通过与目标相同的冻结VAE提供。我们构建了一个在线的GPU端数据合成流程，通过任务同质化批处理和两阶段课程即时构建所有任务变体，使得在一个模型内实现生成和编辑目标的稳定联合训练成为可能。

用于增强指令遵循的逐层深度LLM融合。我们将冻结的Qwen2.5-Omni-7B文本主干中均匀采样层的隐藏状态，通过学习的线性投影注入到对应的MM-DiT双流块中。这提供了深度匹配的条件。具体来说，早期的DiT块接收编码词汇和音韵结构的浅层LLM表征，而后期的块处理更抽象的语义特征。这种层次化对齐提高了跨任务的文本遵循能力（在消融实验中验证，§4.4）。

对多样化音频任务的全面评估。我们在跨越T2A、TTS、零样本克隆、混合生成、音频编辑、场景内语音编辑和定时合成的多个基准上评估UNISON，证明单个检查点在所有评估领域上都取得了与任务专家模型相比具有竞争力或更优的结果。

2 相关工作

2.1 音频与语音生成

文本条件的声音生成已收敛于潜在扩散和流匹配 (Lipman et al., 2023; Liu et al., 2023b)。AudioLDM (Liu et al., 2023a) 和AudioGen (Kreuk et al., 2023) 分别率先采用潜在扩散和自回归token建模进行文生音频；AudioLDM 2 (Liu et al., 2024)、Make-An-Audio 2 (Huang et al., 2023)、TangoFlux (Hung et al., 2026)、GenAU (Haji-Ali et al., 2026) 和MMAudio (Cheng et al., 2025) 通过更大的DiT (Peebles and Xie, 2023) 模型、偏好优化或联合视频-音频训练逐步提高质量，但所有这些模型都以单层文本（最终的T5/CLAP/LLM隐藏状态相同地馈送到每个块）为条件。在TTS中，神经解码器语言模型如VALL-E (Wang et al., 2023) 展示了通过上下文学习进行零样本克隆的能力，激发了现代流匹配系统 (F5-TTS (Chen et al., 2025), E2-TTS (Eskimez et al., 2024), MaskGCT (Wang et al., 2025), CosyVoice (Du et al., 2024a,b), ZipVoice (Zhu et al., 2025))，这些系统实现了高质量但仍依赖任务特定的文本前端，如音素编码器、字符编码器或时长预测器。UniSonate (Qiang et al., 2026a) 使用Qwen2.5-7B统一了TTS、T2A和音乐，但仍需要G2P音素和[SFX] token，并且不支持克隆或编辑。

UNISON在三个方面有所不同：(i) UNISON的转录是纯文本LLM指令，而非音素/G2P流程，零样本说话人由与目标相同的冻结VAE编码；(ii) 它馈送逐块投影的LLM隐藏状态，而非单层嵌入，为组合提示提供深度匹配的语义条件；(iii) 它统一了生成和编辑：单个检查点通过任务掩码通道和VAE编码的源潜在在处理T2A、TTS、T2AS、零样本克隆和场景编辑，通过在线多任务流程训练，没有针对每个任务的独立头或反演栈。

2.2 音频编辑

音频编辑范围从词级语音工具 (FluentSpeech (Jiang et al., 2023), EditTS (Tae et al., 2022)) 到混合音频的场景级操作。UNISON聚焦于后者。ZETA (Manor and Michaeli, 2024) 和SDEdit (Meng et al., 2022) 通过DDPM反演或噪声-去噪时间表进行编辑。MMEDIT (Tao et al., 2025) 在合成对上使用带有独立Qwen2-Audio (Chu et al., 2023) 编码器的MM-DiT进行训练。Audio-Omni (Tian et al., 2026) 使用混合MLLM交叉注意力加上用于编辑的梅尔通道。

UNISON将编辑视为条件生成：源音频使用与目标相同的VAE编码，作为由条件掩码指定的通道拼接输入潜在。这避免了反演、辅助梅尔编码器和任务特定解码器，同时在潜在域中保留了频谱细节。

2.3 统一架构与表征融合

UniAudio (Yang et al., 2024) 和AudioBox (Vyas et al., 2023) 分别通过下一token预测和流匹配填充统一了多个任务。最接近的同期系统是AudioOmni (Tian et al., 2026) 和UniSonate (Qiang et al., 2026a)。Audio-Omni (3.05B DiT) 仅通过交叉注意力馈送倒数第二层MLLM层，并通过第二个路由由梅尔/视频，这分离了语义和低级线索，但复制了条件路径；其TTS主要在英语上评估。UniSonate (1.30B) 使用最后一层Qwen特征与音素驱动的MM-DiT，并省略了编辑和基于参考的克隆。如表9（附录A）总结，UNISON (621M-732M) 据我们所知是首个在一个MM-DiT中联合提供逐层深度融合、纯文本双语零样本TTS、场景级编辑和定时合成的模型，无需音素或梅尔侧编码器。

在表征方面，将冻结LLM隐藏状态逐层路由到DiT中改善了文本-图像对齐 (Tang et al., 2025) 并可扩展到大型视觉生成器 (Cai et al., 2025)；BAGEL (Deng et al., 2025) 进一步交错语言和视觉token。音频指令通常比图像描述更具组合性（说话人 + 词汇 + 背景 + 时间戳），使得深度匹配融合特别有益。UNISON是首个将这一原理应用于涵盖生成、克隆和编辑的统一音频模型中的工作。

3 方法

图2和以下小节描述了用于生成、编辑和TTS的架构。冻结模块（VAE，Qwen）提供潜在和文本特征；可训练的DeepFusion MM-DiT预测流匹配速度场。

3.1 概览与符号

端到端流程。对于每个训练样本，我们 (i) 构建文本指令和可选的源波形，(ii) 使用冻结的VAE编码波形以获得 $\mathbf{z}$ （目标）和 $\mathbf{z}_s$ （源/参考），(iii) 采样流时间 t 并形成带噪声目标 $\mathbf{z}_t$ ，(iv) 拼接 $[\mathbf{z}_t \parallel \mathbf{z}_s \parallel \mathbf{m}]$ 并将其嵌入到音频token $\mathbf{h}_0$ 中，(v) 运行冻结的LLM一次并将逐块文本条件 $\tilde{\mathbf{E}}_k$ 馈入可训练的MM-DiT，以及 (vi) 预测速度 v_θ 并反向传播流匹配损失。推理重复步骤 (vi)，使用ODE求解器从噪声开始，然后VAE解码去噪后的潜在。

符号。 C 和 T' 表示VAE潜在通道和帧数； $d = 1024$ 是DiT token维度； D 是双流块的数量； $L = 28$ 是Qwen层数； N 是token级别的指令长度。

符号/形状/含义 $\mathbf{z} [C \times T]$ 干净的目标潜在（要生成的音频） $\mathbf{z}_s [C \times T]$ 源潜在（纯生成为零） $\mathbf{m} [T]$ 每帧任务标签，取值于 $\{0, 1, 2\}$ $\epsilon [C \times T]$ 用于流匹配的高斯噪声 $\mathbf{z}_t [C \times T]$ 流时间 t 处的带噪声目标 $X [(2C+1) \times T]$ DiT通道输入 $[\mathbf{z}_t \parallel \mathbf{z}_s \parallel \mathbf{m}]$ $\mathbf{h}_k [T' \times d]$ 第 k 块后的音频token $\mathbf{E}^{(l)} [N \times 3584]$ 第 l 层Qwen隐藏状态 $\tilde{\mathbf{E}}_k [N \times d]$ 馈给DiT第 k 块的文本token $v_\theta [C \times T]$ 预测速度（仅目标通道）

3.2 音频VAE

我们采用MMAudio连续VAE (Cheng et al., 2025)。波形转换为梅尔频谱图（STFT），然后编码为 $\mathbf{z}$ 或 $\mathbf{z}_s \in \mathbb{R}^{C \times T'}$ ，在 44.1kHz 时 $C = 40$ ，在 16kHz 时 $C = 20$ 。相同的VAE编码目标、编辑源和说话人参考，并在推理时解码去噪后的潜在。

3.3 多任务输入

所有任务共享一个网络；只有 $(\mathbf{z}, \mathbf{z}_s, \mathbf{m})$ 和文本指令发生变化。

任务标签 $\mathbf{m}$ 。每个潜在帧携带一个标量标签（作为 $\mathbf{X}$ 中的一个通道广播）：

$\mathbf{m} = 0$ ：生成（T2A, TTS, T2AS, 定时合成）。 $\mathbf{z}_s = 0$ 。 $\mathbf{m} = 1$ ：编辑。 $\mathbf{z}_s$ 是编辑前混合的VAE潜在； $\mathbf{z}$ 是编辑后的目标。 $\mathbf{m} = 2$ ：零样本文语转换。 $\mathbf{z}_s$ 编码参考前缀；标签区分参考区域和待合成的帧。

每个任务的 $(\mathbf{z}, \mathbf{z}_s)$ 和指令模板的构建总结在表10（附录B）中。

时长。我们使用固定长度的填充潜在，没有单独的时长头；末尾的静音被隐式学习。定时事件在文本中指定并由LLM解析。

图2: UNISON架构。左图：逐层深度LLM融合通过学习的投影器将每层Qwen隐藏状态注入到对应的DiT块中。中图：每个双流块执行联合注意力；每块刷新文本token ($\mathcal{X}$)，而音频token通过MLP。底部： $[\mathbf{z}_t \parallel \mathbf{z}_s \parallel \mathbf{m}]$ 进行通道拼接和嵌入；ODE求解器对潜在在进行去噪，然后由VAE解码为波形。详见§3.4。

3.4 DeepFusion MM-DiT

基于来自§3.3的通道输入 $\mathbf{X}$ ，可训练主干是一个流匹配 (Lipman et al., 2023; Liu et al., 2023b) MM-DiT (Peebles and Xie, 2023; Cheng et al., 2025)，具有逐层深度LLM融合 (Tang et al., 2025)。它将 $(\mathbf{X}, \{\tilde{\mathbf{E}}_k\}, t)$ 映射到目标通道上的速度 v_θ 。默认配置： $D = 20$ 块（记为D20）， $d = 1024$ ，8头。

加噪与通道输入。给定干净的 $\mathbf{z}$ 和噪声 ϵ ，我们采样 σ_t 并设置 $\mathbf{z}_t = (1 - \sigma_t)\mathbf{z} + \sigma_t\epsilon$ 。DiT看到

$$\mathbf{X} = [\mathbf{z}_t \parallel \mathbf{z}_s \parallel \mathbf{m}] \in \mathbb{R}^{(2C+1) \times T'}. \quad (1)$$

一个Conv-MLP嵌入器 $\mathcal{E}$ 将 $\mathbf{X}$ 映射到 $\mathbf{h}_0 \in \mathbb{R}^{T' \times d}$ （每帧一个token）。我们将 $\mathcal{E}$ 中连接 $\mathbf{z}_s$ 和 $\mathbf{m}$ 到token空间的权重零初始化，而 $\mathbf{z}_t$ 使用标准初始化——因此早期训练表现为仅去噪，模型逐渐学习使用源和任务通道。

文本条件（图2中的左分支）。冻结的Qwen2.5-Omni-7B (Xu et al., 2025) Thinker在指令上运行一次，返回 $\mathbf{E}^{(l)}$ ，其中 $l = 1, \dots, L$ 。由于DiT块数 D 可能与 L 不同，我们均匀选取 $i_k = \lfloor 1 + k \cdot \frac{L-1}{D-1} \rfloor$ 以获得

$$\tilde{\mathbf{E}}_k = \mathbf{E}^{(i_k)} \mathbf{W}_k, \quad (2)$$

其中 $\mathbf{W}_k \in \mathbb{R}^{3584 \times d}$ 是对应的线性投影器。这确保了浅层DiT块看到浅层Qwen层（词汇/句法），深层块看到更深的语义 (Tenney et al., 2019)。

双流块（图2中的右分支）。第 k 块接收 $(\mathbf{h}_k, \tilde{\mathbf{E}}_k)$ 。AdaLN注入 t ；联合注意力让所有音频和文本token相互关注。只有 $\mathbf{h}_k$ 被MLP更新以形成 $\mathbf{h}_{k+1}$ 。我们并不将 $\tilde{\mathbf{E}}_k$ 传递到下一块；相反，每个深度从Qwen接收一个新的 $\tilde{\mathbf{E}}_k$ 。因为 $\tilde{\mathbf{E}}_k$ 已经从冻结的LLM编码了丰富的语义，DiT注入语言信息而无需重新学习完整的语言结构。跳过文本MLP也节省了计算。RoPE (Su et al., 2023) 仅应用于 $\mathbf{h}_k$ （索引 $0, \dots, T' - 1$ ）；QK-范数稳定注意力。

输出。一个线性头将 $\mathbf{h}_D$ 映射到 $v_\theta \in \mathbb{R}^{C \times T'}$ （仅目标通道；不预测 $\mathbf{z}_s$ 和 $\mathbf{m}$ ）。

3.5 训练与推理

损失。目标速度 $\mathbf{u} = \epsilon - \mathbf{z}$ ，我们最小化

$$\mathcal{L} = \mathbb{E}_{t, \mathbf{z}, \epsilon} \left[\left\| v_{\theta}(\mathbf{X}, \{\tilde{\mathbf{E}}_k\}, t) - \mathbf{u} \right\|_2^2 \odot \mathbf{M}_{\text{loss}} \right],$$

其中 $\mathbf{M}_{\text{loss}}$ 在零样本TTS中将参考前缀置零，使梯度仅应用于待合成的帧。文本条件以0.1的概率丢弃，用于无分类器引导 (Ho and Salimans, 2021)。

推理。从 $\mathbf{z}_t \leftarrow \epsilon$ 开始，我们使用100步欧拉ODE求解器积分学习到的速度，然后VAE解码去噪后的 $\mathbf{z}$ 为波形。推理时我们使用CFG尺度 $\omega = 4.5$ 。

3.6 在线多任务数据合成

我们不构建每个任务的静态数据集，而是实现了一个GPU端的在线合成流程，从原始音频和语音片段即时构建任务特定的元组。表10（附录B）总结了每个任务如何组装 $\mathbf{z}_s$ 、 $\mathbf{z}$ 和指令模板。该流程处理用于信噪比控制混合的RMS归一化、边界淡入/淡出和随机时间偏移；指令从预定义的模板池中组装。

3.7 带同质化批处理的课程训练

为防止生成和编辑目标之间的梯度冲突，我们采用：

两阶段课程。第一阶段仅在前150K步训练生成任务（T2A、TTS、零样本TTS、T2AS），建立稳定的生成先验。第二阶段引入所有编辑任务，采用完整的任务概率分布（大约70%生成，30%编辑）。

任务同质化批处理。每个小批量包含来自单个任务类型的样本，防止批次内对立目标（例如，“添加事件” vs. “移除事件”）之间的梯度冲突。

4 实验

4.1 实现细节

模型配置。我们训练两个变体：(1) D20 (44kHz)：20个双流块，40个潜在通道，44.1 kHz MMAudio VAE，621M参数；(2) D24 (16kHz)：24个双流块，20个潜在通道，16 kHz MMAudio VAE，732M参数。两者使用相同的冻结Qwen2.5-Omni-7B文本编码器。

训练数据。我们在大约36M个片段（ $\sim 57\text{K}$ 小时；音频2.3M，语音33.7M）的组合语料库上训练；每个数据集详情列于表11（附录C）。

训练配置。AdamW优化器， $\beta_1 = 0.9$ ， $\beta_2 = 0.95$ ，学习率 10^{-4} ，带有余弦衰减和2000步预热，权重衰减0.01，梯度裁剪1.0。在 $8 \times \text{H800}$ 上每GPU批次大小56。BF16混合精度。EMA衰减0.999，每10步更新。CFG丢弃概率0.1。基础模型在最大时长10s上训练；仅对长语音微调至22s。推理细节见 §3.5。

4.2 评估设置

指标。我们使用FAD (VGGish) 和FD (PANNs (Kong et al., 2020)) 评估分布质量；KL散度和IS用于基于分类器的评估；CLAP (LAION-CLAP (Wu et al., 2023)) 用于文本-音频语义对齐；通过Whisper-large-v3 (Radford et al., 2023) (英文) 和Paraformer (Gao et al., 2023) (中文) 的WER/CER评估可懂度；LSD用于评估相对于参考目标的频谱保真度；性别准确率通过基于LibriSpeech微调用于性别识别的wav2vec2-large-XLSR-53 (Conneau et al., 2021)¹ 进行评估；语音移除率通过Siler-VAD (Team, 2024) 评估。

评估数据。对于T2A和TTS，我们使用标准基准：AudioCaps (Kim et al., 2019) 测试集（881个片段）和Seed-TTS (Anastassiou et al., 2024) 测试集（1088英文 + 2020中文）。对于没有公共基准的任务，我们使用固定种子构建评估集：T2AS（600个样本，Seed-TTS语音 + 非语音AudioCaps音效，0dB混合）；音频编辑（1200个，每子任务400个，非语音AudioCaps对，随机信噪比 $\in [-3, 3]$ dB）；场景内语音编辑（600个，每子任务200个，AudioCaps背景 + Seed-TTS语音，10dB混合）；性别TTS（300个，平衡性别分配）；定时合成（150个，2-3段时间线）。表中的“GT CLAP”值表示伪GT相对于其描述的计算CLAP值，作为经验性的真值参考，因为伪GT本身是人工混合的。

基线。T2A：AudioLDM 2 (Liu et al., 2024)、Tango (Ghosal et al., 2023)、Stable Audio Open (Evans et al., 2025)、Make-An-Audio 2 (Huang et al., 2023)、GenAU-L (Haji-Ali et al., 2026)、Audio-Omni (Tian et al., 2026)、MMAudio-L (Cheng et al., 2025)、UniSonate (Qiang et al., 2026a)。TTS：MaskGCT (Wang et al., 2025)、CosyVoice 2 (Du et al., 2024b)、ZipVoice (Zhu et al., 2025)、E2-TTS (Eskimez et al., 2024)、F5-TTS (Chen et al., 2025)、InstructAudio (Qiang et al., 2026b)、UniSonate、Audio-Omni。编辑：SDEdit (Meng et al., 2022)、ZETA (Manor and Michaeli, 2024)、MMEDIT (Tao et al., 2025)、Audio-Omni。TangoFlux (Hung et al., 2026) 因其偏好优化（CRPO）与架构正交而被排除；GenAU-L 被纳入参考，尽管其训练集大 $20\times$ 。

4.3 主要结果

4.3.1 文生音频生成

如表1所示，UNISON D24（16kHz）在可比模型中取得了最佳的FAD（1.558）和CLAP（0.503），而D20（44kHz）获得了最低的FD（15.82）和最高的IS（12.04）。尽管比Audio-Omni（3.05B）和MMAudio-L（1.03B）更小，两者在FAD上均优于它们。低FD和高CLAP分数验证了逐层深度LLM融合对语义对齐的有效性（进一步由表8确认，其中仅L变体显示较低的CLAP）。两个变体展现出互补的优势：D24的更大容量有利于FAD/CLAP，而D20的44.1 kHz VAE更好地保留了FD/IS的频谱细节。GenAU-L取得了更高的CLAP（0.561），但使用了 $20\times$ 更大的音频数据集，并且是一个没有编辑或TTS能力的单任务模型。

表1: AudioCaps (Kim et al., 2019) 测试集（881个片段）上的文生音频结果。GT CLAP = 0.526，GT IS = 11.25。标记†的模型使用明显更大的训练数据或偏好优化。

模型\架构\参数\FAD↓\FD↓\KL↓\IS↑\CLAP† AudioLDM 2-Large\UNet\712M\3.09\729.68\1.490\7.98\0.452 Tango\UNet\866M\1.84\624.52\1.305\7.45\0.498 Stable Audio Open\DiT\1.06B\10.83\52.03\3.049\6.13\0.203 Make-An-Audio 2\DiT\937M\2.14\220.14\1.597\10.02\0.441 GenAU-L†\DiT\1.25B\1.59\118.41\1.290\11.94\0.561 Audio-Omni\DiT\3.05B\2.53\31.42\1.337\9.55\0.486 MMAudio-L\MM-DiT\1.03B\5.89\316.53\1.421\11.98\0.441 UniSonate\MM-DiT\1.34B\4.21\30.21\2.440\8.22\ UNISON (D24, 16kHz)\MM-DiT\732M\1.558\16.28\1.459\10.90\0.503 UNISON (D20, 44kHz)\MM-DiT\621M\1.756\15.82\1.455\12.04\0.467

4.3.2 文语转换

如表2所示，UNISON (D24) 在所有设置中实现了最低的错误率：纯WER 1.27%（英文），CER 0.92%（中文），零样本WER 1.50%，CER 0.89%。尽管比Audio-Omni（3.05B，纯WER 1.35%）小 $\sim 4\times$ ，它超越了后者，并且超越了专用的TTS模型如ZipVoice（ZS WER 1.70%）和F5-TTS（ZS WER 1.83%）。值得注意的是，UNISON不使用音素编码器（文本条件完全通过冻结的LLM提供），但其性能与依赖显式G2P流程的模型（UniSonate, MaskGCT）相匹配。D20变体显示出稍高的WER（纯1.42%，ZS 1.80%），归因于其较小的容量和44.1kHz音频增加的建模难度。这些结果确认了多任务训练不会降低TTS质量。

表2: Seed-TTS测试集上的TTS结果。纯TTS：基于指令的生成，无说话人参考。ZS TTS：从参考话语进行说话人克隆。

模型	参数	英文	中文	纯WER↓	ZS WER↓	纯CER↓	ZS CER↓	MaskGCT↓	1.05B↓	-2.62↓	-2.27	CosyVoice 2↓	618M↓	-2.57↓	-1.45	ZipVoice↓	123M↓	-1.70↓	-1.40	E2-TTS↓	333M↓	-2.19↓	-1.97	F5-TTS↓	336M↓	-1.83↓	-1.56	InstructAudio↓	1.30B↓	1.52↓	-1.35↓	UniSonate↓	1.34B↓	1.47↓	-1.25↓	Audio-Omni↓	3.05B↓	1.35↓	1.77↓	-	UNISON (D24)↓	732M↓	1.27↓	1.50↓	0.92↓	0.89	UNISON (D20)↓	621M↓	1.42↓	1.80↓	1.11↓	1.71
----	----	----	----	-------	---------	-------	---------	----------	--------	--------	-------	--------------	-------	--------	-------	-----------	-------	--------	-------	---------	-------	--------	-------	---------	-------	--------	-------	----------------	--------	-------	--------	------------	--------	-------	--------	-------------	--------	-------	-------	---	---------------	-------	-------	-------	-------	------	---------------	-------	-------	-------	-------	------

4.3.3 性别可控TTS

如表3所示，两个变体仅从文本指令（例如，“一个男声说...”）即实现了完美的性别准确率（300/300），无需训练时显式的说话人嵌入或性别标签。WER/CER仍然很低（D24: 1.21% 英文，1.00% 中文；D20: 1.47% 英文，1.02% 中文），表明性别控制未引入相比标准TTS设置（表2）的可懂度下降。

表3: 在平衡的双语测试集（300个样本：106英文，194中文，150男/150女）上的性别可控TTS。测试提示来自Seed-TTS (Anastassiou et al., 2024) 并随机分配性别。性别准确率通过基于LibriSpeech微调的wav2vec2-large-XLSR-53评估 (Conneau et al., 2021)。

指标	UNISON (D24, 16kHz)	UNISON (D20, 44kHz)	性别准确率↑	100%	100%	WER-EN↓	1.21↓	1.47	CER-ZH↓	1.00↓	1.02	WER (男)↓	1.64↓	1.31	WER (女)↓	0.74↓	1.65	CER (男)↓	1.30↓	1.05	CER (女)↓	0.71↓	0.99
----	---------------------	---------------------	--------	------	------	---------	-------	------	---------	-------	------	----------	-------	------	----------	-------	------	----------	-------	------	----------	-------	------

4.3.4 混合语音+声音生成

如表4所示，UNISON (D24) 实现了CLAP 0.444（伪GT CLAP 0.476的93.3%），WER 2.04%和CER 3.64%直接在混合输出上测量，无需源分离。D20变体显示出稍低的语音清晰度（WER 3.44%，CER 5.80%）但实现了更低的LSD（2.36 vs. 2.44），表明对伪GT混合具有更好的波形级保真度。这项任务是独特的，因为不存在现有公共基准或基线用于单模型联合语音+声音生成；UNISON通过利用T2A和TTS数据上的多任务训练自然地处理它，无需专用混合模块或两阶段流程。

表4: T2AS：从联合指令生成包含清晰语音和匹配背景声景的统一输出。测试集（600个样本）通过将Seed-TTS语音条目与AudioCaps声音片段配对，以0 dB SNR混合作为伪真值构建。GT CLAP是针对评估描述在此伪GT上计算的。WER/CER直接在混合输出上测量（未分离）。LSD是针对伪GT计算的。

指标	UNISON (D24, 16kHz)	UNISON (D20, 44kHz)	CLAP↑	(GT: 0.476)↓	0.444↓	0.430	WER-EN↓	2.04↓	3.44	CER-ZH↓	3.64↓	5.80	LSD↓	2.44↓	2.36
----	---------------------	---------------------	-------	--------------	--------	-------	---------	-------	------	---------	-------	------	------	-------	------

4.3.5 音频编辑

如表5所示，UNISON (D24) 在所有子任务上实现了最佳的FD和CLAP，整体FD为12.38（对比MMEDIT的20.60）和CLAP为0.364（对比0.257），达到伪GT CLAP的 82%。所有子任务的LSD均 ≤ 2.15，确认了未编辑内容的保持。“移除”子任务对所有方法均显示出较低的CLAP（D24: 0.308, MMEDIT: 0.221），反映了频谱解缠的难度。D20由于更高带宽的VAE实现了更低的LSD，但显示出更高的FD和更低的CLAP。

通过将源音频通过用于目标的相同冻结VAE编码，UNISON在一个共享的潜在空间中操作，不同于SDEdit/ZETA（噪声注入/反演）或Audio-Omni（独立梅尔编码器）。定性梅尔频谱图见附录F（图3-4）。

4.3.6 场景内语音编辑

场景内语音编辑通过插入、删除或重写语音来操作现有音频场景（语音与背景声音混合）中的语音内容，同时保持非语音背景完整。结果见表6。

D24实现了 99.16% 的语音移除（删除），LSD为1.56，并保持插入/重写的WER ≤ 1.35%，确认了有效的语音抑制和高合成语音可懂度。D20在子任务中显示出更低的LSD但更低的CLAP和移除率，与音频编辑中观察到的D24/D20权衡一致。定性示例见附录F（图5-6）。

表5: 1200个构建的测试样本（每子任务400个）上的音频编辑。源/目标对通过在随机SNR下混合AudioCaps (Kim et al., 2019) 测试片段合成（见 §4.2）。GT CLAP（括号内）是构建的目标相对于评估描述的CLAP分数，作为伪GT参考。LSD在生成音频和构建的目标之间计算。

任务 (GT CLAP)	模型	FD↓	LSD↓	CLAP↑
添加				
(0.429)	SDEdit	78.86	2.21	0.168
ZETA	67.27	2.18	0.243	
MMEDIT	25.98	2.23	0.339	
Audio-Omni	34.92	1.99	0.332	
UNISON (D24)	19.26	1.49	0.416	
UNISON (D20)	20.18	1.43	0.391	
移除				
(0.485)	SDEdit	87.65	2.11	0.053
ZETA	66.34	2.09	0.141	
MMEDIT	45.25	3.86	0.221	
Audio-Omni	64.00	2.51	0.112	
替换				
(0.417)	UNISON (D24)	33.20	2.15	0.308
UNISON (D20)	37.93	2.18	0.169	
SDEdit	79.09	1.90	0.119	
整体				
(0.444)	ZETA	62.71	1.89	0.180
MMEDIT	27.56	2.77	0.210	
Audio-Omni	55.39	1.82	0.202	
UNISON (D24)	21.31	1.68	0.368	
UNISON (D20)	23.09	1.57	0.307	
SDEdit	73.85	2.07	0.114	
ZETA	57.27	2.05	0.189	
MMEDIT	20.60	2.95	0.257	
Audio-Omni	36.29	2.11	0.217	
UNISON (D24)	12.38	1.77		
UNISON (D20)	13.44	1.73		

表6: 场景内语音编辑（每子任务200个样本）。测试对由AudioCaps背景 + Seed-TTS (Anastassiou et al., 2024) 语音以10 dB SNR混合构建。CLAP在伪GT上计算。WER/CER在完整输出上测量。LSD针对构建的目标计算。移除率通过Silero-VAD (Team, 2024) 评估。

子任务	模型	CLAP↑	GT CLAP	LSD↓	WER↓	CER↓	移除率↑
插入	D24	0.433	0.459	1.70	1.35	0.65	-
D20	0.429	0.459	1.66	1.70	1.08	-	-
删除	D24	0.412	0.468	1.56	-	-	99.16%
D20	0.320	0.468	1.52	-	-	-	95.72%
重写	D24	0.408	0.456	1.60	0.98	0.95	-
D20	0.396	0.456	1.46	1.35	1.09	-	-

4.3.7 定时音频生成

如表7所示，两个变体均实现了每段CLAP ≥ 0.308，整体CLAP超过了每段值（D24: 0.345；D20: 0.405），表明尽管存在一些边界软化，但整体场景是连贯的。时间控制纯粹依赖于冻结LLM的自然语言时间戳解析，无需专用对齐模块。附录G中的梅尔频谱图（图7-8）确认了与指定时间间隔的频谱对齐。

表7: 定时合成（150个测试样本，2-3段时间指令）。每段CLAP衡量每个时间窗口内的语义对齐；整体CLAP衡量整体场景质量。

指标	UNISON (D24, 16kHz)	UNISON (D20, 44kHz)	每段CLAP↑	0.308	0.311	整体CLAP↑	0.345	0.405
----	---------------------	---------------------	---------	-------	-------	---------	-------	-------

4.4 消融研究

我们在三个轴向上进行了消融（LLM条件模式、流架构和LLM规模），使用相同的训练数据和超参数。

对于LLM条件模式，我们在双流D24架构上比较了三种策略：（1）D24-O（仅深度融合）：来自均匀采样LLM层的逐块投影，无持久文本流，文本MLP禁用；（2）D24-L（仅倒数第二层）：来自倒数第二LLM层的单一投影广播到所有DiT块，文本MLP启用；（3）D24-OL（深度+倒数第二）：两种机制同时激活。对于流架构，我们比较了D24-O（双流，24块，独立文本/音频归一化和QKV）与S32-O（单流，32块，文本和音频token共享归一化、QKV投影和MLP），计算量相当。对于LLM规模，我们测试了D24-O-3B，将默认的7B Qwen2.5-Omni Thinker替换为3B变体，以评估LLM容量对条件质量的影响。

表8揭示了几项发现：

深度融合改善语义遵循。D24-L（仅倒数第二层）在D24变体中实现了最低的CLAP（0.175）和最高的FD（22.71），确认广播单层LLM提供的条件弱于深度匹配注入。D24-O和D24-OL均实现了更低的FD（20.46，20.18）和更高的CLAP（0.180，0.187），表明逐块深度融合更好地捕获了用于音频生成的层次化文本语义。

冗余文本token损害TTS。D24-OL实现了最佳的FD（20.18）和CLAP（0.187），但WER最高（5.52%）。在此变体中，文本token从两个源进入DiT（持久的最后一层流和逐块深度融合投影），有效地复制了条件信号。这种冗余改善了T2A语义对齐，但引入了增加TTS难度的噪声。D24-O通过仅使用带有短暂文本token的逐块投影避免了这种权衡，实现了有竞争力的FD/CLAP（20.46/0.180），同时保持了最低的WER（4.33%）。

双流架构至关重要。S32-O（单流）显示了最差的FD（23.19）、最低的CLAP（0.169）和高WER（4.84%），尽管使用了与D24-O相同的深度融合。在文本和音频token之间共享归一化和QKV投影阻止了模态特定的表征；双流设计通过维护独立特征空间并仅通过联合注意力进行交互来避免这一点。

LLM规模很重要。D24-O-3B在所有指标上均显示出性能下降（FD: 20.46-21.53, CLAP: 0.180-0.174, WER: 4.33-5.61），确认了更丰富的LLM表征直接有利于语义遵循和语音可懂度。

表8: AudioCaps (T2A) 和 Seed-TTS EN (纯TTS) 上的消融。所有变体使用相同的训练数据和超参数（80K步）。“3B”表示使用Qwen2.5-Omni-3B Thinker替代默认的7B。

条件\架构\参数	FD↓	CLAP↑	WER-EN↓	O（深度融合，7B）	D24 732M 20.46 0.180 4.33	L（倒数第二层，7B）	D24 975M 22.71 0.175 4.44	OL（深度+倒数第二，7B）	D24 1,063M 20.18 0.187 5.52	O（深度融合，7B）	S32 685M 23.19 0.169 4.84	O（深度融合，3B）	D24 694M 21.53 0.174 5.61
----------	-----	-------	---------	------------	---------------------------	-------------	---------------------------	----------------	-----------------------------	------------	---------------------------	------------	---------------------------

5 结论

我们提出了UNISON，一个通过逐层深度LLM融合和通道拼接架构统一音频生成与编辑的框架，该架构将所有任务路由通过单个VAE、DiT主干和前向传递。一个621M-732M参数的单一检查点在T2A、TTS、零样本克隆、音频编辑和时间合成上取得了具有竞争力或更优的结果，无需任务特定模块，表明大规模多任务音频生成不一定需要异构的条件路径。这些结果表明了一条通向通用音频系统的实用路径，该系统通过数据和模型扩展而非架构专门化来增长能力。

局限性

VAE重建质量。UNISON依赖于预训练的MMAudio VAE，其最初设计用于环境声音合成。虽然它为通用音频提供了一个紧凑有效的潜在空间，但其对于语音——特别是高频共振峰细节、细微韵律变化以及气息或耳语语音质量——的重建保真度为整体输出质量设定了一个上限。这在零样本本文语转换中尤其明显，其中细粒度的说话人音色细微差别可能在VAE编码过程中被平滑掉。一个自然的下一步是训练一个具有改进语音重建能力的统一VAE，可能采用更高的潜在分辨率或多尺度架构，以更好地保留频谱细节和时间动态。

用于编辑的合成训练数据。我们的编辑和T2AS训练数据是通过算法混合开源音频片段（基于RMS的重叠，带有随机时间放置和淡入/淡出）构建的。虽然这种方法验证了架构设计并实现了无需手动标注的大规模训练，但由此产生的数据分布与自然录音在几个方面不同：(i) 真实世界音频场景表现出复杂的声学交互（例如，混响、掩蔽、Lombard效应），简单的混合无法捕捉；(ii) AudioSet/WavCaps来源的描述质量未经过严格的人工验证，引入了标签噪声；(iii) 合成混合的信噪比分布和时间对齐可能无法反映实践中遇到的典型编辑场景。未来的工作将探索更真实的合成流程（例如，房间脉冲响应卷积、物理信息混合）并纳入人工验证的编辑时。

规模和模态覆盖。当前模型（621M-732M DiT参数）在 ~ 36M 片段（~ 57K 小时）上训练。相对于近期的规模扩展努力，如GenAU（1.25B参数，47M带合成描述的片段），模型大小和数据量都是适中的。该架构设计为可扩展：通道拼接机制自然扩展到其他模态（例如，用于V2A生成的视频特征），深度融合框架可以容纳更大的LLM主干。我们尚未探索这些方向，但预期从增加的规模中会获得显著的收益。

语言和领域范围。当前系统支持英语和中文语音；扩展到其他语言需要额外的多语言语音数据，但无需架构更改。我们目前不针对音乐生成，主要是因为大规模、开放许可且带有高质量文本标注的音乐数据集由于版权限制仍然难以获得。此外，音乐生成涉及独特的挑战——长距离和声结构、多乐器编排以及节拍/速度一致性 (Copet et al, 2023)——这些可能受益于领域特定的设计选择（例如，层次化潜在表征或音乐感知tokenization），超出了我们当前的范围。尽管如此，该架构本身是领域无关的，如果有合适的训练语料库可用，可以纳入音乐数据。

附录 A 架构比较

表9提供了UNISON与两个最接近的同期统一音频系统（Audio-Omni和UniSonate）的详细并排比较，突出了LLM条件策略、转录编码、参考音频处理、任务覆盖和模型规模方面的差异。

表9: 与Audio-Omni和UniSonate的架构比较。

方面	Audio-Omni	UniSonate	UNISON (ours)
LLM条件	倒数第二MLLM层	交叉注意力	Qwen2.5-7B最后一层
逐层	LLM第i层	DiT第i块	转录编码
ConvNeXt V2	字符编码器	G2P音素 + [SFX] token	通过LLM的纯文本；无额外模块
参考音频	梅尔编码器 + 通道拼接	不支持	相同冻结VAE + 通道拼接
零样本TTS	仅英文（语音转换）	不支持	双语（EN/ZH），VAE通道拼接
音频编辑	混合流（AudioEdit数据）	不支持	相同前向传递，掩码=1
音乐领域	支持	支持	非目标
参数	3.05B	1.34B	621M / 732M

附录 B 在线多任务数据合成

表10总结了训练期间每个任务的训练元组（ $(\mathbf{z}_s, \mathbf{z})$ ，指令）如何从原始音频和语音片段即时构建。所有合成在数据加载时在GPU上执行，无需预先计算的静态数据集。

表10: 在线数据合成：每个任务在训练时从基础音频/语音片段构建。

任务	源潜在 $\mathbf{z}_s$	目标潜在 $\mathbf{z}$	指令格式
T2A (生成)	零	音频片段	[Audio] (描述) TTS (性别控制)
零	语音片段	[Speech] A (性别) voice saying “(文本)”	零样本TTS
VAE(参考 + 零填充)	完整话语	[Speech with voice] (文本) T2AS (混合语音 + 声音)	零
RMS混合语音 + 音效	[Speech] ...	[Audio] ...	音频编辑 — 添加
VAE(基础)	基础 + 添加事件	[Edit]	[Audio]

Add (事件) 音频编辑 — 移除[VAE(基础+事件)]仅基础[[Edit][Audio] Remove (事件) 音频编辑 — 替换[VAE(基础+旧)]基础 + 新事件[[Edit][Audio] Remove (旧) [Edit][Audio] add (新) 场景内语音 — 插入[VAE(背景)]背景 + 语音[[Edit][Speech] Add a voice saying "(文本)" 场景内语音 — 删除[VAE(背景+语音)]仅背景[[Edit][Speech] Remove the speech 场景内语音 — 重写[VAE(背景+旧语音)]背景 + 新语音[[Edit][Speech] Change speech to "(新)" 定时合成[零]多事件时间线[Audio] From (t1)s to (t2)s, (事件) ...

附录 C 训练数据组成

表11列出了所有用于训练的数据集，按领域（音频 vs. 语音）细分。组合语料库包含约36M个片段，总计 ~ 57K 小时。带有语音密集描述的音频片段在加载时被过滤掉（约移除 390K 个）；短于3秒的语音片段从零样本TTS采样中排除（33.7M总计中约 29M 个符合条件）。

表11: 训练数据组成。来源包括WavCaps (Mei et al., 2024)、AudioSet (Gemmeke et al., 2017)、VGGSound (Chen et al., 2020)、LibriTTS (Zen et al., 2019)、WenetSpeech (Yao et al., 2021) 和Emilia (He et al., 2024)。

领域	数据集	片段	小时
音频	WavCaps	841K	2,189
AudioSet (带标签)	1,718K	4,772	
VGGSound	174K	482	
语音	LibriTTS	281K	332
WenetSpeech	8,133K	7,693	
Emilia-EN (20M子集)	11,560K	19,802	
Emilia-ZH (20M子集)	13,759K	22,892	
语音小计	33,733K	~50,700	
总计	~36M	~57K	

附录 D 任务概率分布

表12显示了训练期间使用的任务采样概率。阶段1（前150K步）仅训练生成任务；阶段2引入具有如下所示完整概率分布的编辑任务。

表12: 阶段2（联合训练）中的任务采样概率。

任务|阶段1|阶段2 概率 TTS (性别控制)|√|0.15 零样本TTS|√|0.25 T2A (单事件)|√|0.10 T2A (混合)|√|0.08 语音+音频混合 (T2AS)|√|0.08 定时合成|√|0.04 音频编辑 — 添加|×|0.04 音频编辑 — 移除|×|0.04 音频编辑 — 替换|×|0.03 场景内语音 — 插入|×|0.04 场景内语音 — 删除|×|0.03 场景内语音 — 重写|×|0.04 去噪|×|0.04 其他编辑变体|×|0.04

附录 E 架构细节

表13提供了两个模型变体（D20S0-44kHz和D24S0-16kHz）的完整架构和训练超参数集，包括VAE配置、DiT维度、优化器设置和计算资源。

表13: 完整架构和训练超参数。

超参数|D20S0-44kHz (主要)|D24S0-16kHz 音频VAE|MMAudio 44.1kHz VAE|MMAudio 16kHz VAE VAE潜在通道 (C)|40|20 DiT输入通道 (目标+源+掩码)|81 (40+40+1)|41 (20+20+1) 采样率|44,100 Hz|16,000 Hz 最大训练时长|10 s (基础) / 22 s (微调)|10 s (基础) / 22 s (微调) DiT隐藏大小|1,024|1,024 注意力头数|8|8 头维度|128|128 MLP宽度比|4.0|4.0 双流块数|20|24 单流块数|0|0 补丁嵌入|conv_mlp (kernel=7)|conv_mlp (kernel=7) RoPE维度|[96, 16, 16]|[96, 16, 16] LLM编码器|Qwen2.5-Omni-7B (冻结)|Qwen2.5-Omni-7B (冻结) LLM隐藏维度|3,584|3,584 LLM总层数|28|28 融合模式|O (仅深度)|O (仅深度) 层选择|均匀间隔 (28 → 20)|均匀间隔 (28 → 24) 逐块投影器|Linear (3584 → 1024)|Linear (3584 → 1024) 可训练参数|621M|732M 流调度器|FlowMatchEulerDiscrete|FlowMatchEulerDiscrete 推理步数|100|100 CFG尺度|4.5|4.5 优化器|AdamW (β1=0.9, β2=0.95)|AdamW (β1=0.9, β2=0.95) 学习率|1e-4 (余弦, 2000预热)|1e-4 (余弦, 2000预热) 权重衰减|0.01|0.01 梯度裁剪|1.0|1.0 混合精度|BF16|BF16 EMA衰减|0.999 (每10步更新)|0.999 (每10步更新) 训练GPU|8 × H800|8 × H800 每GPU批次大小|56|56

附录 F 编辑定性示例

图3-4和图5-6分别展示了两个模型变体在音频编辑和场景内语音编辑任务的梅尔频谱图比较。每个图显示三列——源音频（模型输入）、UNISON生成输出和构建的真值——针对每个子任务（音频编辑的添加/移除/替换；语音编辑的插入/删除/重写）的一个代表性样本。指令文本显示在每行下方。这些可视化补充了表5和表6中的定量结果，提供了直观的证据，表明UNISON在准确执行指定修改的同时保持了未编辑内容。

附录 G 定时生成定性示例

图7和图8可视化了两个模型变体定时生成输出的梅尔频谱图。每个面板对应一个生成样本；虚线垂直线和彩色阴影标记了自然语言提示中指定的时间边界，段描述标注在上方。顶部两行显示顺序（非重叠）提示，而底部两行显示重叠片段。在两个模型中，频谱图确认了不同的频谱模式在指定的时间间隔内激活，验证了UNISON的时间控制纯粹通过冻结的LLM指令解析运行，无需显式的对齐模块。

图3: UNISON (D24, 16 kHz) 的音频编辑定性示例。每行显示一个子任务（添加/移除/替换）。左：源音频。中：UNISON输出。右：构建的真值。

图4: UNISON (D20, 44.1 kHz) 在与图3相同样本上的音频编辑定性示例。更高带宽的VAE在源和生成输出中保留了更多的频谱细节。

图5: UNISON (D24, 16 kHz) 的场景内语音编辑定性示例。每行显示一个子任务（插入/删除/重写）。模型插入语音，移除现有语音同时保留声景，或重写语音内容。

图6: UNISON (D20, 44.1 kHz) 在与图5相同样本上的场景内语音编辑定性示例。

图7: UNISON (D24, 16 kHz) 的定时生成梅尔频谱图。每行对应一个不同的时间提示（顺序或重叠）。虚线垂直线和彩色区域标记提示中指定的时间边界，段描述标注在每段上方。频谱模式在指定的时间窗口内清晰激活。

图8: UNISON (D20, 44.1 kHz) 在与图7相同提示上的定时生成梅尔频谱图。更高的采样率和40通道VAE产生了更丰富的频谱细节，特别是在高频段。时间对齐在两个模型变体中保持一致。