

好的，这是根据你提供的VoiceBox论文PDF翻译的中文版本。我已严格按照要求，去除了参考文献部分和附录部分，并完整保留了原文的结构、所有内容、公式、表格和图表示意，其中“token”一词根据指示未作翻译。

Voicebox: 大规模文本引导的多语言通用语音生成

Matthew Le* Apoorv Vyas* Bowen Shi* Brian Karrer* Leda Sari Rashel Moritz Mary Williamson Vimal Manohar Yossi Adi* Jay Mahadeokar Wei-Ning Hsu*

基础人工智能研究 (FAIR), Meta

摘要

像GPT和DALL-E这样的大规模生成模型已经彻底改变了自然语言处理和计算机视觉研究。这些模型不仅能生成高保真度的文本或图像输出，而且也是能够解决未被明确教授的任务的通才。相比之下，语音生成模型在规模和任务泛化方面仍然原始。在本文中，我们提出了Voicebox，这是规模最大、用途最广泛的文本引导语音生成模型。Voicebox是一个非自回归的流匹配模型，训练用于在给定音频上下文和文本的情况下填充语音，训练数据超过5万小时的未经筛选或增强的语音。与GPT类似，Voicebox可以通过上下文学习执行许多不同的任务，但它更加灵活，因为它也可以以未来上下文为条件。Voicebox可用于单语或跨语言的零样本文本到语音转换、噪声去除、内容编辑、风格转换和多样本生成。特别是，Voicebox在可懂度（词错误率从5.9%降至1.9%）和音频相似度（从0.580提升至0.681）方面均优于最先进的零样本TTS模型VALL-E，同时速度最高可提升20倍。音频样本可在 <https://voicebox.metademolab.com> 找到。

1 引言

近期大规模生成模型[Brown et al., 2020, Nichol et al., 2021, Ramesh et al., 2021]的进展已导致构建通用模型的主要范式转变，这些模型可以执行许多未被明确训练的新任务。这些生成模型学习在给定上下文的情况下预测缺失数据。训练后，我们可以直接输入一个问题，可选地附带几个上下文中的问答示例，而不是使用带标签的数据进行微调。举一个具体的例子，模型可以回答像“日本的首都是什么？”这样的问题，并在上下文中附带此类关系的一个示例：“德国的首都是柏林。日本的首都是”。

虽然训练目标看似简单，但它涵盖了许多任务，因为人们可以将它们转换为某种形式的上下文。为了让模型在每个任务上都表现良好，这意味着对 p （缺失数据 | 上下文）的估计需要对每个上下文都准确。因此，规模和多样性是构建通用模型的最关键因素[Hoffmann et al., 2022, Aghajanyan et al., 2023]，正如我们看到的最先进的（SOTA）语言和视觉-语言模型是在网络规模的数据上训练的，参数规模达到数十亿到数千亿。

尽管大规模生成模型在其他领域取得了成功，但大多数语音模型仍然在数十到数百小时规模的数据集上训练[Ren et al., 2021, Kim et al., 2020, 2021, Popov et al., 2021, Huang et al., 2022, Tan et al., 2022, Casanova et al., 2021]。先前的工作考虑了高度精选的数据集，如VCTK[Yamagishi et al., 2019]，其中仅包含在录音室录制的约100位说话人的清晰音频，说话风格和文本变化很少。此类模型难以合成具有丰富情感、声音、背景噪声和声学条件变化的语音，并且尚未测试其泛化到未被明确训练的任务的能力。

曾有几项尝试使用野外数据，如CommonVoice[Ardila et al., 2019]、Librispeech[Panayotov et al., 2015]和LibriTTS[Zen et al., 2019]来训练文语转换（TTS）模型。与在精选数据集上训练相比，这导致了巨大的质量下降[Hsu et al., 2019, Wang et al., 2021]。特别是，虽然野外数据通常质量较低，但合成语音与训练语音之间的差距相比于在精选语音上训练的模型要大得多[Wang et al., 2021]，这表明先前的模型严重欠拟合野外数据。

本文介绍了Voicebox，这是规模最大、用途最广泛的文本条件语音生成模型。Voicebox在文本引导的语音填充任务上训练，其目标是在给定周围音频和文本转录的情况下生成被掩码的语音。这可以被视为一个引导的上下文学习问题，其中音频风格从音频上下文中推断，文本内容通过转录指定。Voicebox不需要任何音频风格标签（例如，说话人、情感和噪声），这使其与先前大量使用此类标签的工作区分开来。先前的工作使用标签使输入（文本和音频风格）和输出（语音）之间的映射更加确定，以减少欠拟合[Wang et al., 2021, Popov et al., 2021]。我们展示了Voicebox的文本引导语音填充方法在数据方面更具可扩展性，同时涵盖了许多常见的语音生成任务。

在建模方面，Voicebox是一个非自回归（NAR）连续归一化流（CNF）模型[Chen et al., 2018]。类似于扩散模型[Ho et al., 2020]，CNFs对从简单分布到复杂数据分布（ p (缺失数据 | 上下文)）的变换进行建模，由神经网络参数化。我们使用流匹配[Lipman et al., 2023]训练Voicebox，这是最近提出的一种方法，通过简单的向量场回归损失，使得CNFs的高效和可扩展训练成为可能。与自回归模型相比，Voicebox不仅可以利用过去的上下文，还可以利用未来的上下文。此外，推理时的流步数可以控制，以灵活地权衡质量和运行时效率。

Voicebox在6万小时的英语有声读物和5万小时的6种语言的多语言有声读物上训练，分别用于单语和多语言设置。Voicebox在单语/跨语言零样本TTS、语音去噪、语音编辑、多样本语音采样以及在语音识别数据创建中的应用方面均达到了SOTA性能。为解决由于使用主观指标而缺乏可比性的问题，本文提出了一系列使用公共模型的指标，以促进语音生成研究中可重复的比较和模型开发。

1. Voicebox代表了语音生成式建模的突破。通过学习用大规模数据解决文本引导的语音填充任务，Voicebox可以通过上下文学习解决未被明确训练的任务。
2. Voicebox优于VALL-E，并在英语零样本TTS上取得了新的SOTA结果（词错误率（WER）从 5.9% $\rightarrow$ 1.9%，音频相似度从 0.580 $\rightarrow$ 0.681）。
3. Voicebox是第一个能够在六种语言中执行高质量跨语言零样本TTS的模型。它不使用任何风格标签、预训练嵌入或多语言样本。与之前的跨语言SOTA模型YourTTS相比，Voicebox将平均WER从 10.9% 降低到 5.2%，并将音频相似度从 0.335 提高到 0.481。
4. Voicebox能够填充任意长度的语音，并在文本引导的去噪方面优于之前的SOTA模型A3T，WER降低了 -8.8% ，相似度提高了 $+0.450$ ，平均意见分数提高了 $+0.80$ 。
5. Voicebox可以生成多样且逼真的语音。仅使用Voicebox生成的合成语音训练的ASR系统，在Librispeech test-other/test-clean上相比使用真实数据训练，WER绝对增加仅为 0.4%/1.7%。相比之下，先前的TTS模型则至少遭受 18.2%/44.5% 的WER绝对增加。

2 相关工作

生成式语音模型。大多数语音生成模型是任务特定的，并在不同的数据集上训练。一种常见的任务类型是音频风格转换，旨在仅转换特定属性，同时保持其他属性不变。语音转换[Kameoka et al., 2018, Lorenzo-Trueba et al., 2018]、情感转换[Robinson et al., 2019, Kreuk et al., 2022]、语音增强[Xu et al., 2014, Defossez et al., 2020, Serra et al., 2022]属于此类别。许多此类模型是有监督的，并在仅在一个属性上不同的数据对上训练，例如情感[Kreuk et al., 2022]。获得此类数据很困难。此外，一些属性，如说话风格，难以标注。因此，这些模型通常在小数据集上训练，泛化能力不佳。

可控文语转换合成（TTS）是另一个常见任务，其目标是在给定文本的情况下，以目标音频风格（例如，声音、说话风格、录音环境）合成语音。虽然某些风格如声音可以通过标签[Kim et al., 2021]或预训练嵌入（如YourTTS[Casanova et al., 2021]和Jia et al.[2018]）来指定；但其他风格如韵律则难以标注或嵌入。先前的研究[Wang et al.,

2018, Akuzawa et al., 2018, Hsu et al., 2019]试图通过学习残差嵌入来控制它们。然而，这些模型将风格编码在低维空间中，并对给定文本和残差嵌入的语音施加了过于简单的分布[Ren et al., 2021, Shen et al., 2017]。它们无法在给定低维向量的情况下生成逼真的带噪语音，并且在以带噪参考为条件时性能会下降[Hsu et al., 2019]。

填充可以被视为另一种类型的任务。其目标是在给定上下文[Lakhotia et al., 2021, Borsos et al., 2022a]和可选的文本引导[Bai et al., 2022, Borsos et al., 2022b, Wang et al., 2023]的情况下预测语音。填充模型不是学习显式嵌入来控制风格，而是预测与上下文连贯的语音。换句话说，这些模型执行类似于大语言模型（LLMs）的上下文学习，通过上下文指定任务（即要转换的所需风格）。虽然这是朝着使用极少显式监督构建大规模通用模型迈出的一步，但大多数先前使用文本引导的工作仍然假设从文本和上下文到目标的确定性映射[Bai et al., 2022, Borsos et al., 2022b]，这仅对非常短的片段是现实的。因此，具有这些假设的模型通常只能填充最多1秒的片段[Borsos et al., 2022b]。Voicebox是一个文本引导的填充模型，但它利用CNF模型，该模型可以参数化任何分布。因此，Voicebox可以填充任意长度的语音，并且可以在具有丰富变化的野外数据集上训练，并以文本引导的方式提供一个涵盖许多任务的通用解决方案。

大规模上下文学习模型。随着用于语音的神经编解码器的进步[Hsu et al., 2021, Defossez et al., 2022, Zeghidour et al., 2022]，许多近期研究探索了基于token的语言建模用于语音生成。GSLM系列[Lakhotia et al., 2021, Kharitonov et al., 2021, Nguyen et al., 2022]是建立在HuBERT单元[Hsu et al., 2021]之上的无文本语言模型，用于在不使用文本的情况下进行语音续写。HuBERT单元主要编码内容[Polyak et al., 2021]，生成的语音不保留提示的声音。为解决这个问题，AudioLM[Borsos et al., 2022a]考虑了一种级联方法，首先生成HuBERT类似的token，然后预测SoundStream[Zeghidour et al., 2022] token，这是一种基于重建的编解码器，可以保留风格。这些模型不以文本为条件，并在口语语言建模任务上进行了评估。

VALL-E[Wang et al., 2023]与Voicebox最为相关。它是一个在Encoder[Defossez et al., 2022] token（类似于SoundStream）上训练的文本条件LM。Encoder用残差量化层对语音进行分词，该层以75Hz的帧率用8个码本对每帧进行编码。码本的排序使得第一个码本包含最多的信息，依此类推。VALL-E有两个模块。第一个是一个自回归（AR）模型，给定文本和音频提示，预测每帧的第一个码本。第二个是一个NAR模型，顺序预测剩余的七个码本（预测每个码本时所有帧同时预测）。

VALL-E通过上下文学习展示了最先进的（SOTA）零样本TTS性能，其中所需风格的语音被用作提示。该模型将提示视为整个话语的一部分，从而生成包含目标文本的剩余话语，采用相同的音频风格。Voicebox相比VALL-E有几个设计优势。1) Voicebox可以利用过去和未来的上下文，这对于只需要生成中间片段的编辑很有用。2) Voicebox可以比VALL-E快得多地生成语音，因为流匹配可以用少于十个NAR步产生高质量样本，而VALL-E需要一个AR步和七个NAR步。3) Voicebox将时长和音频建模解耦，实现更精细的对齐控制。4) Voicebox与任何连续特征兼容，包括Encoder嵌入。

NaturalSpeech2[Shen et al., 2023]是另一个探索用于上下文语音生成的扩散风格模型的同期工作。它采用潜在扩散框架[Rombach et al., 2022]，该框架使用带残差向量量化器的自编码器将语音编码为潜在特征，并使用扩散模型生成以文本、（预测的）音高和语音提示为条件的潜在特征。预测的潜在特征使用同一自编码器的解码器转换为波形。

NaturalSpeech2在几个关键方面与Voicebox不同。1) 它有一个额外的音高预测器，并以音高为条件进行特征生成。2) NaturalSpeech2预测学习到的潜在特征，而Voicebox预测梅尔频谱图。3) 它对语音提示和语音目标采用非对称编码器，并使用两阶段交叉注意力来查询提示。NaturalSpeech2的推理在注意力计算方面更高效，因为提示只编码一次并在每个扩散步骤中重用，但尚不清楚这种设计如何影响填充性能，该性能未被评估。4) 时长和音高预测器是一个回归模型，对于相同的提示和文本只预测一个时长和音高。5) NaturalSpeech2在推理时总是以语音提示为条件，这不允许进行第5.5节中演示的多样本采样。6) Voicebox利用带最优传输路径的流匹配，该路径被证明比扩散路径训练和推理更快，而扩散路径是NaturalSpeech2采用的目标。Voicebox仅用16个ODE步就能生成高质量样本，而NaturalSpeech2将扩散步数设置为150。Voicebox的整体推理时间预计会更快。

3 方法

3.1 背景：带最优传输路径的流匹配

设 $\mathbb{R}^d$ 为数据空间，数据点 $x \in \mathbb{R}^d$ 从某个未知分布 $q(x)$ 中抽取。连续归一化流（CNFs）[Chen et al., 2018]是一族生成模型，学习从简单先验分布 p_0 （例如，正态分布）到数据分布 $p_1 \approx q$ 的变换。CNFs参数化一个时间相关的向量场 $v_t: [0, 1] \times \mathbb{R}^d \rightarrow \mathbb{R}^d$ ，该向量场用于构建一个流： $\phi_t: [0, 1] \times \mathbb{R}^d \rightarrow \mathbb{R}^d$ ，将点从先验推向目标分布。向量场和流之间的关系通过常微分方程（ODE）定义为：

$$\frac{d}{dt}\phi_t(x) = v_t(\phi_t(x)); \phi_0(x) = x. \quad (1)$$

$$p_t(x) = p_0(\phi_t^{-1}(x)) \det \left[\frac{\partial \phi_t^{-1}}{\partial x}(x) \right]. \quad (2)$$

要从 $p_t(x)$ 中采样，我们首先从 p_0 中抽取 x_0 ，然后求解 $\phi_t(x_0)$ 的初值问题（IVP），给定 $d\phi_t(x)/dt = v_t(\phi_t(x))$ 和 $\phi_0(x) = x_0$ 。我们互换使用 x_t 和 $\phi_t(x_0)$ 。

设 p_t 为一个概率路径， u_t 为生成 p_t 的对应向量场。由神经网络 θ 参数化的向量场 $v_t(x; \theta)$ 可以通过流匹配目标进行训练：

$$\mathcal{L}_{FM}(\theta) = \mathbb{E}_{t, p_t(x)} \|u_t(x) - v_t(x; \theta)\|^2, \quad (3)$$

其中 $t \sim \mathcal{U}[0, 1]$ 且 $x \sim p_t(x)$ 。虽然目标看似简单，但在实践中我们并不知道 p_t 或 v_t 的先验知识，无法直接计算损失或其梯度估计量。

设 x_1 为根据数据分布 q 分布的随机变量。Lipman et al.[2023]首先指出，概率路径 $p_t(x)$ 可以通过混合更简单的条件路径 $p_t(x | x_1)$ 来构建，其向量场 $u_t(x | x_1)$ 可以轻松计算。为构建 $p_t(x)$ ，定义一个条件路径，使得 1) $p_0(x | x_1) = p_0(x)$ 且 2) $p_1(x | x_1) = \mathcal{N}(x | x_1, \sigma^2 I)$ ，即一个以 x_1 为中心、 σ 足够小（通常为 10^{-5} ）的高斯分布。边际路径计算为 $\int p_t(x | x_1) q(x_1) dx_1$ ，它在 $t = 1$ 时近似 $q(x_1)$ 。由此，[Lipman et al., 2023]提出了条件流匹配（CFM）目标：

$$\mathcal{L}_{CFM}(\theta) = \mathbb{E}_{t, q(x_1), p_t(x_1)} \|u_t(x | x_1) - v_t(x; \theta)\|^2. \quad (4)$$

已证明FM和CFM关于 θ 具有相同的梯度。更重要的是，我们可以轻松地 $p_t(x | x_1)$ 中抽取样本并计算 $u_t(x | x_1)$ 来导出无偏梯度估计量。

下一个问题是如何选择条件流。一个流定义了轨迹，描述了每个点如何在 p_0 和 p_1 之间移动。直观上，更简单的轨迹（例如，直线）可以学习得更快，并且IVP可以更准确和高效地求解。Lipman et al.[2023]提出了一种称为最优传输（OT）路径的条件流，其形式为 $p_t(x | x_1) = \mathcal{N}(x | tx_1, (1 - (1 - \sigma_{min})t)^2 I)$ 和 $u_t(x | x_1) = (x_1 - (1 - \sigma_{min})x)/(1 - (1 - \sigma_{min})t)$ 。这个流可以说很简单，因为点以恒定的速度和方向移动。我们为Voicebox采用了它。

Lipman et al.[2023]还提出了另一种流，它恢复了扩散模型的路径[Song and Ermon, 2019]，这比OT路径更复杂。我们将在消融研究中比较不同的路径（OT vs. 扩散）和不同的目标（CFM vs. 分数匹配）。结果显示了带OT路径的CFM在性能和效率上的优越性。

3.2 问题表述

给定一个带有转录的语音数据集 (x, y) ，其中 x 和 y 分别表示一个音频样本及其转录，目标是构建一个单一的模型，该模型可以通过上下文学习执行许多文本引导的语音生成任务。我们提出在文本引导的语音填充任务上训练这样一个生成模型，该模型在给定周围音频和完整文本转录的情况下预测一段语音。设 m 为一个与 x 长度相同

的二元时间掩码,³ 并设 $x_{mis} = m \odot x$ 和 $x_{ctx} = (1 - m) \odot x$ 为 x 的互补掩码版本。生成模型学习 $p(x_{mis} | y, x_{ctx})$ 。换句话说, y 和 x_{ctx} 是上下文, x_{mis} 是缺失数据。

3.3 模型与训练

鉴于某些应用需要在语音和文本之间进行细粒度对齐控制, 我们将Voicebox解耦为两个组件: 一个音频模型和一个时长模型。设 $x = (x^1, x^2, \dots, x^N)$ 为一个 N 帧的音频样本, $y = (y^1, y^2, \dots, y^M)$ 为一个 M 个音素的文本序列, $l = (l^1, l^2, \dots, l^M)$ 为每音素时长, 其中 l^j 表示 y^j 对应多少音频帧, 且 $\sum_{j=1}^M l^j = N$ 。我们进一步定义 $z = \text{rep}(y, l) = (z^1, z^2, \dots, z^N)$ 为帧级音素转录, 它重复每个 y^j 共 l^j 次, 使得 z^i 表示音频帧 x^i 的音素标签。对于一对 (x, y) , l 和 z 可以通过使用语音识别模型的强制对齐来估计。

对 $q(x_{mis} | y, x_{ctx})$ 的估计随后被分解为音频模型 $q(x_{mis} | z, x_{ctx})$ 和时长模型 $q(l_{mis} | y, l_{ctx})$, 其中 l_{mis} 和 l_{ctx} 表示由 m' 和 $1 - m'$ 掩码的 l , 而 m' 是根据 l 从 m 下采样的, 其中 $m = \text{rep}(m', l)$ 。

图2: Voicebox音频模型示意图。下半部分说明了训练期间如何创建输入。 N 表示帧数, H 为音素嵌入维度, F 为频谱特征维度, D 为Transformer输入维度。深灰色实心块表示可训练组件, 带虚线边框的浅灰色块是冻结组件或无训练参数的操作。

音频模型 (图2)。 给定长度 N 的上下文 z 和 x_{ctx} , x_{mis} 的分布是高度随机的, 特别是当 x_{mis} 具有大的时间跨度时。因此, 我们使用CNF对其进行参数化, 并使用带最优传输路径的流匹配目标进行训练。音频 x 表示为以100Hz帧率提取的80维对数梅尔频谱图 ($x^i \in \mathbb{R}^{80}$)。音频上下文 $x_{ctx}^i = 0$ (其中 $m^i = 1$), $x_{ctx}^i = x^i$ (其中 $m^i = 0$)。

为简化条件, 我们对所有帧 x 的条件分布 $q(x | z, x_{ctx})$ 进行建模, 而不仅仅是掩码帧 x_{mis} 。一个神经网络被用来参数化条件向量场 $v_t(x_t, x_{ctx}, z; \theta)$, 该向量场额外以 x_{ctx} 和 z 为输入。注意, x_t 是流步骤 t 处的样本。

给定输入 $x_{ctx} \in \mathbb{R}^{N \times F}$, $x_t \in \mathbb{R}^{N \times F}$, 音素序列 $z \in [K]^N$ (K 表示音素类别数) 以及时间步 $t \in [0, 1]$, 我们采用Transformer模型来参数化向量场 v_t 。一个查找表, 记为 $L \in \mathbb{R}^{K \times H}$, 用于嵌入音素序列 z , 得到嵌入序列 $z_{emb} \in \mathbb{R}^{N \times H}$, 其中 $z_{emb}^i = L(z^i)$, $i \in 1, \dots, N$ 。随后, 这三个序列 (x_t , x_{ctx} 和 z_{emb}) 逐帧拼接, 并通过使用矩阵 $W_p \in \mathbb{R}^{(2F+H) \times D}$ 进行投影, 从而获得序列 $H_c \in \mathbb{R}^{N \times D}$, 其中 D 表示Transformer模型的嵌入维度。

为嵌入流步骤, 应用正弦位置编码将 $t \in [0, 1]$ 映射到 $h_t \in \mathbb{R}^D$ 。序列 $\tilde{H}_c \in \mathbb{R}^{(N+1) \times D}$, 作为Transformer模型的输入, 通过沿时间维度拼接 $\tilde{H}_c$ 和向量 h_t 得到。给定Transformer输出 $v_t(x_t, x_{mis}, z; \theta) \in \mathbb{R}^{N \times F}$ (即对应于 H_c 的子序列), 损失计算为:

$$\mathcal{L}_{\text{audio-CFM}}(\theta) = \mathbb{E}_{t, m, q(x, z), p_0(x_0)} \|u_t(x_t | x) - v_t(x_t, x_{ctx}, z; \theta)\|^2, \quad (5)$$

通过对公式(4)进行重参数化得到。在训练期间, 给定音频样本 x 和先验样本 x_0 , 我们有 $x_t = (1 - (1 - \sigma_{\min})t)x_0 + tx$ 和 $u_t(x_t | x) = x - (1 - \sigma_{\min})x_0$ 。该函数计算所有帧的损失, 包括那些未被掩码且在推理时不会需要的帧。

为使模型聚焦于被掩码的帧, 我们提出了 $\mathcal{L}_{\text{audio-CFM}}$ 的掩码版本:

$$\mathcal{L}_{\text{audio-CFM-m}}(\theta) = \mathbb{E}_{t, m, q(x, z), p_0(x_0)} \|m \odot (u_t(x_t | x) - v_t(x_t, x_{ctx}, z; \theta))\|^2, \quad (6)$$

其中损失仅在掩码的帧上计算。附录B.1显示这能带来更好的结果。

时长模型。 我们考虑两种解决方案。第一种紧密跟随音频模型。它通过条件向量场对 $q(l | y, l_{ctx})$ 进行建模, 该向量场将 (x, x_{ctx}, z) 与 (l, l_{ctx}, y) 互换, 并相应地调整流, 其中 $l, l_{ctx} \in \mathbb{R}^{M \times 1}$ 且 $y \in [K]^M$ 。训练时使用CFM损失的掩码版本。另一方面, 先前的研究表明, 回归时长模型可以产生合理的语音[Ren et al., 2021, Lañucci, 2021]。因此我们考虑第二种解决方案, 即给定上下文时长 l_{ctx} 和音素转录 y , 回归预测被掩码的时长 l_{mis} 。使用相同的Transformer模型, 只是输入序列只有两个而不是三个, 并且不使用时间嵌入。该模型在被掩码的音素上使用 L_1 回归损失进行训练:

$$\mathcal{L}_{\text{dur-reg-m}}(\theta) = \mathbb{E}_{m, q(l, y)} \|m' \odot (l_{mis} - g(l_{ctx}, y; \theta))\|_1, \quad (7)$$

其中 g 表示基于回归的时长模型。这类似于FastSpeech2[Ren et al., 2021]中使用的时长模型, 但额外增加了时长上下文 l_{ctx} 作为输入。

3.4 推理

为从学习到的音频分布 $p_1(x | z, x_{ctx})$ 中采样, 首先从 p_0 中采样噪声 x_0 , 然后使用ODE求解器在给定 $d\phi_t(x_0)/dt = v_t(\phi_t(x_0), x_{ctx}, z; \theta)$ 和初始条件 $\phi_0(x_0) = x_0$ 的情况下计算 $\phi_1(x_0)$ 。图3提供了该过程的说明。

直观上, ODE求解器通过在多个 t 处评估 v_t 来计算 $\phi_1(x_0)$, 以近似从 $t = 0$ 到 $t = 1$ 的积分, 给定初始条件 $\phi_0(x_0) = x_0$ 。函数评估次数 (NFE) 定义为 $d\phi_t(x_0)/dt$ 被评估的次数。更高的NFE通常会导致更精确的 $\phi_1(x_0)$ 解, 但代价是运行时间更长。这为用户提供了极大的灵活性, 以决定速度和准确性之间的权衡。此外, 我们凭经验发现Voicebox可以在少于10次NFE的情况下生成非常高质量的语音, 使其比自回归模型快得多。

图3: 推理等同于求解一个ODE, 其初始条件为从先验采样的 x_0 , 导数为 $\frac{d\phi_t}{dt}$ 由音频模型指定, 以及条件输入 (z, x_{ctx}) 。在每一步, ODE求解器根据 t 、前一步的 x_t 、音频模型和条件输入估计 x_{t+1} 。最终, 它产生 x_1 , 这是从学习到的分布 p_1 中抽取的样本。

3.5 无分类器引导

分类器引导 (CG) [Dhariwal and Nichol, 2021]是一种用于在训练后权衡扩散模型的模式覆盖和样本保真度的技术, 类似于生成对抗网络[Brock et al., 2018]和离散流模型[Kingma and Dhariwal, 2018]的截断或低温采样的效果。它修改扩散模型的分数量估计, 以包含辅助分类器的对数似然的梯度。Ho and Salimans[2022]指出, CG近似于从 $p(x | c)p(c | x)^\alpha$ 中采样, 其中 c 是条件器, 这可以通过混合条件模型和无条件模型的分数量估计来模拟, 而无需分类器。无条件模型可以通过以一定概率丢弃条件器 c 来联合训练, 并且同一个模型为 $p(x)$ 和 $p(x | c)$ 都提供分数量估计。

我们将无分类器引导 (CFG) 的思想扩展到流匹配模型。条件器 c 对于音频模型等同于 (z, x_{ctx}) , 对于时长模型等同于 (y, l_{ctx}) , 在训练期间以 p_{uncond} 的概率被丢弃。在推理期间, 音频模型的修改后向量场 $\tilde{v}_t$ 变为:

$$\tilde{v}_t(w, x_{mis}, z; \theta) = (1 + \alpha) \cdot v_t(w, x_{ctx}, z; \theta) - \alpha \cdot v_t(w; \theta), \quad (8)$$

其中 α 是引导的强度, $v_t(w; \theta)$ 通过丢弃 x_{ctx} 和 z 获得。我们对音频和时长模型分别使用 α 和 α_{dur} 作为CFG强度, 这些值根据经验结果选择。⁵

3.6 应用

我们通过展示几个如何创建上下文以执行Voicebox未被明确训练的任务的示例，来演示Voicebox展现出类似于LLMs的上下文学习能力。这些示例也在图1和图4中进行了说明。

零样本TTS与对齐保持的风格转换。给定目标文本 $\hat{y}$ 和带转录的参考音频 (x, y) ，零样本TTS旨在合成类似于参考音频的（可能未见过的）音频风格的语音。Voicebox通过将参考音频和目标语音视为一个话语来执行该任务，其中目标语音被掩码。设 l 和 z 为 (x, y) 的音素时长和帧级转录。目标时长 $\hat{l}$ 在给定时长上下文 l 和拼接的音素序列 $\text{cat}(y, \hat{y})$ 的情况下采样。然后，目标语音 $\hat{x}$ 在给定上下文 x 和拼接的帧级音素 $\text{cat}(z, \text{rep}(\hat{y}, \hat{l}))$ 的情况下采样。

Voicebox还可以在保持其对齐 z 的同时，转换语音 x 的音频风格。这对于编辑与其他模式（如视频）同步的音频很有用。类似于零样本TTS，Voicebox只需在给定上下文 x 和拼接的帧级音素 $\text{cat}(z, \hat{z})$ 的情况下采样目标语音 $\hat{x}$ 即可执行该任务。

瞬态噪声去除与内容编辑。在录音时，可能会说错几个词，或者录音可能被意外的背景噪声打断。在这些情况下，理想的做法是仅修改有问题的片段，而不是重新录制语音。Voicebox可以通过在给定原始帧级转录和周围清晰音频的情况下重新生成被噪声损坏的片段来执行瞬态噪声去除。具体来说，给定带转录的带噪语音 (x, y) 的帧级转录 z ，用户创建一个掩码 m 来指示带噪片段。片段 $\hat{x}_{mis}$ 随后在给定 z 和 $x_{ctx} = (1 - m) \odot x$ 的情况下采样。音频模型很可能会为 $\hat{x}_{mis}$ 生成清晰的语音，因为在训练期间，清晰的音频上下文大多数时候与清晰的目标音频共同出现。新音频为 $\hat{x} = \hat{x}_{mis} + x_{ctx}$ 。

对于内容编辑，设 $\hat{y}$ 为新的期望转录，其中原始转录 y 中的一些词被替换， l 为原始时长。用户首先通过从 l 中复制未被替换的音素的时长，并将新音素的时长设置为0，来构建（与 $\hat{y}$ 等长的） l_{ctx} 。新音素的时长 $\hat{l}_{mis}$ 在给定 l_{ctx} 和 $\hat{y}$ 的情况下采样，新时长 $\hat{l} = \hat{l}_{mis} + l_{ctx}$ 。新的帧级转录用 $\hat{z} = \text{rep}(\hat{y}, \hat{l})$ 构建。类似地，音频上下文 x_{ctx} 与 $\hat{z}$ 等长，通过用 x 中映射到未被替换的音素的帧填充，并将新音素的帧留为0来创建。新音素的帧 $\hat{x}_{mis}$ 在给定 $\hat{z}$ 和 x_{ctx} 的情况下采样。编辑后的语音计算为 $\hat{x} = \hat{x}_{mis} + x_{ctx}$ 。

多样本语音采样与对齐保持的风格混洗。Voicebox可以通过填充整个话语来生成多样化的语音样本。我们首先使用时长模型在给定音素转录 $\hat{y}$ 的情况下采样 $\hat{l}$ 。然后，我们使用音频模型在给定 $\hat{z} = \text{rep}(\hat{y}, \hat{l})$ 的情况下采样 $\hat{x}$ 。

类似于风格转换，Voicebox还可以通过在给定目标语音片段 $\hat{x}$ 的帧级转录 $\hat{z}$ 的情况下采样 $\hat{x}$ 来混洗音频风格，同时保持对齐。

图4: 多样本语音采样、内容编辑和风格转换的详细示意图。模型输入中的红色文本和橙色块表示待预测的片段。模型输出中的蓝色数字和青色频谱图表示预测的时长和频谱图。

4 指标

Voicebox将许多语音生成任务表述为文本引导的上下文学习问题。音频条件任务的共同目标是产生与上下文连贯且具有正确文本内容的逼真语音。对于不以音频上下文为条件的任务，期望生成多样且逼真的样本，其分布与训练数据相似且内容正确。

先前的研究通常采用主观指标，如平均意见分数（MOS）[Ribeiro et al., 2011]，这些指标在不同论文之间甚至在同一论文的不同研究之间都不可比，因为评分可能会受到同一试验中评估的其他系统样本质量的影响。一些研究也考虑了测量信号级相似性的自动定量指标，如用于语音合成和语音转换的平均倒谱距离（MCD）[Kubichek, 1993, Skerry-Ryan et al., 2018]，以及用于语音增强的信噪比/失真比（SNR/SDR）[Le Roux et al., 2019]。这些指标假设输出在给定输入的情况下是确定性的，这通常是不适定的，并且不公平地惩罚了产生逼真且有效样本的生成模型。这些指标的注意事项已在文献中得到充分记录[Le Roux et al., 2019, Skerry-Ryan et al., 2018, Shen et al., 2023, Wang et al., 2022]。在本文中，我们提倡以下可重复的基于模型的感知指标。

正确性与可懂度。这可以通过合成语音转录相对于输入文本的词错误率（WER）来衡量，这在先前的工作中已被采用[Wang et al., 2018]。使用公共自动语音识别（ASR）模型以确保可比性。对于仅英文的设置，我们遵循[Wang et al., 2023]，使用在6万小时LibriLight[Kahn et al., 2019]上预训练并在960小时LibriSpeech[Panayotov et al., 2015]上微调的HuBERT-L[Hsu et al., 2021]。对于多语言设置，我们使用Whisper large-v2模型[Radford et al., 2022]。

应注意，较低的WER表明生成的语音对模型来说更易懂且包含更正确的内容，但并不一定意味着质量更好。类似地，当生成多样化的样本或转移到更具表现力或更嘈杂的音频风格时，生成的语音可能更难被ASR模型识别，这会导致更高的WER，但这并不意味着样本不好。

连贯性。通过生成语音嵌入与音频上下文嵌入之间的相似度来衡量，不同的嵌入模型会反映不同属性的连贯性。VALL-E提出使用WavLM-TDCNN说话人嵌入模型[Chen et al., 2022]（将音频片段映射到固定维度的向量）来衡量声音相似度。我们考虑使用相同的模型来与VALL-E进行比较。特别是，VALL-E报告的是相对于其声码器（Codec解码器）重建的音频上下文的相似度，我们称之为SIM-resyn（SIM-r）。SIM-resyn在不同模型使用不同声码器时不可比。因此，我们提倡计算相对于原始音频上下文的相似度，我们称之为SIM-orig（SIM-o）。

多样性与质量。Fréchet Inception Distance（FID）[Heusel et al., 2017]被广泛用于图像生成评估，它在某个特征空间中捕获生成图像与真实图像在分布层面的相似性。它在某个特征空间中为真实样本拟合一个高斯分布，为生成样本拟合另一个，并计算两者之间的Fréchet距离。更短的距离意味着分布更相似，通常反映更高的样本质量和多样性。我们通过使用自监督的wav2vec 2.0特征[Baevski et al., 2020]来调整该指标用于语音，并将其称为Fréchet Speech Distance（FSD）。我们在附录C.1中验证了其有效性以及替代特征。

作为补充指标，我们包括用于主观音频质量评估的质量MOS（QMOS），以及用于在提示和系统生成的音频片段对之间进行主观音频相似度评估的相似度MOS（SMOS）。两者均采用1到5的评分标准，5为最佳。每个系统评估50个样本，每个样本收集10个评分。报告平均评分及95%置信区间。为此，使用了CrowdMOS[Ribeiro et al., 2011]包及其推荐的过滤异常值和不准确评分的配方。MOS说明可在附录C.5中找到。

为评估时长模型，可以继续使用前述指标来衡量端到端性能。或者，我们也提出了一些专注于时长模型的独立指标。描述和结果可在附录C.2至C.4中找到。

5 实验

5.1 设置

数据。我们在6万小时ASR转录的英语有声读物上训练仅英文模型，在5万小时来自六种语言的多语言有声读物上训练多语言模型：英语（En）、法语（Fr）、德语（De）、西班牙语（Es）、波兰语（Pl）和葡萄牙语（Pt）。遵循[Babu et al., 2022]，对于给定的上采样因子 β ，我们对低资源语言进行上采样，以模拟从多项式分布 $p_s \sim \left(\frac{n_s}{N}\right)_{s=1, \dots, S}$ 中采样批次，其中 S 是语言总数， n_s 是语言 s 的预训练小时数， N 是总小时数。我们设置 $\beta = 0.25$ 。

这两个模型分别缩写为VB-En和VB-Multi。Montreal Forced Aligner（MFA）[McAuliffe et al., 2017]用于基于MFA音素集（国际音标（IPA）的修改版本）对转录进行音素化和强制对齐。词位置依赖音素被使用（见附录A.2）。Conformer[Gulati et al., 2020]和对称双向ALiBi自注意力偏置[Press et al., 2021]同时用于音频和时长模型。流步骤 x_t

的ALiBi偏置设置为0。更多细节见附录A.6。音频模型有24层、16个注意力头、1024/4096嵌入/前馈网络（FFN）维度，共3.3亿参数。我们以UNet架构的风格添加了连接对称层的跳跃连接（第一层到最后层，第二层到倒数第二层，等等）。状态按通道拼接，然后使用线性层进行组合。时长模型有8个头、512/2048嵌入/FFN维度，英语/多语言设置分别有8/10层（总共2800万/3400万参数）。所有模型均以FP16训练。

训练。VB-En/VB-Multi音频模型训练了50万/75万次更新，有效批次大小为24万帧。为提高训练效率，音频长度限制为1600帧，如果超过此阈值则随机分块。时长模型训练了60万次更新，有效批次大小为6万帧。使用Adam[Kingma and Ba, 2014]优化器，峰值学习率为 $1e-4$ ，线性预热5k步，并在其余训练中线性衰减。对于音频模型，我们将梯度范数裁剪为0.2以提高训练稳定性。音频/时长序列以 $p_{\text{drop}} = 0.3/0.2$ 的概率被掩码，否则掩码序列长度的 $r\%$ 的片段，其中 $r \sim \mathcal{U}[70, 100]/\mathcal{U}[10, 100]$ 。 p_{uncond} 对于音频/时长模型设置为0.2。

推理。使用torchdiffeq[Chen, 2018]包，它实现了固定步长和自适应步长ODE求解器。默认情况下，使用中点求解器，步长为0.0625（NFE=32）。默认使用回归时长模型。两端的静音最多修剪到0.1秒。

基线。我们考虑三个基线：1) VALL-E[Wang et al., 2023]，在LibriLight上训练的英语零样本TTS SOTA模型。2) YourTTS[Casanova et al., 2021]，在VCTK、LibriTTS、TTS-Portuguese[Casanova et al., 2022]和M-AILABS French上训练的多语言（英语、法语和葡萄牙语）零样本TTS SOTA模型。它是一个基于流的模型，改编自VITS[Kim et al., 2021]，使用预训练的多语言说话人嵌入器进行声音条件。3) A3T[Bai et al., 2022]，在VCTK上使用回归损失训练的NAR语音编辑和填充SOTA模型。我们还在去噪实验中考虑了Demucs[Defossez et al., 2020]，一个使用回归和对抗性损失训练的SOTA语音增强模型。表1总结了每个基线能够解决的任务。

表1: 将Voicebox与基线在任务能力上进行比较。“采样”指无需任何音频条件即可生成多样化音频片段的能力。通过填充，A3T和Voicebox可以去除瞬态噪声，但不能去除稳态背景噪声。VALL-E只能以过去上下文为条件生成语音。因此，生成的片段只会与过去上下文连贯，而不会平滑过渡到未来上下文。因此，我们将VALL-E标记为不具备去噪或编辑能力。

模型|零样本TTS|去噪|部分编辑|采样 VALL-E| $\sqrt{\times}|\times|\sqrt{\times}$ YourTTS| $\sqrt{\times}|\times|\sqrt{\times}$ A3T| $\sqrt{(\text{短})}|\sqrt{(\text{短})}|\times$ Demucs| $\times|\sqrt{\times}|\times$ Voicebox| $\sqrt{(\text{短})}|\sqrt{(\text{短})}|\sqrt{(\text{短})}$

5.2 单语零样本TTS

表2展示了英语模型VB-En的零样本TTS结果。遵循[Wang et al., 2023]，测试集通过从Librispeech test-clean中选择4到10秒长的样本来构建。

表2: 在过滤后的LS test-clean上的英语零样本TTS结果。“-”表示结果不可用。我们通过与作者沟通获得了VALL-E续写的SIM结果。

模型|WER|SIM-o|SIM-r|QMOS|SMOS 真实值|2.2|0.754|n/a|3.98±0.14|4.01±0.09 跨句子|A3T|63.3|0.046|0.146|-| YourTTS|7.7|0.337|n/a|3.27±0.13|3.19±0.14 VALL-E|5.9|-|0.580|-| VB-En|1.9|0.662|0.681|3.78±0.10|3.71±0.11 续写|A3T|18.7|0.058|0.144|-| VALL-E|3.8|0.452*|0.508|-| VB-En ($\alpha = 0.7$)|2.0|0.593|0.616|-|

5.3 跨语言零样本TTS

表3和表4展示了跨语言零样本TTS结果，其中音频上下文和目标文本使用不同的语言。注意，VB-Multi并未在任何包含同一说话人话语中多种语言的样本上进行训练。测试集使用附录A.4中描述的过滤后的MLS测试划分构建。对于每个目标文本，我们从每种语言中采样一个3秒长的音频上下文，总共创建了36种语言迁移方向。

Voicebox在所有方面都优于YourTTS。具体来说，在YourTTS支持的英/法/葡语上，Voicebox在六种语言的音频上下文中平均实现了 3.1%/5.9%/8.1% 更低的WER和 0.136/0.141/0.160 更高的相似度。Voicebox的平均音频相似度MOS比YourTTS高0.59（3.89 vs 3.30），平均质量MOS高0.27（3.50 vs. 3.23）。

表3: 在过滤后的MLS测试集上的多语言零样本TTS结果。GT/YT/VB-Multi 分别指真实值/YourTTS/多语言Voicebox。“Ref”列显示音频上下文语言。

参 考	德 语	英 语	西 班 牙 语	法 语	波 兰 语	葡萄牙语	WER SIM-o WER SIM-o WER SIM-o WER SIM-o WER SIM-o 真实值 5.9 0.725 5.0 0.636 4.1 0.729 5.2 0.714 4.9 0.743 5.8 0.725	Y T 德 语 英 语 西班牙 语 法 语 波兰 语 葡萄牙 语	VB-Multi ($\alpha = 1$. 均 n/a n/a 7.5 0.263 德 语 4.8 0.632 4.8 英 语 5.9 0.435 4.2 西班牙 语 4.9 0.460 4.3 法 语 4.9 0.476 4.3 波兰 语 4.7 0.491 3.8 葡萄牙 语 4.9 0.422 4.6 平 均 5.0 0.486 4.4
								Y T 德 语 英 语 西班牙 语 法 语 波兰 语 葡萄牙 语	V B - M u l t i (α = 1 . 均 n/a n/a 7.5 0.263 德 语 4.8 0.632 4.8 英 语 5.9 0.435 4.2 西班牙 语 4.9 0.460 4.3 法 语 4.9 0.476 4.3 波兰 语 4.7 0.491 3.8 葡萄牙 语 4.9 0.422 4.6 平 均 5.0 0.486 4.4

表4: 在过滤后的MLS英语测试集上，使用不同语言提示的跨语言零样本TTS SMOS/QMOS结果。YT/VB-Multi 分别指YourTTS/多语言Voicebox。“Ref”显示音频上下文语言。

|参考=德语|参考=英语|参考=西班牙语|参考=法语|参考=波兰语|参考=葡萄牙语 YT|3.26±0.11|3.24±0.11|3.22±0.12|3.48±0.10|3.26±0.09|3.38±0.11 VB-Multi ($\alpha=1.0$)|3.89±0.10|3.93±0.08|3.84±0.10|3.92±0.09|3.81±0.08|3.96±0.09 YT|3.29±0.12|3.17±0.13|3.29±0.12|3.08±0.12|3.35±0.12|3.21±0.12 VB-Multi ($\alpha=1.0$)|3.67±0.09|3.48±0.09|3.45±0.11|3.31±0.12|3.75±0.11|3.35±0.13

5.4 瞬态噪声去除

我们通过将第5.2节中过滤后的Librispeech test-clean与非语音噪声以-10dB的信噪比混合，使其与 50% 的时长重叠，来构建一个带噪测试集。注意，对于像A3T和Voicebox这样的填充模型，瞬态噪声的类型和SNR不会影响性能，因为被损坏的片段被完全掩码，并且语音被重新生成，独立于被损坏的片段。附加条件的结果见附录B.4。

表5展示了Voicebox与A3T和Demucs的比较结果。应注意，A3T和Voicebox利用转录和噪声的位置，而Demucs则没有。尽管如此，该研究的目标是提出一个新的范式，并展示Voicebox可以在未被明确训练的情况下执行去噪。与基线相比，Voicebox在这种具有挑战性的噪声条件下生成的样本更加易懂（2.0% WER），与音频的清晰部分更相似（0.612 SIM-o），并且质量更高（3.87 MOS）。A3T在可懂度和质量方面优于Demucs，但填充的语音不连贯，因为它仅在VCTK上训练，无法泛化到新的音频风格。

表5: 瞬态噪声去除, 其中噪声与 50% 的语音重叠, SNR为-10dB。

模型|WER|SIM-o|QMOS 清晰语音|2.2|0.687|4.07±0.15 带噪语音|41.2|0.287|2.50±0.15 Demucs|32.5|0.368|2.86±0.17 A3T|11.5|0.148|3.10±0.15 VB-En ($\alpha=0.7$)|2.0|0.612|3.87±0.17

5.5 多样本语音采样及其在ASR数据生成中的应用

表6比较了为Librispeech test-other文本生成多样本的能力。我们考虑带有回归 (regr) 或流匹配 (FM) 时长模型的英语Voicebox (VB-En)。VITS-VCTK额外以说话人ID为条件, 我们为每个句子随机采样一个。YourTTS以文本和参考音频为条件, 我们从LS训练划分中抽取。

定性地看, A3T在未以音频上下文为条件时生成相同的机器声音, 而VITS-LJ生成高质量但单一的声音, 因此两者都产生较高的FSD (质量或多样性差), 但VITS-LJ的WER较低。VITS-VCTK改善了声音多样性和FSD, YourTTS由于在更多说话人上训练而进一步提升了它。Voicebox模型 (使用不同的时长采样器) 在FSD上大幅优于基线, 展示了Voicebox产生逼真且多样样本的能力, 其分布接近训练数据。其中, FM时长模型相比回归模型产生了更多变的说话风格, ASR可能更难识别。Voicebox甚至产生了比Librispeech test-other划分的真实样本更低的FSD, 因为后者只包含数十个说话人, 多样性有限。

接下来, 我们仅使用合成语音训练一个ASR模型, 并在真实语音上评估, 这在以前从未成功过, 因为合成数据不够逼真和具有代表性。

表6: 从LS test-other文本生成多样本语音。

模型|WER|FSD 真实值|4.3|171.1 需要额外输入|VITS-VCTK|10.6|306.6 YourTTS (参考=LS训练)|9.0|277.9 仅文本|A3T|37.9|373.0 VITS-LJ|5.6|344.2 VB-En ($\alpha = 0$, 时长=regr)|3.1|155.7 VB-En ($\alpha = 0$, 时长=FM, $\alpha_{dur} = 0$)|5.6|159.8

表7: 在真实或合成语音上训练的ASR模型在真实语音上的性能, 使用或不使用4-gram语言模型解码。

ASR训练数据	真实数据上的WER	无LM test-c test-o 4-gram LM test-c test-o	真实音频 (100小时) 9.0 21.5 6.1 16.2	真实音频 (960小时) 2.6 6.3 2.2 5.0	VITS-LJ 58.0 81.2 51.6 78.1	VITS-VCTK 33.8 55.5 30.2 53.1	YourTTS (参考=LS训练) 25.0 54.6 20.4 51.2	VB-En ($\alpha = 0$, 时长=regr) 7.1 17.6 6.5 14.6	VB-En ($\alpha = 0$, 时长=FM, $\alpha_{dur} = 0$) 3.1 8.3 2.6 6.7

表7比较了来自Voicebox和三个基线模型的真实数据和合成数据。每个TTS模型为Librispeech训练集中的每个文本生成一个样本, 每个系统产生28.1万个话语。对于真实数据, 我们考虑train-960和train-clean-100。关于ASR模型和训练配置的细节见附录A.5。

结果与合成数据的FSD分数高度相关。VITS-LJ给出了最差的结果, 因为合成语音只有一个声音。YourTTS在test-clean上表现更好, 但在test-other上与VITS-VCTK相似。这表明, 虽然YourTTS在更多声音上训练并能生成具有更高声音多样性的语音, 但它仍然无法产生逼真的带噪语音, 因此生成的ASR模型在test-other上仍然表现不佳。

两个Voicebox变体都大幅优于基线。特别是, 当使用FM时长模型时, Voicebox生成更多样化的语音, 这在用于训练时会产生更好的ASR系统。与基线相比, 在使用Voicebox数据 (带FM时长模型) 训练的ASR模型上, WER降低了超过 85%, 并且仅落后于真实数据 0.4% 和 1.7% 的绝对值。

5.6 推理效率与性能的权衡

我们检查了由用户指定的不同引导强度 (α) 和NFE设置下, 相关指标 (WER、SIM、FSD) 的权衡。图5a显示了Voicebox在NFE变化时生成10秒音频样本 (包括声码化和预测时长) 的推理时间, 并与VALL-E进行比较。在无CFG、NFE=2时, Voicebox耗时约0.31秒, 比VALL-E快约20倍。在NFE=64时, Voicebox仅比VALL-E慢 4%。

接下来, 我们研究第5.2节的跨句子设置, 以分析对WER和SIM-r的影响。我们发现, 在所有设置下, Voicebox的WER都优于VALL-E。如图5b所示, WER保持稳定, 均值为2.0, 方差为0.005。图5c显示, 在SIM-r方面, 较低的分类器引导强度值 ($\alpha = 0$ 或0.3) 在较低的NFE设置 (≤ 4) 下产生更高的说话人相似度。然而, 从NFE=8开始, 更高的分类器引导强度会提高说话人相似度。

最后, 在图5e中, 我们通过为Librispeech test-other文本生成样本来检查FSD。我们发现较低的分类器引导强度产生较低的FSD分数和更多样的样本。增加每种设置的NFE都会改善FSD。图5d显示了相同测试案例的WER。我们发现, 对于 $\alpha = 0$, 当NFE从2增加到32时, WER从2.8略微增加到3.1。对于更大的分类器引导强度, WER保持更稳定。通过FSD和主观听觉, 我们发现较低的NFE会导致生成较少多样化的样本, 特别是当引导权重较低时 ($\alpha = 0$ 或0.3)。虽然这些样本质量较低, 但它们更容易被ASR模型识别, 因为它们往往不包含极端的音频风格, 如耳语或高背景噪声。因此, WER较低。

图5: NFE与不同指标之间的权衡。使用CFG时推理时间将翻倍。

5.7 上下文长度如何影响单语和跨语言零样本TTS

单语: 对于第5.2节中的上下文零样本TTS, 我们使用了3.0秒的提示音频。这里我们使用目标文本的回归时长模型得出的时长, 检查WER/SIM-r如何随不同数量的提示音频变化。如果所需的提示长于可用的音频, 则使用较短的音频作为提示。结果如图6所示。如预期, WER略有下降, SIM-r快速增长并随着更长的音频提示而趋于平缓。与VALL-E相比, Voicebox在利用音频提示方面更高效, 使用大约三分之二的输入音频即可达到与VALL-E相同的说话人相似度。

图6: 对于零样本TTS任务5.2, WER和SIM-r作为提示音频时间 (秒) 的函数。音频使用无分类器引导强度 (α) 为0.7和中点ODE求解器 (NFE为32) 生成。蓝色线为Voicebox, 红色星号为3秒时的VALL-E。对于更长的提示 (最长10秒), 说话人相似度 (SIM-r) 保持不变。

跨语言: 这里我们研究在跨语言零样本TTS情况下增加提示长度的影响。如5.2所述, 此设置对于每对源语言和目标语言共有36种语言迁移方向。对于给定迁移设置中的每个目标文本, 我们检查WER/SIM-o⁷ 如何随提示长度增加而变化。类似地, 对目标文本使用回归时长模型。图7和图8分别绘制了SIM-o (说话人相似度) 和WER的趋势。当将提示拼接到MLS的目标时, 我们发现样本比模型训练时的长度 (最大16秒) 要长得多, 因为MLS测试集样本平均约15秒长。为缓解这个超出领域的问题, 并将研究重点放在改变提示长度上, 我们将目标序列截断为4秒 (在词边界处)。我们注意到WER高于表3, 可能是因为ASR模型在处理不完整的句子时存在困难。每个子图包含来自所有六种源语言的、针对一种目标语言的趋势。

说话人相似度随着提示长度的增加而持续提高, 类似于单语设置。相比之下, 我们发现对于大多数方向, WER随着提示长度的增加而增加。对于 En $\rightarrow$ 非英语方向, WER增加得更多。我们假设这是由于训练数据跨语言的不平衡, 其中英语占多语言训练数据的 90% 以上。因此, 当从英语迁移时, 随着提示长度的增加, 模型更可能假设整个句子都是英语, 并为非英语目标产生不正确的发音。注意, 在训练阶段, 模型仅接触到来自单一语言的音频样本和音素。

图7: 每个子图考虑六种目标语言之一, 并显示SIM-o (说话人相似度) 作为跨语言风格迁移中来自不同源语言的提示音频时长 (秒) 的函数。我们设置无分类器引导强度 (α) 为1.0, 并使用中点ODE求解器, NFE为32。

图8: 每个子图考虑六种目标语言之一, 并显示WER作为跨语言风格迁移中来自不同源语言的提示音频时长(秒)的函数。我们发现除“英语”到“X”风格迁移外, 所有情况的WER都保持在合理低水平。我们设置无分类器引导强度 (α) 为1.0, 并使用中点ODE求解器, NFE为32。

5.8 生成式建模方法的消融

在本节中, 我们比较了三种生成式建模方法: 提出的带OT路径的流匹配 (FM w/ OT)、带方差保持 (VP) 扩散路径的流匹配 (FM w/ diff) 以及带VP扩散路径的分数的匹配 (SM w/ diff)。后两个目标对相同的概率路径进行建模, 但它们预测不同的对象 (向量场 vs 分数函数)。采用8.1中描述的简化设置, 学习率降低 ($1e-4$) 并在所有帧上计算损失 (公式(5)), 以确保所有三个目标都能收敛。

我们改变训练和推理步数, 并在零样本TTS任务 (第5.2节) 上评估模型。表8的结果显示, FM w/ OT的训练速度显著快于其他两个目标, 在10万训练步时达到最佳性能, 甚至仅用5万次更新就优于SM w/ diff。表9的结果显示FM w/ OT具有优越的推理效率, 仅需8次NFE即可产生良好结果, 而FM w/ diff至少需要16次NFE, SM w/ diff则需要超过64次NFE。完整结果见表B4。

表8: 比较不同目标在训练效率上的表现。推理时使用32次NFE。每个模型在单语零样本TTS任务上评估。

方	更新	更新	更新=150K WER SIM-o WER SIM-o WER SIM-o FM w/ OT (提出的) 2.5 0.424 2.2 0.487 2.1 0.508 FM w/												
法	=50K	=100K	diff 76.0 0.066 3.1 0.344 2.6 0.478 SM w/ diff 73.3 0.062 17.4 0.176 5.1 0.349												

6 伦理声明

我们认识到一个能够以任意人物风格生成语音的模型的潜在风险。为降低这些风险, 我们展示了一个二元分类模型能够持续区分真实世界语音和我们模型生成的语音。

受[Kharitonov et al., 2023]启发, 我们训练了一个卷积二元分类模型来区分真实和生成的语音。该模型由6个块组成, 隐藏维度大小为: [64, 128, 256, 256, 512, 512]。每个块包含一个沿时间轴的 (3×1) 卷积、一个沿频率轴的 (1×3) 卷积, 后跟ReLU激活和批归一化。在每个增加隐藏维度大小的块之后, 我们还应用步幅为2的最大池化, 跨越时间和频率两个维度。最后, 应用全局最大池化, 一个线性层将其投影到单个值, 该值被馈入二元交叉熵损失。在推理时, 我们创建一个步长为250ms的滑动窗口, 将每个音频块通过分类器运行, 并平均输出。

该模型在Librispeech的dev-clean划分上进行测试。然后, 我们从6万小时的英语数据中取出一个100小时的子集, 并留出2703个随机话语 (以匹配dev-clean的大小) 作为验证划分。来自100小时子集的剩余话语用作训练的真实话语。对于每个划分, 我们通过掩码该划分中每个话语的频谱图中对应于该话语 90%、50% 和 30% 音素的帧来合成音频。所有样本均使用无分类器引导生成, $w = 0.7$, 中点ODE求解器 (步长0.0625 / NFE=64), 以及回归时长模型。

我们考虑两个检测任务。第一个是区分原始音频和Voicebox生成的音频。第二个是区分重合成音频和Voicebox生成的音频。重合成音频通过从原始音频中提取梅尔频谱图, 然后用HiFi-GAN声码器进行声码化来创建。

表10展示了每种设置的结果。该模型可以轻易区分原始音频和Voicebox生成的音频。这源于这样一个事实: 模型也可以轻易区分原始音频和重合成音频, 很可能是通过识别声码器产生的伪影。区分Voicebox生成的音频和重合成音频的任务要困难得多。当 90% 的音频被掩码时, 模型能够可靠地将音频分类为Voicebox生成的。在较低的掩码设置下, 这有所下降, 但这很可能是由于一种朴素的推理方法, 即对所有滑动窗口的输出进行平均。由于大多数窗口是非合成的, 这导致了误分类。

表10: 合成语音检测指标

% 掩码 准确率 精确率 召回率																							
原始音频 vs Voicebox生成的音频						30%	1.000	1.000	1.000	50%	1.000	1.000	1.000	重合成音频 vs Voicebox生成的音频		30%	0.704	0.714	0.680	50%	0.809	0.796	0.831
90%						1.000	1.000	1.000							90%	0.907	0.881	0.942					

7 结论与讨论

本文介绍了Voicebox, 用途最广的语音生成模型。通过学习在大规模多语言数据集上使用强大的模型和训练目标解决文本引导的语音填充任务, Voicebox展示了令人印象深刻的任务泛化能力。Voicebox在单语和跨语言零样本TTS、语音修复和多样本语音采样方面达到了最先进的性能, 并且生成语音的速度比最佳的自回归模型快20倍。

局限性。本文中展示的Voicebox模型是在多达六种书面语言的有声读物朗读语音上训练的。因此, 当前的模型可能无法很好地迁移到会话语音[Godfrey et al., 1992], 这种语音更随意, 包含更多非语言声音, 如笑声和回馈信号 (例如, um-hmm)。我们计划通过扩展训练数据以纳入更多样化的语音来解决这个问题。

另一方面, Voicebox依赖音素化器和强制对齐器来生成帧级音素转录。此外, 许多现有的音素化器[McAuliffe et al., 2017]是基于词的, 在预测发音时不考虑目标的相邻词。这种音素化器无法根据文本准确预测音素转录, 因为在许多语言中发音是上下文相关的 (例如, 法语中的连音)。未来, 我们将探索更端到端的方法, 使模型能够接收带标点的原始文本作为输入[Casanova et al., 2021], 并消除对音素化器和强制对齐器的需求, 以提高性能并增加语言覆盖范围。

最后, 虽然Voicebox在迁移音频风格 (声音、说话风格、情感和声学条件) 方面取得了令人印象深刻的结果, 但该模型不允许对每个属性进行独立控制。换句话说, 人们无法要求模型生成的声音类似于一个样本的声音, 而情感类似于另一个样本。我们将通过提示或文本描述进行属性的解耦控制留作未来工作。

更广泛的影响。像Voicebox这样高质量且用途广泛的通用语音生成模型可以启用许多改善我们生活质量的应用程序。例如, 零样本TTS可以为因疾病或手术 (如喉切除术) 导致无法说话的人恢复声音。零样本TTS也可以与视觉语音识别系统[Hsu et al., 2022]结合, 以避免打字的需要。当与语音翻译模型配对时, 跨语言零样本TTS使每个人都能用自己的声音说任何语言。内容编辑和语音去噪可以成为用户更轻松地创建内容的效率工具。如本文所示, 多样本语音采样可以显著降低为训练语音输入模型创建数据的成本。

虽然Voicebox可以带来许多积极的社会影响, 但它也带有潜在的滥用和非预期伤害的风险。为降低风险, 我们在第6节中展示了一个高效的分类器, 表明该模型可以准确区分真实和合成语音。对于未来的工作, 我们还计划研究训练生成模型的主动方法, 以便合成语音可以更容易被检测到, 例如嵌入人工指纹[Yu et al., 2021], 这些指纹可以轻易被检测到而不会损害语音质量。

为防止Voicebox学习偏见, 我们还需要仔细选择其训练数据。首先, 如果Voicebox仅在一个特定群体的较少说话人上训练, 且具有相似的口音, 它将无法生成代表全球口音的多样化语音, 并且在Voicebox生成的语音上训练的下游模型将在代表性不足的口音群体上表现更差。对于零样本风格迁移, 代表性不足的口音的性能也会下降。为缓解这一问题, 我们利用了包含多种口音的野外语音, 并将继续投资于收集多样化的语音以避免此类偏见。

其次, 如果Voicebox在这样一个数据集上训练: 其中一个族群的样本始终具有较低的音频质量 (例如, 更多噪声), 而另一个族群的样本始终具有较高的音频质量, 那么模型也会学习到不期望的关联。为缓解这一问题, 我们希望音频质量 (和其他音频属性) 与族群之间的分布相关性较低, 这通常是我们从野外来源收集更大规模数据时的情况。我们可以通过利用数据增强来去相关分布来进一步解决这个问题, 例如添加噪声和增强语音以拓宽音频质量分布。

致谢

作者感谢Kristin Lauter和Joelle Pineau对该项目的支持，感谢Ricky Chen、Yaron Lipman、Alexandre Defossez、Gabriel Synnaeve进行的技术讨论，感谢Jade Copet和Gabriel Synnaeve提供的计算支持，感谢Eleonora Presani和Jackie Pan讨论负责任AI研究，感谢William Ngan、Somya Jain、Lydia Baillargeon、Dana Beaty、Chantal Mora、Daniel Duncan、Gopika Jhala、Steph Miles、Josh Terry、Valeryia Aranovich、Ashton Evans、Aly Gill、Andrea Mileskiewicz、Emily Richards和Aaron Vasquez开发视觉资产和网站，感谢Alyssa Newcomb和Oliver Libaw开发帖子，感谢Peter Gray、Natalie Hereth、Shauna Kelleher、Ashley Gabriel、Seine Kim、Ana Paula Kirschner Mofarej和Aiman Farooq协调发布，感谢Harrison Rudolph、Mallika Malhotra、Carolyn Krol、Lauren Cohen和Mo Metanat进行审查，并感谢Alexandra Gualdino、Ana Paula Kirschner Mofarej、Benjamin Muller、Chloe Rolland、Daniella Kalfa、Darcie Da Silva、Gabriel Synnaeve、Hunter Goldman、Juan Pino、Karen Ulrich、Kris Sekula、Manuel Ribeiro、Marina Zannoli、Mary Williamson、Rashel Moritz、Stephanie Castillo、Tu Anh Nguyen、Vlad Sobal、Volker Seeker以及为演示分享语音样本的匿名志愿者。