

好的，这是根据你提供的VoiceCraft论文PDF翻译的中文版本。我已严格按照要求，去除了参考文献部分，并完整保留了原文的结构、所有内容、公式、表格和图表示意，其中“token”一词根据指示未作翻译。

VoiceCraft: 野外环境下的零样本语音编辑与文语转换

Puyuan Peng¹, Po-Yao Huang², Shang-Wen Li², Abdelrahman Mohamed³, David Harwath¹ ¹ 德克萨斯大学奥斯汀分校 ² FAIR, Meta ³ Rembrand pyp@utexas.edu

摘要

我们介绍了 VoiceCraft，一个神经编解码器语言模型，它通过token填充的方式，在有声书、网络视频和播客上实现了语音编辑和零样本文语转换（TTS）的最先进性能¹。VoiceCraft采用Transformer解码器架构，并引入了一种token重排流程，该流程结合了因果掩码和延迟堆叠，以实现在现有序列中的生成。在语音编辑任务上，VoiceCraft生成的编辑后语音在自然度方面，据人类评估，几乎与未编辑的录音无法区分；对于零样本TTS，我们的模型优于先前的SotA模型，包括VALL-E和流行的商业模型XTTS v2。关键在于，这些模型是在具有挑战性和现实性的数据集上评估的，这些数据集包含多样的口音、说话风格、录音条件以及背景噪声和音乐，而我们的模型相比于其他模型和真实录音表现出一致的优越性能。特别地，对于语音编辑评估，我们引入了一个高质量、具有挑战性且现实性的数据集，名为REALEDIT。我们鼓励读者在https://jasonppy.github.io/VoiceCraft_web 上收听演示。

1 引言

我们介绍了VoiceCraft，一个基于Transformer的神经编解码器语言模型（NCLM），它以双向上下文为条件，自回归地执行神经语音编解码器tokens的填充生成。VoiceCraft在语音编辑（如图1所示）和零样本TTS上都取得了最先进的性能。我们的方法基于一个两步token重排流程，包括因果掩码步骤和延迟堆叠步骤。因果掩码技术的灵感来自于因果掩码多模态模型在联合文本-图像建模中的成功（Aghajanyan et al., 2022），而我们提出的技术适用于语音编解码器序列，这使得具有双向上下文的自回归生成成为可能。此外，我们进一步将因果掩码与延迟堆叠（Kharitonov et al., 2021a; Copet et al., 2023）整合为我们提出的token重排流程，以确保高效的多码本建模。

为了评估语音编辑，我们手工制作了一个首创的、现实且具有挑战性的数据集，名为REALEDIT。REALEDIT包含310个真实世界的语音编辑示例，波形来源于有声书（Zen et al., 2019）、YouTube视频（Chen et al., 2021a）和Spotify播客（Clifton et al., 2020），时长范围从5秒到12秒。为了创建目标转录，源语音的转录被编辑，使得编辑后的转录在语法上保持正确且在语义上连贯。该数据集旨在覆盖广泛的编辑场景，包括插入、删除、替换和多跨度编辑，编辑文本的长度从1个单词到16个单词不等。与仅包含有声书的常用语音合成评估数据集（如VCTK（Yamagishi et al., 2019）、LJSpeech（Ito and Johnson, 2017）和LibriTTS（Zen et al., 2019））相比，REALEDIT更具挑战性，因为其中的录音具有多样化的内容、口音、说话风格、录音条件和背景声音。我们相信REALEDIT的真实性和多样性使其成为语音编辑模型在现实世界中实用性的可靠指标。

图1: 使用VoiceCraft进行语音编辑。在并排自然度比较中，人类听者将VoiceCraft编辑的语音偏好于原始真实录音的比例达 \(\approx 48\%\)（详见§5.3）。

在主观听力测试中，VoiceCraft在REALEDIT上显著优于先前最先进的语音编辑模型。重要的是，VoiceCraft产生的编辑后语音在自然度方面几乎与原始未编辑录音无法区分。我们发现VoiceCraft无需任何微调即可很好地泛化到零样本TTS，在一个由有声书和YouTube视频组成的数据集上取得了SotA性能，优于强大的基线模型，包括复现的VALL-E（Wang et al., 2023a）和流行的商业模型XTTS v2（COQUI, 2023）。总之，我们的贡献是：

1. 我们引入了VoiceCraft，一个用于语音编辑的神经编解码器语言模型，据人类听者判断，其合成的语音几乎与野外录音无法区分。我们还发布了VoiceCraft的代码和模型权重。
2. 我们展示了VoiceCraft无需微调即可很好地泛化到零样本TTS。
3. 我们发布了一个高质量、具有挑战性且现实性的语音编辑评估数据集REALEDIT。

2 相关工作

神经编解码器语言模型 (NCLM) 与零样本TTS。 将语音信号分词为可学习的离散单元序列，然后在该单元序列上训练语言模型，最初是在无文本NLP的背景下提出的 (Hsu et al., 2021; Lakhota et al., 2021; Kharitonov et al., 2021b; Nguyen et al., 2022)，其目标是在口语话语上直接执行NLP任务，而无需先将语音转录为文本。近来，基于残差向量量化 (RVQ) 模型 (Zeghidour et al., 2021; Defossez et al., 2022) 的token上运行的NCLM因其高质量的生成而受到越来越多的关注。例如，AudioLM (Borsos et al., 2022a) 在长期连贯语音续写方面表现出强大的性能。零样本TTS是一个任务，其中模型需要在给定目标转录和目标说话人的短参考录音的情况下，以训练期间未见过的目标声音合成语音。将零样本TTS框架化为转录条件下的语音续写，VALL-E (Wang et al., 2023a) 和Spear-TTS (Kharitonov et al., 2023) 是该任务上NCLM的首批应用，显著优于非NCLM方法。Zhang et al. (2023) 将VALL-E扩展到跨语言TTS。Guo et al. (2022) ; Yang et al. (2023) ; Liu et al. (2023) ; Ji et al. (2023) ; Lyth and King (2024) 将NCLM适配于风格可控的语音合成。Song et al. (2024) ; Du et al. (2024b) 增强了NCLM中的音素对齐以减少错误。Wang et al. (2023b) 提出了一个统一的NCLM用于语音生成和识别任务。Borsos et al. (2023) 提出了一种高效的并行解码方法。Jiang et al. (2024) 提出了解耦的音色和韵律建模，其中后者使用NCLM建模。NCLM也已成功应用于其他音频领域。Kreuk et al. (2022) 将NCLM应用于音效生成，而Agostinelli et al. (2023) ; Donahue et al. (2023) ; Garcia et al. (2023) ; Copet et al. (2023) 使用NCLM进行音乐生成。

语音编辑。 该任务要求模型更改话语中的单词或短语以匹配目标转录，但未指定编辑的原始语音区域必须保持不变 (参见图1的示例)。早期的方法通过组合单说话人TTS模型和语音转换模型来生成所需的语音片段，然后将其与未编辑部分拼接，从而实现文本引导的语音插入和替换 (Jin et al., 2017)。由于生成不以语音的未编辑部分为条件，结果因韵律不匹配和边界伪影而不自然 (Morrison et al., 2021)。较新的语音编辑模型试图以其周围的语音上下文为条件进行生成。Tan et al.

(2021) 使用了两个带有双向融合的单向LSTM模型。Wang et al. (2022) ; Bai et al. (2022) ; Borsos et al. (2022b) 使用带卷积或Transformer模型的掩码重建目标进一步改善了上下文文化。FluentSpeech (Jiang et al., 2023b) 是一个基于扩散的语音编辑模型，在LibriTTS和VCTK上达到了SotA性能。

研究界开始探索拥有一个同时用于零样本TTS和语音编辑的统一模型的可能性。Yin et al. (2022) ; Jiang et al. (2023a) 提出了针对这两个任务的模块化模型，而我们的模型是端到端的。同期工作SpeechX (Wang et al., 2023c) 通过提示微调将VALL-E适配于包括语音编辑和零样本TTS在内的任务范围，但其论文中未进行人工评估。同期工作UniCATS (Du et al., 2024a) 是一个用于这两个任务的基于扩散的模块化模型。然而，他们的模型仅在跨度长度小于2秒的掩码语音重建上进行了评估，而我们的模型在长达16个单词的编辑上进行了评估。Voicebox (Le et al., 2023) 是一个最近的基于流匹配模型，能够处理包括语音编辑和零样本TTS在内的广泛任务。然而，其语音编辑能力并未在其论文中评估，仅在其演示页面上展示。因此，我们在演示页面上使用其演示页面中的相同示例，将我们模型的编辑结果与Voicebox的进行了比较。

3 方法

VoiceCraft通过重排神经编解码器的输出token，将序列填充（用于语音编辑）和续写（用于零样本TTS）都转化为简单的从左到右的语言建模。重排涉及两个步骤：(1) 因果掩码 (§3.1) 以启用具有双向上下文的自回归续写/填充，以及 (2) 延迟堆叠 (§3.2) 以确保高效的多码本建模。VoiceCraft采用解码器-only的Transformer，并使用自回归序列预测进行训练 (§3.3)。我们在§3.4中介绍了用于语音编辑和零样本TTS的推理设置。

3.1 重排步骤1：因果掩码

如图2左侧所示，给定一个连续语音波形作为输入，我们首先使用Encodec (Defossez et al., 2022) 将其量化为一个 T 行 K 列的编解码器矩阵 X ，其中 T 是时间帧数， K 是RVQ码本的数量。 X 可以写成 $(X_1, \dots, X_T)$ ，其中 X_t 是长度为 K 的向量，表示时间步 t 处来自不同码本的编码，并且我们假设来自码本 k 的编码对来自码本 $k-1$ 的残差进行建模。在训练期间，我们的目标是随机掩码一些token跨度 $(X_{t_0}, \dots, X_{t_1})$ ，然后以所有未掩码token为条件自回归地预测这些被掩码的token。当 $t_1 < T$ 时，这是一个问题，因为我们无法在执行自回归生成时以未来输出为条件。我们需要修改对 X 的掩码使其成为因果的，方法是将要被掩码的跨度移动到序列的末尾，以便在填充这些token时，模型可以以过去和未来的未掩码token为条件 (Aghajanyan et al., 2022; Donahue et al., 2020; Bavarian et al., 2022)。

上述过程可以简单地扩展到多个被掩码的跨度，只需将所有被掩码的跨度移动到序列的末尾即可。要被掩码的跨度数量 n 从泊松分布 (λ) 中采样，然后对于每个跨度，我们采样一个跨度长度 $l \sim \text{Uniform}(1, L)$ 。最后，我们在 X 内随机选择这些跨度的位置，约束它们彼此不重叠。选定的 n 个跨度然后被替换为掩码token $\langle \mathbf{M}_1 \rangle, \dots, \langle \mathbf{M}_n \rangle$ 。这些被掩码跨度内的原始token被移动到序列 X 的末尾，每个跨度前面有其对应的掩码token。

考虑这个例子：设 $X = (X_1, \dots, X_6)$ ，假设我们希望掩码从 X_2 到 X_4 的一个跨度。原始序列 X 被重排为 $Y = (Y_1; \langle \mathbf{M}_1 \rangle; Y_2; \langle \mathbf{M}_1 \rangle; Y_3)$ ，其中 $Y_1 = (X_1)$ ， $Y_2 = (X_5, X_6)$ ，以及 $Y_3 = (X_2, X_3, X_4)$ 。我们称 Y_1 和 Y_2 为未掩码跨度， Y_3 为被掩码跨度。在每个被掩码跨度的末尾添加一个跨度结束或EOS token（在此例中位于 Y_3 的末尾），并在话语的末尾（即 Y_2 ）添加一个话语结束或EOU token。为简洁起见，我们未明确表示这些特殊token，并假定它们是跨度的一部分。

3.2 重排步骤2：延迟堆叠

在因果掩码token重排之后，重排矩阵 Y 的每个时间步是一个长度为 K 的token向量。Copet et al. (2023) 观察到，当对堆叠的RVQ token执行自回归生成时，应用延迟模式是有利的，这样码本 k 在时间 t 的预测可以以同一时间步的码本 $k - 1$ 的预测为条件。我们采取了类似的方法，在此描述。假设一个跨度 Y_s 的形状为 $L_s \times K$ 。应用延迟模式将其重排为 $Z_s = (Z_{s,0}, Z_{s,1}, \dots, Z_{s,L_s+K-1})$ ，其中 $Z_{s,t}$ ， $t \in [L_s + K - 1]$ 定义为：

$$Z_{s,t} = (Y_{s,t,1}, Y_{s,t+1,2}, \dots, Y_{s,t-K+1,K}) \quad (1)$$

其中 $Y_{s,t-k+1,k}$ 表示位于矩阵 Y_s 中坐标 $(t - k + 1, k)$ 的token，即第 $(t - k + 1)$ 个时间步的第 k 个码本条目。为确保 $\forall t \in [L_s + K - 1]$ ， $Z_{s,t}$ 包含 K 个有效token，我们引入了一个特殊的可学习 [empty] token，并定义 $Y_{s,t-k+1,k} \triangleq [\text{empty}]$ ， $\forall t \in \{s : s < k \cup s - k + 1 > L_s\}$ 。注意，掩码token不属于任何跨度，并且在延迟堆叠期间不会改变。我们定义延迟堆叠的结果矩阵 $Z = (Z_1, \langle \mathbf{M}_1 \rangle, Z_2, \langle \mathbf{M}_1 \rangle, \dots, \langle \mathbf{M}_{\frac{s-1}{2}} \rangle, Z_S)$ （假设 Y 由 S 个跨度组成）。关于 Z 的图示，请参见图2中的示意图。

图2: token重排流程和建模框架示例。重排流程涉及两个步骤：(1) 因果掩码，其中被掩码的跨度被替换为掩码token并移动到末尾，以及 (2) 延迟堆叠，其中token根据其码本索引在时间维度上移位。

3.3 建模

如图2右侧所示，我们使用一个Transformer解码器以语音的转录 W 为条件，自回归地对 Z 进行建模。因此，解码器的输入是 $[W; Z]$ ，其中“;”表示拼接。在编解码器矩阵 Z 中跨度 s 的时间步 t ，模型通过使用 K 个MLP头将Transformer的最终隐藏状态投影到 K 组logits（每组对应一个码本）来同时预测 $Z_{s,t}$ 的所有 K 个token。注意，预测以转录 W 和 Z 中 $Z_{s,t}$ 之前的所有token（记为 $H_{s,t}$ ）为条件。数学上，Transformer解码器对 Z 的因式分解条件分布进行建模：

$$\begin{aligned} \mathbb{P}_\theta(Z|W) &= \prod_s \prod_t \mathbb{P}_\theta(Z_{s,t}|W, H_{s,t}) \\ &= \prod_s \prod_t \prod_{k=1}^K \mathbb{P}_\theta(Z_{s,t,k}|W, H_{s,t}) \end{aligned} \quad (3)$$

其中 θ 表示模型的参数。公式2是跨时间步的自回归分解，而公式3是在给定独立性假设下跨码本的分解——给定 W 和 $H_{s,t}$ ， $Z_{s,t}$ 中的 K 个RVQ编码被假定为相互独立。我们在附录D中论证这个假设是温和的。

有了公式3中的token级概率公式，我们推导出训练损失为负对数似然 $\mathcal{L}(\theta) = -\log \mathbb{P}_\theta(Z|W) = -\sum_{k=1}^K \mathcal{L}_k(\theta)$ 。根据经验，我们发现对前几个残差码本赋予比后几个码本更大的权重会导致更好的性能，因此我们的最终损失是 $\mathcal{L}(\theta) = \sum_{k=1}^K \alpha_k \mathcal{L}_k(\theta)$ ，其中 $(\alpha_k)_{k=1}^K$ 是可调超参数。注意，我们遵循Aghajanyan et al. (2022)，对除掩码token和[empty] token之外的所有token（不仅是掩码跨度中的token）计算预测损失。

3.4 推理

语音编辑。 语音编辑的设置如下：我们有一个语音录音 R 及其转录 W ，我们希望模型仅修改 R 的相关跨度，使其与目标转录 W' 匹配。我们假设 W' 是 W 的编辑版本，其中一些词被插入、替换或删除。此任务与训练任务几乎完全相同，有两个不同之处：1) 在训练期间，输入转录仅仅是原始录音的转录 W ，而在推理期间，它是修改后的转录 W' ；2) 在训练期间，要被掩码（即编辑）的跨度是随机选择的。在推理期间，我们通过比较原始转录和目标转录来识别应被掩码的词来选择它们，然后使用原始转录的词级强制对齐来识别对应于这些要被掩码的词的编解码器token跨度。为确保编辑后语音与未编辑语音之间的平滑过渡，被编辑跨度周围的相邻词也需要稍微修改，以建模协同发音效应。因此，我们指定一个小的边际超参数 ϵ ，并将掩码跨度长度在左右两侧各延长 $\epsilon \wedge 3$ 。在自回归生成期间，我们向模型提供目标转录和所有未掩码跨度，并在应进行编辑的位置插入掩码token。然后我们让模型自回归地续写这个序列，从而填充被掩码的跨度。生成的编解码器token随后被拼接回话语中的正确位置，我们使用Codec解码器网络将完整的编解码器token序列映射回波形。

零样本TTS。正如我们之前指出的，我们的模型进行零样本TTS很简单，因为它仅对应于在原始话语的末尾执行一个插入编辑。在这种情况下，模型被提供一个带有其转录的声音提示，以及要生成语音的目标转录。这三个输入被拼接在一起并馈送给模型，之后它自回归地生成目标转录的编解码器序列。

4 REALEDIT：一个现实且具有挑战性的语音编辑数据集

为支持尽可能现实的评估，我们构建了一个首创的、包含310个手工制作的语音编辑示例的数据集。每个示例包含一个元组：（原始音频，原始转录，编辑后转录）。该数据集包含来自LibriTTS（dev-clean和dev-other）（Zen et al., 2019）的100个话语，来自YouTube（来自Gigaspeech测试集）（Chen et al., 2021a）的100个话语，以及来自Spotify播客数据集（Clifton et al., 2020）的110个话语。我们手动检查了话语的准确性，然后让以英语为母语的人修改它们以创建编辑后的转录。对于每个话语，我们使用编辑类型、要编辑的不连续跨度数量以及编辑跨度长度的预定义概率分布来确定修改类型。具体来说，我们研究以下类别：1）编辑跨度数量：1或2；2）编辑类型：插入、删除和替换；3）编辑跨度长度：短（1-2个词）、中（3-6个词）、长（7-12个词）。关键的是，编辑后的转录必须在语法上正确且在语义上连贯。数据集的示例见表1和表8，统计信息见表2。

表2: 语音编辑评估的数据集统计。注意，对于2跨度编辑，每个示例使用3种编辑类型中的2种进行编辑。

长度\类型\插入\删除\替换\总计	1-2词（1跨度）	8 17 38 63	3-6词（1跨度）	22 24 79 125	7-12词（1跨度）	15 11 56 82	1跨度总计	45 52 173 270	2跨度总计	13 13 54 40
1-2词（1跨度）	8 17 38 63	22 24 79 125	15 11 56 82	45 52 173 270	13 13 54 40					
3-6词（1跨度）		22 24 79 125	15 11 56 82	45 52 173 270	13 13 54 40					
7-12词（1跨度）			22 24 79 125	15 11 56 82	45 52 173 270	13 13 54 40				
1-2词（2跨度）				22 24 79 125	15 11 56 82	45 52 173 270	13 13 54 40			
3-6词（2跨度）					22 24 79 125	15 11 56 82	45 52 173 270	13 13 54 40		
7-12词（2跨度）						22 24 79 125	15 11 56 82	45 52 173 270	13 13 54 40	
总计	8 17 38 63	22 24 79 125	15 11 56 82	45 52 173 270	13 13 54 40					

5 实验

5.1 设置

数据。Gigaspeech训练集（Chen et al., 2021a）被用作训练数据，包含9k小时的16kHz采样率的有声书、播客和YouTube视频。短于2秒的音频文件被丢弃。对于消融研究，我们使用掩码重建任务，以及Gigaspeech验证集的一个1000个话语的随机子集作为测试话语（详见 §C）。对于语音编辑评估，我们使用提出的REALEDIT数据集。对于零样本TTS评估，我们从LibriTTS（Zen et al., 2019）和Gigaspeech测试集的YouTube部分构建了一个包含250个提示-转录对的数据集，每个数据集的示例各占一半。每个语音提示的长度尽可能保持在3秒左右，并施加了只允许在完整单词之间剪切音频的约束。转录是语音提示转录和目标转录的拼接。目标转录选自与提示相同说话人的不同话语，长度从8到40个词不等。我们仅选择由Whisper medium.en（Radford et al., 2022）测得的WER低于15%的话语。

模型。Encoder（Defossez et al., 2022）被用作语音分词器，具有4个RVQ码本，每个码本词汇量为2048，在16kHz录音上的编解码器帧率为50Hz（详见 §C 的详细配置）。为选择训练中要掩码的跨度数量，我们使用截断为最小1和最大3的泊松分布(1)。跨度长度从均匀分布(1, 600)中采样，即被掩码的语音最长可达12秒。在每个时间步，来自不同码本的编码嵌入被求和（Wang et al., 2023a），然后加上正弦位置编码（Vaswani et al., 2017），再馈送到Transformer。文本转录使用Bernard and Titeux（2021）提供的工具包基于IPA音素集进行音素化。我们的主要VoiceCraft模型有16个Transformer层，隐藏/FFN维度为2048/8192，以及12个注意力头。最后一层的输出被馈送到四个独立的2层MLP模块以获得预测logits。我们的主要模型有8.3亿参数，码本权重超参数 α 设置为 (5, 1, 0.5, 0.1)。关于模型大小和码本权重的消融见 §5.2。

训练与推理。Encoder模型的训练在很大程度上遵循Copet et al.（2023）中的设置，详见 §C。为训练VoiceCraft，我们使用了(Yao et al., 2024)中提出的ScaledAdam优化器和Eden调度器，基础学习率为0.05，批次大小为400k帧（即133.2分钟），总训练步数为50k，并使用梯度累积。8.3亿参数的VoiceCraft模型的训练在4张NVIDIA A40 GPU上耗时约2周。更多详情见 §C。我们在 §A.1 中比较了ScaledAdam和AdamW的性能。对于推理，我们对所有实验使用Nucleus采样（Holtzman et al., 2020）， $p = 0.8$ ，温度为1。由于自回归生成的随机性，通过手动检查我们发现，虽然大多数时候模型产生听起来自然的语音，但有时会产生过长的静音或拖长某些声音。我们发现当编解码器token生成陷入重复循环时会发生这种情况。为解决这个问题，我们使用一个简单的启发式方法：对于每个输入话语，我们生成几个不同的输出话语，并丢弃最长的输出。具体来说，对于语音编辑，我们使用不同的边际参数运行推理10次，将 ϵ 从0.05逐步增加到0.14，步长为0.01。丢弃最长的4个输出，然后我们从剩余的6个输出中随机选择一个样本。对于零样本TTS，我们按比例降低连续时间步生成相同token的概率，该比例与该token在紧邻的前几个时间步中连续生成的次数相关。此外，我们使用不同的随机种子生成5个样本，并为TTS评估选择最短的。样本选择过程完全自动且无监督（即，无需人工干预或ASR评分）。

基线。对于语音编辑，我们将VoiceCRAFT与基于扩散的模型FluentSpeech (Jiang et al., 2023b) 进行比较，后者是当前开源的语音编辑SotA模型。由于原始FluentSpeech模型是在LibriTTS上训练的，为了公平比较，我们获取了官方GitHub仓库并将模型在Gigaspeech上进行了训练。更多详情请见 §C。对于零样本TTS，我们将我们的VoiceCRAFT与VALL-E (Wang et al., 2023a)、XTTS v2 (COQUI, 2023)、YourTTS (Casanova et al., 2021) 和FluentSpeech进行比较。由于原始VALL-E未开源，我们使用了Li (2023) 提供的流行开源实现的代码，并将模型在Gigaspeech上进行了训练。XTTS v2是一个流行的商业零样本TTS模型，在公开可用数据和网络爬取数据的混合上训练，但确切的数据来源未知。YourTTS在VCTK、LibriTTS以及法语和葡萄牙语语料库上训练。

指标。对于消融研究，由于真实波形可用，除了WER（使用Whisper medium.en作为ASR模型）外，我们还使用梅尔倒谱失真（MCD）、F0距离（F0）和能量距离（Energy）。这些都是客观指标，其定义详见 §C。对于语音编辑和零样本TTS评估，我们结合使用客观和主观指标。对于客观指标，我们遵循先前工作(Wang et al., 2023a; Kharitonov et al., 2023)使用WER和说话人相似度（SIM）。SIM使用WavLM-TDCNN (Chen et al., 2021b) 计算。WER和SIM在REALEDIT中的所有310个话语以及零样本TTS数据集中的250个话语上计算。对于我们的主观评估，我们使用Amazon Mechanical Turk平台进行人工听力测试。对于语音编辑，我们模型在REALEDIT所有310个话语上的输出由Turkers在自然度和可懂度方面进行评估，我们使用5点李克特量表，其中1表示差，5表示优秀。我们还进行了VoiceCraft输出与原始（未编辑）语音以及FluentSpeech产生的编辑语音的并排A/B测试。在这两种情况下，Turkers被要求判断哪个话语听起来更自然。Turkers可以选择两者中的任何一个，或表示它们同样自然。每次评估收到来自5位不同Turkers的5个评分。对于零样本TTS，我们从原始评估集中随机抽取80个话语（40个来自LibriTTS，40个来自YouTube），并让Turkers在5点李克特量表上对生成语音相对于参考提示的自然度、可懂度和说话人相似度进行评分。每次评估收到10个评分。对于除并排比较之外的所有评估，报告了具有95%置信区间的平均意见分数（MOS）。对于并排比较，我们报告一个模型优于另一个模型的时间百分比。分别有64位和59位Turkers参与了语音编辑和TTS评估。请参阅 §E 了解说明和参与者描述。

5.2 消融

在表3中，我们看到更大的模型尺寸在所有指标上都带来了更好的性能。此外，我们看到较大模型之间的差距更大，表明进一步扩展模型（可能还有训练数据）规模的潜力。关于码本重加权的影响，我们看到对早期码本赋予更大权重会导致与可懂度相关的指标WER和MCD性能更好，而与韵律相关的指标F0和Energy性能较差。我们在最终的8.3亿模型中选择权重 (5, 1, 0.5, 0.1)，因为据观察，VoiceCRAFT在韵律方面比在可懂度方面更强（关于NCLM的类似属性也在 (Jiang et al., 2023a; Song et al., 2024; Du et al., 2024b) 中发现）。

表3: 扩展模型大小和码本重加权的影响。所有指标越低越好。

参数\权重	WER	MCD	F0	Energy
120M (1,1,1,1)	10.18	8.75	78.49	3.22
120M (5,1,0.5,0.1)	7.75	8.31	87.74	3.54
430M (1,1,1,1)	7.87	8.22	70.05	3.17
430M (5,1,0.5,0.1)	7.30	8.13	73.41	3.19
830M (5,1,0.5,0.1)	6.68	8.05	67.81	3.12

5.3 语音编辑结果

表4显示了语音编辑评估在WER以及可懂度和自然度的人类偏好方面的结果。我们的VoiceCRAFT在不同来源的可懂度和自然度MOS方面均优于FluentSpeech。有趣的是，FluentSpeech的WER低于原始录音（4.5对比5.4），尽管其可懂度MOS（3.97）比VoiceCRAFT（4.11）和原始录音（4.22）都差。这表明ASR模型和人类判断在FluentSpeech的可懂度上存在分歧。根据观察，我们发现FluentSpeech倾向于产生沉闷且有时机械的语音⁶，并且我们假设这种类型的语音往往更容易被ASR识别，但人耳听起来可懂度较低。我们在零样本TTS的结果中注意到了同样的现象。

人类听者对LibriTTS的自然度评分低于YouTube和Spotify的原始语音（TTS的结果与此一致）。这表明，为了更好地评估一般的语音合成，研究界应该考虑评估除有声书以外的其他语音领域，而不是像通常那样。

表5展示了VoiceCRAFT与FluentSpeech以及VoiceCRAFT与原始未编辑语音的并排话语自然度比较。我们观察到VoiceCRAFT在 56.1% 的情况下优于FluentSpeech，另外 19.7% 的情况下两者持平。这意味着 75.9% 的情况下，人类听者认为VoiceCRAFT产生与FluentSpeech相同或更自然的语音。令人印象深刻的是，人类听者认为VoiceCRAFT产生的编辑后语音在 56.4% 的情况下与原始未编辑语音同样自然或更自然。图4显示了按编辑类型和编辑跨度长度划分的并排比较的细分。我们看到与原始语音相比，VoiceCRAFT在不同编辑类型上表现一致，但人类听者认为其输出在编辑跨度较长时略微不那么自然。

表4: 语音编辑的性能比较。

模型	WER	可懂度 MOS	自然度 MOS LibriTTS YouTube Spotify 总计 LibriTTS YouTube Spotify 总计									
			FluentSpeech	4.5	3.89±0.09	4.08±0.08	3.95±0.08	3.97±0.05	3.42±0.10	4.07±0.10	3.93±0.10	3.81±0.06
			VoiceCRAFT	6.1	4.05±0.08	4.14±0.07	4.12±0.07	4.11±0.05	3.68±0.10	4.25±0.09	4.16±0.08	4.03±0.05
			原始	5.4	4.22±0.07	4.30±0.07	4.16±0.08	4.22±0.05	3.84±0.09	4.35±0.08	4.29±0.08	4.17±0.05

图3: 比较VoiceCRAFT编辑语音与原始语音的自然度并排人类偏好的细分。按编辑类型（左）和编辑跨度长度（右）分组。

表5: VoiceCRAFT (VCR) 与原始语音 (Orig.) 和 FluentSpeech (FS) 的自然度并排比较。

比较|VCR更好|持平|VCR更差 VoiceCRAFT v. FS|56.1%|19.7%|24.1% VoiceCRAFT v. Orig.|40.3%|16.2%|43.6%

5.4 零样本TTS结果

表6显示了零样本TTS的客观和主观评估结果。我们观察到VoiceCRAFT在自动说话人相似度指标SIM和所有人类评估指标上都取得了最佳结果。特别是，VoiceCRAFT在可懂度MOS（4.23对比4.39）和说话人相似度MOS（4.34对比4.44）方面仅略逊于真实值。自然度方面的差距在VoiceCRAFT和真实值之间更大（4.17对比4.48），尤其是在YouTube话语上，这突显了在有噪声的野外数据上进行零样本TTS的挑战。商业模型XTTS v2在可懂度和自然度方面排名第二，而在说话人相似度MOS方面排名倒数第二。VALL-E在自动指标SIM和主观指标说话人相似度MOS上都取得了第二好的成绩。与语音编辑结果类似，表6中真实YouTube话语获得了比真实LibriTTS话语更高的MOS分数，这再次表明我们应该考虑使用更多样化的数据用于未来的语音合成模型评估。最后，我们再次观察到FluentSpeech的WER低于真实值，但在可懂度MOS方面从人类听者那里获得了低得多的评分，表明WER在评估语音合成系统的可懂度时可能具有误导性⁷。

表6: 零样本TTS任务上，VoiceCRAFT与其他模型的比较。

模型	可懂度 MOS	自然度 MOS	说话人相似度 MOS WER SIM Libri. YouTube 总计 Libri. YouTube 总计									
			YourTTS	6.6	0.41	3.28±0.11	3.01±0.12	3.14±0.08	2.99±0.12	2.59±0.12	3.10±0.12	
			FluentSpeech	3.5	0.47	3.70±0.11	3.65±0.12	3.67±0.08	3.34±0.11	3.43±0.12	3.92±0.11	VALL-
			E	7.1	0.50	4.05±0.09	3.94±0.10	4.00±0.07	3.85±0.10	3.86±0.07	4.12±0.10	XTTS
			v2	3.6	0.47	4.29±0.09	3.97±0.10	4.13±0.07	4.02±0.09	3.96±0.07	3.64±0.12	
			VoiceCRAFT	4.5	0.55	4.38±0.08	4.08±0.10	4.23±0.06	4.16±0.08	4.18±0.09	4.17±0.06	真实
			值	3.8	0.76	4.37±0.08	4.42±0.08	4.39±0.06	4.32±0.08	4.64±0.06	4.26±0.10	

6 结论

我们引入了一个神经编解码器语言模型VoiceCRAFT，它在野外数据上的语音编辑和零样本TTS方面取得了最先进的性能。关键在于一种创新的token重排流程，该流程实现了具有双向上下文的高效且有效的自回归编解码器生成。此外，我们引入了一个首创的高质量、具有挑战性且现实性的语音编辑数据集REALEDIT，我们相信它可以可靠地衡量语音编辑模型的实用性。

7 局限性

鉴于VoiceCRAFT取得的进步，仍存在局限性。首要的是生成过程中偶尔出现的长时间静音和刮擦声。尽管在这项工作中，我们通过采样多个话语并选择较短的声音来克服它，但需要更优雅和高效的方法。另一个重要方面是AI安全性，我们如何对合成语音进行水印和检测？虽然水印和深度伪造检测已引起研究界越来越多的关注，并取得了显著进展（Zhang et al., 2020; Yamagishi et al., 2021; Chen et al., 2023; Roman et al., 2024），但像VoiceCRAFT这样更先进的模型为安全性研究带来了新的机遇和挑战。为促进语音合成和AI安全性研究，我们完全开源了我们的代码库和模型权重。

8 伦理影响

本工作中介绍的语音合成模型VoiceCRAFT具有正面和负面的影响。

从正面来看，VoiceCRAFT在多个领域具有带来显著益处的潜力。对于有语言障碍或失去说话能力的个体，VoiceCRAFT可能是变革性的，使这些个体能够以以前不可能的方式轻松清晰地交流。内容创作者，无论他们是在教育、视频制作还是播客领域工作，都可以利用VoiceCRAFT来简化他们的编辑流程，使其更容易制作高质量的内容，而无需在出现小错误时重新录制。此外，VoiceCRAFT处理多样口音而不影响质量的能力为创建合成数据开辟了新的可能性。这反过来可以通过为他们提供更丰富和更多样化的学习数据集来增强语音识别系统，如Voicebox (Le et al., 2023)，从而提高其准确性和对全球用户的可访问性。

然而，VoiceCRAFT潜在的负面影响不容忽视。主要关注点之一是模型可能加剧现有的偏见，特别是与种族相关的偏见。如果不仔细监控和纠正，这些偏见可能导致不同群体之间的不平等表现，延续甚至可能恶化现有的差距。此外，语音克隆的易用性引发了关于滥用的严重担忧，包括冒充和欺诈。仅用几秒钟的参考音频就能复制某人的声音，可能被利用来实施犯罪或传播错误信息，构成重大的伦理和安全挑战。因此，虽然VoiceCRAFT的好处是明确且重大的，但我们必须谨慎对待其部署，确保采取措施来减轻这些风险并防止潜在的滥用。

尽管存在与VoiceCRAFT相关的冒充和欺诈方面的担忧，但有令人信服的理由支持其发布。其中首要的是它为更广泛的研究界和技术开发者提供了机会，以更好地理解减轻这些负面影响。通过将方法开源，我们可以促进针对语音克隆技术滥用的更强大对策的开发。这种协作方法允许快速识别漏洞并探索创新策略来解决它们。此外，本工作的作者完全致力于负责任地推进该领域。我们正在积极研究专门为合成语音设计的开创性深度伪造检测和水印算法。通过这样做，我们不仅承认了与我们的技术相关的潜在风险，还采取了具体措施来确保其符合伦理的使用。这种开放协作和致力于保护机制研究的双重方法反映了我们致力于培育一个技术生态系统的承诺，在这个生态系统中，语音克隆的好处可以实现，同时将其潜在的危害降到最低。

9 致谢

我们感谢Ziyue Jiang为运行FluentSpeech模型的推理和扩展提供的指导。我们感谢德克萨斯大学奥斯汀分校SALT实验室的学生们进行的有益讨论。本工作部分由美国国家科学基金会根据Grant No. 2238605资助。

附录 A 附加实验

A.1 比较 ScaledAdam 和 AdamW

ScaledAdam的超参数设置见表9。对于AdamW (Loshchilov and Hutter, 2017)，我们尝试了3种设置：

设置1：峰值学习率：1e-5，批次大小：3.3分钟，更新步数：500k 设置2：峰值学习率：1e-4，批次大小：33.3分钟（与ScaledAdam相同），更新步数：80k 设置3：峰值学习率：1e-4，批次大小：3.3分钟，更新步数：500k

对于所有设置，我们使用线性调度器，在前 8% 步中线性地将学习率提升到峰值，之后线性衰减。我们对其他超参数使用常见的默认值，设置 $\beta_1 = 0.9$, $\beta_2 = 0.999$ ，权重衰减 = 0.01。所有实验均在4张A40 GPU上完成。结果见表7^8。我们看到ScaledAdam在所有指标上都取得了更好的性能，同时使用了更少的计算量。然而，我们注意到由于计算资源的限制，我们无法对AdamW进行穷举超参数搜索，因此我们在此不对我们的发现进行过度概括。

表7: ScaledAdam 在所有指标上均优于 AdamW，同时训练时间减少 10%。

优化器	设置	训练时间	WER	MCD	F0	Energy
AdamW	$\text{lr}=1\text{e-}5$, $\text{bsz}=13.3\text{min}$, $\text{steps}=500\text{k}$	262小时	16.45	8.91	196.15	5.94
AdamW	$\text{lr}=1\text{e-}4$, $\text{bsz}=133.2\text{min}$, $\text{steps}=57\text{k}$	273小时	10.77	8.45	117.38	4.91
AdamW	$\text{lr}=1\text{e-}4$, $\text{bsz}=13.3\text{min}$, $\text{steps}=500\text{k}$	262小时	7.58	8.32	82.73	3.70
ScaledAdam	$\text{lr}=3\text{e-}2$, $\text{bsz}=133.2\text{min}$, $\text{steps}=50\text{k}$	237小时	7.30	8.13	73.41	3.19

A.2 并排人类偏好比较的细分

VoiceCRAFT与FluentSpeech之间的比较细分如图4所示。我们看到VoiceCRAFT在所有方面都优于FluentSpeech，特别是对于替换编辑和当编辑跨度长度较长时。

A.3 频谱图比较

FluentSpeech和VoiceCRAFT之间的频谱图级别比较如图5、6、7所示，编辑部分用深绿色矩形标记。这三个示例在口音和录音条件方面的难度递增，特别是，图7中的示例似乎处于低带宽传输中。在所有3个示例中，我们看到VoiceCRAFT能够生成更详细的频率模式。相应的音频可以在演示页面上找到。

图4: VoiceCRAFT与FluentSpeech在语音编辑上的自然度并排人类偏好比较的细分。按编辑类型（左）和编辑跨度长度（右）分组。

图5: 上：FluentSpeech；下：VoiceCRAFT

图6: 上：FluentSpeech；下：VoiceCRAFT

图7: 上：FluentSpeech；下：VoiceCRAFT。注意，由于语音是在极具挑战性的条件下录制的，词对齐并非十分精确。我们看到，对于FluentSpeech的结果，由于整个梅尔频谱图都传递给HiFi-GAN进行重建，即使是未编辑的语音也包含高频噪声。

附录 B REALEDIT 语音编辑数据集示例

REALEDIT的示例如表8所示。

附录 C 实现细节

Encodec模型。我们使用的Encodec模型的步幅为320个样本，这意味着对于采样率为 16kHz 的录音，编解码器帧率为 50Hz。基础维度为64，在编码器的5个卷积层中的每一层加倍。遵循Copet et al. (2023)，我们使用开源的audiocraft仓库进行Encodec模型训练。从Gigaspeech采样的1秒语音片段，在总共160个epoch（320k步）上训练，批次大小为240。模型使用Adam（Kingma and Ba, 2014）训练，基础学习率为 $3e-4$ 。

Eden调度器（Yao et al., 2024），该调度器在步骤 t 使用以下公式调整学习率 α_t ：

$$\alpha_t = \alpha_{\text{base}} \cdot \left(\frac{t^2 + \alpha_{\text{step}}^2}{\alpha_{\text{step}}^2} \right)^{-0.25}.$$

其中 α_{base} 是基础学习率， t 是步索引， e 是epoch索引， α_{step} 和 α_{epoch} 控制模型在显著降低学习率之前已见的数量。 $\text{linear}(\alpha_{\text{start}}, t_{\text{warmup}}, t)$ 在 t_{warmup} 步上线性地将结果从 α_{start} 增加到1，然后保持在1。在我们的实验中，我们设置

$$\alpha_{\text{base}} = 0.05, \alpha_{\text{step}} = 3000, \alpha_{\text{epoch}} = 4,$$

由于我们的数据集相当大，我们使用伪epoch而不是实际的epoch，并将1个伪epoch设置为3000个训练步。注意，这些超参数的选择受到Yao et al. (2024) ; Li (2023) 的启发，如果计算资源允许，网格搜索可能会找到更好的超参数设置。

消融研究中的配置。不同模型的配置如表9所示。注意，我们为430M模型使用基础学习率 $3e-2$ 而不是 $5e-2$ ，因为后者给出了NaN错误。

消融研究的任务和数据。评估任务是掩码重建，其中对于每个话语，我们随机选择一个长度从1到15个词的跨度进行掩码，并要求VoiceCRAFT基于转录和未掩码语音重建被掩码的语音。我们使用Gigaspeech验证集的一个1000个话语的随机子集，其中包含YouTube视频和播客数据。我们确保子集中的每个话语在被Whisper medium.en（Radford et al., 2022）解码时WER低于 15%。

消融研究的指标。由于掩码重建评估中真实值可用，除了WER（从Whisper medium.en的输出测量）之外，我们还测量梅尔倒谱失真（MCD）（Kubichek, 1993）、F0距离（F0）和能量距离（Energy）。WER和MCD与语音的可懂度相关性更好，而F0和Energy与生成语音和真实语音之间的韵律相似性相关性更好。MCD测量生成语音和真实语音之间梅尔频率倒谱系数（MFCC）的差异，定义为

$$\text{MCD} = \frac{10}{\ln 10} \sqrt{\frac{1}{2} \sum_{i=1}^L (m_i^g - m_i^r)^2}$$

其中 L 是MFCC的阶数，我们将其设置为13。 m_i^g 是真实录音的第 i 个MFCC， m_i^r 是生成语音的第 i 个MFCC。我们使用 $\text{pymcd包}^{\wedge}10$ 来计算MCD。对于F0估计，我们使用librosa (McFee et al., 2015) 中实现的pYIN (Mauch and Dixon, 2014) 算法，最小频率为80hz，最大频率为600hz。对于能量计算，我们使用频谱图幅度的均方根，这是使用短时傅里叶变换提取的，窗口长度为640，跳跃大小为160。注意，由于生成语音的长度可能与真实值不同，在计算它们的欧氏距离之前，首先应用动态时间规整来对提取的MFCC/F0/能量进行时间对齐。对于消融研究中的每个模型，我们使用3个不同的随机种子并报告平均结果。

扩展FluentSpeech。原始的FluentSpeech (Jiang et al., 2023b) 是在LibriTTS上训练的，我们尽最大努力对其进行扩展以进行公平比较。在FluentSpeech作者的指导下，我们将批次大小从16个话语扩展到256个话语。扩散基础隐藏维度从320扩展到1024，残差层从20层扩展到30层，残差通道从256扩展到512。最终的模型包含3.3亿参数，大致与Voicebox模型 (Le et al., 2023) 相同。该模型在Gigaspeech训练集上使用1张A40 GPU训练了626k步，耗时10天。HiFi-GAN声码器也在Gigaspeech训练集上重新训练了400k步，使用Voicebox (Le et al., 2023) 上使用的超参数（他们也使用HiFi-GAN作为声码器解码为16kHz语音）。

零样本TTS的基线。对于零样本TTS，我们将我们的VoiceCRAFT与VALL-E (Wang et al., 2023a)、XTTS v2 (COQUI, 2023)、YourTTS (Casanova et al., 2021) 和FluentSpeech进行比较。由于原始VALL-E未开源，我们使用了Li (2023) 提供的流行开源实现的代码，并将模型在Gigaspeech上进行了训练。AR和NAR模型都使用ScaledAdam优化器和Eden调度器训练了50k步，与我们的VoiceCRAFT相同。商业模型XTTS v2由三个模块组成：用于语音分词的VQ-VAE (van den Oord et al., 2017)、用于语音token建模的GPT-2 (Radford et al., 2019) 模型以及用于token到波形生成的定制HiFi-GAN (Kong et al., 2020) 模型。XTTS v2在公开可用数据和网络爬取数据的混合上训练，但确切的数据来源未知。YourTTS是一个零样本TTS模型，建立在对抗性VAE模型VITS (Kim et al., 2021) 之上，具有新颖的零样本多说话人和多语言训练。该模型在VCTK、LibriTTS以及法语和葡萄牙语语料库上训练。我们用于TTS的FluentSpeech模型与语音编辑中的相同，因为该模型可以像Voicebox (Le et al., 2023) 一样配置为执行零样本TTS。

语音语料库的许可证。许可证：LibriTTS: CC BY 4.0; Gigaspeech: Apache-2.0; Spotify Podcast数据集: CC BY 4.0。

附录 D 条件独立性假设

为了更好地解释公式3中条件独立假设背后的理由，我们回到由因果掩码产生的序列 Y 。我们为公式3成立所做的假设等效于假设：给定 W 和 $H_{s,t}$ ， $Y_{s,t,k}$ 与 $I_{s,t,k}^{(1)}$ 和 $I_{s,t,k}^{(2)}$ 独立，其中 $I_{s,t,k}^{(1)} \triangleq (Y_{s,t+k-1,1}, Y_{s,t+k-2,2}, \dots, Y_{s,t+1,k-1})$ $I_{s,t,k}^{(2)} \triangleq (Y_{s,t-1,k+1}, Y_{s,t-2,k+2}, \dots, Y_{s,t-K+k,K})$

我们认为这个假设是温和的，因为 1) $I_{s,t,k}^{(1)}$ 是来自时间 t 之后的token，因此给定过去的token $H_{s,t}$ ，它们对 $Y_{t,k}$ 分布的影响应该较小（如果 $Z_{s,t}$ 在被掩码的跨度中， $H_{s,t}$ 也可能包含物理时间上的未来token）；2) 虽然 $I_{s,t,k}^{(2)}$ 是来自时间 t 之前的token，但它们来自残差量化链中晚于码本 k 的码本，这意味着它们对码本 k （在相应时间步）留下的残差进行建模。鉴于 $\{Y_{s,t-1,k}, Y_{s,t-2,k+1}, \dots, Y_{s,t-K+k,K-1}\} \subset H_{s,t}^{11}$ ，即“已拟合部分”已给定，因此“未拟合部分”（即残差）对 $Y_{s,t,k}$ 分布的影响应该较小。根据经验，MusicGen表明，使用延迟模式训练的编解码器语言模型享有朴素并行模式的效率，同时实现了与完全扁平化序列相似的建模性能。

附录 E 人类听力测试说明

我们在Amazon Mechanical Turk上使用的人类听力测试说明截图如图8（语音编辑-可懂度）、图9（语音编辑-自然度）、图10（语音编辑-并排比较）、图11（零样本TTS-可懂度）、图12（零样本TTS-说话人相似度）、图13（零样本TTS-自然度）所示。对于语音编辑评估，有64位Turkers参与，我们共支付474.3美元；对于零样本TTS评估，有59位Turkers参与，我们共支付457.6美元。我们只允许居住在美国的Turkers执行任务，目的是提高Turkers是英语母语者的概率。我们承认这不是一个完美的方法，可能会在判断中引入偏差，但由于Amazon Mechanical Turk不允许根据母语进行选择，这是我们能想到的作为约束母语的代理的最佳方法。

图8: 语音编辑-可懂度偏好的说明。每个任务包含5个录音。由于第一段也出现在说明页面的所有其他任务中，我们仅在此截图中显示它。

图9: 语音编辑-自然度偏好的说明。每个任务包含5个录音。

图10: 语音编辑，并排自然度偏好的说明。每个任务包含3对录音。

图11: 零样本TTS，可懂度偏好的说明。每个任务包含5个录音。

图12: 零样本TTS，说话人相似度偏好的说明。每个任务包含3对。

图13: 零样本TTS，自然度偏好的说明。每个任务包含5个录音。