

好的，这是根据你提供的DreamOmni2论文PDF翻译的中文版本。我已严格按照要求，去除了参考文献部分，并完整保留了原文的结构和所有内容，其中“token”一词根据你的指示未作翻译。

DREAMOMNI2: 基于多模态指令的编辑与生成

Bin Xia^{1,4}, Bohao Peng¹, Yuechen Zhang¹, Junjia Huang⁴, Jiyang Liu⁴, Jingyao Li¹, Haoru Tan³, Sitong Wu¹, Chengyao Wang¹, Yitong Wang⁴, Xinglong Wu⁴, Bei Yu¹, and Jiaya Jia^{2,1} 香港中文大学² 香港科技大学³ 香港大学⁴ 字节跳动公司¹ <https://github.com/dvlab-research/DreamOmni2>

图1：总览概览：支持基于多模态指令的编辑与生成，并将能力扩展至具体物体之外的抽象属性。

摘要

近期，基于指令的图像编辑和主体驱动的生成取得了显著进展，引起了广泛关注。然而，这两项任务在满足实际需求方面仍存在局限性。基于指令的编辑仅依赖语言指令，这往往无法捕捉到具体的编辑细节，因此需要参考图像。与此同时，主体驱动的生成仅限于组合具体的物体或人物，而忽略了更广泛的抽象概念。为解决这些挑战，我们提出了两个新任务：基于多模态指令的编辑与生成。这两个任务同时支持文本和图像指令，并将适用范围扩展到具体和抽象概念，极大地增强了它们的实际应用价值。我们引入了DreamOmni2，主要解决两大挑战：数据创建和模型框架设计。我们的数据合成流程包括三个步骤：（1）使用一种特征混合方法，为抽象和具体概念创建提取数据；（2）利用编辑和提取模型生成基于多模态指令的编辑训练数据；（3）进一步应用提取模型为基于多模态指令的生成创建训练数据。在框架方面，为了处理多图像输入，我们提出了一种索引编码和位置编码偏移方案，帮助模型区分图像并避免像素混淆。此外，我们引入了VLM与我们的生成/编辑模型的联合训练，以更好地处理复杂指令。同时，我们为这两个新任务提出了全面的基准测试，以推动其发展。实验表明，DreamOmni2取得了令人印象深刻的结果。模型和代码将公开发布。

1 引言

近期，统一生成与编辑模型（OpenAI, 2025; Google, 2025b）的进步在市场上获得了显著关注和赞誉。这些模型的成功可归因于几个因素：（1）它们通过简化流程极大地改善了用户体验，允许用户在一个模型内执行各种设计任务，而无需在不同的模型间切换。（2）统一模型降低了服务提供商的部署成本。（3）在学术上，它们有助于探索AGI和世界模型，能够准确理解用户指令，并创建或修改真实世界的视觉内容。

当前已发布的工作（Batifol et al., 2025; Wu et al., 2025a; Deng et al., 2025）主要关注基于指令的编辑和主体驱动的生成，其输入为文本提示和单张源图像，但这两者在应用和推动智能发展方面都存在局限性。（1）对于基于指令的编辑（Brooks et al., 2023; Liu et al., 2025; Xia et al., 2025b），仅靠指令往往无法完全捕捉用户的意图。例如，当用户说“让图像中的包具有给定图像中裙子的相同图案”时，很难用语言描述“裙子”的复杂图案。因此，精确的编辑需要多模态指令，包括参考图像和文本。值得注意的是，这一挑战不仅涉及修改物体，还包括任何难以用语言描述的抽象属性，如纹理、材质、姿态、发型和设计风格。（2）主体驱动的生成模型（Xiao et al., 2025; Wu et al., 2025c）乃至商业统一模型（Google, 2025b）主要关注从特定的具体物体或人物生成内容，而对于从输入图像中引用更一般的抽象属性的研究有限。

为了创建一个更智能、更全面的统一创作工具，我们提出了DreamOmni2。最大的挑战在于训练数据，因此我们为基于多模态指令的编辑和生成引入了一个全面的数据流程，包括以下步骤（图2）：（1）我们提出了一种特征混合方案，用于在两个批次之间交换注意力特征，使模型能够生成具有相同抽象属性或具体物体的图像对。与先前用于生成图像对的双联画方法（Wu et al., 2025c）相比，我们的方案成功率更高，生成的图像分辨率更高，并且在分割图像对时完全消除了边缘的任何内容混合。（2）利用步骤1生成的图像对，我们训练一个生成-

编辑模型作为提取模型。该模型从给定图像中提取具体物体或抽象属性，并根据指令生成另一个图像。与先前依赖分割和检测的方法（Wu et al., 2025c; Chen et al., 2025）相比，我们的提取模型具有三个关键优势：它可以处理抽象概念、被遮挡的物体，并能生成更多样化的参考图像。然后，我们生成基于多模态指令的编辑训练数据，其中包括目标图像、源图像、编辑指令和多个参考图像。我们使用文生图（T2I）模型基于多个关键词生成目标图像，或从真实图像数据库中选择一个。提取模型随后为其中一个关键词生成参考图像。此外，我们使用一个基于指令的编辑模型（Batifol et al., 2025）将所选关键词定义的内容转换为不同的内容，从而获得源图像。（3）我们通过应用提取模型，基于步骤2中创建的源图像的关键词生成多个参考图像，来创建基于多模态指令的生成数据。这样，我们就构建了从多个参考图像生成图像的数据。

此外，当前的SOTA统一生成和编辑模型（Batifol et al., 2025）仍然无法处理多图像输入。为此，我们提出了DreamOmni2框架。首先，我们提出了索引编码和位置编码偏移方案。索引编码帮助模型识别输入图像的索引，提高其对指令中引用图像的理解。位置编码根据先前的输入进行偏移，防止生成结果中出现像素混淆和复制-粘贴效应。此外，我们提出了生成/编辑模型与VLM的联合训练方案。虽然生成和编辑模型中的指令通常是简单的，但真实世界的用户指令往往是不规则且逻辑复杂的。在大规模语料库上预训练的VLM可以更好地理解这些复杂意图，将指令翻译成模型能够理解的形式，显著提高在真实场景中的性能。此外，针对这两个新任务，我们使用真实图像数据构建了DreamOmni2基准测试。这可以更准确地评估模型在真实场景中的泛化能力和性能。我们的主要贡献有四个方面：

- 我们提出了两个高度实用的任务：由任意具体或抽象概念引导的基于多模态指令的编辑与生成。引入这两个任务使当前的统一生成和编辑模型成为更智能、更通用的创意工具。
- 我们提出了一个三阶段的数据创建流程。利用这一流程，我们构建了一个高质量、全面的基于多模态指令的编辑与生成数据集。
- 我们提出了DreamOmni2框架，该框架引入了索引编码和位置编码偏移方案，使模型能够处理多参考图像输入。此外，我们提出了生成/编辑模型与VLM的联合训练方案，增强了模型理解复杂用户指令的能力。
- 针对这两个新任务，我们提出了一个基于真实图像数据构建的DreamOmni2基准测试。实验证明了DreamOmni2在真实场景中的有效性。

2 相关工作

基于指令的编辑 指的是根据用户的语言指令修改图像（Deng et al., 2025; Sheynin et al., 2023; Xia et al., 2024）。这项任务的主要挑战在于创建高质量和精确的编辑数据集。作为开创性工作，InstructP2P (Brooks et al., 2023) 通过使用 SD 1.5 (Rombach et al., 2022) 微调 GPT-3 和 Prompt-to-Prompt (Hertz et al., 2022) 引入了一个基于指令的图像编辑数据集。此后，出现了许多其他创建数据集的方法 (Zhang et al., 2024; Xia et al., 2025b; Wei et al., 2024; Ge et al., 2024)，例如雇佣人员创建数据、使用修复方法、基于拼贴的方法以及使用不同的专家模型。最近，DreamVE (Xia et al., 2025a) 统一了基于指令的图像和视频编辑。然而，基于语言的编辑是有限的，因为现实世界场景中的许多细节无法用语言捕捉，需要参考图像来更好地描述。为此，我们提出了基于多模态指令的编辑，使得能够从参考图像中的具体物体或抽象属性获得指导。这使得统一的图像生成和编辑模型 (Batifol et al., 2025; Wu et al., 2025a) 更加全面和实用。

主体驱动的生成 已被广泛研究。像 Dreambooth (Ruiz et al., 2023) 和文本反转 (Gal et al., 2022) 这样的方法在同一个主体的多张图像上微调模型，从而实现主体驱动的生成。然而，这要求用户为每个新主体准备多张图像并进行微调，这对用户不友好。后来出现的方法如 IP-adapter (Ye et al., 2023) 和 BLIP-diffusion (Li et al., 2023) 使用视觉编码器将参考图像的主体压缩成一个向量，并将其注入扩散模型，从而无需微调即可实现主体驱动的生成。IC LoRA (Huang et al., 2024) 和 Ominicontrol (Tan et al., 2024) 进一步探索了 DIT 模型 (Peebles & Xie, 2023) 固有的图像参考能力。最近，统一的生成和编辑模型 (Xia et al., 2025b; Batifol et al., 2025; Wu et al., 2025a; Xiao et al., 2025) 采用了简单的方法，将参考图像编码为视觉 token，将其与文本和噪声 token 连接起来，然后输入到 DIT 模型中。然而，先前的方法主要关注具体物体，限制了它们捕捉更广泛抽象概念的能力。

在本文中，我们提出了基于多模态指令的生成，这是一个新任务，能够引用参考图像中的任何具体物体或抽象属性来生成新的图像。这扩展了主体驱动生成的范围并增强了其实用性。

图2：DreamOmni2 训练数据构建概览。(1) 在第一阶段，我们使用特征混合方案利用基础模型的 T2I 能力，创建包含具体物体和抽象属性的高质量数据对。(2) 在第二阶段，我们生成基于多模态指令的编辑数据。使用第一阶段的数据，我们训练一个提取模型来模拟目标图像中的物体或属性，并根据指令生成参考图像。此外，我们使用一个基于指令的编辑模型将目标图像中提取的物体或属性修改为不同的内容，从而创建源图像。这就生成了从参考图像和源图像到目标图像的训练对。(3) 在第三阶段，我们从第二阶段源图像中提取物体以创建新的参考图像，形成从参考图像生成目标图像的训练数据。

3 方法论

3.1 合成数据

基于多模态指令的编辑与生成是新任务，主要挑战在于缺乏训练数据。对于基于多模态指令的编辑，先前的数据创建流程 (Brooks et al., 2023; Wei et al., 2024) 涉及生成指令、源图像和目标图像的三元组。然而，这种方法无法创建将参考图像作为编辑条件的数据。对于基于多模态指令的生成，先前的主题生成数据流程 (Wu et al., 2025c; Chen et al., 2025) 依赖于分割检测模型来创建参考图像。这种方法使得合成用于生成参考抽象属性或被遮挡的具体物体的数据变得困难。

为了解决这两个任务的训练数据问题，我们提出了一个全面的合成数据流程。具体来说，如图2所示，我们的方法包括三个阶段。在第一阶段，我们引入了一种特征混合方案，采用双分支结构同时生成源图像和目标图像，如下所示：

$$\text{Attn}_{\text{latr}}(Q, K, V) = \text{softmax}\left(\frac{QK^\top}{\sqrt{d}}\right)V, \quad (1)$$

其中 $Q = [Q_{tar}^n; Q_{tar}^t]$, $K = [K_{tar}^n; K_{tar}^t; K_{src}^n]$, 且 $V = [V_{tar}^n; V_{tar}^t; V_{src}^n]$ 。 Q_{tar}^t 、 K_{tar}^t 和 V_{tar}^t 是来自目标分支的文本特征，而 Q_{tar}^n 、 K_{tar}^n 和 V_{tar}^n 是来自目标分支的噪声特征。 K_{src}^n 和 V_{src}^n 是来自源分支的噪声特征，与 K_{tar}^n 和 V_{tar}^n 位于同一层。 $[\cdot]$ 表示 token（或称为长度）维度的拼接。

我们的特征混合方案利用模型固有的 T2I 能力来生成配对的训练数据。与之前的 UNO (Wu et al., 2025c) 双联画生成方法相比，我们的特征混合方案有几个明显的优势：(1) 双联画方法通过将两张图像强制放入一张来减半图像分辨率，而特征混合则在两个分支中生成，不降低分辨率。(2) 双联画方法经常错放分割线，导致内容混合。我们的方法避免了这个问题。(3) 特征混合方案生成的数据在质量和准确性上均优于双联画方法。然后，我们使用这些数据来训练提取模型。我们的训练数据不仅增强了基础模型 (Batifol et al., 2025) 提取具体物体的能力，还使其能够捕捉之前缺乏的抽象概念。

之后，如图2第二阶段所示，我们创建了基于多模态指令的编辑数据。具体来说，我们首先创建目标图像，使用 T2I 模型生成的数据和真实图像。对于 T2I 生成的图像，我们随机选择不同的元素关键词（例如，物体或属性），并使用 LLM 编写提示，然后 T2I 模型使用该提示生成目标图像。对于真实图像，我们直接使用 VLM 提取关键词。T2I 数据更灵活，允许任何概念组合，而真实图像反映了自然分布。因此，我们结合了这两种类型的数据。接下来，使用第一阶段训练的提取模型，我们根据所选关键词从目标图像中提取一个物体或属性来创建参考图像。然后，我们应用基于指令的编辑模型 (Batifol et al., 2025) 改变目标图像中的所选关键词，从而获得源图像。最后，我们使用 LLM 生成编辑指令，形成一个包含源图像、指令、参考图像和目标图像的训练元组。

之后，如图2第三阶段所示，我们创建了基于多模态指令的生成数据。我们使用提取模型从第二阶段源图像中提取关键词，生成参考图像。通过将这些与第二阶段的参考图像结合，我们可以获得由多个参考图像、一个指令和一个目标图像组成的训练元组。

我们创建的数据集如图3所示。我们的数据集包括真实和合成的目标数据，涵盖了广泛的用于生成和编辑的对象类别，包括各种抽象属性和具体物体。此外，我们提供了全面的参考图像集，参考图像数量从一到五不等，使模型能够处理各种任务。

图3：基于多模态指令的编辑与生成训练数据的数据分布和样本。我们的数据集全面且多样，包括具体物体以及抽象属性（如局部和全局属性）的生成与编辑。

3.2 框架与训练

统一的生成与编辑基础模型 (Batifol et al., 2025) 只能处理单张输入图像。为此，我们提出了 DreamOmni2 框架。在基于多模态指令的任务中，用户通常为了方便将图像引用为“图像1”、“图像2”。然而，在 DIT 中，仅靠位置编码无法准确区分参考图像的索引。因此，我们通过向位置通道添加索引编码来解决这个问题。尽管索引编码有助于区分参考图像，但我们发现位置编码仍然需要根据先前输入的参考图像的大小进行偏移。通过将这种偏移添加到位置编码中，我们观察到复制-粘贴伪影和参考图像之间的像素混淆减少了。

目前，用于生成和编辑模型的训练指令通常是结构良好且格式固定的。然而，现实世界的用户指令通常是不规则的或逻辑不一致的，这会造成差距，阻碍模型的理解并降低性能。为了解决这个问题，我们提出了 VLM 和生成模型的联合训练，使 VLM 能够解释复杂的用户指令，并以训练中使用的结构化格式输出，帮助编辑和生成模型更好地理解用户意图。对于基于多模态指令的编辑，预定义的输出格式结合了用户指令和精细化的图像描述，而对于基于多模态指令的生成，VLM 直接输出精细化的图像描述。

在训练期间，我们以 1×10^{-5} 的学习率微调 Qwen2.5-VL (Wang et al., 2024) 7B 约 10 个 A100 小时，以学习预定义的标准输出格式。然后，我们使用 LoRA 在 Flux Kontext (Batifol et al., 2025) 上训练编辑和生成模型，以使用预定义的标准指令格式执行基于多模态指令的编辑与生成。值得注意的是，通过使用 LoRA 进行训练，我们可以保留 Kontext 原有的指令编辑能力。一旦检测到参考图像，我们的 LoRA 就会被激活，将基于多模态指令的编辑与生成无缝集成到统一模型中。此外，我们分别训练用于生成和编辑的 LoRA，因为生成和编辑之间的区别在于是否保留源图像的一致性。由于指令通常不会明确用户意图是编辑还是生成，分开训练允许用户自行选择。DreamOmni2 编辑和生成 LoRA 均在批量大小为 16 和学习率为 5×10^{-6} 的条件下进行训练，耗时约 384 个 A100 小时。

3.3 基准测试

目前，尚不存在用于基于多模态指令的编辑与生成的基准测试。如表1所示，DreamBooth (Ruiz et al., 2023) 仅支持单图像生成。尽管 Omni-Context (Wu et al., 2025b) 包含一些多参考测试案例，但它仅关注具体物体的组合，并未评估基于多模态指令的编辑或包含抽象属性。为了解决这个问题，我们提出了 DreamOmni2 基准测试，以推动这些领域的发展。我们的基准测试是全面的，由真实图像组成，以准确评估模型在真实场景中的性能。测试案例涵盖了多种类别，包括抽象属性（全局和局部）和具体物体的参考生成与编辑。关于我们的 DreamOmni2 基准测试的更多细节可以在附录中找到。

4 实验

基于多模态指令的图像编辑评估。如表2所示，我们比较了几个原生支持多图像输入的竞争模型，如 DreamO (Mou et al., 2025)、Omnigen2 (Wu et al., 2025b) 和 Qwen-Image-Edit-2509 (Wu et al., 2025a)。尽管 Kontext (Batifol et al., 2025) 和 Qwen-Image-Edit (Wu et al., 2025a) 并不原生支持多图像输入，但我们应用了 Diffusers (von Platen et al., 2022) 的方法，将多个图像组合成一个输入。我们还比较了闭源商业模型，如 Nano Banana (Google, 2025b) 和 GPT-4o (OpenAI, 2025)。我们在 DreamOmni2 基准测试上测试了包含具体物体和抽象属性的编辑示例。模型由 Gemini 2.5 (Google, 2025a) 和 Doubao 1.6 (ByteDance, 2025) 评估成功率，并由几名专业工程师手动评估结果。如表2所示，我们的 DreamOmni2 在人工评估中取得了最佳性能。在 VLM 测试中，

图4: 基于多模态指令的编辑的视觉比较。与其他竞争方法甚至闭源商业模型 (GPT-4o 和 Nano Banana) 相比, DreamOmni2 展现出更准确的编辑结果和更好的一致性。

	抽象属性	Gemini† Doubao† Human† Gemini† Doubao† Human†	GPT-4o (OpenAI, 2025) 0.6829 0.7805 0.5610 0.7195 0.7439 0.5793	Nano Banana (Google, 2025b) 0.6829 0.7073 0.5366 0.6463 0.5488 0.3293	UNO (Wu et al., 2025c) 0.0000 0.0244 0.0000 0.0061 0.0183 0.0000	DreamO (Mou et al., 2025) 0.0244 0.0732 0.0000 0.0183 0.0183 0.0000	Omnigen2 (Wu et al., 2025b) 0.2195 0.2927 0.2927 0.0427 0.0793 0.0305	Qwen-Image-Edit (Wu et al., 2025a) 0.0976 0.1463 0.0244 0.0244 0.0183 0.0000	Kontext (Batifol et al., 2025) 0.0488 0.1220 0.0976 0.0183 0.0122 0.0122	Qwen-Image-Edit-2509 (Wu et al., 2025a) 0.2683 0.2927 0.2195 0.0488 0.1159 0.0427	DreamOmni2 (Ours) 0.5854 0.6585 0.6098 0.5854 0.6280 0.6829
--	------	---	--	--	---	--	--	---	---	--	--

基于多模态指令的图像生成评估。如表3所示，我们的方法在人工评估以及 Doubao 1.6 和 Gemini 2.5 的评估中均优于商业模型 Nano Banana，并取得了与 GPT-4o 相当的结果。与主要关注生成包含多个具体物体的图像的 DreamO、Omnigen2 和 Qwen-Edit-2509 等开源模型相比，DreamOmni2 即便在其专长领域内，在生成准确性和物体一致性方面也显著优于它们。这进一步强调了 DreamOmni2 在基于多模态指令生成方面的有效性。

联合训练。如表4所示，我们验证了生成或编辑模型与 VLM 联合训练的影响。方案1代表基础模型 Kontext。在方案2中，我们在不引入 VLM 的情况下，用基本指令训练生成和编辑模型。在方案3中，我们用标准描述性指令训练 VLM，并将 VLM 生成的描述输入到 Kontext。在方案4中，我们对 VLM 和我们的生成或编辑模型在我们的数据上进行联合训练。比较方案2和方案1，我们的数据显著增强了模型处理基于多模态指令的编辑与生成的能力。比较方案3和方案4，引入 VLM 有助于生成和编辑模型更好地理解现实世界用户复杂的指令，从而提高性能。此外，方案4中的联合训练方案优于方案2和方案3，证明了其有效性。

方 具	抽象属性	Gemini†	Doubao†	Human†	Gemini†	Doubao†	Human†	GPT-4o (OpenAI,
法 体		2025)	0.6250	0.6250	0.5610	0.6889	0.6333	0.5793 Nano Banana (Google,

物 体	2025b) 0.5000 0.5417 0.5366 0.5556 0.5111 0.3293 UNO (Wu et al.,
	2025c) 0.0000 0.0000 0.0000 0.0333 0.0556 0.0000 DreamO (Mou et al.,
	2025) 0.0417 0.0833 0.0000 0.0667 0.0222 0.0000 Omnigene2 (Wu et al.,
	2025b) 0.2083 0.2500 0.2927 0.1000 0.0778 0.0305 Qwen-Image-Edit (Wu et al.,
	2025a) 0.0417 0.1250 0.0244 0.0889 0.1000 0.0000 Kontext (Batifol et al.,
	2025) 0.2500 0.3750 0.0976 0.0556 0.1222 0.0122 Qwen-Image-Edit-2509 (Wu et al.,
	2025a) 0.1250 0.2917 0.2195 0.1111 0.1556 0.0427 DreamOmni2
	(Ours) 0.5833 0.6667 0.6098 0.5778 0.6333 0.6829

表4：生成或编辑模型与 VLM 联合训练的验证。

方法	生成或 编辑模 型训练	VLM 训练	编 辑	生成 具体物体 抽象属性 具体物体 抽象属性 方案1 ×									
				× 0.1220 0.0122 0.3750 0.1222 方案2 √ × 0.3659 0.3171 0.4583 0.3444 方案									
				3 × √ 0.2439 0.3415 0.5417 0.4778 方案4 (Ours) √									
				√ 0.6585 0.6280 0.6667 0.6333									

索引和位置编码。如表5所示，我们比较了不同的编码方案，以帮助模型适应多图像输入。比较方案3和方案1，我们发现添加索引编码使模型能够理解用户指令中“图像1”、“图像2”和“图像3”等引用对应哪张图像，从而产生更准确的生成和编辑。此外，比较方案3和方案4，我们观察到，在包含索引编码的情况下，多张图像需要位置编码偏移，而不是使用相同的位置编码。这种调整防止了复制-粘贴效应，并提高了模型的编辑和生成性能。因此，在 DreamOmni2 中，我们对多个参考图像采用了索引编码和位置编码偏移。

表5：多图像输入不同编码方案的验证。

方法	索引编码	位置编码	编辑	生成 具体物体 抽象属性 具体物体 抽象属性 方案1 ×									
				× 0.2439 0.2805 0.2917 0.2222 方案2 √ × 0.4634 0.5427 0.5417 0.5111 方案3 ×									
				√ 0.3415 0.3902 0.4167 0.4556 方案4 (Ours) √ √ 0.6585 0.6280 0.6667 0.6333									

5 结论

当前的基于指令的编辑依赖于语言，但它常常难以清晰地描述所需的编辑。因此，需要参考图像来指导该过程。此外，主体驱动的生成模型通常关注具体物体，无法基于抽象概念生成图像。为此，我们提出了两个新任务：基于多模态指令的编辑与生成，其中参考包括具体物体和抽象属性。这些任务面临两大挑战：训练数据和支持多图像输入的框架。对于训练数据，我们引入了一个三阶段数据合成流程。在第一阶段，我们使用特征混合方法为提取模型创建数据，该模型可以生成与给定图像具有相同元素（物体或属性）的图像。在第二阶段，我们使用提取和基于指令的编辑模型创建基于多模态指令的编辑数据。在第三阶段，我们将提取模型应用于第二阶段的数据，以生成基于多模态指令的生成数据。对于框架，我们设计了一种索引编码和位置编码偏移方案，以帮助模型区分多张图像并避免复制-粘贴效应。我们还提出了生成/编辑模型与 VLM 的联合训练方案，提高了模型理解复杂现实世界指令的能力。大量实验展示了 DreamOmni2 的出色性能。

附录

A.1 DREAMOMNI2 基准测试

我们的 DreamOmni2 基准测试包括 205 个基于多模态指令的编辑测试案例和 114 个基于多模态指令的生成测试案例。编辑和生成测试案例的可视化分别在图7和图6中展示。该基准测试涵盖了广泛的测试案例，输入参考

图像从一到五张不等，并包含多样的局部和全局属性以及具体物体。DreamOmni2 基准测试将公开发布。

图6：DreamOmni2 基准测试中基于多模态指令生成的示例。
图7：DreamOmni2 基准测试中基于多模态指令编辑的示例。

A.2 更多基于多模态指令的编辑案例

如图8、图9、图10、图11、图12、图13、图14、图15、图16、图17、图18、图19、图20和图21所示，我们展示了 DreamOmni2 在基于多模态指令编辑任务上的更多视觉案例。

A.3 更多基于多模态指令的生成案例

如图22、图23、图24、图25、图26、图27、图28、图29和图30所示，我们展示了 DreamOmni2 在基于多模态指令生成任务上的更多视觉案例。

图8：DreamOmni2 的基于多模态指令编辑案例。

图9：DreamOmni2 的基于多模态指令编辑案例。

图10：DreamOmni2 的基于多模态指令编辑案例。

图11：DreamOmni2 的基于多模态指令编辑案例。

图12：DreamOmni2 的基于多模态指令编辑案例。

图13：DreamOmni2 的基于多模态指令编辑案例。

图14：DreamOmni2 的基于多模态指令编辑案例。

图15：DreamOmni2 的基于多模态指令编辑案例。

图16：DreamOmni2 的基于多模态指令编辑案例。

图17：DreamOmni2 的基于多模态指令编辑案例。

图18：DreamOmni2 的基于多模态指令编辑案例。

图19：DreamOmni2 的基于多模态指令编辑案例。

图20：DreamOmni2 的基于多模态指令编辑案例。

图21: DreamOmni2 的基于多模态指令编辑案例。

图22: DreamOmni2 的基于多模态指令生成案例。

图23: DreamOmni2 的基于多模态指令生成案例。

图24: DreamOmni2 的基于多模态指令生成案例。

图25: DreamOmni2 的基于多模态指令生成案例。

图26: DreamOmni2 的基于多模态指令生成案例。

图27: DreamOmni2 的基于多模态指令生成案例。

图28: DreamOmni2 的基于多模态指令生成案例。

图29: DreamOmni2 的基于多模态指令生成案例。

图30: DreamOmni2 的基于多模态指令生成案例。