

好的，这是根据你提供的FireRed-Image-Edit论文PDF翻译的中文版本。我已严格按照要求，去除了参考文献部分，并完整保留了原文的结构、所有内容、公式、表格和图表示意，其中“token”一词根据指示未作翻译。

FireRed-Image-Edit-1.0 技术报告

小红书超级智能团队

摘要

我们推出了 FireRed-Image-Edit，这是一个用于基于指令的图像编辑的扩散Transformer模型，通过在数据策展、训练方法和评估设计上的系统优化，实现了最先进的性能。我们构建了一个包含16亿样本的训练语料库，其中包括9亿个文生图对和7亿个来自不同来源的图像编辑对。经过严格的清洗、分层、自动标注和两阶段过滤，我们保留了超过1亿个高质量样本，在生成和编辑之间保持平衡，确保了强大的语义覆盖和指令对齐。我们的多阶段训练流程通过预训练、监督微调和强化学习逐步构建编辑能力。为提高数据效率，我们引入了用于可变分辨率批处理的多条件感知桶采样器，以及具有动态提示重索引的随机指令对齐机制。为稳定优化并增强可控性，我们提出了用于DPO的非对称梯度优化、用于文本编辑的带布局感知OCR奖励的DiffusionNFT，以及用于身份保持的可微一致性损失。我们进一步建立了REDEdit-Bench，这是一个涵盖15个编辑类别的综合基准测试，包括新引入的美化和低级增强任务。在REDEdit-Bench以及公共基准（ImgEdit和GEdit）上的大量实验表明，我们的模型相对于开源和专有系统均具有竞争力或优越的性能。我们发布了代码、模型和基准测试套件以支持未来的研究。

GitHub <https://github.com/FireRedTeam/FireRed-Image-Edit> HuggingFace 模型

<https://huggingface.co/FireRedTeam/FireRed-Image-Edit-1.0> HuggingFace 演示 在线演示 (HuggingFace)

图1 | 本图在四个人类评估维度（对齐、一致性、真实感、美学）和三个编辑任务（ImgEdit、GEdit、REdit）上对生成式图像模型进行了基准测试。

图2 | FireRed-Image-Edit 在通用图像编辑中的展示。

目录

1 引言 4 2 数据 4 2.1 数据分布 5 2.2 数据预过滤 6 2.2.1 去重 6 2.2.2 光度与统计过滤 7 2.2.3 内容有效性与伪影移除 7 2.2.4 感知质量与美学 7 2.2.5 AIGC 检测 7 2.3 数据生产引擎 7 2.4 长尾数据补充 9 2.5 标注引擎 9 2.5.1 结构化标注 9 2.5.2 指令标注 9 2.6 数据后过滤 10 3 模型训练 11 3.1 架构 11 3.2 训练效率优化 12 3.3 预训练 13 3.4 持续预训练 (CT) 13 3.5 监督微调 (SFT) 14 3.6 基于人类反馈的强化学习 (RLHF) 15 3.6.1 直接偏好优化 (DPO) 15 3.6.2 Diffusion NFT 15 3.7 一致性损失 16 3.8 训练策略 17 4 REDEdit-Bench 18 4.1 基准构建 18 4.2 评估流程 18 5 性能与评估 18 5.1 人类评估 19 5.1.1 评估维度 19 5.1.2 结果分析 19 5.2 定量与定性结果 19 5.2.1 通用编辑 19 5.2.2 以文本为中心的编辑 21 5.2.3 创意编辑 21 5.2.4 虚拟试穿编辑 21 6 结论 29 7 作者 30 参考文献 31

1 引言

近年来，文生图（T2I）合成领域经历了范式转变，从基础纹理生成快速发展到具有复杂语义对齐的照片级真实感图像创建 [26, 7, 13, 38, 29, 20, 1]。然而，这种性能的飞跃也设置了巨大的进入壁垒。当前的生态系统日益两极分化：一方面，专有商业巨头——如 Nano Banana Pro [10] 和 Seedream 4.0 [29]——作为不透明的“黑盒”运

行，提供卓越的保真度，但零可解释性或可复现性。另一方面，虽然开源社区致力于民主化，但主流趋势是无情地扩大模型规模——膨胀到数百亿参数（例如，Qwen-Image [38] 的 20B，FLUX.2 [14] 的 32B，以及 Step-1X-Edit [20] 的 19B）。这种趋势给训练和部署带来了不可持续的计算负担。因此，从专有模型蒸馏合成数据已成为资源受限学术领域的一种流行变通方法 [22, 17]。尽管做出了这些努力，社区仍固守于纯粹扩大模型参数，往往牺牲了数据处理的效率和模型训练的效率。两个关键领域仍存在重大缺口：高效构建高质量的图像编辑数据集，以及开发能够跨通用指标评估这些模型的科学严谨、标准化的基准测试。

在本文中，我们介绍了 FireRed-Image-Edit，一个整体性的端到端框架，严格优化了模型生命周期的每个方面——涵盖数据策展、架构设计、训练效率和推理优化——利用大规模高质量数据实现最先进的性能。

为充分利用这一架构，我们将训练规模扩展到约1亿个多样化的图像-文本对，涵盖文生图生成、单图像和多图像到图像的合成，以及基于复杂指令的编辑。支撑如此大规模的数据需要系统性的训练效率创新。我们引入了多条件感知桶采样器，明确考虑不同编辑任务中输入图像数量的可变性，优化宽高比分桶以最小化填充带来的计算浪费，同时保持空间布局完整性。与此相辅相成，我们的随机指令对齐机制在数据整理期间采用参考图像的随机丢弃和置换，并动态重索引文本提示以保持语义对应——迫使模型将空间顺序与内容解耦，从而增强在复杂多参考场景中的泛化能力。在系统层面，我们集成了预提取文本特征缓存、用于分布式状态管理的完全分片数据并行（FSDP）、梯度检查点和混合精度训练，以在不牺牲稳定性的情况下最大化吞吐量。

我们的训练策略通过三个协调机制进一步细化收敛。分布式分层时间步采样将扩散时间范围分解为子区间，分配到各GPU上，并通过同步轮换防止特定rank的过拟合，确保噪声覆盖的全局均匀性。Logit-正态损失加权将梯度贡献集中在语义关键的中间扩散时间步，同时抑制可忽略的极端值。最后，通过指数移动平均进行的模型权重平均，综合了优化轨迹中的参数，消除了瞬态波动，增强了针对现实世界分布偏移的鲁棒性。

此外，我们认识到传统指标往往无法捕捉到生产就绪应用所需的细微差别，导致学术分数与实际用户体验脱节。为弥合这一差距，我们建立了一个全面的、多维度的基准测试，旨在更接近实际部署标准来严格评估模型性能。该评估框架涵盖广泛的编辑任务，从细微的纹理调整到复杂的结构修改，并在多个轴向上评估模型——包括指令对齐、背景保持和摄影保真度。通过将评估焦点从理论指标转向应用效用，我们的基准测试提供了对当前局限性的细粒度分析，并展示了我们的模型在促进真正、无限制创意工作流程方面的卓越适应性。

2 数据

训练数据的质量对于生成模型至关重要，并且在很大程度上决定了它们可达到的性能。为此，我们总共收集了16亿个样本，包括9亿个文生图对和7亿个图像编辑对。编辑数据来自不同来源，包括开源数据集（例如，OmniEdit [37]，UnicEdit-10M [47]）、我们的数据生产引擎、视频序列和互联网，而文生图样本则被纳入以保留生成先验并确保训练稳定性。通过严格的清洗、细粒度分层和全面标注，以及两阶段过滤流程（预过滤和后过滤），我们保留了超过1亿个高质量样本用于训练，在文生图和图像编辑数据之间均匀分配，确保了广泛的语义覆盖和高数据保真度。

2.1 数据分布

我们的数据集经过精心策展，以支持开发稳健的图像编辑模型。数据集分为两个主要类别：文生图（T2I）和图生图（I2I）。数据在各个子类别中得到细致平衡，以确保多样性并全面覆盖现实场景，如图3所示。经过彻底过滤和选择后，数据集最终在T2I和I2I数据之间实现了大约1:1的平衡。这种平衡构成是有意为之，因为纳入T2I数据对于建立强大的文本语义理解基础至关重要，这使得模型能够在各种图像编辑任务上实现更好的泛化。

图3 | 数据分布概览。经过数据清洗后，我们的训练数据集在文生图（T2I）和图生图（I2I）任务之间实现了大约1:1的比例。T2I部分分为三个主要类别：自然（通用生成）、人物（以人为中心的生成）和设计（艺术风格、文本渲染和复杂布局）。I2I部分也分为三个类别：语义编辑（基于内容的修改）、风格编辑（美学调整）和结构

编辑（空间排列和构图）。我们的数据收集策略确保了训练过程中多样性和质量的平衡，提供了全面的覆盖和精确的标注，以促进稳健的模型训练。

文生图（T2I） T2I数据被纳入训练过程以保留生成先验并确保训练稳定性，使模型能够从文本提示生成连贯逼真的图像。数据集分为几个关键类别，每个类别旨在覆盖广泛的上下文、风格和主题。T2I数据集中的主要类别如下：

- **自然（57.7%）**：最大的类别，涵盖多样化的子类别，如物体、景观、城市景观、植物、动物、食物和室内场景。该类别对于生成逼真且多样化的自然环境至关重要。
- **设计（22.6%）**：侧重于结构化和艺术性视觉内容，包括海报、用户界面、卡通和其他艺术形式。它在训练模型理解复杂布局、艺术风格和详细文本提示方面发挥着关键作用。
- **人物（19.7%）**：包含与人类形象相关的图像，如肖像、运动和活动。该类别对于训练模型生成准确多样的人物相关图像至关重要，增强了其处理以人为中心任务的能力。

图生图（I2I） 我们数据集的I2I部分对于基于特定指令增强或修改现有图像至关重要。任务大致分为三种主要类型：语义编辑、风格编辑和结构编辑。这些类别根据对图像所做修改的性质来定义——无论是改变内容、增强视觉风格，还是调整场景的结构和构图。下面，我们描述每个类别及其相关子类别：

- **语义编辑（26.2%）**：此类别涉及修改图像的内容，例如改变物体或背景。它包括添加、移除或替换物体，以及改变背景等任务。这些任务对于使模型能够编辑场景的主要元素非常重要，允许在保持图像整体连贯性的同时进行精确的内容操作。
- **风格编辑（24.2%）**：风格编辑侧重于在不改变核心内容的情况下增强图像的视觉风格和美学特征。此类别中的任务包括颜色改变、风格迁移、色调转换和材质修改。这些任务对于训练模型改变图像外观至关重要，例如修改氛围、应用艺术风格或在保持主题的同时改善视觉美学。
- **结构编辑（49.6%）**：结构编辑涵盖图像内元素的空间排列和位置变化。它包括细粒度、控制密集的场景，如视角变化、运动变化和肖像变化。除此之外，还包括文本修改和更高级的混合变化等更复杂的案例，需要协调的空间和视觉推理，使模型能够执行更先进和可控的场景变换。

2.2 数据预过滤

2.2.1 去重

为减轻来自不同来源的冗余并确保高质量的训练数据，我们实施了一个多级分层去重流程，该流程包含三个严格程度递增的层级：

第一级：粗略全局去重 在第一级，我们使用可扩展的图像去重系统 [25] 对所有图像进行大规模近似重复检索和聚类。图像被嵌入到共享特征空间中，我们识别并分组视觉上相似的样本，只保留对数据集贡献独特视觉内容的代表性样本。此阶段主要解决图像池中的精确重复和广泛相似性问题。

第二级：对级去重 第二级侧重于图像到图像（I2I）编辑数据，其中冗余也可能表现为重复的源-目标对。在此阶段，我们应用粗略的对级去重，使用 CLIP [27] 嵌入和内部图像嵌入模型计算源图像和目标图像之间的相似度分数。具有高语义相似度的对被丢弃，以移除琐碎的恒等映射或相同的编辑结果。这有助于减少可能对模型泛化产生负面影响的基于模板的冗余。

第三级：细粒度多度量去重 在最后一级，我们应用严格的多样化去重策略，以确保只保留真正独特且有意义的编辑样本。在这里，我们结合峰值信噪比（PSNR）[9]、结构相似性指数（SSIM）[36]、2021年图像相似度挑战赛指标（ISC21）[6] 和 CLIP 相似度来进行细粒度比较。这种多度量方法使我们能够消除细微的近似重复、变化极小的模板以及视觉上变化不显著的图像。通过应用这种严格的过滤，我们确保数据集只保留高质量、多样且非重复的编辑样本。

图4 | 数据过滤概览。我们的多阶段数据过滤流程包括去重、光度与统计过滤、伪影移除、感知质量评估和 AIGC 检测。这些步骤确保数据集没有冗余、视觉噪声、伪影和合成内容，为图像编辑模型训练保持高质量样本。

2.2.2 光度与统计过滤

为减少视觉噪声并稳定训练，我们使用亮度、饱和度、RGB熵、纹理复杂度和锐度等描述符进行光度和统计过滤。亮度和饱和度用于检测曝光不足或过度的图像，以及因极端光照或非自然渲染导致颜色响应异常的图像。RGB熵过滤掉具有大面积均匀区域或平坦背景的图像，而纹理复杂度移除具有不规则高频模式的样本，这些通常由压缩伪影或非语义纹理引起。锐度用于识别具有运动模糊、散焦或其他影响细节的退化的图像。我们估计每个描述符的经验分布，并丢弃统计范围之外的样本，确保数据集保留稳定的光度特性和更丰富的结构内容用于训练。

2.2.3 内容有效性与伪影移除

为确保有效内容并防止误导性监督信号，我们使用专用检测器移除带有不良伪影的图像。这包括过滤带有水印、可见文本叠加、马赛克、拼贴、隐私掩码、二维码、条形码的图像，因为这些可能引入非语义模式或扭曲，损害模型性能。我们还基于元数据和几何线索应用旋转校正，以确保一致的空间对齐，减少不必要的几何变化。这种过滤提高了视觉监督的有效性，并为精确的图像编辑提供了更干净的基础。

2.2.4 感知质量与美学

我们使用深度学习评估器来评估图像质量和美学。IQA指标 [24, 23] 检测模糊、噪声和曝光不平衡等问题，而美学预测器 [28] 评估构图和吸引力。低质量或评分较差的样本被过滤掉，确保为图像编辑训练提供更好的视觉连贯性。

2.2.5 AIGC 检测

我们使用内部 AIGC 检测来识别并过滤由生成模型生成的图像。这些样本可能绕过标准质量检查，但表现出如平滑纹理、均匀光照和细节抑制等偏差。移除 AIGC 内容可保留真实的图像统计信息，并防止合成先验降低模型泛化能力。

2.3 数据生产引擎

虽然现实世界数据提供了自然分布，但它通常缺乏支持专门编辑任务所需的数据密度。为解决这一局限性，我们构建了一个数据生产流水线，通过三种前向构建策略生成配对的编辑数据，如图5所示，从而在编辑任务空间中实现密集覆盖和可控合成。

通过指令控制合成专家模型 我们采用仅需输入图像和指令的图像编辑模型 [51, 39, 32, 16] 作为默认专家，实现快速广泛的数据生成。在此基础上，我们开发了一个指令驱动的专家合成流水线，以稳定地将多样化编辑任务映射到不同专家模型的能力边界。具体来说，我们将每个专家的范围形式化为确定性指令模板，并构建和维护：一个专家指令库和一个编辑目标词典。专家指令库将模型约束和触发条件总结为规范原语和结构化槽位，提高指令稳定性和性能。编辑目标词典通过结合 VLM 发现（解释图像并提出接地编辑目标）、任务清单（作为任务对齐的可编辑对象/属性库，用于长尾覆盖）和辅助元数据（例如，OCR、坐标）作为精确接地的可计算锚点，来定义要编辑的内容。为进一步提高编辑质量，我们在策展数据上使用 SFT 或 LoRA 对专家模型进行细化。

通过结构化控制合成专家模型 我们进一步引入了需要结构化控制的专家模型 [51, 35, 43, 45, 18, 55, 12, 34, 11]，其中编辑由非文本的结构化信号驱动，以减少语言歧义并提高生成可控性。具体来说，我们从辅助感知模

块（如 SAM [3] 和 DWpose [46]）提取结构先验，包括分割掩码和姿态关键点，并将其与预配置模板中的任务参数结合，以导出特定于任务的结构化控制信息。然后将结构化信息输入专家模型以精确调制编辑过程。这种结构化控制方法对于空间敏感的任务尤其有效，如精确物体移除、面部表情和身体姿态转移以及外观重定向。

无模型模板合成 为补充生成方法，我们采用无模型模板合成流水线，避免模型推理，而是利用丰富的预定义算法模板库来生成具有精确编辑且无伪影的编辑对。模板集包括但不限于：3D参数化模板，利用图形引擎和骨骼系统合成像素一致的面部表情、身体重新姿态和其他参数化变换；结构化布局模板，为文本、标志、UI元素和类似的图形组件定义空间锚点，以严格执行排版和布局约束；以及算法过滤模板，涵盖确定性图像处理操作，如颜色调整、滤镜和几何变换。

图5 | 数据引擎概览。数据生产引擎通过三种前向构建策略生成配对的图像编辑样本。(1) 指令控制通过使用由 VLM 发现和辅助元数据支撑的指令模板和编辑目标词典来合成专家模型。(2) 结构化控制利用从感知模块提取的掩码和姿态关键点等结构先验，以精确控制信号引导专家模型。(3) 无模型模板合成包括预定义的3D模板、布局模板和算法过滤器等方法，以实现可控且确定性的生成。该流水线设计为可迭代的，支持复杂的多步编辑。

2.4 长尾数据补充

为处理某些编辑任务缺乏足够样本的长尾问题，我们采用了一种简单的“检查和填充”策略。

我们首先通过将所有训练指令索引到向量数据库中来评估现有数据集的覆盖范围。当模型在特定编辑领域表现不佳时，我们查询该索引以量化可用的训练样本。如果特定指令的样本密度不足，我们将其识别为需要针对性补充的“数据缺口”。

一旦识别出缺口，我们利用稳健的图像检索框架从大规模候选池中获取基础图像。该框架采用专门的深度特征编码器将原始图像映射到高维隐空间，生成密集、高度判别性的嵌入。在大型向量索引引擎的支持下，系统利用种子图像或语义查询，通过度量学习检索在空间布局、纹理、颜色分布和语义连贯性方面具有高保真度的样本。通过使用文生图和图生图检索，我们可以精确定位符合缺失任务要求的图像。然后，这些检索到的图像通过我们的数据生产引擎进行处理，以生成新的高质量训练对，从而有效纠正我们数据分布中的薄弱环节。

2.5 标注引擎

为对文生图（T2I）生成和图生图（I2I）编辑提供高质量的文本监督，我们开发了一个全面的标注引擎。该引擎逐步运行：从静态单图像理解到动态跨图像差异推理，最后到以用户为中心的指令细化。

2.5.1 结构化标注

对于 T2I 训练和 I2I 对的视觉基础，简单的 alt 文本是不够的。我们采用 VLM 生成结构化标注（见标注提示 7），提供图像的全面分解。这些标注明确详述了主要主体、背景元素、光照条件、艺术风格和相机角度。这种“结构化”监督确保模型在学习如何改变图像之前，先理解图像中的内容。

图6 | 指令标注示例。详细指令标注生成视觉变化的精确描述，简洁指令细化在保留关键细节的同时简化这些指令，而用户风格指令细化则将其改写为更自然、对话式的语气。

2.5.2 指令标注

为向 I2I（图生图）编辑任务提供高质量的文本监督，我们将指令生成分为三种不同类型：详细指令标注、简洁指令细化和用户风格指令细化。

详细指令标注 利用专门微调的 VLM [33]，此阶段侧重于为图像对之间的视觉转换生成基础真实基准。目标是产生准确、完整且明确反映源到目标变化的描述。该模型专门训练以进行高保真差异推理，持续建模主体属性、空间关系和语义变化。特别强调高敏感度维度，如左右方向、视角变化和细粒度属性，这些要求模型具备卓越的识别和表达能力。

简洁指令细化 此阶段同时处理指令简洁性和语言多样性，将它们整合到一个统一的细化流程中。通过利用来自多样化 VLM 模型套件 [8, 31] 的随机 VLM 模型和广泛的词汇库，我们在严格保留原始编辑意图的同时实现不同级别的简化。为防止模型过度拟合基础标注 VLM 的刚性模板，我们在重写过程中动态采样多样化的句法结构，从倒装、无主语句式到非正式措辞和各种其他语言模式。这种方法通过剥离冗余视觉修饰语和抽象具体概念来促进意图净化，确保模型掌握核心编辑逻辑而非特定于对象的模式。

用户风格指令细化 此阶段将简洁输出细化为自然的日常语言，以更好地反映人们的实际说话方式。目标是通过注入角色驱动语气和寻求帮助标记来弥合技术命令与人类对话之间的差距。这模拟了现实场景，用户可能使用诸如“你能帮我修一下这个吗？”或“你能通过改变某些东西来保存这张图片吗？”等短语寻求帮助。通过以不同比例融入这些温暖、交互式的短语，我们显著增强了模型解释非正式、直观和寻求帮助的用户意图的能力。

通过将这些重写的简洁指令与原始详细描述混合用于训练，我们构建了一个覆盖从最简口语化到细粒度规格的多尺度数据分布。这种混合策略使得从长文本中学到的细粒度视觉推理能力能够有效地泛化到短文本场景。因此，即使面对模糊或简洁的用户指令，模型也能利用其深层视觉知识进行准确的推理和执行。

2.6 数据后过滤

为确保高保真度和精确语义对齐，我们实现了一个用于自动化数据质量评估和策展的后过滤流水线。此阶段作为一个自动化质量门控，用于细化包括自然真实对和合成对在内的数据。具体来说，我们通过结合 LLM 驱动的难度负例挖掘和专家级人工标注，基于 Qwen3-VL-8B [33] 训练了一个专门的多模态评估模型。该模型在多个维度上精确量化编辑后的图像。随后，我们利用此模型对超过一亿个原始样本的数据集进行自动过滤。通过消除存在语义错位或感知质量较差的样本，我们显著提升了训练数据集的整体分布质量。

难度负例挖掘与多维度标注 高质量的负样本对于在数据细化过程中增强评估模型的判别能力至关重要。我们首先从海量原始数据集中采样 50,000 个“源图像-编辑指令-目标图像”三元组作为正样本。随后，我们使用 LLM 对原始指令应用语义扰动和随机重写。此过程生成偏差指令以构建 50,000 个负样本，从而形成一个包含 100,000 个实例的平衡数据集。为建立金标准基准，我们组织了一组人类专家进行双盲标注。评估标准侧重于两个关键指标：指令对齐（评估编辑是否准确执行了文本命令）和感知质量（检查清晰度、伪影和美学吸引力）。这种严格的标注方案确保了平衡的语义分布，为后续评估模型的精度提供了坚实的基础。

视觉-语言评估模型的训练 为实现与人类美学和逻辑判断紧密一致的自动化评估机制，我们使用 Qwen3-VL-8B 作为微调的主干。通过对前述 100,000 个高质量标注样本进行监督微调（SFT），该模型获得了解析复杂编辑指令和感知细微视觉差异的能力。实验结果表明，评估模型在多维度评分任务中表现出卓越的鲁棒性。其指标与人类专家的评估显示出强相关性。除了识别细微语义偏差外，该模型对生成图像中的结构扭曲和纹理伪影高度敏感，可作为替代昂贵人工评估的可靠自动化代理。

大规模数据策展与质量保证 使用训练好的评估模型，我们对超过一亿个样本规模的原始训练数据进行了全面的质量评估。我们建立了严格的过滤阈值，基于对齐分数和质量分数两个维度进行联合筛选。具体来说，模型自动识别并丢弃未能遵循指令、存在语义偏移或视觉保真度低（例如，模糊、伪影或逻辑不一致）的样本。这种系统性的数据纯化过程显著细化了训练集的分布。它确保生成模型在后续大规模训练中专注于高质量、高保真的编辑对，从而从根本上提高最终模型的性能。

3 模型训练

图7 | 架构概览。数据流程从桶采样器开始，该采样器根据任务类别和宽高比组织输入序列，以高效处理可变分辨率。随后是整理洗牌与丢弃机制，通过随机置换或省略图像标识符来增强文本提示，以提高鲁棒性。核心模型采用 MMDiT 块处理多模态特征，其中视觉输入由 VAE 编码器编码，多模态条件（参考图像和文本指令）由 Qwen VL 处理。为确保高保真生成，训练过程结合了一致性相似度损失；该机制从预测图像和真实图像中提取感兴趣区域（RoI），通过共享图像编码器以最小化身份差异。

3.1 架构

可扩展性和指令保真度是指导我们模型设计的基石目标。基于开源多模态文生图基础模型 [38] 构建，我们的架构继承了对视觉-语言细微差别的深刻理解，我们进一步将其扩展到生成和编辑领域。为弥合从多模态感知到高保真合成的差距，我们使用约十亿个图像-文本对的策展数据集扩展了训练规模。这一广泛语料库包含多样化的任务，包括文生图、单/多图像到图像生成以及基于复杂指令的编辑。如此大规模的数据使模型能够将抽象编辑命令与像素级语义转换相协调，确保跨不同领域的稳健泛化。

遵循统一序列建模的范式，我们采用双流多模态扩散Transformer（MM-DiT）作为核心生成引擎。在此配置中，来自 [38] 主干的文本嵌入、高保真 VAE 的隐 token，以及在编辑场景中的参考图像特征，被拼接成统一的输入流。这种设置促进了模态间的密集双向交互，最大限度地提高了模型在执行精确修改时保持结构完整性的能力。

为管理高维序列，我们利用 3D 统一 RoPE，其中参考和目标图像 token 共享空间坐标，但通过时间间隔进行区分。这种坐标对齐，加上对干净参考和带噪目标隐变量的不同时间条件设置，使我们的模型能够在多个竞争性基准上实现最先进的（SOTA）性能，在复杂图像操作中展现出卓越的稳定性和风格一致性。

3.2 训练效率优化

多条件感知宽高比分桶。为促进从文生图（T2I）生成到复杂多图像参考编辑等任务的分布式高效训练，我们设计了一个多条件感知桶采样器。与仅依赖单图像分辨率的传统采样器不同，我们的方法明确考虑了不同编辑指令中固有的输入图像数量 N 的可变性。为最小化同步开销并确保 GPU 间计算负载均衡，我们定义了一个由目标宽高比 r 和输入图像数量 n 表征的桶 $\mathcal{B}_{r,n}$ 。对于给定批次，总视觉序列长度 L_{vis} 被严格约束以确保与硬件的计算能力对齐，公式为 $L_{vis} = \sum_{i=1}^n \left\lceil \frac{H_i \cdot W_i}{p^2} \right\rceil \approx C$ ，其中 p 表示补丁大小， C 表示每个设备的恒定 token 容量。此策略有效减少了由不均匀 token 长度引起的 GPU 空闲时间。

为保持多样化空间布局（例如，1:1, 9:16, 3:4）的结构完整性，并确保分布式批次内的张量一致性，我们最小化应用于一组图像 $\{I_1, \dots, I_n\}$ 的裁剪变换 $\mathcal{T}$ 。我们通过最小化总裁剪面积来定义最佳桶尺寸 (h, w) ，确保信息损失在数学上最小化：

$$\arg \min_{(h,w) \in S} \sum_{i=1}^n |(H_i \cdot W_i) - (h \cdot w)| \quad (1)$$

其中 S 代表预定义分辨率桶的集合。此优化确保分布式节点间同步批次内的所有图像共享相同的张量维度，显著减少填充引起的计算浪费，同时为各种输入尺度保持高保真宽高比一致性。

随机指令对齐。为增强模型对输入排列的鲁棒性，并防止过拟合特定参考模式，我们实现了一个整理洗牌与丢弃机制。在数据整理阶段，参考图像经历随机丢弃概率和输入顺序的随机置换。关键的是，为保持视觉 token 与语言参考之间的语义对齐，文本提示会随动态更新以反映这些空间变化。例如，如果一张原本标记为“图1”的图像因洗牌而被置换到“图2”的位置，指令提示中的相应 token 会被重新索引，以确保文本正确引用洗牌后的图像序列。这种统一的增强策略迫使模型将特定的空间顺序与语义内容解耦，从而在复杂、多参考编辑场景中促进卓越的泛化能力，而不依赖于固定的输入序列。

系统级效率与稳定性。为解决大规模 DiT 架构的巨大内存需求，我们实施了一系列系统级优化以最大化训练吞吐量。一个关键策略是通过预计算嵌入并将其存储为离线张量来解耦 VLM 编码过程。这消除了冗余的在线计算，并减少了每次迭代的 FLOPs，使系统的计算能力完全用于生成式 Transformer。

在离线特征提取所获得的内存空间基础上，我们使用完全分片数据并行（FSDP）来管理分布式模型状态。通过分片优化器状态和梯度，我们将这些开销的内存复杂度从 $O(M)$ 降低到 $O(M/N)$ ，其中 N 是 GPU 数量。为进一步降低峰值内存占用，我们集成了梯度检查点并使用了 BF16 混合精度训练。

关键的是，VRAM 开销的累积减少使我们能够从全局 FSDP 方法过渡到通信效率更高的混合分片数据并行（HSDP）方案。标准的 FSDP 将模型状态分片到整个集群——这常常导致节点间链路的通信瓶颈——而 HSDP 将分片限制在单个节点内。这使我们能够充分利用高速节点内互连（例如，NVLink）进行纵向扩展效率，同时跨节点使用传统数据并行。通过减少节点间同步量，我们将横向扩展策略与可用网络带宽协调一致，从而显著提高了整体训练吞吐量。

图8 | 如图所示，我们的训练流程包括多个渐进阶段。我们从预训练和持续预训练开始，以建立稳健的语义和美学基础。然后模型进行监督微调以与编辑指令对齐，随后进行强化学习（DPO），最终得到具有增强生成质量和遵循能力的 DiffusionNFT 模型。

3.3 预训练

在基础预训练阶段，我们的主要目标是建立全面的视觉词汇和稳健的世界知识理解。与后续优先考虑美学质量的微调阶段不同，此阶段强调数据规模和语义多样性。我们采用了一个包含三个关键支柱的整体方法：

具有任意分辨率适应性的可扩展框架。为适应现实世界图像的多样化特性，我们实现了一个高效且灵活的训练框架。我们不坚持固定的方形分辨率——这通常需要进行激进的裁剪或缩放，从而破坏图像构图——而是采用动态桶采样策略。该机制自动将相似宽高比的图像分组到预定义的桶中，使模型能够原生地训练任意分辨率和宽高比（VAR）。这种方法不仅保留了视觉数据的语义完整性，还通过最小化填充来优化计算效率。此外，我们的框架设计为能够在文生图和单图像输入模式之间无缝切换。这种灵活性使模型能够利用配对图像-文本数据进行语义对齐，并利用未配对图像数据进行纯粹的视觉特征学习，最大限度地利用可用计算资源。

大规模数据集成与混合条件。我们的数据策略优先考虑信息的广度，利用从开放互联网收集的大规模语料库。考虑到网络数据固有的长尾分布和可变质量，我们采用包容性过滤协议。我们不强制实施严格的美学策展或人工类别平衡——这可能会丢弃稀有但语义上有价值的概念——而是集成所有“有效”的数据样本。这使模型能够学习视觉世界的广阔（尽管有噪声）表示。为解决网络文本中的噪声，我们采用混合标注方案，使模型联合训练于：(1) 原始元数据，保留原始、有噪声的描述以捕获丰富的非结构化世界知识和多样的语言风格；(2) 结构化合成标注，生成以提供精确、标签密集的描述，增强模型的提示遵循能力和对象识别能力。这种混合确保了模型获得通用知识，同时保持对结构化提示的响应能力。

通过渐进时间步采样的课程学习。鉴于数据质量的高方差和数据集的巨大规模，训练稳定性至关重要。我们引入了一个渐进时间步课程来管理噪声扩散过程。在初始阶段，采样偏向于高噪声时间步。由于高噪声水平对应于图像的低频分量，此策略迫使模型优先学习全局语义结构、布局 and 大规模视觉模式，这些即使在低质量数据中通常也是稳健的。随着训练收敛，我们逐渐将分布转向所有时间步的均匀采样。这种转变使模型能够细化其高频细节和纹理的生成。该课程有效缓解了噪声网络数据上训练时的发散风险，并确保了从学习粗粒度概念到掌握细粒度细节的平滑过渡。

3.4 持续预训练（CT）

统一任务采样与分辨率适应性 为增强模型在不同生成范式中的通用性，持续预训练（CT）阶段采用统一采样策略，在文生图、单图像和多图像任务之间平衡输入。这种联合训练机制利用计算预算来巩固模型同时处理不同

输入模态的能力。此外，我们通过实施更广泛的桶采样协议来显著扩展分辨率管理的范围。我们明确训练于全面的宽高比谱系——包括 2:1、16:9、3:2、4:3、1:1、3:4、2:3、9:16 和 1:2。这种广泛的宽高比覆盖防止了过拟合标准格式，并确保无论用户请求的画布尺寸如何，模型都能保持构图完整性和视觉保真度。

合成增强与密集语义对齐 此阶段训练数据的组成经过精心设计，以弥合数量和质量之间的差距。我们维持从互联网采样的高质量数据流，并辅以大量旨在覆盖代表性不足领域的合成数据。此阶段的一个关键创新是集成了密集标注训练。通过使用全面、高度详细的描述进行训练样本，我们迫使模型将视觉特征与复杂且特定的文本线索对齐。这种方法对于学习长尾词汇特别有效，确保模型对稀有对象、细微纹理和复杂场景（这些通常被稀疏标注所忽略）发展出稳健的理解。

基于聚类的分布平衡 为解决大规模数据集中固有的不平衡问题，我们在整个 CT 阶段强制执行严格的类别平衡协议。我们不依赖于原始数据频率，而是将整个数据集分类为不同的语义聚类，并跨这些组应用统一的采样策略。此方法确保每个类别——从常见对象到小众艺术风格——在训练期间获得足够的曝光。通过保证每个语义聚类被充分且平等地训练，我们减轻了模式崩溃或过拟合于主导类别的风险，从而使模型在广泛多样的主题上展现出持续的高质量生成能力。

3.5 监督微调（SFT）

高质量数据对齐与平衡分布。 为将模型从广泛的、有噪声的预训练分布过渡到聚焦的、高质量的子流形，我们构建了一个分层组织的数据集，该数据集以经过细致人工过滤的高分辨率图像（1024x1024）为主。与预训练中松散的监督不同，我们的 SFT 阶段利用遵循指令的标注和结构化提示，在文本描述和视觉输出之间强制执行精确对齐。这种严格的监督充当锚点，迫使模型丢弃低质量模式（例如，伪影或不一致的渲染）并收敛于卓越的纹理质量。此外，为解决关于长尾概念的灾难性遗忘风险，我们跨不同语义聚类强制执行严格的一致性。通过采用动态重采样策略确保数据类别之间的严格平衡，我们在提升美学保真度的同时保留了预训练模型的语义多样性。

通过模型权重平均进行精细化优化。 在优化过程中，我们采用比预训练阶段显著更小的学习率。这种保守的更新策略旨在细化高频细节并优化照片级真实感属性，而不干扰先前建立的全局结构理解。为进一步增强模型的生成稳定性和美学鲁棒性，我们纳入了指数移动平均（EMA）策略，也称为模型权重平均。通过在训练轨迹中维护模型参数的移动平均值，我们有效地平滑了优化景观。这种融合过程有助于综合不同训练步骤的能力，减轻单个检查点固有的特定偏差，并确保最终模型实现平衡的性能。

表1 | 训练阶段与超参数

阶段属性 预训练 CT SFT DPO NFT		训练配方 分辨率(像素) 384-512 512-1024 1024 1024 1024 1024 训练步数 300K 65K 5K 5K 500 预热身数 0 0 500 500 0 优化器 colspan="5" AdamW ($\beta_1 = 0.9$, $\beta_2 = 0.999$) 梯度裁剪 colspan="5" 1 权重衰减 colspan="5" 0.01
数据集 互联网收集 100M 5M 50K 10K 10K 合成数据 5M 10M 50K 50K 10K	标注 原始标注占比 55% 20% 10% 10% 10%	结构化标注占比 40% 60% 45% 30% 30% 指令性标注占比 5% 20% 45% 60% 60%

3.6 基于人类反馈的强化学习（RLHF）

3.6.1 直接偏好优化（DPO）

我们使用增强有正样本强化（PSR）的 DPO 框架来优化模型，以确保训练稳定性。对齐依赖于两阶段数据合成策略，结合混合策略构建以实现稳健的指令遵循，以及特定的视觉增强采样以实现美学保真度。

正样本强化（PSR）策略 尽管标准 DPO 提供了稳健的框架，但我们的实验揭示了一种“双重退化”现象。具体来说，我们观察到 Win Diff 和 Lose Diff 项在训练期间常常呈现出同步上升的趋势。这表明优化轨迹偏离了高质量数据流形；模型在试图远离被拒绝样本 (x_l) 的同时，实际上降低了对选中样本 (x_w) 的生成能力。

这种不稳定性表明，在连续高维空间中，仅仅惩罚负样本不足以将策略引导至期望分布。为解决此问题，我们提出了一种非对称梯度优化策略，将对齐锚定在正样本强化（PSR）上。我们引入权重系数 ω 和 SFT 正则化项 λ ，以明确优先考虑高质量分布的重建：

$$\mathcal{L}_{\text{Ours}} = -\mathbb{E}_{(c_{x_w}, x_l) \sim \mathcal{D}} \left[\log \sigma(\beta[(L_l^{\text{ref}} - L_l^{\text{ref}}) - \omega \cdot \underbrace{(L_w^{\text{ref}} - L_w^{\text{ref}})}_{\text{Win Diff}}] - \lambda \mathcal{L}_w^{\text{ref}}) \right] \quad (2)$$

通过设置 $\omega > 1$ ，我们放大了 Win Diff 项的梯度贡献，确保优化主要由高保真模式 (x_w) 驱动，而不是被无约束地避开负样本所误导。

自动化数据合成与混合策略 为绕开人工标注的成本，我们实现了一个完全自动化的流程，该流程采用多阶段指令演化策略，使用 VLM 合成从原子任务到复杂现实请求的指令。为避免自采样固有的“能力上限”，我们采用混合策略数据构建方法。我们不只依赖 SFT 模型，而是从不同的专家分支和美学优化模型中获取高质量的正样本，并将其与来自基础模型的 VLM 过滤负样本进行对比。这种方法创造了更陡峭的学习信号，打破了自我生成的自我强化循环，同时特别增强了视觉保真度和纹理质量。

3.6.2 Diffusion NFT

在此阶段，我们通过 DiffusionNFT [54] 进行在线强化学习，优化由细粒度 VLM 和布局感知 OCR 模型导出的复合奖励。此过程进一步通过半难样本挖掘策略来增强数据效率。

扩散负感知微调 我们采用 DiffusionNFT 直接在前向过程中进行在线强化学习。与需要配对数据的 DPO 不同，DiffusionNFT 利用每个在线采样图像的最优概率 $r \in [0, 1]$ 。目标通过隐式参数化的正负策略最小化加权流匹配误差：

$$\mathcal{L}_{\text{NFT}} = \mathbb{E}_{t, x_0 \sim \pi^{\text{old}}} [r \|v_{\theta}^{+}(x_t, t) - v\|^2 + (1 - r) \|v_{\theta}^{-}(x_t, t) - v\|^2] \quad (3)$$

其中 v 表示目标速度，隐式策略定义为 $v_{\theta}^{+} = (1 - \beta)v^{\text{old}} + \beta v_{\theta}$ 和 $v_{\theta}^{-} = (1 + \beta)v^{\text{old}} - \beta v_{\theta}$ 。从理论上讲，此公式定义了一个对比改进方向，将策略推向高奖励区域，同时明确惩罚低奖励轨迹。

细粒度 Logit 加权集成奖励 利用第 2.6 节中详述的专门奖励模型，我们在关键维度上导出密集的强化信号。这些模型在评分前整合了思维链（CoT）推理，确保与细微的人类判断对齐。为避免稀疏离散整数奖励固有的优化不稳定性，我们在 VLM 前向传递期间采用连续软评分机制。具体来说，在生成的 CoT 序列之后，我们立即提取对应于数字评分 token 的 logits，以计算 Softmax 归一化的概率加权期望，而不是依赖于硬 argmax 预测。通过跨 K 次随机推理传递平均这些软分数，我们有效地平滑了奖励景观，保证了用于稳健优化的连续稳定强化信号 R ：

$$R(\mathbf{x}, \mathbf{y}) = \frac{1}{K} \sum_{k=1}^K \sum_{v \in \mathcal{V}} \nu \cdot P(v | \mathbf{x}, \mathbf{y}, \mathbf{c}_k), \quad \text{with } P(\nu | \cdot) = \frac{\exp(z_v)}{\sum_{v' \in \mathcal{V}} \exp(z_{v'})}, \quad (4)$$

其中 $\mathbf{c}_k$ 表示第 k 次传递生成的 CoT 理由， $\mathcal{V}$ 代表数字 token 的集合（例如， $\{1, \dots, 5\}$ ）， ν 是与该 token 关联的标量值。

布局感知的基于 OCR 的奖励 对于文本编辑任务，我们引入了一种布局感知的基于 OCR 的奖励，它更准确地反映了文本保真度和空间一致性。传统的基于 OCR 的奖励仅依赖于识别文本与目标字符串之间的编辑距离。虽然直接，但这忽略了排版和布局，允许模型通过生成超大字符来作弊，因为 OCR 系统更容易识别这些字符，但它们与图像融合不佳并破坏布局一致性。为克服此限制，我们在文本正确性之外纳入了布局一致性。我们不再将 OCR 输出视为平面字符串，而是将预测和参考 OCR 输出分解为具有位置和比例的字符级元素，并评估每个字符是否出现在合理的位置和大小。此公式在保留语义对齐信号的同时，惩罚缺失、错位或异常缩放的字符。一个轻量级门控机制进一步确保布局项仅在文本内容合理正确时才激活。总奖励公式为：

$$\mathcal{R}_{\text{LA-OCR}} = w_{\text{text}} \underbrace{\left(1 - \frac{d(s_{\text{pred}}, s_{\text{tgt}})}{\max(|s_{\text{tgt}}|, 1)}\right)}_{\mathcal{R}_{\text{text}}} + w_{\text{layout}} \text{Gate}(\mathcal{R}_{\text{text}}) \underbrace{\left(\frac{|s_{\text{pred}}|}{|s_{\text{tgt}}|} \sum_i e^{-d_i} e^{-\Delta_i}\right)}_{\mathcal{R}_{\text{layout}}} \quad (5)$$

其中 s_{pred} 和 s_{tgt} 是 OCR 预测和目标文本字符串， d_i 和 Δ_i 表示第 i 个匹配字符的中心距离和过度缩放惩罚。此设计减轻了奖励作弊并极大地减少了文本崩溃，从而在文本编辑任务中产生更稳定的字形和更自然的排版。

用于数据效率的半难样本挖掘 我们凭经验观察到，单纯的随机采样产生的收益微乎其微，因为模型效率低下地将容量分配给了已在其舒适区内的样本。为缓解这种低效性，我们引入了一个难度感知课程，利用先前的 DPO 检查点进行离线难度估计。通过为每个指令生成一组多样化的候选编辑，我们估计了潜在的奖励分布。我们特别针对“半难”样本，其定义为一个独特的性能特征：有能力但高方差。这些样本通常表现出令人满意的平均奖励——表明模型掌握了语义对齐——但其下限分数却存在显著的不稳定性。与提供有限信息增益的平凡样本或常常引发优化崩溃的完全困难样本不同，这些半难样本通过瞄准模型的能力边界来最大化梯度效用。通过关注概念上可行但缺乏鲁棒性的样本，此策略最大化每步训练的信息增益，从而显著增强编辑过程的一致性和保真度。

3.7 一致性损失

我们观察到，在通用图像编辑中，当仅依赖标准均方重建损失时，保持身份仍然是一个重大挑战，尤其是在以人为中心的应用中。虽然这些目标对于确保底层像素保真度有效，但它们往往无法捕捉到身份一致性所需的高层语义细微差别，导致不期望的身份漂移现象。鉴于以人为中心的图像编辑具有高实用价值和日益增长的需求，迫切需要能够在整个编辑过程中稳健保持身份的机制。因此，我们将一个稳健的身份一致性约束整合到训练框架中。

修正流中的去噪过程遵循明显的从粗到细的进展。我们观察到早期阶段（高噪声区域）对于身份形成至关重要，此时建立全局语义结构，而后期阶段则侧重于细化细粒度纹理。我们认为，当模型进入低噪声区域时，带噪输入图像已经承载了稳定的身份结构。由于此时身份实际上已“锁定”在输入中，进一步的面向身份的优化不仅不太可能改变已建立的面部特征，还可能因与模型合成细粒度细节的能力竞争而引入非预期的视觉伪影。受此洞察驱动，我们为身份损失 L_{id} 提出了一种动态权重调度。具体来说，权重 λ_{id} 被定义为噪声水平 σ 的函数：

$$\lambda_{id}(\sigma) = \begin{cases} \eta \cdot \sigma^2, & \text{if } \sigma < 0.9 \\ 0, & \text{otherwise} \end{cases} \quad (6)$$

其中 η 是缩放超参数。这种二次衰减确保约束在模型从语义锚定向像素级细化过渡时逐渐减弱。总训练目标则公式化为：

$$L_{\text{total}} = L_{\text{mse}} + \lambda_{id}(\sigma) \cdot L_{id}. \quad (7)$$

身份损失 L_{id} 的实现首先定义一个可微的空间变换 T ，旨在从图像中提取并归一化感兴趣区域（ROI）。对于以人为中心的编辑，此变换专门从真实图像 x_{gt} 中检测到的面部关键点导出，将脸部对齐到规范表示。在训练期间，我们从预测速度 v_t 获得单步去噪估计 $\hat{x}_0$ ，即 $\hat{x}_0 = x_t - \sigma_t \cdot v_t$ 。尽管 $\hat{x}_0$ 在较高噪声水平下可能模糊或包含伪影，但预训练的语义主干——最显著的是人脸识别模型——对此类退化表现出显著的鲁棒性。这种鲁棒性确保 L_{id} 能够提供相对稳定的语义指导，并有效地优化主体的身份，即使底层图像重建是粗糙的。为保持严格的空间对应关系并确保训练稳定性，我们将相同的变换 T （由 x_{gt} 参数化）应用于预测的 $\hat{x}_0$ ，确保损失在完美对齐的区域上计算。

此框架自然扩展到多主体场景。对于包含 N 个个体的图像，我们独立检测并对齐每张脸，以获得一组变换 $\{T_i\}_{i=1}^N$ 。总身份损失公式化为所有检测主体上的平均余弦距离：

$$L_{id} = \frac{1}{N} \sum_{i=1}^N \left(1 - \frac{\phi(T_i(\hat{x}_0)) \cdot \phi(T_i(x_{gt}))}{\|\phi(T_i(\hat{x}_0))\|_2 \cdot \|\phi(T_i(x_{gt}))\|_2} \right), \quad (8)$$

其中 $\phi(\cdot)$ 表示预训练的人脸识别主干。通过跨所有主体聚合损失，我们的模型在关键的结构形成窗口期间有效地锚定了每个个体的独特身份，同时保持了文本完整性。这种对齐是可扩展的，并且可能通过采用适当的语义编码器来适应其他通用物体的保持。

3.8 训练策略

为增强训练稳定性并最大化数据效率，我们的框架整合了严格的优化策略，旨在确保稳健的模型泛化。该方法通过分布式分层采样机制协调全局时间步分布，并通过训练后权重平均协议细化参数收敛。

分布式分层时间步采样。 在标准分布式训练中，跨 GPU 的独立随机采样扩散时间步常导致统计聚类，阻止全局批次均匀覆盖噪声谱。为解决此问题，我们实施了一种离散分层采样策略。总扩散时间范围 T 被分解为 K 个不相交的等距子区间，其中 K 对应于分布式世界大小（或组大小）。在每次训练迭代中，每个计算 rank 被分配一个特定的子区间，从中均匀采样 t 。为防止归纳偏差——即特定 rank 过拟合于固定噪声水平——我们采用同步区间轮换机制。一个全局排列种子被定期广播，以在各 rank 间动态重新分配噪声区间。这确保了聚合的全局批次在每一步都近似于 $t \in [0, T]$ 上的完美均匀分布，显著稳定了扩散目标的收敛。

Logit-正态损失加权。 虽然采样概率是全局均匀的，但每个时间步对梯度的贡献由 Logit-正态加权方案调制。损失权重根据噪声水平确定，遵循以扩散过程有意义的中间轨迹为中心分布。这使得优化器能够抑制来自可忽略的高噪声或低噪声极端的贡献，同时将容量集中在语义结构和纹理主要建立的关键中间阶段。

模型权重平均。 为综合模型在整个优化轨迹中的优势，我们采用指数移动平均（EMA）协议。我们不依赖于可能对最后几个批次的随机性敏感的单一最终检查点，而是计算收敛迭代中模型参数 θ 的算术平均值。这种权重集成方法平滑了损失景观，有效中和了瞬态波动，并增强了模型在现实编辑场景中应对分布偏移的鲁棒性。

4 REDEdit-Bench

图9 | REDEdit-Bench 的任务类别分布。

为更好地评估指令遵循保真度和保持质量，我们引入了 REDEdit-Bench，一个包含 1,673 个双语（中文-英文）编辑对的基准测试，涵盖 15 个结构化编辑类别。如图9所示，该基准测试在所有任务类别中提供了平衡的分布。如表2总结，REDEdit-Bench 在规模和评估设计方面均明显优于广泛使用的开源编辑基准测试。

4.1 基准构建

我们从互联网和合法采购渠道收集了超过 3,000 张真实世界图像，涵盖自然景观、建筑、物体、动物和肖像。专业技术工作人员首先选择每张图像并编写相应的编辑指令，最终构建了 1,673 个双语（中文-英文）编辑对。

这些对随后由多位专家进行审查和验证，以确保编辑指令的多样性和图像来源的合法性。

表2 | 开源图像编辑基准测试的关键属性比较。REDEdit-Bench 实现了最大规模，并且是唯一涵盖所有列出属性的基准测试。

基准测试	规模	真实图像	人工过滤	子任务数	双语	特定任务评估提示
MagicBrush [50]	1,053	✓	✓	7	✗	✗
AnyEdit [30]	1,250	✓	✗	25	✗	✗
ImgEdit [48]	811	✓	✓	14	✗	✓
GEdit-Bench [21]	606	✓	✓	11	✓	✗
REDEdit-Bench (Ours)	1,673	✓	✓	15	✓	✓

4.2 评估流程

基于 REDEdit-Bench，我们对主流图像编辑模型进行了全面评估，主要关注提示合规性、视觉自然度以及物理与细节连贯性。采用 Gemini 3 Flash 作为自动评估器，我们的模型在开源模型中达到了 SOTA 性能。

对于文本编辑任务，我们引入了两个新颖指标：OCR 和 VLM Judge。OCR 指标通过将 OCR 结果与真实值进行比较，计算莱文斯坦距离、完成率和单词准确率，生成加权归一化分数来量化字符生成精度。为弥补 OCR 仅关注拼写的局限性，VLM Judge 利用多模态大语言模型评估视觉质量。它评估的指标包括 SuccessEdit、OverEdit、Style 和 Consistency（背景融合）。这些指标共同构建了一个平衡字符准确性与视觉保真度的综合评估。

5 性能与评估

我们通过人工评估和标准化基准测试来全面分析我们方法的有效性。如第5.1节所述，我们首先进行结构化人工评估，让标注者根据精心设计的维度评估模型输出。第5.2节随后展示了在基准数据集上的定量和定性结果，涵盖四个代表性编辑类别：通用编辑、以文本为中心的编辑、创意编辑和虚拟试穿编辑。这种双重评估框架能够从感知和客观两个角度进行充分验证。

5.1 人工评估

图10 | 该图比较了 FireRed-Image-Edit 与其他四个模型在两个指标上的表现。FireRed-Image-Edit 获得最高的一致性分数，并在文本到图像的对齐方面领先于大多数竞争对手，除了 Nano-Pro 在该类别中略胜一筹。

为全面评估我们图像编辑基础模型的感知质量和实际效果，我们针对强大的开源和商业基线进行了多模型盲测人工评估。不是采用成对比较，而是将同一输入多个模型输出同时以随机顺序呈现，不透露模型身份。标注者独立评估每个结果，以确保公平性并消除位置或品牌偏差。该评估协议旨在从多个互补角度共同衡量指令执行的正确性和编辑结果的感知质量。

5.1.1 评估维度

我们沿着两个精心设计的维度评估每个编辑结果：

提示遵循。此维度衡量模型理解和执行用户提供提示的准确性和完整性。标注者评估预期编辑类型是否被正确识别，所有关键约束是否被满足，以及最终输出是否忠实地反映了用户的编辑意图，没有遗漏或多余的修改。

一致性保持。此指标侧重于保护未编辑区域。理想情况下，只应修改提示明确指定的区域，而所有其他内容——如面部身份、背景、物体结构、纹理和全局布局——应保持不变。此维度对于局部和迭代编辑场景尤为关键。

5.1.2 结果分析

如图10所示，我们的模型在提示遵循和一致性方面均取得了领先性能。FireRed-Image-Edit 显著优于 LongCat 和 Qwen-Image-Edit-2511 等开源基线，并与商业系统保持竞争力，表明其具有强大的指令理解和执行能力。

在一致性保持方面，我们的模型在所有比较方法中获得了最高分，展示了其仅修改预期区域同时保留未编辑内容的卓越能力。这突显了其在受控和精确编辑场景中的鲁棒性。

5.2 定量与定性结果

5.2.1 通用编辑

ImgEdit。我们在 ImgEdit 基准上评估了我们的模型，该基准测量指令完成度和视觉质量。表3显示 FireRed-Image-Edit 取得了最先进的性能，超越了开源和闭源模型。此结果突显了模型在遵循常见编辑命令方面的熟练程度。

GEdit。我们在 GEdit 基准上评估了模型的能力，这是一个综合评估套件，旨在测试指令遵循和输出视觉保真度。如表4所示，FireRed-Image-Edit 优于现有的开源模型。这种优越的性能强调了模型卓越的命令理解和多样化编辑任务的精确执行能力。

REDEdit-Bench。REDEdit-Bench 是我们自建的基准，用于评估现实世界的编辑使用情况，更加强调复杂的复合指令和保持约束。它在第4节中构建。表5-6总结了主要结果。FireRed-Image-Edit 在开源模型中排名最高，展示了具有竞争力的基于指令的编辑性能。

可视化 我们展示了与常见且明确的用户请求相对应的通用编辑案例。这些示例包括对象插入和替换（添加、替换）、属性和外观修改（颜色）、混合编辑任务（组合），以及图像恢复任务（称为低级）。此类任务要求指令与结果之间的精确对齐，同时保持全局一致性并避免对无关区域进行不必要的更改。所呈现的图11-13表明，FireRed-Image-Edit 能够可靠地执行这些编辑，具有精确的定位、物理上合理的交互和稳定的视觉质量，使其适用于广泛的日常图像编辑应用。

表3 | ImgEdit-Bench 上的结果（按类别和总体性能）。最佳结果以粗体显示，次佳结果以下划线显示。

模型	添加	调整	提取	替换	移除	背景	风格	混合	动作	总体↑
Nano-Banana	[10]	4.62	4.41	3.68	4.34	4.39	4.40	4.18	3.72	4.83
Seedream4.0	[29]	4.33	4.38	3.89	4.65	4.57	4.35	4.22	3.71	4.61
Seedream4.5	[29]	4.57	4.65	2.97	4.66	4.46	4.37	4.92	3.71	4.56
Nano-Banana-Pro	[10]	4.44	4.62	3.42	4.60	4.63	4.32	4.97	3.64	4.69
Instruct-Pix2Pix	[2]	2.45	1.83	1.44	2.01	1.50	1.44	3.55	1.20	1.46
MagicBrush	[50]	2.84	1.58	1.51	1.97	1.58	1.75	2.38	1.62	1.22
AnyEdit	[49]	3.18	2.95	1.88	2.47	2.23	2.24	2.85	1.56	2.65
UltraEdit	[53]	3.44	2.81	2.13	2.96	1.45	2.83	3.76	1.91	2.98
OmniGen	[44]	3.47	3.04	1.71	2.94	2.43	3.21	4.19	2.24	3.38
ICEdit	[52]	3.58	3.39	1.73	3.15	2.93	3.08	3.84	2.04	3.68
BAGEL	[5]	3.56	3.31	1.70	3.30	2.62	3.24	4.49	2.38	4.17
UniWorld-V1	[19]	3.82	3.64	2.27	3.47	3.24	2.99	4.21	2.96	2.74
OmniGen2	[40]	3.57	3.06	1.77	3.74	3.20	3.57	4.81	2.52	4.68
Dreamomni2										

[42]	[3.93 3.09 2.11 3.95 3.64 3.75 4.38 2.90 4.04 3.53	FLUX.1 Kontext [Dev]
[15]	[3.99 3.88 2.19 4.27 3.13 3.98 4.51 3.23 4.18 3.71	Step1X-Edit-v1.2
[20]	[3.91 4.04 2.68 4.48 4.26 3.90 4.82 3.23 4.22 3.95	Qwen-Image-Edit-2509
[38]	[4.34 4.27 3.42 4.73 4.36 4.37 4.91 3.56 4.80 4.31	FLUX.2 [Dev]
[14]	[4.50 4.18 3.83 4.65 4.65 4.31 4.88 3.46 4.70 4.35	Emu3.5 [4] 4.61 4.32 3.96 4.84 4.58 4.35 4.79 3.69 4.57 4.41
ChronoEdit	[41] 4.48 4.39 3.49 4.66 4.67 4.57 4.91 3.82 4.83 4.42	LongCat-Image-Edit
[32]	[4.44 4.53 3.83 4.80 4.60 4.33 4.92 3.75 4.82 4.45	Qwen-Image-Edit-2511
[38]	[4.54 4.57 4.13 4.70 4.46 4.36 4.89 4.16 4.81 4.51	FireRed-Image-
Edit	[4.55 4.66 4.34 4.75 4.58 4.45 4.97 4.07 4.71 4.56	

表4 | GEdit 上的结果（按类别和总体性能）。最佳结果以粗体显示，次佳结果以下划线显示。

模 型	GEdit- Bench- EN	GEdit-Bench-CN	G_SC↑	G_PQ↑	G_O↑	G_SC↑	G_PQ↑	G_O↑	Nano-Banana
		[10]	[7.396 8.454 7.291 7.540 8.424 7.399	Seedream4.0					
		[29]	[8.143 8.124 7.701 8.159 8.074 7.692	Nano-Banana-Pro					
		[10]	[8.102 8.344 7.738 8.135 8.306 7.799	Seedream4.5					
		[29]	[8.268 8.167 7.820 8.254 8.167 7.800	FLUX.2 [Dev]					
		[14]	[7.835 8.064 7.413 7.697 8.046 7.278	Qwen-Image-Edit-2509					
		[38]	[7.974 7.714 7.480 7.988 7.679 7.467	Step1X-Edit-v1.2					
		[20]	[7.974 7.714 7.480 7.988 7.679 7.467	LongCat-Image-Edit					
		[32]	[8.128 8.177 7.748 8.141 8.117 7.731	Qwen-Image-Edit-2511					
		[38]	[8.297 8.202 7.877 8.252 8.134 7.819	FireRed-Image-					
		Edit	[8.363 8.245 7.943 8.287 8.227 7.887						

表5 | REEdit-Bench-CN 上的结果（通用维度）。最佳结果以粗体显示，次佳结果以下划线显示。

模型	总体	添加	调整	背景	美化	颜色	组合	提取	肖像	低级	运动	移除	替换	风格化	文本	视角	Nano-Banana
[10]	[4.13 4.66 4.26 4.63 4.37 4.13 3.94 3.17 4.83 4.05 4.75 4.07 4.74 3.63 3.69 3.09	Seedream4.0															
[29]	[4.15 4.55 4.11 4.61 3.83 4.14 4.16 2.48 4.77 4.17 4.68 4.02 4.53 4.94 3.94 3.29	Seedream4.5															
[29]	[4.18 4.58 4.09 4.57 3.97 4.12 4.05 2.56 4.80 3.99 4.78 4.12 4.53 4.94 4.07 3.53	Nano-Banana-Pro															
[10]	[4.48 4.66 4.41 4.58 4.35 4.58 4.36 3.42 4.86 4.46 4.91 4.54 4.79 4.85 4.69 3.75	Qwen-Image-Edit-2509															
[38]	[4.00 4.45 4.04 4.48 3.36 4.20 3.92 2.64 4.16 3.52 4.66 4.27 4.66 4.81 3.53 3.32	FLUX.2 [Dev]															
[14]	[4.05 4.31 3.88 4.57 3.80 3.91 3.85 2.47 4.50 4.43 4.68 3.50 4.47 4.95 3.53 3.88	LongCat-Image-Edit															
[32]	[4.12 4.34 4.25 4.54 3.72 4.12 3.92 2.48 4.49 4.31 4.67 4.27 4.61 4.94 3.83 3.30	Qwen-Image-Edit-2511															
[38]	[4.18 4.50 4.23 4.52 3.61 4.09 4.00 3.22 4.31 4.19 4.66 4.41 4.68 4.83 4.08 3.51	FireRed-Image-															
Edit	[4.33 4.57 4.37 4.64 3.69 4.45 4.29 3.49 4.50 4.56 4.65 4.47 4.81 4.93 4.49 3.14																

表6 | REEdit-Bench-EN 上的结果（通用维度）。最佳结果以粗体显示，次佳结果以下划线显示。

模型	总体	添加	调整	背景	美化	颜色	组合	提取	肖像	低级	运动	移除	替换	风格化	文本	视角	
[10]	4.15	4.65	4.23	4.60	4.37	4.08	3.98	3.39	4.72	4.03	4.63	4.07	4.68	3.68	3.87	3.23	Seedream4.0
[29]	4.18	4.59	4.12	4.63	3.89	4.10	4.14	2.28	4.77	4.12	4.73	4.23	4.56	4.98	4.21	3.42	Seedream4.5
[29]	4.20	4.66	4.08	4.64	4.12	4.07	4.10	2.23	4.74	4.28	4.75	4.24	4.58	4.97	4.20	3.44	Nano-Banana-Pro
[10]	4.42	4.72	4.40	4.64	4.37	4.43	4.32	3.25	4.82	4.36	4.85	4.52	4.75	4.90	4.54	3.51	Qwen-Image-Edit-2509
[38]	3.99	4.47	4.06	4.49	3.13	3.98	3.85	2.91	4.30	3.71	4.58	4.40	4.67	4.77	3.77	2.85	FLUX.2 [Dev]
[14]	4.07	4.37	3.96	4.47	3.72	3.86	3.87	2.36	4.44	4.45	4.67	4.02	4.48	4.87	3.80	3.84	LongCat-Image-Edit
[32]	4.12	4.38	4.04	4.49	3.89	4.10	3.93	2.98	4.47	4.27	4.69	4.24	4.51	4.86	3.83	3.25	Qwen-Image-Edit-2511

[38]|4.23|4.55|4.17|4.56|3.49|4.07|4.34|3.54|4.42|4.52|4.72|4.42|4.65|4.85|4.06|3.38 FireRed-Image-Edit|4.26|4.41|4.33|4.60|3.55|4.47|4.25|3.49|4.50|4.44|4.65|4.46|4.70|4.94|4.44|2.78

5.2.2 以文本为中心的编辑

以文本为中心的评估。为进一步评估文本编辑能力，我们将提出的 OCR 和 VLM Judge 流程应用于 REEdit-Bench 的文本子集，在五个特定维度上评估性能。评估检查了编辑内容在字符和单词级别的准确性、原始字体风格和视觉属性的保持、编辑文本与周围图像之间的整体视觉一致性，以及是否在给定指令之外引入了不必要的修改。这种设置能够对文本中心行为进行更细粒度的分析。如表7所示，FireRed-Image-Edit 在开源模型中取得了领先结果，展示了在准确修改文本同时保持风格保真度和全局连贯性方面的强大能力。

可视化。我们还在图16-17中展示了以文本为中心的编辑结果，重点关注复杂的文本生成和海报式视觉设计。展示的示例包括具有一致排版和布局的长文本合成、在保持字体风格和视觉外观的同时进行精确的文本替换和纠正，以及文本内容必须与底层图像和谐融合的海报和封面编辑场景。这些案例要求在字符和单词级别上准确遵循指令，同时具备全局布局意识以及跨文本、图形和背景的美学一致性。结果证明，FireRed-Image-Edit 能够可靠地处理文本密集型编辑场景中的内容正确性和视觉连贯性，使其适用于海报设计、封面编辑和创意视觉传达等实际应用。

表7 | REEdit-Bench（文本维度）上的结果。

模型	OCR	Success	Edit	Over	Edit	Style	Consistency
Nano-Banana [10]	0.958	7.93	9.53	9.30	8.04	Seedream4 [29]	0.969
Seedream4.5 [29]	0.975	8.61	9.37	9.00	8.93	Nano-Banana-Pro [10]	0.984
FLUX.2 [Dev] [14]	0.950	7.93	8.90	8.83	8.33	Qwen-Image-Edit-2509 [38]	0.957
Qwen-Image-Edit-2511 [38]	0.969	9.42	9.36	9.31	9.27	LongCat-Image-Edit [32]	0.976
FireRed-Image-Edit	0.983	9.57	9.53	9.49	9.51		

5.2.3 创意编辑

创意编辑不同于图像编辑任务，它通常需要更深入的指令理解、隐式场景推理和全局构图重构。挑战在于合成遵循文本但保持与原始图像视觉一致的内容。

可视化。图15展示了 FireRed-Image-Edit 的创意编辑能力。显示的结果范围从结构抽象（例如，设计草图、剖面视图）和概念驱动合成（例如，雕塑风格、可折叠设计）到挑战物理约束的想象编辑（例如，漂浮物体）。虽然并非详尽无遗，但这些示例表明 FireRed-Image-Edit 能够有效地将高层次创意思图转化为连贯的视觉结果。

5.2.4 虚拟试穿编辑

我们进一步在结构化的虚拟试穿设置下评估 FireRed-Image-Edit，其中模型的任务是将服装从参考图像转移到目标人物身上，同时遵循详细的风格指令。

可视化。如图14所示，每个案例涉及将一件服装与目标模特结合，并附加关于服装合身度（例如，宽松或紧身轮廓）、长度、颜色规格和配饰组成（例如，手提包、珠宝、鞋类）的约束。此类场景要求准确的服装保持、在身体姿态下的自然变形，以及与新引入物品的一致整合，同时保持身份和整体视觉真实感。与现有的编辑基线相比，FireRed-Image-Edit 产生更连贯的服装几何形状、更清晰的边界过渡，以及文本风格指令与视觉结果之间更好的对齐。这些结果表明，该模型能够稳定且可控地处理组合多约束编辑，使其适用于实际的时尚和造型应用。

图11 | 对象添加演示，模型将新元素无缝插入场景，保持与原始上下文的一致性。我们的模型通过严格遵守指令并确保添加的对象与场景自然融合，优于竞争对手。

图12 | 对象修改示例，展示了对对象属性的精确控制。我们的模型实现了准确的编辑而不破坏周围纹理，而竞争对手常常过度编辑主体或在非目标区域丢失细节。

图13 | 低级编辑任务案例，展示了模型在图像恢复和增强方面的能力。我们的模型在细节恢复和视觉质量方面显著优于基线，能够从严重退化的输入中有效重建高保真细节。

图14 | 虚拟试穿任务的可视化，我们的模型以优于竞争对手的保真度转移参考服装，准确渲染文本指定的风格属性（例如，合身度、配饰），同时保留基线常常扭曲或忽略的细节。

图15 | 此可视化展示了我们的 FireRed-Image-Edit 在各种创意场景中的能力。结果清楚地展示了模型解释复杂指令并生成高质量、创意编辑图像的能力。

图16 | 以文本为中心的展示。我们的模型在文本编辑方面展现出卓越的可读性和风格一致性。虽然竞争对手常在模糊字符或布局扭曲上挣扎，但我们的方法实现了精确的文本渲染，保留了原始视角和材质纹理。

图17 | 以文本为中心的展示。

6 结论

我们介绍了 FireRed-Image-Edit，一个用于基于指令的图像编辑的扩散Transformer，其贡献涵盖数据工程、训练方法和评估。

在数据工程方面，我们策展了约十亿个多源图像-文本对，涵盖文生图生成、多图像合成和多样化编辑任务。通过一个整合了严格清洗、细粒度分层、自动标注和两阶段过滤机制的端到端流程，我们提炼出超过1亿个高质量样本，在生成和编辑之间均匀平衡。这种大规模、结构化的策展显著改善了语义对齐和数据可靠性。

在训练方法方面，我们开发了一个面向效率的框架，其特点包括用于减少填充开销的多条件感知桶采样器和用于增强鲁棒性的随机指令对齐机制。一个多阶段训练流程（预训练、监督微调、强化学习）整合了用于稳定优化的 DPO 非对称梯度优化。其他组件——包括多图像 DPO、用于文本编辑的 Diffusion NFT、一致性损失、分布式分层时间步采样、Logit-正态损失和 EMA——共同改善了一致性、可控性和收敛稳定性。

在评估方面，我们引入了 REDEdit-Bench，一个涵盖15个结构化编辑类别的基准测试，包含1,673个双语样本，包括新设计的肖像美化和低分辨率增强任务。在 REDEdit-Bench、ImgEdit 和 GEdit 上的大量实验表明，我们的模型在开源模型中达到了最先进的性能，并与专有系统相比具有竞争力，验证了精心设计的效率和系统级优化可以媲美蛮力扩展。

7 作者

- 核心贡献者（按字母顺序排列）：Changhao Qiao, Chao Hui, Chen Li, Cunzheng Wang, Dejia Song, Jiale Zhang, Jing Li, Qiang Xiang, Runqi Wang, Shuang Sun, Wei Zhu, Xu Tang, Yao Hu, Yibo Chen, Yuhao Huang, Yuxuan Duan, Zhiyi Chen, Ziyuan Guo
- 贡献者（按字母顺序排列）：Haohua Chen, Haolu Liu, Honghao Cai, Qing Yu, Shurui Shi, Shuyang Lin, Sijie Xu, Tianshuo Yuan, Tianze Zhou, Wenxin Yu, Xiangyuan Wang, Xudong Zhou, Xuecan Wang, Yahui Wang, Yandong Guan, Yanqin Chen, Yilian Zhong, Ying Li, Yunfan Liu, Yunhao Bai, Yushun Fang, Zeming Liu, Zhangyu Lai, Zhiqiang Wu

（参考文献部分按原文保留，不翻译）