

好的，这是根据你提供的OmniGen论文PDF翻译的中文版本。我已严格按照要求，去除了参考文献部分和附录部分，并完整保留了原文的结构、所有内容、公式、表格和图表示意，其中“token”一词根据指示未作翻译。

OmniGen: 统一图像生成

Shitao Xiao*, Yueze Wang*, Junjie Zhou*, Huaying Yuan*, Xingrun Xing, Ruiran Yan, Chaofan Li, Shuting Wang, Tiejun Huang, Zheng Liu† 北京人工智能研究院 {stxiao, yzwang}@baai.ac.cn, zhengliu1026@gmail.com

摘要

大语言模型（LLMs）的出现统一了语言生成任务，并彻底改变了人机交互。然而，在图像生成领域，一个能够在单一框架内处理各种任务的统一模型在很大程度上仍未得到探索。在这项工作中，我们介绍了OmniGen，一种用于统一图像生成的新型扩散模型。OmniGen具有以下特点：1) 统一性：OmniGen不仅展示了文生图能力，而且天然支持各种下游任务，如图像编辑、主体驱动生成和视觉条件生成。2) 简洁性：OmniGen的架构高度简化，无需额外插件。此外，与现有的扩散模型相比，它对用户更友好，可以通过指令端到端地完成复杂任务，无需额外的中间步骤，极大地简化了图像生成工作流程。3) 知识迁移：受益于统一格式的学习，OmniGen有效地跨不同任务迁移知识，处理未见过的任务和领域，并展现出新颖的能力。我们还探索了模型的推理能力和思维链机制的潜在应用。这项工作代表了通用图像生成模型的首次尝试，我们将发布我们的资源在 <https://github.com/VectorSpaceLab/OmniGen> 以促进未来的发展。

1. 引言

对通用人工智能（AGI）的追求加剧了对能够在单一框架内处理各种任务的生成式基础模型的需求。在自然语言处理（NLP）领域，大语言模型（LLMs）已成为实现这一目标的典范，在众多语言任务中展现出卓越的多功能性。然而，在视觉生成领域，尚未出现能够与LLMs的通用性相匹配的对应模型。当前的图像生成模型已在特定任务上展现出熟练度。例如，在文生图领域，如SD系列 [12, 51, 55]、DALL-E [54]和Imagen [25]等模型已经取得了显著进展。与此同时，许多努力已被投入到将扩散模型的能力扩展到特定任务中，例如ControlNet [75]、InstantID [64]和InstructPix2Pix [3]。目前，对于每个新任务，都需要设计特定的模块并进行微调，这阻碍了图像生成的发展。更糟糕的是，这些任务特定模型导致了一个严重的问题：我们无法仅通过输入指令来完成任任务，而是需要一个涉及多个模型和众多步骤的复杂而繁琐的工作流程。例如，ControlNet需要使用检测器提取条件（如姿态估计图），然后加载相应的条件模块。InstantID只能处理单人图像，并且需要事先使用人脸检测模型检测人脸，然后使用人脸编码器对人脸进行编码。如果用户想要编辑生成的图像，则需要加载像InstructPix2Pix这样的额外模型。

图1. OmniGen可以灵活地遵循指令完成各种任务，无需任何额外插件。对于复杂任务（例如，第二行的示例），它也可以端到端地完成，无需繁琐的中间步骤。

能否有一个单一模型通过用户指令端到端地完成各种任务，类似于ChatGPT处理语言任务的方式？我们设想一个图像生成变得简单而灵活的未来：任何任务都可以直接通过用户指令完成。受此目标驱动，我们提出了一个统一框架：OmniGen。如图1所示，该框架允许为任何目的方便灵活地生成图像，无需额外插件或操作。鉴于遵循任意指令的灵活性，新框架也有助于激发更多有趣的图像生成任务。

与流行的扩散模型不同，OmniGen具有非常简洁的结构，仅包含两个主要组件：一个VAE和一个Transformer模型。OmniGen支持任意交错的文本和图像输入作为条件来引导图像生成，而不是仅接受纯文本或纯图像。为了将此架构训练为统一模型，我们构建了一个大规模的跨任务图像生成数据集X2I，该数据集以统一格式统一了不

同的任务。我们基于多个基准评估了经过良好训练的模型，展示了其与现有模型相比优越的生成能力。值得注意的是，OmniGen实现了跨不同场景的有效知识迁移，使其能够处理未见过的任务和领域，同时促进新能力的涌现。

我们的贡献总结如下：

我们介绍了OmniGen，一个在多个领域表现出色的统一图像生成模型。该模型展示了有竞争力的文生图能力，并天然支持各种下游任务，如可控图像生成和经典的计算机视觉任务。此外，它可以端到端地处理复杂任务，无需任何冗长的中间步骤。据我们所知，OmniGen是第一个实现如此全面功能的图像生成模型。我们构建了第一个名为X2I的综合图像生成数据集，代表“anything to image”。该数据集涵盖了广泛的图像生成任务，所有这些任务都被标准化为统一格式。通过多任务数据集上的统一训练，OmniGen可以应用所学知识来处理未见过的任务和领域，并展现新能力。此外，我们还探索了模型的推理能力和思维链机制。OmniGen朝着通用图像生成的基础模型迈出了第一步。我们将开源相关资源（模型、代码和数据），并希望这项工作能为未来的图像生成模型提供一些见解。

2. OmniGen

在本节中，我们介绍OmniGen框架的细节，包括模型架构和训练方法。

2.1. 模型设计

网络架构。 OmniGen的设计原则是通用性和简洁性。如图2所示，OmniGen采用了一种由变分自编码器（VAE）[27]和预训练的大型Transformer模型组成的架构。具体来说，我们使用SDXL [51]中的VAE从图像中提取连续的视觉特征。Transformer模型由Phi-3 [1]初始化，根据作为条件的指令生成图像。训练期间仅冻结VAE。与需要额外编码器预处理条件信息（如CLIP文本编码器和图像编码器）的最先进的扩散模型不同，OmniGen本身就对条件输入进行编码，显著简化了流程。此外，OmniGen在单个模型中联合建模文本和图像，而不是像现有工作[8, 64, 68, 70, 72]那样使用独立的编码器独立建模不同的输入条件，后者缺乏不同模态条件之间的交互。

输入表示。 模型的输入可以是自由形式的、多模态交错的文本和图像。我们使用Phi-3的分词器处理文本。对于图像，我们首先使用VAE和一个简单的线性层来提取潜在表示。然后，通过线性嵌入潜在空间中的每个补丁，将它们展平为视觉token序列。遵循[49]，补丁大小设置为2。

图2. OmniGen的框架。文本被分词为token，而输入图像通过VAE转换为嵌入。OmniGen可以接受自由形式的多模态提示，并通过修正流方法生成图像。

2.2. 训练策略

训练目标。 在这项工作中，我们使用修正流[39]来优化模型的参数。与DDPM [24]不同，流匹配通过在噪声和数据之间进行线性插值来执行前向过程。在步骤 t ， $\mathbf{x}_t$ 定义为： $\mathbf{x}_t = t\mathbf{x} + (1 - t)\epsilon$ ，其中 $\mathbf{x}$ 是原始数据， $\epsilon \sim \mathcal{N}(0, 1)$ 是高斯噪声。模型被训练来直接回归目标速度，给定带噪数据 $\mathbf{x}_t$ 、时间步 t 和条件信息 c 。具体来说，目标是最小化均方误差损失：

$$\mathcal{L} = \mathbb{E} [\|(\mathbf{x} - \epsilon) - v_\theta(\mathbf{x}_t, t, c)\|^2]。 \quad (1)$$

对于图像编辑任务，目标是修改输入图像的特定区域，同时保持其他区域不变。因此，输入图像和目标图像之间的差异通常很小，这使得模型可以学习一个意外的捷径：直接复制输入图像作为输出，从而使相关的训练损失非常低。为减轻这种现象，我们放大了图像中发生变化的区域的损失。更具体地说，我们根据输入图像 $\mathbf{x}'$ 和目标图像 $\mathbf{x}$ 的潜在表示计算每个区域的损失权重。

表1. OmniGen每个训练阶段的详细信息。

阶段	分辨率	步数 (K)	批次大小	学习率	1	256×256	500	1040	1e-4	2	512×512	300	520	1e-4
3	1024×1024	100	208	4e-5	4	2240×2240	30	104	2e-5	5	多种	80	104	2e-5

$$w_{i,j} = \begin{cases} 1 & \text{如果 } \mathbf{x}_{i,j} = \mathbf{x}'_{i,j} \\ \frac{1}{\|\mathbf{x} - \mathbf{x}'\|^2} & \text{如果 } \mathbf{x}_{i,j} \neq \mathbf{x}'_{i,j} \end{cases} \quad (2)$$

因此，发生变化的区域被赋予比未变化区域显著更高的权重，引导模型关注待修改的区域。

训练流程。遵循先前工作[5, 12, 16]，我们在训练过程中逐步提高图像分辨率。低分辨率数据效率高，而高分辨率可以增强生成图像的美学质量。每个训练阶段的详细信息见表1。我们采用AdamW [40]， $\beta = (0.9, 0.999)$ 作为优化器。所有实验均在104张A800 GPU上进行。

3. X2I数据集

为实现稳健的多任务处理能力，在大规模和多样化的数据集上训练模型至关重要。然而，在图像生成领域，一个现成的大规模、多样化数据集尚未出现。在这项工作中，我们首次构建了一个大规模的跨任务图像生成数据集，我们称之为X2I数据集，意为“anything to image”。我们将所有数据转换为统一格式，图3展示了X2I数据集的一些示例。整个数据集包含约1亿张图像。组成的详细描述将在以下部分提供。

3.1. 文生图

此子集数据的输入是纯文本。我们从各种来源收集了多个开源数据集：RecapDataComp [33]（5600万张图像的子集）、SAM-LLaVA [5]、ShareGPT4V [6]、LAION-Aesthetic [57]（400万张图像的子集）、ALLaVA-4V [4]、DOCCI [45]、DenseFusion [34]和JourneyDB [59]。虽然这些数据集数量庞大，但其图像质量并不总是足够高。在训练早期，我们使用它们来学习广泛的图像-文本匹配关系和多样化的知识。在第3阶段之后，我们使用内部收集的1600万张高质量图像来增强生成图像的美学质量。我们使用InternVL2 [10]为内部数据和LAION-Aesthetic创建合成标注。

3.2. 多模态到图像

与现有的扩散模型不同，OmniGen可以接受更灵活的多模态指令，从而适应各种数据和任务类型。

3.2.1. 常见的混合模态提示

这部分数据的输入是任意交错的文本和图像。我们从多个任务和来源收集数据：图像编辑（MagicBrush [74]、InstructPix2Pix [3]和SEED-edit [17]）、人体运动（Something-Something [21]）、虚拟试穿（HRVITON [30]和FashionTryon [77]）以及风格迁移（StyleBooth [23]）。利用额外的视觉条件进行更精细的空间控制引起了广泛关注[31, 75]。我们使用MultiGen [52]数据集来学习此功能，并选择了六种代表性的视觉条件：Canny、HED、深度、骨骼、边界框和分割。这些类型的任务将文本提示与特定的视觉条件（如分割图和人体姿态图）作为多模态输入。我们将所有任务标准化为如图3-(b)所示的输入-输出对格式。

3.2.2. 主体驱动的形象生成

我们为主体驱动的形象生成构建了一个大规模的基础数据集（GRIT-Entity数据集）和一个高质量的高级数据集（Web Images数据集）。对于GRIT-Entity数据集，我们利用GRIT数据集[50]，该数据集标注了图像中的对象名称。使用这些标注，我们应用GroundingDINO [38]进行开放集文本到边界框的检测。基于grounding的边界框，我们使用SAM [28]从裁剪图像中分割对象掩码。我们进一步使用MS-Diffusion [66]重新绘制对象图像，以

获得更高的数据质量和多样性。数据构建过程和最终的指令格式在补充材料中说明。通过这些方法，我们获得了600万对数据。

尽管基于GRIT的方法提供了大量的样本，但从原始图像中直接提取的输入数据容易导致模型陷入简单的复制-粘贴模式。为了充分释放OmniGen的主体驱动图像生成能力，我们从网络上构建了一个高质量的自然图像数据集。我们使用搜索引擎收集同一人物的多张不同图像，将其中一张作为输入，另一张作为输出。示例如图3-(c)所示。关于构建过程的更多细节见补充材料。

图3. X2I数据集的示例。我们将所有任务的输入标准化为交错的图像-文本序列格式。占位符 [image_i] 表示第 i 张输入图像的位置。

3.2.3. 计算机视觉任务

我们引入经典的计算机视觉任务来扩展模型生成能力的边界。对于低级视觉任务（低光图像增强[67]、去雨[73]、去模糊[44]、修复[52]、外推[52]和着色[57]），其标注本身是一张图像，我们仅添加文本指令，这些指令是从GPT-4o生成的指令中随机采样的。对于高级视觉任务，我们选择将所有标注表示为图像。我们使用来自LAION [57]的图像作为源图像，并使用来自[52]的标注作为目标来构建图像对（例如，源图像及其人体姿态映射）。这些标注包括人体姿态、深度映射、Canny、Hed边缘和分割。此外，我们还使用了几个用于指代图像分割的数据集，包括RefCOCO [26]、ADE20k [78]和ReasonSeg [29]。如图3-(d)所示，输入是源图像和自然语言表达，输出是相应对象用蓝色高亮显示的图像。

3.3. 少样本到图像

我们构建了一个少样本到图像的数据集，以激发模型的上下文学习能力。具体来说，对于前述章节中描述的每个任务，我们随机选择几个示例，并将原始输入与这些示例组合形成新的输入。具体的数据格式如图3-(e)所示。由于训练资源的限制，我们选择仅使用一个示例来提高训练效率。

4. 实验结果

默认推理步数设置为50。我们遵循[3]对文本条件和图像条件均使用无分类器引导。默认引导尺度设置为2.5，图像引导尺度设置为1.6。对于图像编辑任务，我们将图像引导尺度增加到2。

4.1. 图像生成

4.1.1. 定性结果

图4总结了不同图像生成任务的结果，包括文生图、图像编辑和视觉条件生成。这些结果表明，OmniGen可以基于多模态指令处理各种下游任务。

图5展示了主体驱动生成任务的结果。OmniGen可以从给定的参考图像中提取所需对象，并据此生成新图像。此外，当参考图像包含多个对象时，模型可以根据文本指令（例如，图像中穿深红色衬衫的那个）直接选择需要的对象，而无需额外的预处理步骤。相比之下，现有模型[22, 64]需要从多人图像中手动裁剪目标人物，使用人脸检测器检测人脸，使用人脸编码器编码人脸，然后通过交叉注意力模块将其输入到扩散模型中。无需这些复杂的过程，OmniGen就可以在单个端到端步骤中完成任务。

更多定性结果见补充材料。

4.1.2. 文生图

我们在图6中展示了计算机视觉任务的几个定性结果。OmniGen可以处理各种低级视觉任务，如去雨、去模糊和修复。在图6底部，我们可以看到OmniGen也能够处理高级视觉任务，如人体姿态识别。

需要注意的是，OmniGen在CV任务上的能力并非旨在超越那些为特定任务长期开发的现有最先进模型。我们希望它能将从这些传统计算机视觉任务中获得的知识迁移到图像生成任务中，从而释放更大的潜力。一些示例如图7所示。ControlNet涉及多个步骤和插件：首先使用相应的检测器从参考图像中提取信息，然后加载适当的ControlNet模块来处理视觉条件。相比之下，OmniGen在单个模型的单步中完成整个任务。

图7. ControlNet的现有工作流程涉及使用检测器从参考图像中提取空间条件信息，然后加载相应的控制模块来建模空间条件信息以进行图像生成。我们能否直接使用OmniGen基于参考图像一步生成新图像？令人惊讶的是，即使以前从未遇到过这样的任务，OmniGen也能出色地处理它，而无需显式提取额外的条件图像。更具体地说，我们可以直接输入参考图像和文本指令（例如，遵循此图像的人体姿态生成新图像。）在单步中生成目标图像，无需任何显式的额外中间过程。

5. 进一步分析

LLMs展现出卓越的泛化能力，并可以通过上下文学习和思维链等机制提升性能。我们在OmniGen中也观察到了类似的功能，并在本节中展示我们的发现。

5.1. 涌现能力

通过将所有任务标准化为统一格式并在X2I数据集上训练，OmniGen可以获得通用知识，并允许跨不同场景和任务的知识迁移，从而实现在未见任务和领域上的生成能力。

任务组合。在现实世界的应用中，用户需求通常涉及任务的组合。如图8-(a)所示，我们的模型能够同时处理多个指令，包括针对不同任务的指令以及同一任务的多个指令。这些结果突显了我们模型的通用性和在现实世界中广泛采用的潜力。

端到端工作流。用户通常需要加载多个模型并执行多步处理才能最终生成满意的图像，这使得工作流非常繁琐且成本高昂。OmniGen兼具优秀的理解能力和图像生成能力，使其能够在不依赖外部模型的情况下完成许多任务，从而显著简化工作流并节省成本。如图7所示，OmniGen可以从参考图像中提取相关的条件信息，并根据捕获的条件在一步内生成新图像。这个过程是隐式的，所有处理都在模型内部完成，用户只需输入简单的指令。

未见过领域的上下文学习。我们使用来自FSS [32]的数据进行评估，该数据集包含先前数据集中从未见过的对象，以评估泛化能力。在图8-(b)的右侧，我们可以看到OmniGen并不熟悉“卷笔刀”的概念，并且无法从图像中识别它。然而，当提供一个示例时，模型能够做出准确的预测。通过提供一个示例，模型能够成功完成这个未见过的分割任务。

图6. OmniGen在各种传统视觉任务中的结果。

图8. OmniGen涌现能力的示例。

5.2. 推理能力

我们探索了模型的推理能力，并将结果展示在图9中。如图9左半部分所示，当给定一个没有明确指定对象的指令时，例如“我可以在哪里洗手？请帮我在 image_1 中找到正确的位置”，模型可以识别图像内容并推断出需要水槽。因此，模型识别并指示了图像中水槽的区域。这一功能在具身智能领域创造了潜在的应用，帮助智能体

理解多模态指令、定位所需对象并规划后续行动。此外，图9右半部分展示，在推断出目标对象后，模型还可以对其执行编辑操作。如果没有匹配的对象，模型将不会编辑任何无关的对象（见图9右下角的示例）。

5.3. 思维链

思维链（CoT）方法可以通过将任务分解为多个步骤并按顺序求解每个步骤以获得准确的最终答案，从而显著提升LLMs的性能。我们考虑是否可以将类似的替代方法应用于图像生成。受人类绘画基本方式的启发，我们希望模仿逐步绘画的过程，从空白画布开始迭代地细化图像。我们构建了一个动漫图像数据集，并使用PAINTS-UNDO模型模拟艺术创作的每个阶段。我们选择了8个代表性帧来描述最终图像的逐步发展。在过滤掉不一致的序列后，我们在此数据集上对模型进行了16,000步的微调。

结果可视化在图10中，以及原始模型生成的输出。对于逐步生成，输入数据由当前步骤的图像和文本组成，然后模型预测下一步的图像。可以观察到，微调后的模型成功模拟了人类艺术家的行为：绘制基本轮廓、逐步添加细节、进行仔细修改并为图像上色。通过这种方式，用户可以修改先前的结果来控制当前的输出，从而更积极地参与图像生成过程，而不是被动地等待黑盒扩散模型生成最终图像。不幸的是，最终生成图像的质量并没有超过原始模型。在逐步生成方法中，模型可能会引入错误的修改，导致最终图像有些混乱。这并不意味着该方法不可行；目前，我们只进行了初步探索，将进一步的优化留给未来的研究。基于先前关于LLMs的工作[36]的发现，表明过程监督显著优于结果监督，我们认为监督图像的绘制过程是一个有前景的方向，可能有助于模型处理更复杂和多样化的场景。

图9. OmniGen的推理能力。

图10. 通过逐步生成模拟人类绘画过程。

6. 消融研究

在本节中，我们评估OmniGen中某些模块的必要性。

注意力掩码。图11-顶部显示了未使用第2.1节中修改的注意力时生成的图像。正如我们所见，图像中存在大量噪声。与图4相比，图11-顶部的生成图像有许多扭曲的区域，证实了LLMs中的单向注意力机制不适用于修正流。

加权损失。图11-底部显示了未使用第2.2节中的加权损失进行训练时的结果。对于图像编辑任务，由于编辑区域通常很小，模型倾向于直接复制输入图像作为输出。比较图11-底部和图4，很明显使用加权损失可以防止模型学习这种捷径。

输入图像表示。CLIP模型广泛用于多模态理解模型[37]。我们还探讨了使用CLIP和使用VAE处理输入图像之间的差异。结果如表5所示。两种策略之间没有太大区别。使用VAE在图像相似性方面略有优势，这可能与输出图像也需要VAE处理有关。使用VAE的另一个优点是避免了额外的模块，保持了模型的简洁性。直接输入原始图像是另一种更简单的方法，我们留给未来的探索。

图11. 顶部：因果注意力的结果；底部：无损失权重的结果。

表5. 获取输入图像视觉嵌入的不同方法的比较。

输入图像表示

EMU-	DreamBench	CLIP-T	CLIP-I	CLIP-T	CLIP-I	CLIP	0.232	0.820	0.312	0.789
Edit	VAE	0.231	0.829	0.315	0.801					

7. 相关工作

生成式基础模型。GPT系列[46, 53]已经证明，语言模型可以通过在大规模数据集上训练来学习众多任务。除语言外，多模态大语言模型[11, 37]已被提出以整合视觉和语言能力。然而，它们缺乏生成图像的能力。一些工作提出将LLMs与扩散模型集成，以使LLMs具备图像生成能力[18, 60, 61, 69]。另一些则使用离散token同时支持图像和文本生成[41, 62, 71]。它们专注于多模态生成，但图像生成能力有限。同期工作如TransFusion [79]和Show-O [71]将扩散和自回归方法统一到单个模型中，自回归生成文本并通过扩散生成图像。尽管如此，像现有的扩散模型一样，这些工作侧重于有限的图像生成任务范围，主要是文生图，无法覆盖更复杂和多样的视觉生成任务。构建一个用于图像生成的通用基础模型尚不明确，且尚未得到充分探索。

扩散模型。近年来扩散模型的进展显著，Stable Diffusion (SD)系列[12, 51, 55]、DALL-E [54]和Imagen [25]做出了显著贡献。这些模型主要设计用于文生图任务。许多努力已被投入到扩展扩散模型的能力中，例如ControlNet [75]、T2I-Adapter [43]、StyleShot [15]。InstructPix2Pix [3]、InstructSD [48]和EMU-edit [58]探索通过指令执行通用图像编辑任务。然而，这些方法是任务特定的，通过修改模型架构来扩展SD的能力。相比之下，OmniGen是一个天然支持各种图像生成任务的模型，不再需要任何预处理步骤或其他模型的辅助。有一些工作探索计算机视觉（CV）任务的统一[2, 14, 19, 65]。然而，这些努力主要集中在经典视觉任务上，而不是通用图像生成任务，并且通常表现不如那些为相应任务专门设计和训练的模型。在我们的工作中，引入CV任务并非旨在获得CV任务上的SOTA性能，而是设计为使模型能够学习通用知识。

8. 局限性与结论

在这项工作中，我们介绍了OmniGen，第一个统一的图像生成模型。它被设计为简单、灵活且易于使用。我们还构建了第一个大规模的统一图像生成数据集X2I，以激活OmniGen模型的通用能力。OmniGen在各种任务中展示了出色的图像生成能力。

然而，当前模型仍存在问题。文本渲染能力有限，长文本无法准确生成。输出图像可能包含不需要的细节（例如，异常的手）。此外，以前未见过的图像类型（例如，表面法线图）很难按预期处理。更多失败案例见补充材料。

我们相信未来图像生成的范式应该是简单而灵活的，允许通过任何多模态指令直接生成各种图像，无需复杂的工作流。OmniGen代表了朝着通用图像生成基础模型迈出的重要一步。我们将开源相关资源，希望能为图像生成的未来提供见解。