

Qwen-Image 技术报告

Qwen 团队

<https://qwen.ai> <https://huggingface.co/Qwen/Qwen-Image> <https://modelscope.cn/models/Qwen/Qwen-Image> <https://github.com/QwenLM/Qwen-Image>

摘要

我们推出 Qwen-Image，这是 Qwen 系列中的一款图像生成基础模型，在复杂文本渲染和精确图像编辑方面取得了显著进展。为应对复杂文本渲染的挑战，我们设计了一套全面的数据流水线，包括大规模数据收集、过滤、标注、合成和平衡。此外，我们采用渐进式训练策略，从非文本渲染开始，逐步从简单到复杂的文本输入，最终扩展到段落级描述。这种课程学习方法显著增强了模型的原生文本渲染能力。因此，Qwen-Image 不仅在英语等字母语言中表现卓越，在更具挑战性的表意语言（如中文）上也取得了显著进步。为增强图像编辑的一致性，我们引入了一种改进的多任务训练范式，不仅包含传统的文生图（T2I）和文本-图像-到-图像（TI2I）任务，还加入了图像-到-图像（I2I）重建任务，有效对齐了 Qwen2.5-VL 和 MMDiT 之间的隐空间表征。此外，我们将原始图像分别送入 Qwen2.5-VL 和 VAE 编码器，以分别获得语义和重建表征。这种双编码机制使编辑模块能够在保持语义一致性和维持视觉保真度之间取得平衡。我们在多个公开基准上对 Qwen-Image 进行了全面评估，包括用于通用图像生成的 GenEval、DPG 和 OneIG-Bench，以及用于图像编辑的 GEdit、ImgEdit 和 GSO。Qwen-Image 达到了最先进的性能，展示了其在图像生成和编辑方面的强大能力。此外，在 LongText-Bench、ChineseWord 和 CVTG-2K 上的结果表明，其在文本渲染方面表现出色——尤其是在中文文本生成上——以显著优势超越了现有的最先进模型。这凸显了 Qwen-Image 作为领先图像生成模型的独特地位，它兼具广泛的通用能力和卓越的文本渲染精度。

(a) 图像生成与编辑基准 (b) 文本渲染基准 图1：Qwen-Image 在图像生成和编辑方面展现出强大的通用能力，同时在文本渲染方面表现出非凡的能力，尤其是中文。

映接风华日天光竞荷莲不西花叶与湖别无四六样分时月红碧同中

图2：Qwen-Image 在复杂文本渲染中的展示，包括多行布局、段落级语义和细粒度细节。Qwen-Image 支持字母语言（如英语）和表意语言（如中文）的高保真渲染。

图3：Qwen-Image 在通用图像生成中的展示，支持多种艺术风格。

图4：Qwen-Image 在通用图像编辑中的展示，包括风格迁移、文本编辑、背景更改、对象添加、移除和替换、姿态操作等。

图5：Qwen-Image 在通用图像理解任务中的展示，包括检测、分割、深度/边缘估计、新颖视角合成和超分辨率——这些任务都可以视为图像编辑的特殊形式。

1 引言

图像生成模型——包括文生图生成（T2I）（Rombach et al., 2021; Wu et al., 2022; Liang et al., 2022; OpenAI, 2023; Podell et al., 2023; Chen et al., 2024c; Li et al., 2024b; Esser et al., 2024; BlackForest, 2024; Gao et al., 2025; Gong et al., 2025; Cai et al., 2025）和图像编辑（TI2I）（Brooks et al., 2023; Zhang et al., 2023; Wang et al., 2025; Deng et al., 2025; Labs et al., 2025; Wu et al., 2025b; Liu et al., 2025b; Cai et al., 2025; OpenAI, 2025）——已成为现代人工智能的基本组成部分，使机器能够根据文本提示合成或修改视觉上引人注目且语义连贯的内容。在过去几年中，该领域取得了显著进展，尤其是基于扩散的架构（Ho et al., 2020; Liu et al., 2022）的出现，使得高分辨率图像生成成为可能，同时捕获细粒度的语义细节。

尽管取得了这些进展，但两个关键挑战依然存在。首先，对于文生图生成，使模型输出与复杂、多方面的提示对齐仍然是一个重大障碍。我们的评估显示，即使是 GPT Image 1（OpenAI, 2025）和 Seedream 3.0（Gao et al., 2025）等最先进的商业模型，在需要多行文本渲染、非字母语言渲染（如中文）、局部文本插入或文本与视觉元素无缝集成的任务中仍然存在困难。其次，对于图像编辑，实现编辑输出与原始图像之间的精确对齐面临着双重挑战：(i) 视觉一致性，即只应修改目标区域，同时保留所有其他视觉细节（例如，在不改变面部细节的情况下改变发色）；(ii) 语义连贯性，即在结构变化期间必须保持全局语义（例如，在保持身份和场景连贯性的同时修改人物姿态）。

在这项工作中，我们推出了 Qwen-Image，这是 Qwen 系列中的一款新型图像生成模型，旨在通过全面的数据工程、渐进式学习策略、增强的多任务训练范式和可扩展的基础设施优化来克服这些挑战。

为解决复杂提示对齐的挑战，我们开发了一个稳健的数据流水线，涵盖大规模收集、标注、过滤、合成增强和类别平衡。我们进一步采用课程学习策略，从基础文本渲染任务开始，逐步推进到段落级和布局敏感的描述。这种方法显著增强了模型遵循多种语言的能力，尤其是像中文这样的表意语言。

为解决图像对齐的挑战，我们提出了一种增强的多任务学习框架，将 T2I、I2I 和 TI2I 目标无缝集成到一个共享的隐空间中。具体来说，输入图像被编码为两种不同但互补的特征表征：语义特征通过 Qwen-VL（Bai et al., 2025）提取，捕获高层场景理解和上下文含义，而重建特征通过 VAE 编码器获得，保留底层视觉细节。这两组特征随后作为条件信号共同馈入 MMDiT 架构（Esser et al., 2024）。这种双条件设计使模型能够同时保持语义连贯性和视觉一致性。

为确保大规模训练下的效率和稳定性，我们设计了一个基于 TensorPipe 的生产者-消费者框架，用于分布式数据加载和预处理。生产者处理 VAE 编码和数据 I/O 等预处理任务，而消费者则使用 Megatron（Shoeybi et al., 2019）框架专注于分布式模型训练。我们还实现了广泛的监控工具，以确保整个大规模训练过程中的可靠收敛和调试能力。

Qwen-Image 在从复杂文本提示生成高质量图像和执行精确、上下文感知的图像编辑方面都取得了显著进展。该模型能够解释复杂的语言结构，并产生与语义意图和视觉约束相匹配的视觉上引人注目的输出。为验证其有效性，我们在包括文生图生成和图像编辑在内的多样化任务上评估了 Qwen-Image。

Qwen-Image 的主要贡献可总结如下：

卓越的文本渲染：Qwen-Image 擅长复杂文本渲染，包括多行布局、段落级语义和细粒度细节。它支持字母语言（如英语）和表意语言（如中文）的高保真渲染。

一致的图像编辑：通过我们增强的多任务训练范式，Qwen-Image 在编辑操作期间在保持语义意义和视觉真实感方面实现了卓越的性能。

强大的跨基准性能：在多个基准上评估，Qwen-Image 在多样化的生成和编辑任务中持续优于现有模型，为图像生成建立了强大的基础模型。

图6：Qwen-Image 架构概览。它采用标准的双流 MMDiT 架构。输入表征由冻结的 Qwen2.5-VL 和 VAE 编码器提供。模型对 QK-Norm 使用 RMSNorm（Zhang & Sennrich, 2019），而所有其他归一化层使用 LayerNorm。此外，我们设计了一种新的位置编码方案 MSRoPE（多模态可扩展 RoPE），用于联合编码图像和文本模态的位置信息。

2 模型

在本节中，我们介绍 Qwen-Image 模型的架构设计，以及训练数据和训练细节的全面概述。

2.1 模型架构

如图6所示，Qwen-Image 架构建立在三个核心组件之上，它们协同工作以实现高保真文生图生成。首先，多模态大语言模型（MLLM）作为条件编码器，负责从文本输入中提取特征。其次，变分自编码器（VAE）作为图像分词器，将输入图像压缩为紧凑的隐表征，并在推理时将其解码回来。第三，多模态扩散 Transformer（MMDiT）作为主干扩散模型，在文本引导下对噪声和图像隐变量之间的复杂联合分布进行建模。虽然本节概述了它们的一般作用，但具体的模型选择和架构细节将在以下章节中详细说明。

2.2 多模态大语言模型

Qwen-Image 采用 Qwen2.5-VL 模型（Bai et al., 2025）作为文本输入的特征提取模块，原因有三：(1) Qwen2.5-VL 的语言和视觉空间已经对齐，这使其相比基于语言的模型（如 Qwen3（Yang et al., 2025））更适合文生图任务；(2) Qwen2.5-VL 保留了强大的语言建模能力，与语言模型相比没有明显退化；(3) Qwen2.5-VL 支持多模态输入，从而使 Qwen-Image 能够解锁更广泛的功能，例如图像编辑（Labs et al., 2025）。令 x 和 y 分别表示图像和文本输入。给定用户输入（如提示和图像），我们采用 Qwen2.5-VL 模型提取特征。为了更好地引导模型生成精细化的表征隐变量，同时考虑到不同任务中输入模态的差异，我们为纯文本输入和文本-图像输入设计了不同的系统提示。我们在图7和图15中展示了系统模板。最后，我们利用 Qwen2.5-VL 语言模型主干最后一层隐藏状态的隐变量作为用户输入的表征。

system 通过详细描述颜色、数量、文本、形状、大小、纹理、物体和背景的空间关系来描述图像： user assistant

图7：文生图任务的系统提示，其中 是用户输入的提示。

2.3 变分自编码器

强大的 VAE 表征对于构建强大的图像基础模型至关重要。当前的图像基础模型通常在大规模图像数据集上训练具有 2D 卷积的图像 VAE，以获得高质量的图像表征。相比之下，我们的工作旨在开发一种与图像和视频都兼容的更通用的视觉表征。然而，现有的联合图像-视频 VAE，如 Wan-2.1-VAE（Wan et al., 2025），通常存在性能权衡，导致图像重建能力下降。为此，我们采用单编码器、双解码器架构。这种设计利用与图像和视频都兼容的共享编码器，以及针对每种模态的独立专用解码器，这使得我们的图像基础模型能够作为未来视频模型的主干。具体来说，我们采用 Wan-2.1-VAE 的架构，冻结其编码器，并仅微调图像解码器。

为增强重建保真度，特别是对于小文本和细粒度细节，我们在一个包含丰富文本图像的自有语料库上训练解码器。该数据集包括真实世界文档（PDF、PowerPoint 幻灯片、海报）以及合成段落，涵盖字母语言（如英语）和表意语言（如中文）。在训练期间，我们观察到：(1) 平衡重建损失和感知损失可有效减少网格伪影，这些伪影常在灌木丛等重复纹理中出现。(2) 随着重建质量的提高，对抗性损失变得无效，因为判别器无法提供有效指导。基于这些观察，我们仅使用重建损失和感知损失，并在微调期间动态调整它们的比例。有趣的是，我们发现仅微调解码器就能有效增强细节并改善小文本的渲染，从而为 Qwen-Image 的文本渲染能力奠定坚实基础。定量和定性结果见第5.2.1节。

2.4 多模态扩散 Transformer

Qwen-Image 采用多模态扩散 Transformer（MMDiT）（Esser et al., 2024）来联合建模文本和图像。这种方法已在 FLUX（BlackForest, 2024; Labs et al., 2025）系列和 Seedream（Gong et al., 2025; Gao et al., 2025）系列等多款工作中被证明有效。

在每个块中，我们引入了一种新的位置编码方法：多模态可扩展 RoPE（MSRoPE）。如图8所示，我们比较了不同的文本-图像联合位置编码策略。在传统的 MMDiT 块中，文本标记直接拼接在展平的图像位置嵌入之后。此外，Seedream 3.0（Gao et al., 2025）引入了 Scaling RoPE，其中图像位置编码被移到图像的中心区域，文本标记被视为形状为 [1, 1] 的 2D 标记。然后使用 2D RoPE（Heo et al., 2024）进行图像-文本联合位置编码。尽管这种调整有助于分辨率缩放训练，但文本和图像的某些位置编码行（例如图8(B)中的第0个中间行）变得同构，使模型更难区分第0个中间行中的文本标记和图像隐变量标记。然而，确定合适的图像行来拼接文本标记也并非易事。为解决上述挑战，我们引入了多模态可扩展 RoPE（MSRoPE）。在这种方法中，文本输入被视为 2D 张量，在两个维度上应用相同的位置 ID。如图8(C)所示，文本被概念化为沿图像对角线拼接。这种设计使 MSRoPE 能够在图像侧利用分辨率缩放优势，同时在文本侧保持与 1D-RoPE 的功能等效性，从而无需确定文本的最佳位置编码。我们在表1中展示了 Qwen-Image 的架构和配置。

图8：不同图像-文本联合位置编码策略的比较。我们设计了多模态可扩展 RoPE（MSRoPE）策略，该策略从图像中心开始编码，并将文本编码沿网格对角线放置，从而实现更好的图像分辨率缩放和改善的文本-图像对齐。

表1：Qwen-Image 架构配置。

配置	VLM	VAE	MMDiT ViT LLM Enc Dec # 层 32 28 11 15 60 # 头数 (Q / KV) 16 / 16 28 / 4 16 / 24 / 24 头大小 80 128 128 中间大小 3,456 18,944
			12,288 补丁/缩放因子 14 - 8×8 8×8 2 通道大小 - - 16 16 - 参数量 7B 54M 73M 20B

3 数据

3.1 数据收集

我们系统地收集和标注了数十亿的图像-文本对，以支持图像生成模型的训练。我们不仅关注原始数据集的规模，更注重数据质量和平衡的数据分布，旨在构建一个良好平衡且具有代表性的数据集，以紧密反映真实世界场景。如图9所示，数据集分为四个主要领域：自然、设计、人物和合成数据。

在这些类别中，自然类别占比最大，约占数据集的 55%。该类别包括多种子类别，如物体、景观、城市景观、植物、动物、室内和食物等。此外，不明确属于人物或设计类别的内容也被归类为自然类别。这一广泛的通用类别是提高模型生成真实多样自然图像能力的关键基础。

第二大类别是设计类别，约占数据集的 27%。它主要包括结构化视觉内容，如海报、用户界面和演示幻灯片，以及各种形式的艺术，包括绘画、雕塑、工艺品和数字艺术。这类数据通常包含丰富的文本元素、复杂的布局和特定于设计的视觉语义。该类别对于增强模型在遵循涉及艺术风格、文本渲染和布局设计的复杂提示方面的能力尤为重要。

接下来，人物类别约占数据集的 13%，包括肖像、运动、人类活动等子类别。它涵盖各种与人类相关的图像，包括肖像、运动、活动等。该类别对于提高模型生成真实多样的人物图像的能力至关重要，以确保令人满意的用户体验和实际适用性。

最后，合成数据类别约占数据集的 5%。需要澄清的是，这里讨论的合成数据不包括其他 AI 模型生成的图像，而是通过受控文本渲染技术（见§3.4）合成的数据。这排除了其他 AI 模型合成的图像，后者通常带来显著风险，如视觉伪影、文本扭曲、偏见和幻觉。我们对这类数据持保守态度，因为使用低保真或误导性图像进行训练可能会削弱模型的泛化能力并损害其可靠性。

图9：数据收集概览。数据集包括四个主要类别：自然（通用生成）、人物（以人为中心的生成）、设计（艺术风格、文本渲染和复杂布局）和合成数据（文本渲染增强）。我们的收集策略在训练期间平衡多样性和质量，确保广泛覆盖和高保真标注，以支持稳健的模型训练。

3.2 数据过滤

为了在图像生成模型的迭代开发过程中策划高质量的训练数据，我们提出了一个多阶段过滤流水线，包括七个连续阶段，如图10所示。这些阶段在训练过程中逐步应用，数据分布随时间不断优化。值得注意的是，合成数据从第4阶段开始引入，此时基础模型已达到一定程度的稳定性。以下部分对每个阶段进行详细描述。

阶段1：初始预训练数据策划 在此早期阶段，模型在调整为256p（256x256像素，包含1:1、2:3、3:2、3:4、4:3、9:16、16:9、1:3和3:1等不同宽高比）的图像上训练。为提高数据质量，应用一系列过滤器以移除低质量或不相关的图像。损坏文件过滤器识别并丢弃损坏或部分损坏的文件（如截断的图像），其中许多文件也与异常小的文件大小相关，由文件大小过滤器检测。分辨率过滤器移除原始分辨率低于256p的图像。去重过滤器消除重复或近似重复的图像-文本对。此外，应用 NSFW 过滤器以排除包含色情、暴力或其他冒犯性内容。

阶段2：图像质量增强 在此阶段，我们专注于系统性地提高数据集的图像质量。旋转过滤器移除具有显著旋转或翻转的图像，如 EXIF 元数据所示。清晰度过滤器丢弃模糊或失焦的图像，确保只保留清晰锐利的图像。亮度过滤器排除过亮或过暗的图像，而饱和度过滤器消除具有不自然高色彩饱和度的图像，这通常表明人为渲染或不现实的数字处理。此外，熵过滤器识别并移除熵显著低的图像，通常表现为大面积的均匀区域或极少的视觉内容。最后，纹理过滤器用于丢弃纹理过于复杂的图像，这些通常与噪声或非语义模式相关。图11展示了此阶段使用的一些过滤操作示例。

阶段3：图像-文本对齐改进 此阶段专注于改善文本描述与视觉内容之间的对齐。为平衡训练数据分布，数据集根据标注来源分为三个部分：原始标注部分、接收标注部分和融合标注部分。原始标注部分包括网站提供的标注以及图像原始关联的标题或标签等元数据。尽管原始标注可能引入噪声，但它们有助于模型处理短文本输入的鲁棒性，并且是许多在合成标注数据集中通常缺失的真实世界知识（如植物名称、卡通 IP）的重要来源。接收标注部分由最先进的 Qwen-VL 标注器（Bai et al., 2025）生成的标注组成，提供更具描述性和结构化的注释。由于模型限制，并非所有 IP 都能被准确识别。融合标注部分结合了原始标注和合成标注，提供了通用知识和详细描述的混合。为进一步改进对齐，我们应用了中文 CLIP（Yang et al., 2022）过滤器和 SigLIP 2（Tschannen et al., 2025）过滤器，以移除原始标注部分中不匹配的图像-文本对。此外，采用标记长度过滤器以消除过长的标注，无效标注过滤器丢弃具有异常内容的标注，如“抱歉，我无法为此图像提供标注。”

阶段4：文本渲染增强 在此阶段，我们专注于提高模型在图像中渲染文本的能力，这对于生成具有高文本保真度的图像至关重要。为此，我们根据图像中文本的存在及其语言对数据集进行分类。具体而言，第3阶段的数据集被分为四个部分：英文部分、中文部分、其他语言部分和无文本部分，以确保在不同语言背景下进行平衡训练。为应对低频字符、混合语言场景和字体多样性等挑战，我们纳入了合成文本渲染数据，这些数据使用§3.4中描述的策略生成。此外，应用密集文本过滤器和小字符过滤器来移除文本过于密集或过小的图像，因为这种情况难以准确标注且难以清晰渲染。

图10：多阶段数据过滤流水线概览。我们的过滤策略包括七个连续阶段（S1-S7），每个阶段针对数据质量、对齐和多样性的特定方面。从初始预训练数据策划到高分辨率细化和多尺度训练，该流水线逐步提高数据集质量，同时保持语义丰富性和分布稳定性。

图11：我们流水线中使用的一些过滤操作示例。这些操作的极端值通常表示非典型或低质量图像。例如，亮度得分过高的图像通常包含大片白色或过曝区域。

阶段5：高分辨率细化 在此阶段，模型过渡到在640p分辨率的图像上训练，并进行进一步的数据集细化以确保高质量和美学吸引力。图像质量过滤器用于消除具有质量缺陷的图像，如过曝、欠曝、模糊或压缩伪影。分辨率过滤器确保所有图像满足最低分辨率要求。美学过滤器用于排除构图不佳或视觉吸引力低的图像。最后，异常元素过滤器移除包含水印、二维码、条形码或其他可能干扰观看的元素的图像。

阶段6：类别平衡和肖像增强 通过仔细的错误分析识别表现不佳的类别后，此阶段将数据集重新划分为三个主要类别：通用、肖像、文本渲染，以便在训练期间进行基于类别的重新平衡。采用基于关键词的检索和图像检索技术，用目标补丁增强数据集，以增强代表性不足的类别覆盖。为进一步提高模型生成高质量肖像的能力，我们首先从人物类别中检索照片级真实肖像、卡通角色和名人图像。然后生成合成标注，以强调角色特定细节，如面部特征、表情和服装，以及背景、光照和情绪等上下文元素。这种方法旨在提高生成图像的质量和模型的指令遵循能力。应用额外过滤器以移除包含面部马赛克或模糊的图像，以避免潜在隐私问题，并确保模型在处理人类主体时的鲁棒性。

阶段7：平衡的多尺度训练 在最后阶段，模型在640p和1328p分辨率的图像上联合训练。施加严格的1328p分辨率阈值会导致显著的数据丢失并扭曲底层数据分布。为提高训练效率并确保平衡的数据分布，我们设计了一个受 WordNet（Miller, 1995）设计原则启发的图像分类层级分类系统。第6阶段的所有图像根据此层级分类系统进行分类。在每个类别内，我们仅保留质量和美学吸引力最高的图像。此外，采用专门的重新采样策略来平衡包含文本渲染的数据，解决标记频率的长尾分布问题。这种平衡的多尺度训练使模型能够在适应更高分辨率输入的同时保留先前学习的通用知识并确保稳定收敛，从而提高细节生成能力而不牺牲鲁棒性。

- 1. 使用自然、描述性文本编写标注，不使用结构化格式或富文本。
- 2. 通过包括以下内容丰富标注细节：物体属性、物体之间的视觉关系以及环境细节。
- 3. 识别图像中可见的文本，不加翻译或解释，并用引号在标注中突出显示。
- 4. 保持真实性和准确性，避免概括。

步骤2：图像质量评估

- 1. 图像类型识别：根据图像的来源和用途返回图像类型。
- 2. 图像风格识别：根据图像的整体视觉特征返回图像风格。
- 3. 水印检测：检测图像中的水印。以列表格式返回检测到的水印。
- 4. 异常元素检测：检查是否有任何影响观看的元素，如二维码或马赛克。

示例输出格式

json "标注": "图像类型": "图像风格": "水印列表": [], "异常元素": "是/否",

图12：Qwen-Image 中使用的标注提示示例。

3.3 数据标注

在我们的数据标注流水线中，我们利用强大的图像标注器（如 Qwen2.5-VL）不仅生成全面的图像描述，还生成捕获基本图像属性和质量特征的结构化元数据。

我们没有将标注和元数据提取视为独立任务，而是设计了一个标注框架，其中标注器同时描述视觉内容并以结构化格式（如 JSON）生成详细信息。关键细节如物体属性、空间关系、环境上下文和可见文本的逐字转录被捕获在标注中，而关键图像属性如类型、风格、水印是否存在以及异常元素（如二维码或面部马赛克）则以结构化格式报告。借助先进的标注器，这种方法超越了传统图像标注，能够一次生成详细的图像描述和结构化元数据，如图12所示。标注流水线设计为高效且可扩展，使我们能够处理大规模数据集，而无需依赖额外模型或后处理步骤。在实践中，我们通过将初始标注与专家规则和轻量级分类模型集成来进一步细化上述流水线，用于水印验证和内容过滤等关键任务。

总体而言，我们的流水线不仅提供了对图像内容的深入洞察，还支持高级数据策划，为训练稳健可靠的图像生成模型奠定了坚实基础。

3.4 数据合成

鉴于真实世界图像中文本内容的长尾分布，特别是对于非拉丁语言（如中文），其中大量字符出现频率极低，仅依赖自然发生的文本不足以确保模型训练期间对这些稀有字符的充分暴露。为解决这一挑战并提高跨不同上下文的文本渲染鲁棒性，我们提出了一个多阶段文本感知图像合成流水线。该流水线集成了三种互补策略：纯渲染、合成渲染和复杂渲染。每种策略的详细说明如下。

图13：数据合成概览。我们设计了三种渲染策略——纯渲染、合成渲染和复杂渲染——分别用于生成纯文本数据、上下文文本数据和复杂布局数据。

简单背景中的纯渲染 此策略是训练模型识别和生成字符（如英文和中文汉字）的最直接有效的方法。从大规模高质量语料库中提取文本段落，并使用动态布局算法（根据画布大小调整字体大小和间距）将其渲染到干净背景上。为确保高质量合成样本，采用严格的质量控制机制：如果段落中任何字符因限制（例如字体不可用或渲染错误）而无法渲染，则丢弃整个段落。这种严格过滤确保只将完全有效和清晰的样本纳入训练数据集，从而在字符级文本渲染中保持高保真度。

上下文场景中的合成渲染 此策略专注于将合成文本嵌入到真实视觉上下文中，模仿其在日常环境中的外观。文本被模拟为书写或打印在各种物理介质（如纸张或木板）上，然后无缝合成到各种背景图像中以创建视觉上连贯的场景。我们采用 Qwen-VL 标注器为每个合成图像生成描述性标注，捕获文本与其周围视觉元素之间的上下文关系。这种方法显著提高了模型理解和生成真实世界场景中文本的能力。

结构化模板中的复杂渲染 为提高模型遵循涉及布局敏感内容的复杂结构化提示的能力，我们提出了一种基于程序化编辑预定义模板（如 PowerPoint 幻灯片或用户界面模型）的合成策略。设计了一个全面的基于规则的系统，以自动替换占位符文本，同时保持布局结构、对齐和格式的完整性。这些合成示例对于帮助模型理解和执行涉及多行文本渲染、精确空间布局以及文本字体和颜色控制的详细指令至关重要。

总之，我们的数据合成框架系统地解决了自然图像数据集中文本内容稀缺和不平衡的挑战。通过整合跨越简单性、真实感和结构复杂性的多种渲染策略，该框架合成了全面多样的训练数据。实现了跨各种文本渲染任务的鲁棒性，从而增强了模型生成高质量图像的能力，这些图像能够准确遵循关于文本渲染的复杂用户提示。

4 训练

4.1 预训练

我们采用流匹配训练目标来预训练 Qwen-Image，通过常微分方程（ODE）促进稳定的学习动态，同时保持与最大似然目标的等价性。形式化地，令 x_0 表示输入图像的隐变量。隐表征 z 通过变分自编码器（VAE）编码器 $\mathcal{E}$ 对 x_0 进行编码获得，即 $z = \mathcal{E}(x)$ ，其中 $\mathcal{E} : x \mapsto z$ 。接下来，从标准多元正态分布中采样随机噪声向量 x_1 ，即 $x_1 \sim \mathcal{N}(0, \mathbf{I})$ 。对于用户输入 S （可能包含文本或提示与图像的组合），引导隐变量 h 从 MLLM ϕ 获得，即 $h = \phi(S)$ ，其中 $\phi : S \mapsto h$ 。此外，从 logit-正态分布中采样扩散时间步 t ， $t \in [0, 1]$ 。根据 Rectified Flow（Liu et al., 2022; Esser et al., 2024），时间步 t 处的中间隐变量及其对应的速度 v_t 可计算为：

$$\begin{cases} x_t = tx_0 + (1-t)x_1 \\ v_t = \frac{dx_t}{dt} = x_0 - x_1 \end{cases} \quad (1)$$

然后，模型被训练来预测目标速度，损失函数定义为预测输出 $f_\theta(x_t, t)$ 与真实速度 v_t 之间的均方误差（MSE）：

$$\mathcal{L} = \mathbb{E}_{(x_0, h) \sim \mathcal{D}, x_1, t} \|v_\theta(x_t, t, h) - v_t\|^2, \quad (2)$$

其中 $v_\theta(x_t, t, h)$ 是模型预测的速度， $\mathcal{D}$ 表示训练数据集。

4.1.1 生产者-消费者框架

为确保在扩展到大规模 GPU 集群时的高吞吐量和训练稳定性，我们采用受 Ray（Moritz et al., 2018）启发的生产者-消费者框架，将数据预处理与模型训练解耦。这种设计使两个阶段能够异步运行并达到最优效率，同时支持在不中断正在进行训练的情况下对数据流水线进行实时更新。在生产端，原始图像-标注对首先根据我们预定义的标准（如图像分辨率和检测算子）进行过滤。选中的数据随后使用 MLLM 模型（如 Qwen2.5-VL）和 VAE 编码为隐表征。处理后的图像随后按分辨率分组到快速访问缓存桶中，并存储在共享的、位置感知的存储中，使消费者能够立即获取而无需排队。生产者和消费者之间的连接通过使用特定的 HTTP 传输层实现，该层原生支持两个端点之间异步、零拷贝调度所需的 RPC 语义。消费者部署在 GPU 密集集群上，专用于模型训练。通过将所有数据卸载到生产者，消费者节点可以将其全部计算预算用于训练 MMDiT 模型。MMDiT 参数以 4 路张量并行的布局分布在这些节点上，每个数据并行组异步地从生产者拉取预处理好的批次。额外的消费者端优化将在以下部分详细说明。

4.1.2 分布式训练优化

鉴于 Qwen-Image 模型参数规模庞大，单独使用 FSDP（Zhao et al., 2023）不足以将模型适配到每个 GPU。因此，我们利用 Megatron-LM（Shoeybi et al., 2019; Korthikanti et al., 2023）进行训练，并应用以下优化：

混合并行策略 我们采用混合并行策略，结合数据并行和张量并行，以在大规模 GPU 集群上高效扩展训练。具体来说，为实现张量并行，我们使用 Transformer-Engine 库构建 MMDiT 模型，该库允许在不同张量并行度之间无缝自动切换。此外，对于多头自注意力块，我们采用头维度上的并行来减少与沿头维度的张量并行相比的同步和通信开销。

分布式优化器和激活检查点 为缓解 GPU 内存压力并在反向传播中最小化重计算开销，我们尝试了分布式优化器和激活检查点。然而，激活检查点在反向传播中引入了大量计算开销，可能显著降低训练速度。通过实证

与256多分辨率图像训练设置进行比较，我们观察到启用激活检查点使每GPU内存消耗减少了 11.3%（从每GPU 71GB降至63GB），但代价是每次迭代时间增加了 3.75×（从2s增加到 7.5s）。基于这种权衡，我们最终选择禁用激活检查点，仅依赖分布式优化器。训练期间，All-Gather 操作以 bfloat16 执行，而梯度 Reduce-Scatter 操作使用 float32，确保计算效率和提高数值稳定性。

4.1.3 训练策略

我们采用多阶段预训练策略，旨在逐步提高数据质量、图像分辨率和模型性能。在不同训练阶段，我们整合了多种训练策略以优化学习过程。这些训练策略列举如下：

提高分辨率：从低分辨率到高分辨率 此策略逐步提升多分辨率、多宽高比输入，从初始分辨率 256×256 像素（包括1:1、2:3、3:2、3:4、4:3、9:16、16:9、1:3和3:1等多种宽高比）开始，然后增加到 640×640 像素，最终达到 1328×1328 像素。通过提高图像分辨率，模型可以捕获更多细节特征，从而获得更好的性能。更丰富的特征空间有助于改善对未见数据的泛化能力。例如，从低分辨率到高分辨率花卉图像的转换使模型能够辨别更精细的细节，如花瓣纹理和颜色渐变。

整本文渲染：从非文本文本 为解决传统视觉数据集中文本内容有限以及由此导致的字形生成性能欠佳的问题（特别是中文字符），我们逐步引入在自然背景上叠加渲染文本的图像。这种策略使模型能够首先学习通用视觉表征，随后获得文本渲染能力。

细化数据质量：从海量数据到精细化数据 在预训练早期，我们利用大规模数据集使模型获得基础视觉生成能力。随着训练的推进，我们逐步采用越来越严格的数据过滤机制来选择更高质量的数据。这种渐进式数据细化确保只利用最相关和高质量的样本来保证训练效率和模型性能。

平衡数据分布：从不平衡到平衡 在整个训练过程中，我们逐步在领域和图像分辨率分布方面平衡数据集。这种调整降低了模型过拟合到特定领域或分辨率的风险，否则可能损害在代表性不足的设置中生成图像的保真度和细粒度细节。通过保持更均匀的数据分布，我们促进了跨不同领域和分辨率的稳健泛化。

用合成数据增强：从真实世界数据到合成数据 某些数据分布，如超现实风格或包含大量文本内容的高分辨率图像，在真实世界数据集中代表性不足甚至缺失。此外，某些高质量数据样本的可用性固有地有限。为解决这些不足，我们采用数据合成技术生成补充样本，从而丰富数据集并确保更全面地覆盖多样化的视觉领域。这种增强策略提高了模型在更广泛场景中泛化和稳健执行的能力。

4.2 后训练

在本节中，我们介绍 Qwen-Image 的后训练框架，包括两个阶段：监督微调（SFT）和强化学习（RL）（Kaelbling et al., 1996）。

4.2.1 监督微调（SFT）

在 SFT 阶段，我们构建了一个按语义类别分层组织的数据集，并采用细致的人工标注来解决模型的特定不足。我们要求选定的图像清晰、细节丰富、明亮且照片级真实。这种方法旨在引导模型生成具有更高真实感和更精细细节的内容。

4.2.2 强化学习（RL）

我们采用两种不同的 RL 策略：直接偏好优化（DPO）（Rafailov et al., 2023）和组相对策略优化（GRPO）（Shao et al., 2024）。DPO 在流匹配（单步）在线偏好建模方面表现出色且计算高效，而 GRPO 在训练期间执行策略内采样，并使用奖励模型评估每条轨迹。为利用离线偏好学习的可扩展性优势，我们使用 DPO 进行相对大规模的 RL，并保留 GRPO 用于小规模细粒度 RL 细化。两种算法的详细说明如下。

(A) 直接偏好优化（DPO）

数据准备 对于 DPO 训练数据，给定相同提示，使用不同的随机初始化种子生成多张图像。然后要求人工标注者从这些候选图像中选择最佳和最差图像。数据分为两类：有参考（金标准）图像的提示和无参考图像的提示。对于有参考图像的数据，标注者首先将生成的输出与参考进行比较。如果存在显著差异，则指示标注者将最差的生成指定为被拒绝样本。对于无参考图像的提示，要求标注者在生成的图像中选择最佳和最差样本，或指示所有生成结果是否质量不佳。

算法 给定文本隐状态 h 、选中的生成图像（或金标准图像） x_0^{win} 和被拒绝的生成图像 x_0^{lose} ，我们采样时间步 $t \sim (0, 1)$ 以构建输入隐变量 x_t^{win} 和 x_t^{lose} 及其对应的速度 v_t^{win} 和 v_t^{lose} ，遵循公式1。然后，受先前工作（Wallace et al., 2024）启发，我们基于流匹配训练准则构建 DPO 目标，可表述为：

$$\begin{cases} \text{Diff}_{\text{policy}} = (\|v_\theta(x_t^{win}, h, t) - v_t^{win}\|_2^2 - \|v_\theta(x_t^{lose}, h, t) - v_t^{lose}\|_2^2) \\ \text{Diff}_{\text{ref}} = (\|v_{\text{ref}}(x_t^{win}, h, t) - v_t^{win}\|_2^2 - \|v_{\text{ref}}(x_t^{lose}, h, t) - v_t^{lose}\|_2^2) \\ \mathcal{L}_{DPO} = -\mathbb{E}_{h, (x_0^{win}, x_0^{lose}) \sim \mathcal{D}, t \sim \mathcal{U}(0,1)} [\log \sigma(-\beta(\text{Diff}_{\text{policy}} - \text{Diff}_{\text{ref}}))] \end{cases} \quad (3)$$

其中 $\text{Diff}_{\text{policy}}$ 和 Diff_{ref} 分别表示策略模型和参考模型计算的偏好差异， β 是缩放参数， $\sigma(\cdot)$ 表示 sigmoid 函数。

(B) 组相对策略优化（GRPO）

算法 在使用 DPO 训练后，我们使用 GRPO 按照 Flow-GRPO（Liu et al., 2025a）框架进行进一步细粒度训练。给定文本隐状态 h ，流模型预测一组 G 张图像 $\{x_0^i\}_{i=1}^G$ 及对应的轨迹 $\{x_T^i, x_{T-1}^i, \dots, x_0^i\}_{i=1}^G$ 。在每组内，优势函数可表述为：

$$A_i = \frac{R(x_0^i, h) - \text{mean}(\{R(x_0^j, h)\}_{j=1}^G)}{\text{std}(\{R(x_0^j, h)\}_{j=1}^G)}, \quad (4)$$

其中 R 是奖励模型。然后，GRPO 的训练目标为：

$$\begin{aligned} \mathcal{L}_{\text{GRPO}}(\theta) &= \mathbb{E}_{h \sim \mathcal{D}, \{x_0^i\}_{i=1}^G \sim \pi_\theta} \left[\frac{1}{G} \sum_{i=1}^G \frac{1}{T} \sum_{t=0}^{T-1} (\min(r_t^i(\theta) A_i, \text{clip}(r_t^i(\theta), 1 - \epsilon, 1 + \epsilon) A_i) - \beta D_{KL}(\pi_\theta || \pi_{\text{ref}})) \right], \quad (5) \\ \text{其中 } r_t^i(\theta) &= \frac{p_\theta(x_{t-1}^i | x_t^i, h)}{p_{\text{old}}(x_{t-1}^i | x_t^i, h)}. \end{aligned}$$

在采样轨迹 $\{x_T^i, \dots, x_0^i\}_{i=1}^G \sim \pi_\theta$ 时，对于流匹配采样（遵循公式1），我们有 $dx_t = v_t dt$ ，其中 $v_t = v_\theta(x_t, t, h)$ 是预测速度。然而，这种采样策略没有随机性，不适合探索。因此，我们将采样过程重新表述为 SDE 过程以增加随机性。SDE 采样过程可写为：

$$dx_t = \left(v_t + \frac{\sigma_t^2}{2t} (x_t + (1-t)v_t) \right) dt + \sigma_t dw, \quad (6)$$

图14：图像编辑（TI2I）任务概览。左图：TI2I 任务训练输入格式的示意图。用户提示为“转换为现实风格”（英文）。右图：TI2I 的 MSRoPE 相应修改，其中引入一个新维度（帧）以区分编辑前后的图像。

图14：图像编辑（TI2I）任务概览。左图：TI2I 任务训练输入格式的示意图。用户提示为“转换为现实风格”（英文）。右图：TI2I 的 MSRoPE 相应修改，其中引入一个新维度（帧）以区分编辑前后的图像。

图15：图像编辑（TI2I）任务的系统提示，其中 是用户输入图像， 是用户输入提示。

其中 σ_t 表示随机性的大小。使用 Euler-Maruyama 离散化，我们有

$$x_{t+\Delta t} = x_t + \left[v_{\theta}(x_t, t, h) + \frac{\sigma_t^2}{2t}(x_t + (1 - t)v_{\theta}(x_t, t, h)) \right] \Delta t + \sigma_t \sqrt{\Delta t} \epsilon. \quad (7)$$

我们使用上述方程来采样轨迹。公式(5)中的 KL 散度可以闭式求解

$$D_{KL}(\pi_{\theta}||\pi_{\text{ref}}) = \frac{\Delta t}{2} \left(\frac{\sigma_t(1 - t)}{2t} + \frac{1}{\sigma_t} \right)^2 ||v_{\theta}(x_t, t, h) - v_{\text{ref}}(x_t, t, h)||^2. \quad (8)$$

4.3 多任务训练

除了文生图（TI2I）生成，我们将基础模型扩展到包含文本和图像输入的多模态图像生成任务，包括基于指令的图像编辑（Wang et al., 2025）、新颖视角合成（Wang et al., 2024b）和计算机视觉任务如深度估计（Bochkovskii et al., 2024）。我们可以将这些广泛视为通用图像编辑任务。基于 Qwen2.5-VL 的能力，我们的模型原生支持图像输入：从用户提供的图像中提取的视觉补丁由视觉 Transformer（ViT）编码，并与文本标记拼接形成输入序列。我们设计如图15所示的系统提示，并将输入图像和文本指令作为 Qwen-Image MMDiT 文本流的输入。

受先前工作（Labs et al., 2025）启发，该工作表明引入 VAE 嵌入有助于保持角色和场景一致性，我们额外将输入图像的 VAE 编码隐表征馈入图像流，沿序列维度与噪声图像隐变量拼接。为使模型能够区分多张图像，我们扩展了 MSRoPE，引入额外的帧维度，除了用于定位单张图像内图像补丁的高度和宽度之外（见图14右图）。经验上，我们发现提供来自 MLLM 的视觉语义嵌入可以实现更好的指令遵循，而引入

图16：Qwen-Image 与领先闭源 API 在 AI Arena 平台上的比较。用户可以根据提示比较两个匿名模型生成的图像，并选择哪一个更好、两者都好或两者都差。Elo 排行榜由 chat.qwen.ai 上的 Qwen3-Coder（Qwen, 2025）驱动。

像素级 VAE 嵌入进一步增强了模型保持视觉保真度和维持用户提供图像结构一致性的能力。

5 实验

5.1 人工评估

为全面评估 Qwen-Image 的通用图像生成能力，并客观地将其与最先进的闭源 API 进行比较，我们开发了 AI Arena，这是一个基于 Elo 评级系统（Elo & Sloan, 2008）构建的开放基准测试平台，如图16所示。

AI Arena 是一个公平且动态的开放竞赛平台。在每一轮中，由随机选择的模型使用相同提示生成的两张图像匿名呈现给用户进行成对比较。用户投票选出更优图像，结果通过 Elo 算法用于更新个人和全球排行榜，使开发者、研究人员和用户能够全面评估模型的性能。具体来说，我们策划了约5000个多样化提示，涵盖广泛的评估维度，包括主题、风格、摄影视角等。邀请了来自不同专业背景的200多名评估者参与评估过程。

AI Arena 现已向公众开放。任何人都可以参与不同模型的比较。未来，该平台将进一步从文生图生成扩展到各种多模态生成任务，如图像编辑、文生音频、文生视频和图生视频生成。平台严格遵守客观性和独立性标准，并将通过各种技术检测和消除作弊或无效数据。

我们选择了五个最先进的闭源 API 作为 Qwen-Image 在竞技场中的竞争对手：Imagen 4 Ultra Preview 0606（Google, 2025）、Seedream 3.0（Gao et al., 2025）、GPT Image 1 [High]（OpenAI, 2025）、FLUX.1 Kontext [Pro]（Labs et al., 2025）和 Ideogram 3.0（Ideogram, 2025）。迄今为止，每个模型至少参与了10,000次成对比较，确保了评估的稳健性和公平性。考虑到大多数闭源 API 不能可靠地支持中文文本生成，我们排除了涉及中文文本的提示，以保持比较结果的客观性。

如图16所示，Qwen-Image 作为唯一开源的图像生成模型，在 AI Arena 中排名第三。尽管 Qwen-Image 落后于领先的 Imagen 4 Ultra Preview 0606 约30个 Elo 点，但与 GPT Image 1 [High] 和 FLUX.1 Kontext [Pro] 等模型相比，它显示出超过30个 Elo 点的显著优势。这些结果确立了 Qwen-Image 作为强大开源图像生成模型的地位，为开发者、研究人员和用户提供了强大的性能和广泛的实用性。

5.2 定量结果

为全面评估我们模型的视觉生成能力，我们首先在§5.2.1中报告其在 VAE 重建上的性能，这用于展示模型生成质量的上限。

表2：VAE 的定量评估结果。

模 型	# 参 数	# 图 像 参 数	Text_256x256 Enc Dec Enc Dec PSNR(↑) SSIM(↑) PSNR(↑) SSIM(↑) Wan2.1-VAE (Wan et al., 2025) 54M 73M 19M 25M 31.29 0.8870 26.77 0.9386 Hunyuan-VAE (Kong et al., 2024) 100M 146M 34M 50M 33.21 0.9143 32.83 0.9773 FLUX-VAE (BlackForest, 2024) 34M 50M 34M 50M 32.84 0.9155 32.65 0.9792 Cosmos-CI-VAE (Agarwal et al., 2025) 31M 46M 31M 46M 32.23 0.9010 30.62 0.9664 SD-3.5-VAE (Esser et al., 2024) 34M 50M 34M 50M 31.22 0.8839 29.93 0.9658 Qwen-Image-VAE 54M 73M 19M 25M 33.42 0.9159 36.63 0.9839									
			Imagenet_256x256									

我们进一步在两个基础视觉生成任务上进行评估：§5.2.2中的文生图（T2I）和§5.2.3中的图像编辑（TI2I），以提供对模型基础生成能力的全面评估。

5.2.1 VAE 重建性能

我们定量评估了几种最先进的图像分词器，报告峰值信噪比（PSNR）和结构相似性指数（SSIM）以评估重建质量。所有比较的 VAE 均以8×8压缩率和16的隐通道维度运行。值得注意的是，FLUX-VAE（BlackForest, 2024）、Cosmos-CI-VAE（Agarwal et al., 2025）和 SD-3.5-VAE（Esser et al., 2024）是图像分词器，而 Wan2.1-VAE（Wan et al., 2025）、Hunyuan-VAE（Kong et al., 2024）和 Qwen-Image-VAE 是联合图像和视频分词器。为公平比较，我们报告了有效的图像参数（见表2中的“图像参数”）。这考虑了将联合模型中的3D卷积转换为用于图像处理的等效2D卷积。按照先前工作，评估在 ImageNet-1k（Deng et al., 2009）验证集上以256x256分辨率进行，以评估通用领域性能。为进一步评估小文本上的重建能力，我们还在一个包含多样化文本来源（PDF、PPT幻灯片、海报和合成本文）和语言的文本丰富图像自有语料库上报告了重

建结果。为提高数值精度，我们使用 float32 评估分词器。如表2所示，Qwen-Image-VAE 在所有评估指标上均实现了最先进的重建性能。值得注意的是，在处理图像时，Qwen-Image-VAE 仅激活编码器中的19M参数和解码器中的25M参数，在重建质量和计算效率之间实现了最佳平衡。

5.2.2 文生图性能

我们从两个角度评估 Qwen-Image 在文生图（T2I）任务上的性能：通用生成能力和文本渲染能力。为评估模型的通用生成性能，我们在四个公开基准上进行了评估——DPG（Hu et al., 2024b）、GenEval（Ghosh et al., 2023）、OnelG-Bench（Chang et al., 2025）和 TIIF（Wei et al., 2025）。这些基准提供了对模型从文本提示生成高质量和语义一致图像能力的全面衡量。为进一步评估模型的文本渲染能力，我们分别评估了其在英文和中文文本生成上的性能。对于英文文本渲染，我们使用 CVTG-2K（Du et al., 2025）基准，该基准专门设计用于评估渲染英文文本的可读性。为解决中文文本渲染缺乏标准化评估的问题，我们引入了一个名为 ChineseWord 的新基准，用于评估模型渲染中文字符的能力，使我们能够系统地评估模型的文本渲染性能。此外，为全面评估 Qwen-Image 准确渲染长文本的能力，我们在 LongText-Bench（Geng et al., 2025）上进行了评估，该基准设计用于评估中英文长文本渲染性能。

DPG 表3显示了在 DPG（Hu et al., 2024b）上的性能比较。该基准包含1K个密集提示，能够细粒度地评估提示遵循的不同方面。总体而言，Qwen-Image 取得了最高的总分，表明其卓越的提示遵循能力。特别是，Qwen-Image 在解释涉及属性和其他方面的提示方面表现出色，在比较中优于所有其他模型。

GenEval 表4展示了模型在 GenEval（Ghosh et al., 2023）基准上的性能比较，该基准专注于使用具有不同对象属性的组合提示进行以对象为中心的文生图生成。我们分别评估了 SFT 模型和 RL 增强模型的性能。

表3：DPG（Hu et al., 2024b）上的定量评估结果。

模型	全局	实体	属性	关系	其他	总体↑
SD v1.5	(Rombach et al., 2021)	74.63	74.23	75.39	73.49	67.81
PixArt-α	(Chen et al., 2024c)	74.97	79.32	78.60	82.57	76.96
Lumina-Next	(Zhuo et al., 2024)	82.82	88.65	86.44	80.53	81.82
SDXL	(Podell et al., 2023)	83.27	82.43	80.91	86.76	80.41
Playground v2.5	(Li et al., 2024a)	83.06	82.59	81.20	84.08	83.50
Hunyuan-DiT	(Li et al., 2024b)	84.59	80.59	88.01	74.36	86.41
Janus	(Wu et al., 2025a)	82.33	87.38	87.70	85.46	86.41
PixArt-Σ	(Chen et al., 2024b)	86.89	82.89	88.94	86.59	87.68
Emu3-Gen	(Wang et al., 2024a)	85.21	86.68	86.84	90.22	83.15
Janus-Pro-1B	(Chen et al., 2025b)	87.58	88.63	88.17	88.98	88.30
DALL-E 3	(OpenAI, 2023)	90.97	89.61	88.39	90.58	89.83
FLUX.1 [Dev]	(BlackForest, 2024)	74.35	90.00	88.96	90.87	88.33
SD3 Medium	(Esser et al., 2024)	87.90	91.01	88.83	80.70	88.68
Janus-Pro-7B	(Chen et al., 2025b)	86.90	88.90	89.40	89.32	89.48
HiDream-II-Full	(Cai et al., 2025)	76.44	90.22	89.48	93.74	91.83
Lumina-Image 2.0	(Qin et al., 2025)	-	91.97	90.20	94.85	-
Seedream 3.0	(Gao et al., 2025)	94.31	92.65	91.36	92.78	88.24
GPT Image 1 [High]	(OpenAI, 2025)	88.89	88.94	89.84	92.63	90.96
Qwen-Image		91.32	91.56	92.02	94.31	92.73

表4：GenEval（Ghosh et al., 2023）上的定量评估结果。

模型	单物体	双物体	计数	颜色	位置	属性绑定	总体↑
Show-o	(Xie et al., 2024)	0.95	0.52	0.49	0.82	0.11	0.28
Emu3-Gen	(Wang et al., 2024a)	0.98	0.71	0.34	0.81	0.17	0.21
PixArt-α	(Chen et al., 2024c)	0.98	0.50	0.44	0.80	0.08	0.07
SD3 Medium	(Esser et al., 2024)	0.98	0.74	0.63	0.67	0.34	0.36
FLUX.1 [Dev]	(BlackForest, 2024)	0.98	0.81	0.74	0.79	0.22	0.45
SD3.5 Large	(Esser et al., 2024)	0.98	0.89	0.73	0.83	0.34	0.47
JanusFlow	(Ma et al., 2025)	0.97	0.59	0.45	0.83	0.53	0.42
Lumina-Image 2.0	(Qin et al., 2025)	-	0.87	0.67	-	0.62	0.73
Janus-Pro-7B	(Chen et al., 2025b)	0.99	0.89	0.59	0.90	0.79	0.66
HiDream-II-Full	(Cai et al., 2025)	1.00	0.98	0.79	0.91	0.60	0.72
GPT Image 1 [High]	(OpenAI, 2025)	0.99	0.92	0.85	0.92	0.75	0.61
Seedream 3.0	(Gao et al., 2025)	0.99	0.96	0.91	0.93	0.47	0.80
Qwen-Image		0.99	0.92	0.89	0.88	0.76	0.77
Qwen-Image-RL		1.00	0.95	0.93	0.92	0.87	0.83

型与其他领先基础模型进行比较。值得注意的是，我们的基础模型已经超越了现有最先进水平，优于 Seedream 3.0（Gao et al., 2025）和 GPT Image 1 [High]（OpenAI, 2025）。经过强化学习（RL）微调后，我们的模型取得了更高的0.91分，成为排行榜上唯一超过0.9阈值的基础模型。这些结果证明了 Qwen-Image 卓越的可控生成能力。

OnelG-Bench 表5和表6报告了在 OnelG-Bench（Chang et al., 2025）上的定量结果，这是一个为跨多个维度细粒度评估 T2I 模型而设计的综合基准。为公平地进行总体比较，我们对所有维度的得分进行平均以获得最终总体得分。总体而言，Qwen-Image 在中英文赛道均取得了最高的总体得分，展示了其强大的通用生成能力。值得注意的是，它在对齐和文本类别中排名第一，证明了其卓越的提示遵循和文本渲染能力。

TIIF 表7显示了在 TIIF Bench mini（Wei et al., 2025）上的性能比较，该基准设计用于系统评估 T2I 模型解释和遵循复杂文本指令的能力。总体而言，Qwen-Image 排名第二，仅次于 GPT Image 1（OpenAI, 2025），凸显了其强大的指令遵循能力。

表5：OnelG-EN（Chang et al., 2025）上的定量评估结果。总体得分是五个维度的平均值。

模型	对齐	文本	推理	风格	多样性	总体↑
Janus-Pro	(Chen et al., 2025b)	0.553	0.001	0.139	0.276	0.365
BLIP3-o	(Chen et al., 2025a)	0.711	0.013	0.223	0.361	0.229
BAGEL	(Deng et al., 2025)	0.769	0.244	0.173	0.367	0.251
BAGEL+CoT	(Deng et al., 2025)	0.793	0.020	0.206	0.390	0.209
Show-02-1.5B	(Xie et al., 2025b)	0.798	0.002	0.219	0.317	0.186
Show-02-7B	(Xie et al., 2025b)	0.817	0.002	0.226	0.317	0.177
OmniGen2	(Wu et al., 2025b)	0.804	0.680	0.271	0.377	0.242
SD 1.5	(Rombach et al., 2021)	0.565	0.010	0.207	0.383	0.429
SDXL	(Podell et al., 2023)	0.688	0.029	0.237	0.332	0.296
SD3.5 Large	(Esser et al., 2024)	0.809	0.629	0.294	0.353	0.225
FLUX.1 [Dev]	(BlackForest, 2024)	0.786	0.523	0.253	0.368	0.238
CogView4	(Zai, 2025)	0.786	0.641	0.246	0.353	0.205
SANA-1.5 1.6B (PAG)	(Xie et al., 2025a)	0.762	0.054	0.209	0.387	0.222
SANA-1.5 4.8B (PAG)	(Xie et al., 2025a)	0.765	0.069	0.217	0.401	0.216
Lumina-Image 2.0	(Qin et al., 2025)	0.819	0.106	0.270	0.354	0.216
HiDream-11-Full	(Cai et al., 2025)	0.829	0.707	0.317	0.347	0.186
Imagen3	(Google, 2024)	0.843	0.343	0.313	0.359	0.188
Recraft V3	(Recraft, 2024)	0.810	0.795	0.323	0.378	0.205
Kolors 2.0	(team, 2025)	0.820	0.427	0.262	0.360	0.300
Seedream 3.0	(Gao et al., 2025)	0.818	0.865	0.275	0.413	0.277
Imagen4	(Google, 2025)	0.857	0.805	0.338	0.377	0.199
GPT Image 1 [High]	(OpenAI, 2025)	0.851	0.857	0.345	0.462	0.151
Qwen-Image		0.882	0.891	0.306	0.418	0.197

表6：OnelG-ZH（Chang et al., 2025）上的定量评估结果。总体得分是五个维度的平均值。

模型	对齐	文本	推理	风格	多样性	总体↑
Janus-Pro	(Chen et al., 2025b)	0.324	0.148	0.104	0.264	0.358
BLIP3-o	(Chen et al., 2025a)	0.608	0.092	0.213	0.369	0.233
BAGEL	(Deng et al., 2025)	0.672	0.365	0.186	0.357	0.268
BAGEL+CoT	(Deng et al., 2025)	0.719	0.127	0.219	0.385	0.197
Cogview4	(Zai, 2025)	0.700	0.193	0.236	0.348	0.214
Lumina-Image 2.0	(Qin et al., 2025)	0.731	0.136	0.221	0.343	0.240
HiDream-11-Full	(Cai et al., 2025)	0.620	0.205	0.256	0.304	0.300
Kolors 2.0	(team, 2025)	0.738	0.502	0.226	0.331	0.333
Seedream 3.0	(Gao et al., 2025)	0.793	0.928	0.281	0.397	0.243
GPT Image 1 [High]	(OpenAI, 2025)	0.812	0.650	0.300	0.449	0.159
Qwen-Image		0.825	0.963	0.267	0.405	0.279

CVTG-2K 表8报告了在 CVTG-2K（Du et al., 2025）上英文渲染的定量结果。该基准包含2K个提示，每个提示要求在生成的图像上渲染2-5个英文区域。引入三个指标：单词准确率、NED、CLIPScore 来衡量文本渲染的准确性。如表所示，Qwen-Image 实现了与最先进图像生成模型相当的性能，凸显了其强大的英文文本渲染能力。

LongText-Bench 表10报告了在 LongText-Bench (Geng et al., 2025) 上的定量结果, 该基准专门设计用于评估模型精确渲染长文本的能力。数据集包含160个提示, 涵盖八个不同场景。如表所示, Qwen-Image 在中文长文本上获得了最高准确率, 在英文长文本上获得第二高准确率, 展示了 Qwen-Image 卓越的长文本渲染能力。

模型	总体	基础遵循	高级遵循	设计者 平均 属性 关系 推理 平均 属性 属性+推理 关系+推理 风格 文本																																																																																																																																																																																																																																																																																																																															
				短										长										短										长										短										长																																																																																																																																																																																																																																																																													
				FLUX.1 [dev] (BlackForest,										2024) 71.09 71.78 83.12 78.65 87.05 83.17 87.25 80.39 75.01 72.39 65.79 68.54 67.07 73.69 73.84 73.34 69.09 71.99 66.67 66.67 43.83 52.83 70.72 71.47										FLUX.1 [Pro] (BlackForest,										2024) 67.32 69.89 79.08 78.91 78.83 81.33 82.82 83.52 75.57 71.57 61.10 65.37 62.32 65.57 69.84 71.47 65.96 67.72 63.00 63.00 35.83 55.83 71.80 68.80										DALL-E 3 (OpenAI,										2023) 74.96 70.81 78.72 78.50 79.50 79.83 80.82 78.82 75.82 76.32 73.39 67.27 73.45 67.20 72.01 71.34 63.59 60.72 89.66 86.67 66.83 54.83 72.93 60.99										SD 3 (Esser et al.,										2024) 67.46 66.09 78.32 77.75 83.33 79.83 82.07 78.82 71.07 74.07 61.46 59.56 61.07 64.07 68.84 70.34 50.96 57.84 66.67 76.67 59.83 20.83 63.23 67.34										PixArt-E (Chen et al.,										2024b) 62.00 58.12 70.66 75.25 69.33 78.83 75.07 77.32 67.57 69.57 57.65 49.50 65.20 56.57 66.96 61.72 66.59 54.59 83.33 70.00 1.83 1.83 62.11 52.41										Lumina-Next (Zhao et al.,										2024) 50.93 52.46 64.58 66.08 56.83 59.33 67.57 71.82 69.32 67.07 44.75 43.63 51.44 43.20 51.09 59.72 44.72 54.46 70.00 66.67 0.00 0.83 47.56 49.05										Hunyuan-DIT (Li et al.,										2024b) 51.38 53.28 69.33 69.00 65.83 69.83 78.07 73.82 64.07 63.32 42.62 45.45 50.20 41.57 59.22 61.84 47.84 51.09 56.67 73.33 0.00 0.83 40.10 44.20										Show-o (Xie et al.,										2024) 59.72 58.86 73.08 75.83 74.83 79.83 78.82 78.32 65.57 69.32 53.67 50.38 60.95 56.82 68.59 68.96 66.46 56.22 63.33 66.67 3.83 2.83 55.02 50.92										LightGen (Wu et al.,										2025c) 53.22 43.41 66.58 47.91 55.83 47.33 74.82 45.82 69.07 50.57 46.74 41.53 62.44 40.82 61.71 50.47 50.34 45.34 53.33 53.33 0.00 6.83 50.92 50.55										SANA 1.5 (Xie et al.,										2025a) 67.15 65.73 79.66 77.08 79.83 77.83 85.57 83.57 73.57 69.82 61.50 60.67 65.32 56.57 69.96 73.09 62.96 65.84 80.00 80.00 17.83 15.83 71.07 68.83										Infinity (Han et al.,										2025) 62.07 62.32 73.08 75.41 74.33 76.83 72.82 77.57 72.07 71.82 56.64 54.98 60.44 55.57 74.22 64.71 60.22 59.71 80.00 73.33 10.83 23.83 54.28 56.89										Janus-Pro-7B (Chen et al.,										2025b) 66.50 65.02 79.33 78.25 79.33 82.33 78.32 73.32 80.32 79.07 59.71 58.82 66.07 56.20 70.46 70.84 67.22 59.97 60.00 70.00 28.83 33.83 65.84 60.21										Midjourney v7 (Midjourney,										2025) 68.74 65.69 77.41 76.00 77.58 81.83 82.07 76.82 72.57 69.32 64.66 60.53 67.20 62.70 81.22 71.59 60.72 64.59 83.33 80.00 24.83 20.83 68.83 63.61										Seedgram 3.0 (Gao et al.,										2025) 86.02 84.31 87.07 84.93 90.50 90.00 89.85 85.94 80.86 78.96 79.16 80.60 79.76 81.82 77.23 78.85 75.64 78.64 100.00 92.33 97.17 87.28 83.21 83.51										GPT Image 1 (High) (OpenAI,										2025) 89.15 88.29 90.75 89.66 91.33 87.08 84.57 84.57 96.32 87.85 88.35 85.37 87.07 89.44 87.22 83.96 85.59 83.21 90.00 93.33 89.83 86.83 89.72 93.46										Qwen-										Image 86.14 86.83 86.18 87.22 90.50 91.50 88.22 90.78 79.81 78.28 79.30 80.88 79.21 78.94 78.85 81.69 75.57 78.59 100.00 100.00 92.76 89.14 90.30 91.91									

模 型	单 词 准 确 率↑	NED↑	CLIPScore↑ 2 区域 3 区域 4 区域 5 区域 SD3.5 Large (Esser et al., 2024) 0.7293 0.6825 0.6574 0.5940 0.6548 0.8470 0.7797 FLUX.1 [dev] (BlackForest, 2024) 0.6089 0.5531 0.4661 0.4316 0.4965 0.6879 0.7401 AnyText (Tuo et al., 2024) 0.0513 0.1739 0.1948 0.2249 0.1804 0.4675 0.7432
			TextDiffuser-2 (Chen et al., 2024a) 0.5322 0.3255 0.1787 0.0809 0.2326 0.4353 0.6765 RAG-Diffusion (Chen et al., 2024d) 0.4388 0.3316 0.2116 0.1910 0.2648 0.4498 0.7797 3DIS (Zhou et al., 2024) 0.4495 0.3959 0.3880 0.3303 0.3813 0.6505 0.7767 TextCrafter
			(Du et al., 2025) 0.7628 0.7628 0.7406 0.6977 0.7370 0.8679 0.7868 Seedream 3.0 (Gao et al., 2025) 0.6282 0.5962 0.6043 0.5610 0.5924 0.8537 0.7821 GPT Image 1 [High] (OpenAI, 2025) 0.8779 0.8659 0.8731 0.8218 0.8569 0.9478 0.7982
			Qwen-Image 0.8370 0.8364 0.8313 0.815

模 型	GEdit-Bench-CN (完整集) [†]	G_SC G_PQ G_O G_SC G_PQ G_O Instruct-Pix2Pix (Brooks et al., 2023) 3.58 5.49 3.68 --- --- --- AnyEdit (Yu et al., 2025) 3.18 5.82 3.21 --- --- --- MagicBrush (Zhang et al., 2023) 4.68 5.66 4.52 --- --- --- UniWorld-v1 (Lin et al., 2025) 4.93 7.43 4.85 --- --- --- OmniGen (Xiao et al., 2025) 5.96 5.89 5.06 --- --- --- OmniGen2 (Wu et al., 2025b) 7.16 6.77 6.41 --- --- --- Gemini 2.0 (DeepMind, 2025) 6.73 6.61 6.32 5.43 6.78 5.36 BAGEL (Deng et al., 2025) 7.36 6.83 6.52 7.34 6.85 6.50 FLUX.1 Kontext [Pro] (Labs et al., 2025) 7.02 7.60 6.56 1.11 6.76 1.23 Step1X-Edit (Liu et al., 2025b) 7.66 7.35 6.97 7.20 6.87 6.86 GPT Image 1 [High] (OpenAI, 2025) 7.85 7.62 7.53 7.67 7.56 7.30 Qwen-Image8.00 7.86 7.56 7.82 7.79 7.52
	GEdit-Bench-EN (完整集) [†]	

8 / 11

新颖视角合成 表13显示了在 GSO (Downs et al., 2022) 数据集上的新颖视角合成结果。我们比较了给定3D物体前视图生成的新颖视角图像与真实图像的相似度。

表14: 与专用模型和多任务模型在零样本数据集上深度估计的定量比较。Qwen-Image 的性能可与最先进模型相媲美。

9 / 11

多物体生成 如图22上半部分所示，Qwen-Image 准确生成了所有要求的动物，忠实地保留了它们指定的位置，并一致应用了正确的毛绒风格。相比之下，GPT Image 1 未能生成毛绒风格的图像，而 Recraft V3 和 Seedream 3.0 生成了与提示不符的错误动物。在图22的下半部分，Qwen-Image 不仅在台球上正确渲染了混合语言文本，还严格遵循指令将台球排列成两行。GPT Image 1 不能完美遵循指令的布局要求，还错误地生成了中文字符“*”，而其他模型无法正确生成大多数中文字符。

空间关系生成 在图23的第一部分，Qwen-Image 生成的图像准确反映了提示，既捕获了正确的攀登场景，也捕获了两人之间指定的互动。相比之下，GPT Image 1、Seedream 3.0 和 Recraft V3 未能完全遵循提示：这些模型产生了不正确的攀登者互动。这种比较展示了 Qwen-Image 理解并精确遵循复杂提示的强大能力。对于其余部分，只有 Qwen-Image 和 GPT Image 1 能够准确描绘角色与鸽子之间以及怀表与杯柄之间的空间关系。

5.3.3 图像编辑的定性结果

为全面评估 Qwen-Image 的图像编辑（TI2I）能力，我们聚焦于五个关键方面进行定性评估：文本和材质编辑、物体添加/移除/替换、姿态操作、链式编辑和新颖视角合成。为进行比较分析，我们将模型与几个领先的基于指令的图像编辑模型进行基准测试，包括 SeedEdit 3.0 (Wang et al., 2025)、FLUX.1 Kontext [Pro] (Labs et al., 2025) 和 GPT Image 1 [High] (OpenAI, 2025)。

文本和材质编辑 图24展示了文本和材质编辑能力的定性比较。在顶部的示例中，涉及具有复杂风格的文本编辑，Seedream 3.0 未能将字母“H”改为“Q”，GPT Image 1 [High] 未能保留原始风格。Qwen-Image 和 FLUX.1 Kontext [Pro] 均成功修改了文本，同时保持了风格一致性。在底部的示例中，除 FLUX.1 Kontext [Pro] 外的所有模型都准确添加了所需文本和相关元素。值得注意的是，Qwen-Image 是唯一正确生成所需珐琅彩色玻璃艺术的模型，展示了卓越的材质渲染和指令遵循能力。

物体添加/移除/替换 物体添加、移除和替换是基于指令的图像编辑中最常见的任务之一。在图25中，我们比较了各种模型在具有挑战性的真实世界场景上的性能。除了 GPT Image 1 [High] 经常无法保持整体图像一致性外，所有其他模型在保留未编辑区域方面通常表现良好。在顶部案例中，任务是添加卡通风格的猫和狗，模型必须确保新物体与整体艺术风格匹配。我们观察到 FLUX.1 Kontext [Pro] 在编辑非照片级真实图像时难以保持一致性，而 SeedEdit 3.0 和 Qwen-Image 都产生了一致的结果，与所需卡通风格很好地契合。在中间示例中，涉及从拥挤场景中移除所有人——一个相对复杂的指令——所有模型都准确完成了任务，仅在细节上有所不同。此外，我们注意到不同模型在编辑过程中偶尔会出现放大和缩小效果。

姿态操作 图26展示了不同模型在姿态操作能力上的定性比较。在第一个示例中，只有 FLUX.1 Kontext [Pro] 和 Qwen-Image 能够在姿态编辑期间保留诸如主体发丝等精细细节。在第二个案例中，要求在姿态变化期间保持服装一致性和场景稳定性，Qwen-Image 是唯一同时保持背景和角色不变的模型。值得注意的是，Qwen-Image 从输入中准确推断出该人物穿着开叉裙搭配丝质长裤，并在站立姿态中忠实地展现了丝质长裤。在第三个示例中，Qwen-Image 再次优于其他模型，更好地保留了原始姿态并保持了服装装饰的一致性。

链式编辑 链式编辑是指生成的图像被迭代用作后续编辑步骤的上下文的场景。在图27的第一个案例中，任务要求提取一件服装并描绘其面料细节的特写。我们选择一幅中国传统绘画作为源图像。SeedEdit 3.0 和 FLUX.1 Kontext [Pro] 在第一个提示时即失败，而 GPT Image 1 [High] 和 Qwen-Image 都准确提取了成对的鸟。Qwen-Image 能比 GPT Image 1 [High] 更好地保留精细纹理细节。在第二个案例中，输入图像具有双开口船尾的船。Qwen-Image 和 FLUX.1 Kontext [Pro] 都能在整个链式编辑过程中保留这一结构特征。然而，FLUX.1 Kontext [Pro] 未能按要求添加两艘货船，而 Qwen-Image 成功完成了整个编辑链。

新颖视角合成 图28评估了不同模型的空间推理和新颖视角合成能力。SeedEdit 3.0 和 FLUX.1 Kontext [Pro] 在相同指令下无法很好地执行视角旋转。虽然 GPT Image 1 [High] 在存在清晰主体时可以生成新视角，但它无法泛化到具有复杂多个物体的真实世界场景。只有 Qwen-Image 保持了全局一致性——包括文本保真度和光照结构——在复杂编辑任务中展示了卓越的空间和语义连贯性。

图18：图像生成中长英文渲染能力的比较。此案例要求渲染长段落，只有 Qwen-Image 和 GPT Image 1 [High] 能够如此清晰且几乎完美地渲染长文本。其他模型要么遗漏单词，要么产生重复。
输入提示
图19：图像生成中复杂英文渲染能力的比较。我们展示两个案例以说明模型在真实场景和幻灯片不同位置生成多个英文文本的能力。只有 Qwen-Image 能够遵循复杂提示成功在合理位置渲染文本。
图20：图像生成中中文文本渲染能力的比较。Qwen-Image 准确生成了预期的中文对联。相比之下，GPT Image 1 [High] 和 Seedream 3.0 遗漏或生成了扭曲的字符。而比较中的其他模型无法生成正确的中文对联。
输入提示
图21：图像生成中复杂中文文本渲染的比较：第一个案例显示 Qwen-Image 可以在多个物体上渲染文本，同时保持与真实场景的一致性，例如使文本与每个牌匾的深度和倾斜对齐；第二个案例展示其在玻璃面板中渲染结构化段落文本的能力。Qwen-Image 是唯一能够准确渲染长文本的模型。
输入提示
图22：图像生成中多物体建模的比较：Qwen-Image 在第一个案例中准确渲染了十二生肖动物和材质，在第二个案例中处理了跨多个物体的复杂双语文本。
输入提示
图23：图像生成中空间关系建模能力的比较。我们展示三个案例以展示涉及多人和多物体的交互。我们发现 Qwen-Image 和 GPT Image 1 [High] 都表现出强大的关系理解能力。
图24：文本和材质修改的定性比较。FLUX.1 Kontext [Pro] 和 Qwen-Image 都能够准确修改文本，同时保留原始风格。在下面的示例中，Qwen-Image 是唯一成功呈现珐琅材质的模型。
图25：物体编辑（添加、移除和替换）的定性比较：物体编辑对所有模型来说都是一个相对稳定的能力。Qwen-Image 在未修改区域表现出优越的一致性，并为新生成的对象实现了更好的风格对齐。
图26：姿态操作的定性比较。Qwen-Image 能够准确遵循姿态操作指令，同时保留人物的精细细节（如发丝）并保持背景的一致性（例如主体身后的石阶）。
图27：两种链式编辑示例：提取+放大（顶部）和放置+缩小（底部）。GPT Image 1 [High] 和 Qwen-Image 正确理解了提取操作，但只有 Qwen-Image 准确捕获并放大了服装的纹理。在第二个案例中，Qwen-Image 在整个链式编辑过程中保留了纸船的开放式船尾。
图28：新颖视角合成的定性比较。我们在相同文本提示“向右转90度”下评估了三个逐步更具挑战性的旋转任务：(1) 单人旋转，(2) 人物与背景共同旋转，(3) 真实世界场景。在所有情况下，Qwen-Image 都取得了最准确和一致的结果。虽然其他模型（如 GPT Image 1 [High]）可以处理基本的主体旋转，但它们无法旋转背景或保留场景细节。

6 结论

在本文中，我们介绍了 Qwen-Image，这是 Qwen 系列中的一款图像生成基础模型，在复杂文本渲染和精确图像编辑方面均取得了重大进展。通过构建全面的数据流水线 and 采用渐进式课程学习策略，Qwen-Image 显著提高了在生成图像中渲染复杂文本的能力。此外，我们改进的多任务训练范式和双编码机制显著增强了图像编辑的一致性和质量，有效改善了语义连贯性和视觉保真度。在公开基准上的广泛实验一致证明了 Qwen-Image 在广泛的图像生成和编辑任务中的最先进性能。这些结果不仅凸显了 Qwen-Image 的技术稳健性，也展示了其在真实世界多模态场景中的广泛适用性，标志着大型基础模型发展中的一个重要里程碑。

我们现在转向对 Qwen-Image 更广泛影响和意义的深入讨论：

Qwen-Image 作为“图像生成”模型，在图像生成领域，重新定义了生成建模的优先级。它不仅仅优化照片级真实感或美学质量（“AI 外观”），而是强调文本与图像之间的精确对齐——尤其是在具有挑战性的文本渲染任务中。我们设想，通过加强基础模型中的这种能力，未来的界面可以从纯粹基于语言的 LUI（语言用户界面）演变为视觉-语言 VLUI（视觉-语言用户界面）。当 LLM 难以传达颜色、空间关系或结构布局等视觉属性时，由 Qwen-Image 赋能的 VLUI 可以生成丰富插图、文本集成的图像——实现结构化的视觉解释和有效的知识外化，将复杂思想转化为可理解的多模态表征。

Qwen-Image 作为“图像生成”模型，在图像理解领域，展示了生成框架可以有效执行经典理解任务。例如，在深度估计中，尽管 Qwen-Image 没有超越专用判别模型，但其性能已非常接近。关键的是，传统专家模型依赖判别式理解——直接将输入映射到输出而不建模底层分布——而 Qwen-Image 利用生成式理解：它首先构建视觉内容的整体分布，从中自然推断出深度。这种从直接推断到分布推理的转变，为统一多模态理解开辟了新途径。

Qwen-Image 作为“图像”生成模型，在 3D 和 视频生成领域，展示出超越 2D 图像合成的强大泛化能力。通过图像编辑的视角，我们将 Qwen-Image 应用于新颖视角合成，发现作为通用图像基础模型，它在多个具有挑战性的渲染场景中优于专用 3D 模型，表现出跨视角的卓越一致性。在姿态编辑任务中，尽管存在显著的运动变化，Qwen-Image 在主体身份和背景结构方面保持了显著的连贯性——这是视频生成的基本要求。此外，与大多数依赖图像 VAE 的图像生成方法不同，我们采用视频 VAE 进行视觉表征。虽然这引入了更大的建模复杂性，但它与我们的核心目标一致：构建一个跨不同视觉模态（而非仅静态图像）泛化的基础模型。

Qwen-Image 作为“视觉生成”模型，在理解与生成一体化的背景下，推动了感知与创造无缝融合的愿景。我们认为，实现真正的理解-生成统一依赖于三个基础支柱：(1) 掌握理解，(2) 掌握生成，(3) 掌握它们的协同融合。作为 Qwen 系列中首个致力于视觉生成的工作，Qwen-Image 填补了第二支柱——生成能力——的关键空白，补充了在视觉理解方面表现出色的 Qwen2.5-VL（第一支柱）。它们共同为下一代多模态 AI 奠定了平衡的基础，为视觉-语言全能系统铺平了道路，这些系统不仅能感知和推理，还能生成文本丰富、视觉连贯的图像——其中语言和视觉无缝融合为说明性、可读且语义忠实的视觉输出。

总之，Qwen-Image 不仅仅是一个最先进的图像生成模型——它代表了我们将概念化和构建多模态基础模型方式的范式转变。其贡献超越了技术基准，挑战了社区重新思考生成模型在感知、界面设计和认知建模中的角色。通过强调图像生成中的复杂文本渲染，并通过图像编辑的视角解决深度估计等经典理解任务，Qwen-Image 指向了一个未来：(1) 生成模型不仅生成图像，而且真正理解它们；(2) 理解模型超越被动判别，通过内在生成过程实现理解。随着我们继续扩展和细化此类系统，视觉理解和生成之间的界限将进一步模糊，为真正交互式、直观和智能的多模态智能体铺平道路。

7 作者

核心贡献者⁴：陈飞武, 李嘉豪, 周靖人, 林俊阳, 高凯元, 严坤, 尹胜明, 白帅, 徐潇, 陈毅磊, 陈宇翔, 唐泽成, 张泽凯, 王正毅

贡献者⁵：杨安, 余博文, 程晨, 刘大义, 李德清, 张航, 孟浩, 胡伟, 倪静远, 陈凯, 曹宽, 彭亮, 曲琳, 吴明刚, 王鹏, 余淑婷, 温廷坤, 冯文森, 徐晓晓, 王毅, 张义昌, 朱永强, 吴宇佳, 蔡宇轩, 刘泽南

参考文献

(此处为论文末尾的参考文献列表，按原文保留，不逐一翻译，但已包含在最终输出中)