

# Z-Image：基于单流扩散Transformer的高效图像生成基础模型

Z-Image 团队，阿里巴巴集团

## 摘要

目前，高性能图像生成模型领域主要由专有系统主导，例如 Nano Banana Pro [27] 和 Seedream 4.0 [64]。领先的开源替代方案，包括 Qwen-Image [76]、Hunyuan-Image-3.0 [8] 和 FLUX.2 [35]，其特点是参数量庞大（20B 到 80B），使得它们在消费级硬件上进行推理和微调变得不切实际。为解决这一差距，我们提出了 Z-Image，一个高效的 6B 参数基础生成模型，构建于可扩展单流扩散 Transformer（S3-DiT）架构之上，挑战了“不计成本地扩大规模”的范式。通过系统地优化整个模型生命周期——从精心策划的数据基础设施到精简的训练流程——我们仅用 314K H800 GPU 小时（约 63 万美元）就完成了完整的训练工作流。我们的少步蒸馏方案结合奖励后训练进一步产生了 Z-Image-Turbo，在企业级 H800 GPU 上提供亚秒级推理延迟，同时兼容消费级硬件（<16GB VRAM）。此外，我们的全任务预训练范式还能够高效训练 Z-Image-Edit，这是一个具有出色指令遵循能力的编辑模型。定性和定量实验均表明，我们的模型在各个维度上均达到或超越了领先竞争对手的性能。最值得注意的是，Z-Image 在照片级真实感图像生成和双语文本渲染方面表现出卓越的能力，其效果可与顶级商业模型相媲美，从而证明了以显著降低的计算开销实现最先进结果是可行的。我们公开发布代码、权重和在线演示，以促进可访问、高性价比且最先进的生成模型的发展。

GitHub <https://github.com/Tongyi-MAI/Z-Image> ModelScope 模型 <https://modelscope.cn/models/Tongyi-MAI/Z-Image-Turbo> HuggingFace 模型 <https://huggingface.co/Tongyi-MAI/Z-Image-Turbo> ModelScope 演示  
在线演示（ModelScope） HuggingFace 演示 在线演示（HuggingFace） 图像画廊 在线画廊 离线画廊

图1 | Z-Image-Turbo 在照片级真实感图像生成中的展示。所有相关提示可在附录 A.1 中找到。

图2 | Z-Image-Turbo 在双语文本渲染中的展示。所有相关提示可在附录 A.2 中找到。

图3 | Z-Image-Edit 在各种图像到图像任务中的展示。每个箭头表示从输入图像到输出图像的编辑。所有相关提示可在附录 A.3 中找到。

图4 | Z-Image-Turbo 与当前最先进模型 [58, 76, 8, 27, 35, 64, 21, 26] 的展示比较。Z-Image-Turbo 展现出显著的照片级真实感生成能力。

## 目录

1 引言 8 2 数据基础设施 9 2.1 数据分析引擎 10 2.2 跨模态向量引擎 11 2.3 世界知识拓扑图 12 2.4 主动策展引擎 12 2.5 基于图表示的高效编辑对构建 13 3 图像标注器 14 3.1 包含 OCR 信息的详细标注 15 3.2 包含世界知识的多级标注 15 3.3 图像编辑的差异标注 16 4 模型训练 16 4.1 架构 16 4.2 训练效率优化 17 4.3 预训练 18 4.4 监督微调（SFT） 19 4.5 少步蒸馏 20 4.5.1 解耦 DMD：解决细节和颜色退化问题 21 4.5.2 DMDR：通过 RL 和正则化增强能力 22 4.5.3 结果与分析 22 4.6 基于人类反馈的强化学习（RLHF） 22 4.6.1 奖励标注与训练 22 4.6.2 阶段1：在客观维度上使用 DPO 进行离线对齐 22 4.6.3 阶段2：使用 GRPO 进行在线细化 23 4.7 图像编辑的持续训练 24 4.8 带推理链的提示增强器 24 5 性能评估 25 5.1 人类偏好评估 25 5.1.1 基于 Elo 的人类偏好评估 25 5.1.2 与 Flux 2 dev 的人类偏好比较 27 5.2 定量评估 27 5.2.1 文生图生成 27 5.2.2 基于指令的图像编辑 32 5.3 定

性评估 32 5.3.1 卓越的照片级真实感生成 32 5.3.2 出色的双语文本渲染 32 5.3.3 精确且交互式的局部编辑 33 5.3.4 先进的相机控制能力和空间一致性 33 5.3.5 稳健的多图像身份一致性 33 5.3.6 通过提示增强器增强推理能力和世界知识 34 5.3.7 新兴的多语言和多元文化理解能力 34 5.3.8 新兴的复合指令理解能力 34 6 结论 53 7 作者 53 7.1 核心贡献者 53 7.2 贡献者 53 参考文献 54

A 报告中使用的提示 60 A.1 图1 60 A.2 图2 64 A.3 图3 70

# 1. 引言

近年来，文生图（T2I）生成领域取得了显著进展，从生成初步纹理发展到生成具有复杂语义一致性的照片级真实感图像 [57, 18, 34, 76, 64, 8, 4]。然而，随着这些模型能力的扩展，其开发和可访问性面临着重大障碍。当前格局日益呈现出两种不同趋势：一方面，最先进的商业闭源模型——如 Nano Banana Pro [27] 和 Seedream 4.0 [64]——仍被封闭在“黑盒”中，提供高性能但透明度和可复现性有限。另一方面，开源模型虽然促进了民主化，但往往诉诸于大规模参数扩展——接近数百亿参数（例如，Qwen-Image [76]（20B）、FLUX.2 [35]（32B）和 Hunyuan-Image-3.0 [8]（80B））——给训练和推理都带来了高昂的计算成本。在此背景下，从专有模型蒸馏合成数据已成为以较低成本训练高性能模型的有吸引力的捷径，成为资源受限学术研究的普遍方法 [13, 20]。然而，这种策略存在创建闭环反馈循环的风险，可能导致误差累积和数据同质化，可能阻碍超出教师模型已有能力的新颖视觉能力的出现。

在这项工作中，我们提出了 Z-Image，一个强大的扩散 Transformer 模型，同时挑战了“不计成本地扩大规模”的范式和依赖合成数据蒸馏的做法。我们证明，这两种方法都不是开发顶级图像生成模型所必需的。相反，我们引入了第一个全面的端到端解决方案，系统性地优化了模型生命周期的每个阶段——从数据策展和架构设计到训练策略和推理加速——仅凭纯真实世界数据实现高效、低成本开发，而不蒸馏其他模型的结果。

最值得注意的是，这种方法论上的高效性使我们能够以极低的计算开销完成整个训练工作流。如表1所示，Z-Image 的完整训练流程仅需 314K H800 GPU 小时，按当前市场价格（约每 GPU 小时 2 美元 [37]）计算约为 62.8 万美元。在领先模型通常需要多几个数量级资源的背景下，这一适度投资证明了精心设计可以有效地对抗蛮力扩展。

表1 | Z-Image 的训练成本，假设 H800 的租赁价格约为每 GPU 小时 2 美元。租赁价格参考自 [37]。

| 训练成本 | 低分辨率预训练 | 全任务预训练 | 后训练   | 总计 H800 GPU 小时 |
|------|---------|--------|-------|----------------|
|      | 147.5K  | 142.5K | 24K   | 314K 美         |
| 元    | \$295K  | \$285K | \$48K | \$628K         |

这一成本效率的突破建立在四大支柱之上的系统方法论：

**高效的数据基础设施：**在资源受限的场景中，高效的数据基础设施至关重要；它一方面最大化单位时间内的知识获取速率——从而加速训练效率——同时确立模型能力的上限。为实现这一目标，我们引入了一个由四个协同模块组成的综合数据基础设施：用于多维特征提取的数据分析引擎、用于语义去重和定向检索的跨模态向量引擎、用于结构化概念组织的世界知识拓扑图，以及用于闭环优化的主动策展引擎。通过对数据属性进行细粒度分析和编排训练分布，我们确保“正确的数据”与模型开发的“正确阶段”相匹配。该基础设施最大化真实世界数据流的效用，有效消除因冗余或低质量样本而产生的计算浪费。

**高效的架构：**受大型语言模型中解码器-only 架构的卓越可扩展性 [6] 启发，我们提出了可扩展单流多模态扩散 Transformer（S3-DiT）。与分别处理文本和图像模态的双流架构不同，我们的设计在每一层都促进了密集的跨模态交互。这种高参数效率使 Z-Image 能够在紧凑的 6B 参数量下实现卓越性能，显著降低训练和部署的硬件要求。紧凑的模型规模也部分得益于我们使用提示增强器（PE）来增强模型对复杂世界知识的理解和提示理解能力，进一步缓解了适度参数量带来的局限。此外，这种早期融合 Transformer 架构通过统一处理来自不同模

态的标记——包括文本标记、图像 VAE 标记和图像语义标记——确保了卓越的多功能性，使模型能够在统一框架内无缝处理文生图生成和图生图编辑等多样化任务。

**高效的训练策略：**我们设计了一个由三个战略阶段组成的渐进式训练课程：（1）低分辨率预训练，在固定的  $256^2$  分辨率下引导模型获得基础视觉-语义对齐和合成知识。（2）全任务预训练，一个统一的多任务阶段，整合了任意分辨率生成、文生图合成和图生图操作。通过将重预训练预算分摊到这些多样化能力上，我们消除了对单独的、资源密集型阶段的需求。（3）PE 感知的监督微调，一个联合优化范式，其中 Z-Image 使用 PE 增强的标注进行微调。这确保了提示增强模块与扩散主干之间的无缝协同，而无需额外的 LLM 训练成本，从而最大化 Z-Image 系统的整体开发效率。

**高效的推理：**我们提出了 Z-Image-Turbo，仅需 8 次函数评估（NFE）即可提供卓越的美学对齐和高保真视觉质量。这一性能得益于两项关键创新的协同作用：解耦 DMD [45]，它明确分离了蒸馏过程中质量提升和训练稳定的作用；以及 DMDR [31]，它通过采用分布匹配项作为内在正则化器来整合强化学习。这些技术共同实现了高效生成，而无需在速度和质量之间进行典型权衡。

在这一坚实基础和高效工作流之上，我们成功衍生了两个专门变体以满足不同的应用需求。首先，我们的少样本蒸馏方案结合强化学习产生了 Z-Image-Turbo，一个加速模型，仅需 8 次 NFE 即可实现卓越的美学对齐。它在企业级 GPU 上提供亚秒级推理延迟，并适配消费级硬件的内存约束（<16GB VRAM）。其次，利用全任务预训练的多任务特性，我们推出了 Z-Image-Edit，一个专用于精确指令遵循图像编辑的模型。

广泛的定性和定量实验证明了 Z-Image 系列的优越性。如图1和图2所示，Z-Image 提供了强大的照片级真实感生成能力和卓越的双语（中文/英文）文本渲染能力，其视觉保真度可媲美更大规模的模型。图3展示了 Z-Image-Edit 的能力，突显了其对编辑指令的精确遵循。此外，图4和第5.3节中的定性比较表明，我们的模型可与顶级商业系统相媲美，证明了以显著降低的计算开销实现最先进结果是可行的。我们公开发布代码、权重和在线演示，以促进可访问、高性价比的生成模型的发展。

## 2. 数据基础设施

虽然最先进的文生图模型的卓越能力以大规模训练数据为基础，但在有限计算资源下实现最优性能需要从数据数量到数据效率的范式转变。简单地扩大数据集规模通常会导致收益递减；相反，高效的训练流程需要一种能够最大化每计算单元信息增益的数据基础设施。为此，一个理想的数据系统必须经过严格策展，使其概念上广泛且不冗余，展现稳健的多语言文本-图像对齐，并且关键地，为动态课程学习而结构化，确保数据组成随模型训练阶段而演进。为实现这一目标，我们设计并实现了一个集成的高效数据基础设施。它远非一个静态存储库，而是作为一个动态引擎运行，旨在在固定训练预算内最大化知识获取速率。作为我们流程的基石，该基础设施由四个核心协同模块组成：

- 1. 数据分析引擎：**该模块作为我们数据策略的定量基础。它从原始数据中提取和计算丰富的多维特征，涵盖底层物理属性（例如，图像元数据、清晰度指标）到高层语义属性（例如，异常检测、文本描述）。这些计算出的轮廓不仅用于基本过滤；它们是量化数据复杂性和质量的关键信号，使我们能够以编程方式为动态学习阶段构建课程。
- 2. 跨模态向量引擎：**建立在数十亿嵌入之上，该模块是确保效率和多样性的引擎。它通过大规模语义去重直接支持我们构建非冗余数据集的目标。此外，其跨模态搜索能力对于诊断和修复模型失败至关重要。这使我们能够精确定位并修剪导致特定失败案例的数据，并进行战略性采样以填补概念空白。
- 3. 世界知识拓补图：**这个结构化知识图为整个基础设施提供了语义主干。它通过分层组织知识直接支撑了我们概念广度的目标。至关重要的是，该拓补图作为数据策展的语义指南针。它使我们能够通过遍历图来发现代表性不足的实体，从而识别和填补数据集中的概念空白。此外，它提供了在训练期间跨不同概念精确重新平衡数据分布所需的结构化框架，确保更高效和全面的学习过程。
- 4. 主动策展引擎：**该模块将我们的基础设施运营化为一个真正的动态、自我改进系统。它服务于两个主要的协同功能。首先，它充当前沿探索引擎，采用自动采样来识别模型表现不佳或缺乏知识的概念（“困难

案例”)。其次，它驱动一个闭环数据标注流程。这确保每次迭代不仅以高价值知识扩展数据集的概念广度，而且持续细化数据质量，最大化整个训练过程的学习效率。

这些组件共同构建了一个稳健的数据基础设施，不仅为文生图模型的训练提供燃料，还建立了用于更广泛多模态模型训练的多功能基础设施。利用该系统，我们成功促进了包括标注器、奖励模型和我们的图像编辑模型（即 Z-Image-Edit）在内的各种关键组件的训练。特别地，我们在此基础设施之上专门为 Z-Image-Edit 构建了一个专用数据流程，其细节将在第2.5节中详述。

## 2.1. 数据分析引擎

数据分析引擎旨在系统性地处理大规模未策展数据池，包括大规模内部版权收藏。它为每个图像-文本对计算一套全面的多维特征，从而实现有原则的数据策展。认识到不同数据源展现出独特偏差，我们的引擎支持特定于源的启发式和采样策略，以确保平衡和高质量的训练语料库。分析过程围绕几个关键维度构建：

**图像元数据。**我们首先缓存每个图像的基本属性。这包括像分辨率（宽度和高度）和文件大小这样的基本元数据，便于基于分辨率和宽高比进行高效过滤。同时，我们从图像的字节流计算感知哈希（pHash）。该哈希作为紧凑的视觉指纹，实现快速有效的低级去重以移除相同或近似相同的图像。这些预计算属性共同构成了数据选择的第一层。

**技术质量评估。**图像的技术质量是模型性能的关键决定因素。我们的引擎采用多方面方法来量化和过滤低质量资产：

- **压缩伪影：**为识别过度压缩的图像，我们计算理想未压缩文件大小（由分辨率和位深导出）与实际文件大小的比率。低比率表明由于过度压缩可能导致的质量退化。
- **视觉退化：**我们使用内部训练的质量评估模型对图像的一系列退化因素进行评分，包括色偏、模糊、可感知水印和过度噪声。
- **信息熵：**为最大化训练期间所见有意义内容的密度，我们过滤掉低熵图像。这通过两种互补方法实现：  
(1) 分析边界像素的方差以检测具有大面积均匀颜色背景或边框的图像，以及 (2) 执行瞬态 JPEG 重新编码并使用所得的每像素字节数（BPP）作为图像复杂度的代理。

**语义和美学内容。**除技术质量外，我们还分析图像的高层语义和美学属性：

- **美学质量：**我们利用在专业标注者标签上训练的美学评分模型来量化每个图像的视觉吸引力。
- **AIGC 内容检测：**遵循 Imagen 3 [3] 的发现，我们训练了一个专用分类器来检测和过滤 AI 生成的内容。这一步对于防止模型输出质量和物理真实感退化至关重要。
- **高层语义标记：**我们训练了一个专门的视觉语言模型（VLM）来生成丰富的语义标签。这些标签包括通用对象类别、以人为中心的属性（例如，人数）和文化特定概念，特别关注与中国文化相关的元素。同一模型还通过分配 NSFW 分数执行安全评估，实现语义不相关和不适当内容的统一过滤。

**跨模态一致性和标注。**图像与其文本描述之间的对齐至关重要。

- **文本-图像相关性：**我们使用 CN-CLIP [86] 计算图像与其关联 alt 标注之间的对齐分数。相关性分数低的对被丢弃以确保文本监督的相关性。
- **多级标注：**对于所有选入预训练的图像，我们生成一组结构化的标注，包括简洁标签、短句和详细的长描述。值得注意的是，与先前工作 [21, 64, 76] 使用独立模块进行 OCR 和水印检测不同，我们的方法利用了 VLM 强大的内在能力。我们明确提示 VLM 描述图像中的任何可见文本或水印，将此信息无缝整合到最终标注中。这种统一策略不仅简化了数据处理流程，还丰富了带有关键视觉细节的文本描述，如第3节进一步详述。

## 2.2. 跨模态向量引擎

我们增强了 Stable Diffusion 3 [18] 中提出的去重方法，将其重构为可扩展的基于图的社区检测任务。为解决原始 `range_search` 函数的严重可扩展性瓶颈，我们将其替换为高效的  $k$  近邻 ( $k$ -NN) 搜索函数。我们从  $k$ -NN 距离构建邻近图，然后应用社区检测算法 [68]。该方法在足够大的  $k$  下紧密近似原始算法的输出，同时大幅降低时间复杂度。我们完全 GPU 加速的 [60] 流程在 8 张 H800 上实现了约 8 小时处理 10 亿项目的速率，涵盖索引构建和 100-NN 查询。这种方法不仅通过识别密集簇进行有效去重来确保非冗余数据集，还通过模块度级别提取语义结构，促进细粒度数据平衡。

此外，我们构建了一个利用多模态特征 [86] 结合最先进索引算法 [54] 的高效检索流程。该系统的跨模态搜索能力对于数据策展和主动模型修复都至关重要。除了识别分布空白以进行战略性采样填补概念空白——从而实现有针对性的增强以实现平衡的预训练分布——该引擎在诊断模型失败方面也发挥了重要作用。通过使用失败案例（例如，有问题的生成图像或文本提示）查询系统，我们可以精确定位并修剪导致错误行为的底层数据簇。这一针对数据空白和模型失败的迭代优化过程确保了数据集的鲁棒性，并且对于为复杂下游任务获取高质量候选数据至关重要。

### 2.3. 世界知识拓扑图

我们知识图的构建遵循三个阶段。最初，我们从所有 Wikipedia 实体及其超链接结构构建了一个全面但冗余的知识图。为细化该图，我们采用双管齐下的修剪策略：首先，基于中心性的过滤移除 PageRank [56] 分数异常低的节点，这些节点代表孤立或鲜少被引用的概念；其次，视觉可生成性过滤使用 VLM 丢弃无法连贯可视化的抽象或模糊概念。随后，为解决修剪后图的概念覆盖有限的问题，我们利用大规模内部标注图像数据集进行增强。我们从所有可用标注中提取标签和对应的文本嵌入。受 [71] 启发，我们随后对这些嵌入执行自动分层策略。每个父节点通过使用 VLM 总结其子节点来命名。这不仅用新概念节点补充了图，还将它们组织成结构化的分类树，显著增强了图的结构完整性。在最后阶段，我们执行权重分配和动态扩展以使图与实际应用对齐。这涉及手动策展并对用户提示中的高频概念进行加权，以及主动整合尚未出现在我们数据池中的新颖、热门概念，以保持图的相关性和时效性。

在应用中，该图支撑了我们的语义级平衡采样策略。我们将每个训练标注中的标签映射到知识图中的对应节点。通过考虑标签的 BM25 [62] 分数及其在图中的层级关系（即父子链接），我们为每个数据点计算语义级采样权重。该权重随后指导我们的数据引擎从数据池中进行有原则的、分阶段的采样，实现对训练数据分布的细粒度控制。

图5 | 主动策展引擎概览。该流程通过跨模态嵌入、去重和基于规则的过滤来细化未策展数据，以构建高质量增强数据集。反馈机制利用 Z-Image 模型诊断长尾分布缺陷，动态引导跨模态检索以加强数据收集过程。“松鼠鱼”案例说明了一个经典的长尾挑战：它实际上是一道中国菜的名称，但模型缺乏该菜品的特定概念，可能依赖于组合推理（将“松鼠”和“鱼”组合），导致缺乏领域特定训练数据的错误生成。

### 2.4. 主动策展引擎

为系统性地提升数据质量并解决长尾分布挑战，我们部署了一个全面的主动策展引擎（图5）。该框架整合了一个过滤工具和 Z-Image 作为诊断生成先验。流程首先通过跨模态嵌入和去重处理未策展数据，然后进行基于规则的过滤以消除低质量样本。

为支持 Z-Image 的持续演进，我们建立了一个人在环主动学习循环（图6），其中奖励模型和标注器逐步优化。在该流程中，我们首先使用拓扑图（第2.3节）和初始奖励模型从未标注媒体池中策展一个平衡子集。当前的标注器和奖励模型随后为这些样本分配伪标签。一个混合验证机制——包括人类和 AI 验证器——验证这些提案；被拒绝的样本触发人类专家进行手动修正阶段以细化标注或分数。这些高质量标注数据随后用于重新训练标注器和奖励模型，从而创造整个数据基础设施增强的良性循环。

图6 | 人在环主动学习循环示意图。从媒体池中采样的数据经过概念和质量平衡后分配伪标签。一个双验证器系统（人类和 AI）过滤这些提案：批准的样本直接通过，而被拒绝的案例触发手动修正阶段。该反馈循环迭代地细化标注并更新拓扑图以确保高精度对齐。

图7 | 使用不同策略进行图像编辑的数据构建：(a) 任意排列和组合同一输入图像的不同编辑版本，其中绿色箭头表示由任务特定专家模型构建的对，红色箭头表示通过组合和排列生成的对；(b) 从视频帧中收集具有内在关系的图像；(c) 用于文本编辑的可控文本渲染系统。

收集具有精确指令遵循的编辑对是具有挑战性的，原因是需要保持一致性以及编辑操作的多样性和复杂性。通过如图7所示的可扩展和可控策略，我们从不同来源构建了一个大规模训练语料库。

**与专家模型的混合编辑。**为保证广泛的任务覆盖，我们首先策展一个多样化的编辑任务分类体系，然后利用任务特定的专家模型为每个类别合成高质量训练数据。为提高训练效率，我们构建了混合编辑数据，其中多个编辑动作被整合到一个编辑对中。因此，模型可以仅从单个复合对中增强其在多个编辑任务中的能力，而无需依赖多个对。

**高效的图表示。**对于输入图像，我们合成对应不同编辑任务的多个编辑版本，使我们能够通过任意成对组合 [41] 以零成本进一步扩展训练数据（例如，从一张输入图像及其  $N$  个编辑版本构建  $2\binom{N+1}{2}$  个对）。除了扩展数量，该策略 1) 通过组合两个编辑版本创建混合编辑训练数据以提高训练效率，以及 2) 产生反向对以提高数据质量，即将真实的、未失真的输入图像变换为输出图像。

**来自视频的配对图像。**从预定义任务构建图像编辑对受限于有限的多样性。为克服此问题，我们利用从媒体池中大规模视频帧收集的自然分组图像。这些图像通过共享内在关联性（例如，共同的主体、场景或风格），隐式地定义了彼此之间复杂的编辑关系。在此基础上，我们使用 CN-CLIP [86] 计算图像嵌入之间的余弦相似度来细化数据，允许我们在每个图像组内过滤出具有高语义相关性的对。由此产生的视频帧对数据集具有三个关键优势：1) 高任务多样性，2) 多种编辑类型的内在耦合（例如，人体姿态和背景的不同步变化），以及 3) 卓越的可扩展性。

**文本编辑的渲染。**获取高质量的文本编辑训练数据面临重大挑战，其中自然图像受限于文本内容的稀缺和不平衡，而文本编辑需要具有精确操作标注的配对样本。为解决这些挑战，我们开发了一个可控文本渲染系统 [76]，该系统不仅允许我们精确控制文本内容，还控制其视觉属性，如字体、颜色、大小和位置。这种方法使我们能够系统性地生成大规模配对图像数据集，其中真实编辑指令由渲染操作决定，从而直接克服了上述数据限制。

### 3. 图像标注器

图8 | 生成文生图标注和图像编辑指令的流程。OCR 结果（通过 CoT 获得）和世界知识（来自元信息）被明确包含在标注中。

我们通过整合多种类型的图像标注构建了一个全能图像标注器 Z-Captioner。

图9 | 单图像标注和差异标注示例。左：对于单图像，我们有不同类型和长度的标注，值得注意的是，包含了 OCR 结果（所有文本均以其原始语言转录）和世界知识（在此示例中明确正确地识别了著名景点中国杭州西湖）。右：差异标注逐步组成。

如先前工作 [49] 所示，不同的标注任务可以相互受益，因为它们共享理解和描绘图像的共同目标。我们的模型不仅旨在描述视觉元素，还利用广泛的世界知识来解释图像的语义上下文。世界知识的整合对于下游文生图合成任务尤为关键，因为它使模型能够准确渲染涉及特定命名实体的图像。图8显示了我们的文生图标注和图像编辑指令生成流程。

### 3.1. 包含 OCR 信息的详细标注

首先，我们特别强调，根据我们的实验，在图像标注中明确包含 OCR 信息与生成图像中准确的文本渲染密不可分。因此，我们采用了一种与思维链（CoT）[73] 精神相同的方法，首先明确识别图像中的所有光学字符，然后基于 OCR 结果生成标注。与直接生成涵盖所有内容的标注相比，这有效减少了文本遗漏，特别是对于文本非常长/密集的情况。此外，我们强制 OCR 结果保持原始语言而不进行任何翻译，避免它们被错误地以翻译后的语言渲染。

### 3.2. 包含世界知识的多级标注

我们总共设计了五种不同类型的图像标注，包括长标注、中标注和短标注，以及标签和模拟用户提示。借助第2节中的数据基础设施，我们通过以元信息为条件执行图像标注，将世界知识纳入所有五种类型的标注中。这显著减少了我们的标注器在识别和命名特定实体（如公众人物、著名地标或已知事件）时的幻觉。

具体来说，对于相对较长的标注，我们包含非常密集的图像信息，以使模型能够尽可能准确地学习从文本到图像的映射。这些标注包含上述完整的 OCR 结果，以及主体、对象、背景、位置信息等。

---

我们故意采用平实客观的语言风格，严格将描述限制在图像中可观察到的事实信息。通过抑制主观解释和联想想象，我们的目的是通过消除非必要信息来提高图像生成任务的数据效率。

另一方面，短标注、标签和模拟用户提示旨在使模型适应真实用户提示（通常较短且不具体），以获得更好的用户体验。值得注意的是，大多数模拟用户指令是不完整的提示。它们与短标注的不同之处在于，短标注提供了整个图像的相对完整和全面的描述。相比之下，短模拟提示可能通过仅关注用户感兴趣的特定部分来模拟用户行为，而对图像的其余部分不做任何提及。

### 3.3. 图像编辑的差异标注

差异标注是一个简洁的编辑指令，指定从源图像到目标图像的变换。为生成此指令，我们采用了一个三步 CoT 过程，系统性地分解比较任务 [100]。

1. 步骤1：详细标注。我们首先分别为源图像和目标图像生成全面的、包含 OCR 的标注。此步骤提供了每张图像内容的结构化详细表示。
2. 步骤2：差异分析。模型随后进行对比分析，利用原始图像及其生成的标注，从视觉和文本角度识别所有差异。
3. 步骤3：指令合成。最后，模型基于识别出的差异生成简洁的编辑指令。

这种逐步过程帮助模型通过从理解到比较，最后到生成指令，创建清晰有用的指令。

## 4. 模型训练

本节介绍 Z-Image 和 Z-Image-Edit 的完整训练流程。我们首先介绍可扩展单流扩散 Transformer（S3-DiT）架构（第4.1节）和训练效率优化（第4.2节），然后是多阶段训练过程：预训练（第4.3节）、监督微调（第4.4节）、少步蒸馏（第4.5节）和基于人类反馈的强化学习（第4.6节）。最后，我们描述了图像编辑能力的持续训练策略（第4.7节）和我们带推理增强的提示增强器（第4.8节）。整体训练流程总结在图11中。在图12中，我们展示了 Z-Image 训练过程中的中间生成结果，以展示每个阶段的贡献。

### 4.1. 架构

效率和稳定性是指导 Z-Image 设计的核心目标。为实现这一目标，我们采用轻量级 Qwen3-4B [85] 作为文本编码器，利用其双语能力将复杂指令与视觉内容对齐。对于图像分词，我们选择 Flux VAE [34]，因其经过验证的

重建质量。专门针对编辑任务，我们增加 SigLIP 2 [69] 以从参考图像中捕获抽象视觉语义。受解码器-only 模型扩展成功的启发，我们采用单流多模态扩散 Transformer (MM-DiT) 范式 [18]。在此设置中，文本标记、视觉语义标记和 VAE 图像标记在序列级别拼接以形成统一输入流，与双流方法 [18, 76] 相比最大化参数效率。我们采用 3D 统一 RoPE [58, 78] 来建模此混合序列，其中图像标记在空间维度上扩展，文本标记在时间维度上递增。关键地，对于编辑任务，参考图像标记和目标图像标记被分配对齐的空间 RoPE 坐标，但在时间维度上以单位间隔偏移分离。此外，对参考图像和目标图像应用不同的时间条件值以区分干净图像和带噪图像。

图10 | Z-Image 系列的架构概览。S3-DiT 由单流 FFN 块和单流注意力块组成。它通过轻量级模态特定处理器处理来自不同模态的输入，然后将它们拼接成统一的输入序列。这种模态无关架构最大化跨模态参数复用以确保参数效率，同时为 Z-Image 和 Z-Image-Edit 中的不同输入配置提供灵活兼容性。

如图10所示，我们的 S3-DiT（可扩展单流 DiT）的具体架构从轻量级模态特定处理器开始，每个处理器由两个 Transformer 块组成，用于初始模态对齐。随后，标记进入统一的单流主干。为确保训练稳定性，我们实现 QK-Norm 来调节注意力激活 [32, 50, 24, 53] 和 Sandwich-Norm 来约束每个注意力/FFN 块输入和输出的信号幅度 [16, 99]。对于条件信息注入，输入条件向量被投影为缩放和门控参数，以调制 Attention 和 FFN 层的归一化输入和输出。为减少参数开销，此投影被分解为低秩对：一个共享的、层无关的下投影层，后跟特定于层的上投影层。最后，RMSNorm [91] 被统一用于所有前述归一化操作。

表2 | S3-DiT 的架构配置。

配置|S3-DiT 总参数|6.15B 层数|30 隐藏维度|3840 注意力头数|32 FFN 中间维度|10240 (dr, dh, dw)|(32, 48, 48)

## 4.2. 训练效率优化

为优化训练效率，我们实施了一个针对计算和内存开销的多方面策略。

图11 | Z-Image 和 Z-Image-Edit 的训练流程。低分辨率预训练和全任务预训练阶段为图像生成和编辑任务提供合适的初始化，之后分别进行后处理以产生 Z-Image 和 Z-Image-Edit 模型。

对于分布式训练，我们采用了混合并行化策略。我们对 VAE 和文本编码器应用标准数据并行 (DP)，因为它们保持冻结且内存占用最小。相比之下，对于大型 DiT 模型（其优化器状态和梯度消耗大量内存），我们利用 FSDP2 [96] 来有效地将这些开销分片到 GPU 之间。此外，我们在所有 DiT 层实现了梯度检查点。该技术以可接受的计算成本增加换取显著的内存节省，从而实现更大的批次大小和改进的整体吞吐量。为进一步加速计算和优化内存使用，DiT 块使用 torch.compile（一个即时 (JIT) 编译器[1]）进行编译。

除系统级优化外，我们还解决了由混合分辨率训练引起的低效问题。将具有显著不同序列长度的样本分组到单个批次中通常会导致过度填充，严重阻碍整体训练速度。为缓解此问题，我们设计了一个序列长度感知的批次构建策略。在训练之前，我们根据元数据中记录的分辨率（高度和宽度）估计每个样本的序列长度。采样器随后将具有相似序列长度的样本分组到同一批次中，从而最小化计算浪费。关键地，我们还额外采用了一个动态批次大小机制：为长序列批次分配较小的批次大小以防止内存溢出 (OOM) 错误，而为短序列使用较大的批次大小以避免资源闲置。该方法确保在不同分辨率下最大化硬件利用率。

## 4.3. 预训练

Z-Image 使用流匹配目标 [44, 48] 进行训练，其中带噪输入首先通过高斯噪声  $x_0$  与原始图像  $x_1$  之间的线性插值构建，即  $x_t = t \cdot x_1 + (1 - t) \cdot x_0$ 。模型随后被训练来预测定义它们之间路径的向量场的速度，即  $v_t = x_1 - x_0$ 。训练目标可表述为：

$$\mathcal{L} = \mathbb{E}_{t, x_0, x_1, y} [\|u(x_t, y, t; \theta) - (x_1 - x_0)\|^2], \quad (1)$$



其中  $\theta$  为可学习参数， $y$  为条件嵌入。遵循 SD3 [18]，我们采用 logit-正态噪声采样器将训练过程集中在中间时间步。此外，为考虑多分辨率训练设置中产生的信噪比（SNR）变化，我们采用 Flux [34] 中使用的动态时间偏移策略。这确保噪声水平针对不同图像分辨率进行适当缩放，从而实现更有效的训练。

Z-Image 的预训练大致可分为两个阶段：低分辨率预训练和全任务预训练。

**低分辨率预训练。**该阶段由单个阶段组成，仅在  $256^2$  分辨率下对文生图任务进行。此阶段的主要重点是高效的跨模态对齐和知识注入——使模型具备生成多样化概念、风格和构图的能力，这与传统多阶段训练协议的初始阶段一致。如图1所示，该阶段占我们总预训练计算量的一半以上。这一分配基于这样的理由：模型的大部分基础视觉知识（例如，中文文本渲染）是在此低分辨率训练阶段获得的。

**全任务预训练。**这里的“全任务”表示三个关键方面：

- **任意分辨率训练：**我们设计了一个任意分辨率训练策略，其中原始图像分辨率通过分辨率映射函数映射到预定义的训练分辨率范围。然后模型在具有不同分辨率和宽高比的图像上进行训练。这使得学习跨尺度视觉信息成为可能，缓解了因下采样到固定分辨率而导致的信息损失，并提高了整体数据效率。
- **文生图与图生图联合训练：**我们将图生图任务整合到预训练框架中。通过利用预训练期间可用的大量计算预算，我们可以有效地利用第2.5节讨论的大规模、自然发生的弱对齐图像对。学习自然图像对之间的关系为图像编辑等下游任务提供了强大的初始化。重要的是，我们观察到这种联合预训练方案在文生图任务上没有引入任何明显的性能下降。
- **多级和双语标注训练：**众所周知，高质量标注对于训练文生图模型至关重要 [4]。为确保双语理解和强大的原生提示遵循能力，我们采用 Z-Captioner 生成双语、多级合成标注（包括长、中、短描述，以及标签和模拟用户提示）。此外，与每个图像关联的原始文本元数据以较小的概率被纳入，以进一步增强模型对世界知识的获取。使用不同粒度和不同视角的标注提供了广泛的模式覆盖，这对后续训练阶段有益。此外，对于图生图任务，我们以一定概率随机采样目标图像的标注或成对差异标注，分别对应参考引导的图像生成和多任务图像编辑。

配合我们的数据基础设施，全任务预训练阶段在多个阶段中进行。在最后阶段完成后，模型能够生成宽比高达 1k-1.5k 范围的任意分辨率图像，并能以图像和文本输入为条件进行输出。这为后续 Z-Image 和 Z-Image-Edit 的训练提供了合适的起点。

#### 4.4. 监督微调（SFT）

**通过高质量对齐进行分布收窄。**虽然全任务预训练阶段建立了广泛的世界理解和模式覆盖，但由此产生的分布不可避免地表现出高方差，反映了网络规模数据的噪声特性。因此，监督微调（SFT）的主要目标不仅是修正局部伪影，而是将生成分布收窄到一个聚焦的、高保真的子流形 [67]。此阶段旨在快速收敛到以一致视觉美学和精确指令遵循为特征的固定分布。为实现此目标，我们从未监督的预训练过渡到以数据基础设施过滤的高度策展图像和超级详细的接地气标注为主导的课程。这种严格的监督充当锚点，迫使模型丢弃低质量模式（例如，不稳定的风格化或不一致的渲染）并严格与详细文本描述对齐，将模型从多样性最大化机制转移到质量最大化操作点。

**通过标记重采样进行概念平衡。**收窄分布的一个关键挑战是灾难性遗忘的风险，特别是对于在收敛期间容易被主导模式掩盖的长尾概念。为解决此问题，我们在整个 SFT 阶段强制执行严格的类别平衡。我们采用由第2节中的世界知识拓扑图引导的动态重采样策略。具体来说，我们维护概念上的目标先验，并利用基于 BM25 的检索来即时计算训练样本的稀有度分数。小批量通过上加权代表性不足的概念——如稀有实体或特定艺术风格——同时下加权代表性过高的概念来构建。该机制确保当模型收敛到目标高质量分布时，概念上的边际分布保持均匀，有效保留了预训练模型的语义多样性。

**通过模型合并增强鲁棒性。**尽管进行了平衡训练，但在特定高质量数据集上的 SFT 可能会引入细微偏差或能力之间的权衡（例如，照片真实感与风格灵活性）。为实现帕累托最优解而无需复杂的推理路由，我们采用模型合并 [75, 93] 作为最终细化步骤。我们从同一主干微调多个 SFT 变体，每个变体略微偏向不同的能力维度（例如，严格指令遵循或美学渲染）。然后我们在参数空间中对它们的权重进行线性插值： $\theta_{\text{final}} = \sum_i \alpha_i \theta_i$ 。这种轻量级合并策略有效平滑了损失 landscape，中和了个体偏差，产生了一个在多样化提示下相比任何单个 SFT 检查点表现出更优稳定性和鲁棒性的最终模型。

## 4.5. 少步蒸馏

少步蒸馏阶段的目标是减少我们基础 SFT 模型的推理时间，达到真实世界应用和大规模部署所要求的效率。虽然我们的 6B 基础模型相比更大规模的同类模型代表了效率上的显著飞跃，但推理成本仍然不可忽视。由于扩散模型固有的迭代特性，我们的标准 SFT 模型需要大约 100 次函数评估（NFE）才能使用无分类器引导（CFG）[29] 生成高质量样本。为弥合生成质量与交互延迟之间的差距，我们实施了一个少步蒸馏策略。

从根本上说，蒸馏过程涉及教导学生模型在更少的时间步内沿其采样轨迹模仿教师的去噪动态。核心挑战在于减少该轨迹的固有不确定性，使学生能够将其概率路径“坍缩”为确定性的高效推理过程。因此，实现稳定的少步积分器的关键是精心控制蒸馏过程。我们最初选择了分布匹配蒸馏（DMD）[88, 89] 范式，因其在学术工作中的表现前景。然而，在实践中，我们遇到了持续性伪影，如高频细节丢失和明显的颜色偏移——这些问题已被社区越来越多地记录。这些观察表明需要算法改进。通过对蒸馏机制的深入探索，我们对 DMD 的底层动态获得了新的见解，从而带来了两项关键技术进展：解耦 DMD [45] 和 DMDR [31]。我们建议感兴趣的读者参阅各自的学术论文以获取完整技术细节。以下，我们介绍这些技术在构建 Z-Image-Turbo 中的实际应用。

图13 | 不同蒸馏策略下的少步蒸馏可视化结果：(a) 原始 SFT 模型；(b) 标准 DMD；(c) 解耦 DMD（D-DMD）；(d) D-DMD+DMDR（Z-Image-Turbo）。所提出的方法实现了实时 8 步推理，同时获得了卓越的感知质量和美学吸引力。

### 4.5.1. 解耦 DMD：解决细节和颜色退化问题

我们的调查揭示了一个核心洞察：现有 DMD 方法的有效性不是一个单一现象，而是两个独立协作机制的结果：

- **CFG 增强（CA）**：这作为驱动蒸馏过程的主要引擎，高效地建立学生模型的少步生成能力。尽管其作用主导，但此因素在先前文献中被很大程度上忽视了。
- **分布匹配（DM）**：这主要充当强大的正则化器，确保训练过程的稳定性并消除出现的伪影。

通过识别和解耦这两种机制，我们能够分别研究和优化它们。这一动机促成了解耦 DMD 的发展，一个改进的蒸馏框架，其特点是 CA 和 DM 项专门定制的去噪时间表的解耦应用。

在实践中，解耦 DMD 有效解决了传统 DMD 的痛点，确保了锐利细节保留和颜色保真度。值得注意的是，所得的蒸馏模型不仅在多步教师方面匹配，甚至在照片真实感和视觉冲击力方面超越。

### 4.5.2. DMDR：通过 RL 和正则化增强能力

为进一步推动少步模型的性能边界，我们将强化学习（RL）整合到少步蒸馏过程中。将 RL 应用于生成模型通常面临“奖励黑客”的风险，即模型利用奖励函数生成高分但视觉上无意义的图像。为缓解此问题，通常需要外部正则化。

我们从解耦 DMD 中获得的洞察提供了一个自然的解决方案：由于我们确定分布匹配（DM）项充当高质量正则化器，它可以与 RL 目标有机地结合。这种综合产生了 DMDR（分布匹配蒸馏与强化学习相遇）[31]。在此框架

中，RL 释放学生模型与人类偏好对齐的能力，而 DM 项作为稳健约束，有效防止奖励黑客。这种协同作用使 Z-Image-Turbo 在保持严格生成稳定性的同时实现了卓越的美学对齐和语义忠实度。

### 4.5.3. 结果与分析

我们的解耦 DMD 和 DMDR 蒸馏策略的有效性在图13中可视化。原始 SFT 模型 (a) 设置了高基线但遭受高延迟。标准 DMD (b) 虽然快速，但表现出特征性退化：模糊纹理和偏移色调。我们的解耦 DMD (c) 成功解决了这些伪影，恢复了锐利细节和准确色彩。最后，通过解耦 DMD 和 DMDR 组合细化的 Z-Image-Turbo (d) 代表了速度和质量的最优收敛。它实现了 8 步推理，不仅与 100 步教师无法区分，而且在感知质量和美学吸引力上经常超越。总之，我们的少步蒸馏框架解决了推理速度和视觉保真度之间长期存在的矛盾。

## 4.6. 基于人类反馈的强化学习 (RLHF)

在前述阶段之后，模型已获得强大的基础能力，但在与细微人类偏好对齐方面可能仍存在不一致。为弥合这一差距，我们引入了一个利用基于人类反馈的强化学习 (RLHF) 的综合后训练框架。该框架依赖于一个强大的多维奖励模型，为在线优化提供有针对性的反馈。在这些反馈信号的引导下，我们的方法被结构化两个连续阶段：初始使用直接偏好优化 (DPO) [59] 的离线对齐阶段，随后使用组相对策略优化 (GRPO) [66, 46] 的在线细化阶段。这种两阶段策略使我们能够首先高效地灌输对客观标准的稳健遵循，然后利用奖励模型的细粒度信号来优化更主观的品质。如图14所示，这一全面过程在照片真实感、美学质量和指令遵循方面产生了显著改进。

### 4.6.1. 奖励标注与训练

作为 RLHF 流程中不可或缺且关键的部分，我们的奖励模型旨在沿着三个关键维度评估模型性能：指令遵循能力、AI 内容检测感知和美学质量。奖励模型随后专门针对沿这些轴提供有针对性的反馈进行训练。对于指令遵循，我们执行提示的语法和语义分解为结构化层次结构，包括 (i) 核心主体实体，(ii) 属性规范，(iii) 动作或交互要求，(iv) 空间或构图约束，以及 (v) 风格或渲染条件。在标注期间，人工评分者只需点击模型输出中未满足的元素。然后我们计算满足元素的比例以获得最终指令遵循分数，用作目标奖励。

### 4.6.2. 阶段1：在客观维度上使用 DPO 进行离线对齐

虽然人工策展用于 DPO 的偏好对于捕获人类审美判断是可行的，但将此过程扩展到大型高质量数据集在实践中构成了显著瓶颈。在主观维度（例如，美学、风格）上获取持续信息丰富的偏好对速度慢且需要大量专家标注。为解决此可扩展性挑战并提高标注效率，我们的 DPO 策略转而专注于客观的、可验证的维度。

这些维度，如文本渲染和物体计数，提供清晰的二元正确性标准，非常适合由现代视觉语言模型 (VLM) 进行自动评估。例如，给定需要特定文本的提示，具有准确渲染字符的图像被指定为正样本（“选中”），而具有拼写错误的图像变为负样本（“拒绝”）。我们利用 VLM 以编程方式生成大量此类候选偏好对。随后对此 VLM 生成的数据集进行简化的人工验证和清理过程，确保高保真度。与纯人工手动策展相比，这种 VLM-人工混合流程显著提高了标注吞吐量和一致性。

此外，为平滑学习曲线，我们为 DPO 训练实施了课程学习策略。该过程从低复杂度提示开始（例如，渲染单个单词，生成少量物体），并逐步推进到涉及多个元素、复杂布局或困难风格的更具挑战性的指令。在此过程中，我们还优化了对选择策略。我们观察到 DPO 的收敛对正负样本之间的区分敏感。为最大化训练效率，我们的课程最初优先考虑中等区分的对，并逐步引入展现更大或更细微差异的更具挑战性的对，我们发现这加速了收敛并提高了最终性能。

### 4.6.3. 阶段2：使用 GRPO 进行在线细化

在 DPO 建立的稳健基础之上，第二阶段采用 GRPO 进行在线强化学习。在奖励模型的引导下，此阶段旨在显著增强模型的照片级真实感图像生成能力，同时提高美学质量和细微指令遵循。

在 GRPO 训练循环中，我们通过聚合奖励模型（例如，真实感、美学、指令遵循等）的分数来计算复合优势函数。这种多面反馈机制实现了有针对性的细粒度优化 [84]。通过为生成的不同方面提供不同信号，GRPO 可以同时增强照片级真实感图像生成、美学质量、提高语义准确性并减少不良伪影。这种集成方法被证明比针对单一奖励进行优化要有效得多，使模型能够在不牺牲其他方面的情况下实现能力的整体提升。

---

图14 | 少步蒸馏（FSD，顶部行）和 RLHF（底部行）之间的视觉比较。建立在 FSD 模型的强大基础之上，RLHF 进一步增强了照片真实感、美学质量和指令遵循。

## 4.7. 图像编辑的持续训练

从基础模型开始，图像编辑的持续预训练包括两个阶段，如图10所示。在持续预训练阶段，我们使用构建的编辑对（见第2.5节）以及文生图 SFT 数据训练模型以确保高图像质量。我们首先以  $512^2$  的分辨率训练全部编辑数据几千步以快速适应编辑任务，然后将图像分辨率提高到  $1024^2$  以获得高生成质量。由于图像编辑数据对昂贵且难以获取，其总量显著小于文生图数据且多样性远低。因此，我们建议相对较高的文生图数据比例（例如，文生图:图生图 = 4 : 1）以避免训练期间的性能下降。

在随后的 SFT 阶段，人工构建了一个任务平衡的高质量训练数据子集，以进一步提高模型的整体性能，特别是其指令遵循能力。然而，合成数据（例如，用于文本编辑的渲染文本数据），虽然易于获取且保证在指令遵循方面 100% 准确，但远离真实世界用户输入的分布，因此在最终训练阶段被大幅降采样。

## 4.8. 带推理链的提示增强器

图15 | PE 可视化。我们比较了没有推理的 PE（中间列）和有推理的 PE（右列）之间的生成结果。如顶部行所示，推理链使模型能够将原始坐标解码为特定场景上下文（例如，西湖），而不是简单地在图像上渲染坐标文本。在第二行中，推理模块为“冲泡普洱茶”规划了详细步骤，使模型能够为每个步骤生成具体插图，而不是通用列表。这证明了推理链有效地注入了世界知识，并为复杂的用户提示提供了细粒度的内容规划。

由于模型规模有限（6B 参数），Z-Image 在世界知识、意图理解和复杂推理方面表现出局限性。然而，它作为一个强大的文本解码器，能够将详细提示翻译成逼真的图像。为解决认知差距，我们建议为 Z-Image 配备由系统提示和预训练 VLM 驱动的提示增强器（PE），以提高其推理和知识能力。

与其他方法不同，我们在对齐期间保持大型 VLM 冻结。相反，我们在监督微调（SFT）阶段通过 PE 模型处理所有输入提示（以及 Z-Image-Edit 的输入图像）。这种策略确保 Z-Image 在 SFT 期间与提示增强器有效对齐。此外，我们将结构化推理链确定为注入推理和世界知识的关键因素。如图15所示，没有推理时，给定地理坐标数据时 PE 仅将坐标文本渲染到图像上；有推理时，它推断位置（例如，西湖）以生成正确的场景。类似地，在生成日志风格指令时，缺乏推理导致单调输出，而推理增强模型通过为每个步骤生成具体插图来丰富结果。

# 5. 性能评估

## 5.1. 人类偏好评估

### 5.1.1. 基于 Elo 的人类偏好评估

图16 | Z-Image-Turbo 在 Artificial Analysis AI Arena 提供的文生图 Elo 排名中位列所有评估模型的第 8 位。

为严格评估 Z-Image-Turbo 在生成模型竞争格局中的能力，我们参与了 Artificial Analysis Image Arena 和 Alibaba AI Arena，两个由基于 Elo 的大规模人类判断驱动的公开独立基准测试平台。与经常与人类感知不一致的自动化指标不同，基于 Elo 的评估提供了反映真实人类偏好的排名。

表3 | Alibaba AI Arena 文生图模型的 Elo 排名。Z-Image-Turbo 全球排名第 4，开源模型中排名第 1。

|    |                                |                   |          |         |        |     |   |                        |           |        |         |         |      |     |
|----|--------------------------------|-------------------|----------|---------|--------|-----|---|------------------------|-----------|--------|---------|---------|------|-----|
| 排名 | 模型名称                           | 公司                | 类型       | 95% CI  | Elo 分数 | 胜率  | 1 | Imagen 4 Ultra Preview | 0606      | Google | 闭源      | -16/+16 | 1048 | 48% |
| 2  | gemini-2.5-flash-image-preview | Google            | 闭源       | -16/+14 | 1046   | 47% | 3 | Seedream 4.0           | ByteDance | 闭源     | -17/+16 | 1039    | 46%  | 4   |
| 4  | Z-Image-Turbo                  | Alibaba           | 开源 (6B)  | -15/+17 | 1025   | 45% | 5 | Seedream 3.0           | ByteDance | 闭源     | -15/+19 | 1012    | 41%  | 6   |
| 6  | Qwen-Image                     | Alibaba           | 开源 (20B) | -16/+16 | 1008   | 41% | 7 | GPT Image 1            | OpenAI    | 闭源     | -14/+17 | 986     | 38%  | 8   |
| 8  | FLUX.1 Kontext Pro             | Black Forest Labs | 闭源       | -15/+14 | 950    | 32% | 9 | Ideogram 3.0           | Ideogram  | 闭源     | -15/+16 | 936     | 29%  |     |

5.1.2. 与 Flux 2 dev 的人类偏好比较

为将我们的 Z-Image 模型与最新的最先进开源模型 Flux 2 dev [35] 进行基准测试，我们进行了额外的用户研究。该研究涉及评估由 Z-Image 和 Flux 2 dev 使用用户风格提示生成的 222 个样本集。每个样本由三名独立标注者评估，以确保鲁棒性并减少评估过程中的偏差。结果总结在表4中，显示了 Z-Image 模型的显著优势。具体来说，“G 率”（即好率）达到 46.4%，表明高比例的满意生成。同时，“S 率”（即相同率）为 41.0%。因此，“G+S 率”达到了令人印象深刻的 87.4%，表明 Z-Image 持续从用户提示中产生高质量或可接受的输出。相比之下，“B 率”（即差率）仅为 12.6%。值得注意的是，这些优越的结果是在 Z-Image 仅拥有 Flux 2 dev 参数量的 1/5 的情况下实现的（6B vs. 32B 参数）。

表4 | 用户偏好评估结果：Z-Image 与 Flux 2 dev 比较的 G、S、B 和 G+S 率

|     |     |     |       |       |       |       |       |
|-----|-----|-----|-------|-------|-------|-------|-------|
| G 率 | S 率 | B 率 | G+S 率 | 46.4% | 41.0% | 12.6% | 87.4% |
|-----|-----|-----|-------|-------|-------|-------|-------|

5.2. 定量评估

为全面评估 Z-Image 及其变体（Z-Image-Turbo 和 Z-Image-Edit）的生成和编辑能力，我们在多个权威基准上进行了广泛实验。这些评估涵盖通用图像生成、细粒度指令遵循、中英文文本渲染以及基于指令的图像编辑。

5.2.1. 文生图生成

**CVTG-2K**。为评估我们的模型在文本渲染任务上的性能，我们在 CVTG-2K 基准 [17] 上进行了定量实验。CVTG-2K 是一个专为复杂视觉文本生成设计的专门基准，涵盖具有不同数量文本区域的多样化场景。如表5所示，我们的模型在 CVTG-2K 的所有评估指标上均实现了优越性能。具体来说，Z-Image 获得了最高的平均单词准确率 0.8671，优于竞争基线如 GPT-Image-1 [55]（0.8569）和 Qwen-Image [76]（0.8288）。值得注意的是，我们的模型在不同复杂度下展现了稳健的性能，即使文本区域数量从 2 增加到 5 也保持了一致的准确率。此外，我们的高效变体 Z-Image-Turbo 在所有模型中获得了最高的 CLIP 分数 0.8048，同时保持了有竞争力的文本准确率（平均单词准确率 0.8585），在生成质量和推理效率之间实现了有效平衡。这些结果证明了我们的方法在复杂视觉文本生成场景中的有效性。

表5 | CVTG-2K [17] 上英文文本渲染的定量评估结果。

| 排 模 | NED | CLIPScore | 单词准确率 2区域 3区域 4区域 5区域 平均↑ 1 Z- |        |        |        |        |        |        |        |               |         |
|-----|-----|-----------|--------------------------------|--------|--------|--------|--------|--------|--------|--------|---------------|---------|
| 名 型 |     |           | Image                          | 0.9367 | 0.7969 | 0.9006 | 0.8722 | 0.8652 | 0.8512 | 0.8671 | 2 Z-Image-    |         |
|     |     |           | Turbo                          | 0.9281 | 0.8048 | 0.8872 | 0.8662 | 0.8628 | 0.8347 | 0.8585 | 3 GPT Image 1 |         |
|     |     |           | [High]                         | [55]   | 0.9478 | 0.7982 | 0.8779 | 0.8659 | 0.8731 | 0.8218 | 0.8569        | 4 Qwen- |

|            |        |        |        |        |        |        |        |                   |
|------------|--------|--------|--------|--------|--------|--------|--------|-------------------|
| Image [76] | 0.9116 | 0.8017 | 0.8370 | 0.8364 | 0.8313 | 0.8158 | 0.8288 | 5 TextCrafter     |
| [17]       | 0.8679 | 0.7868 | 0.7628 | 0.7628 | 0.7406 | 0.6977 | 0.7370 | 6 SD3.5 Large     |
| [18]       | 0.8470 | 0.7797 | 0.7293 | 0.6825 | 0.6574 | 0.5940 | 0.6548 | 7 Seedream 3.0    |
| [21]       | 0.8537 | 0.7821 | 0.6282 | 0.5962 | 0.6043 | 0.5610 | 0.5924 | 8 FLUX.1 [dev]    |
| [36]       | 0.6879 | 0.7401 | 0.6089 | 0.5531 | 0.4661 | 0.4316 | 0.4965 | 9 3DIS            |
| [98]       | 0.6505 | 0.7767 | 0.4495 | 0.3959 | 0.3880 | 0.3303 | 0.3813 | 10 RAG-Diffusion  |
| [39]       | 0.4498 | 0.7797 | 0.4388 | 0.3316 | 0.2116 | 0.1910 | 0.2648 | 11 TextDiffuser-2 |
| [10]       | 0.4353 | 0.6765 | 0.5322 | 0.3255 | 0.1787 | 0.0809 | 0.2326 | 12 AnyText        |
| [70]       | 0.4675 | 0.7432 | 0.0513 | 0.1739 | 0.1948 | 0.2249 | 0.1804 |                   |

**LongText-Bench.** 为进一步评估我们的模型渲染较长文本的能力，我们在 LongText-Bench [22] 上评估了其性能，这是一个专注于评估中英文长文本渲染性能的专门基准。如表6所示，我们的模型在两种语言设置下都展现了强大且一致的性能。在 LongText-Bench-EN 上，Z-Image 获得了 0.935 的竞争分数，在所有评估模型中排名第三，而在 LongText-Bench-ZH 上，它获得了 0.936 的分数，位居第二。Z-Image-Turbo 也交出了令人印象深刻的结果，在英文基准上得分为 0.917，在中文基准上得分为 0.926，展示了强大的效率-性能权衡。这种跨两种语言的一致性能凸显了我们的模型稳健的双语文本渲染能力。

表6 | LongText-Bench [22] 上的定量评估结果。

|                          |                    |                   |                     |       |           |                   |       |       |                      |       |       |       |
|--------------------------|--------------------|-------------------|---------------------|-------|-----------|-------------------|-------|-------|----------------------|-------|-------|-------|
| 排名 模型 LongText-Bench-EN↑ | LongText-Bench-ZH↑ | 1 Qwen-Image [76] | 0.943               | 0.946 | 2 Z-Image | 0.935             | 0.936 |       |                      |       |       |       |
| 3 Z-Image-Turbo          | 0.917              | 0.926             | 4 Seedream 3.0 [21] | 0.896 | 0.878     | 5 X-Omni [22]     | 0.900 | 0.814 | 6 GPT Image 1 [High] |       |       |       |
| [55]                     | 0.956              | 0.619             | 7 Kolrs 2.0 [33]    | 0.258 | 0.329     | 8 BAGEL [15]      | 0.373 | 0.310 | 9 OmniGen2 [78]      | 0.561 | 0.059 |       |
| 10 HiDream-I1-Full [7]   | 0.543              | 0.024             | 11 BLIP3-o [11]     | 0.021 | 0.018     | 12 Janus-Pro [14] | 0.019 | 0.006 | 13 FLUX.1 [Dev]      | [36]  | 0.607 | 0.005 |

**OneIG.** 我们利用 OneIG 基准 [9] 来评估细粒度对齐。如表7和表8所示，Z-Image 在英文赛道上获得了最高的总体得分 (0.546)，超越了 Qwen-Image (0.539) 和 GPT Image 1 [High] (0.533)。值得注意的是，Z-Image 在文本渲染可靠性方面设立了新的最先进水平，英文文本得分 0.987，中文文本得分 0.988，显著优于竞争对手。在中文赛道上，Z-Image 总体排名第二 (0.535)，确认了其多语言鲁棒性。此外，我们的蒸馏版本 Z-Image-Turbo 展示了令人印象深刻的效率，在仅比基础模型略有下降的情况下保持了强劲性能。

表7 | OneIG-EN [9] 上的定量评估结果。总体得分是五个维度的平均值。

|                           |           |       |       |       |       |       |                      |                   |       |       |       |       |       |                |       |       |       |       |       |       |
|---------------------------|-----------|-------|-------|-------|-------|-------|----------------------|-------------------|-------|-------|-------|-------|-------|----------------|-------|-------|-------|-------|-------|-------|
| 排名 模型 对齐 文本 推理 风格 多样性 总体↑ | 1 Z-Image | 0.881 | 0.987 | 0.280 | 0.387 | 0.194 | 0.546                | 2 Qwen-Image      |       |       |       |       |       |                |       |       |       |       |       |       |
| [76]                      | 0.882     | 0.891 | 0.306 | 0.418 | 0.197 | 0.539 | 3 GPT Image 1 [High] | [55]              | 0.851 | 0.857 | 0.345 | 0.462 | 0.151 | 0.533          |       |       |       |       |       |       |
| 4 Seedream 3.0 [21]       | 0.818     | 0.865 | 0.275 | 0.413 | 0.277 | 0.530 | 5 Z-Image-Turbo      | 0.840             | 0.994 | 0.298 | 0.368 | 0.139 | 0.528 |                |       |       |       |       |       |       |
| 6 Imagen 4 [26]           | 0.857     | 0.805 | 0.338 | 0.377 | 0.199 | 0.515 | 7 Recraft V3 [61]    | 0.810             | 0.795 | 0.323 | 0.378 | 0.205 | 0.502 |                |       |       |       |       |       |       |
| 8 HiDream-I1-Full [7]     | 0.829     | 0.707 | 0.317 | 0.347 | 0.186 | 0.477 | 9 OmniGen2 [78]      | 0.804             | 0.680 | 0.271 | 0.377 | 0.242 | 0.475 |                |       |       |       |       |       |       |
| 10 SD3.5 Large [18]       | 0.809     | 0.629 | 0.294 | 0.353 | 0.225 | 0.462 | 11 CogView4 [97]     | 0.786             | 0.641 | 0.246 | 0.353 | 0.205 | 0.446 |                |       |       |       |       |       |       |
| 12 FLUX.1 [Dev]           | [36]      | 0.786 | 0.523 | 0.253 | 0.368 | 0.238 | 0.434                | 13 Kolrs 2.0 [33] | 0.820 | 0.427 | 0.262 | 0.360 | 0.300 | 0.434          |       |       |       |       |       |       |
| 14 Imagen 3 [3]           | 0.843     | 0.343 | 0.313 | 0.359 | 0.188 | 0.409 | 15 BAGEL [15]        | 0.769             | 0.244 | 0.173 | 0.367 | 0.251 | 0.361 |                |       |       |       |       |       |       |
| 16 Lumina-Image 2.0 [58]  | 0.819     | 0.106 | 0.270 | 0.354 | 0.216 | 0.353 | 17 SANA-1.5-4.8B     | [81]              | 0.765 | 0.069 | 0.217 | 0.401 | 0.216 | 0.334          |       |       |       |       |       |       |
| 18 SANA-1.5-1.6B [81]     | 0.762     | 0.054 | 0.209 | 0.387 | 0.222 | 0.327 | 19 BAGEL+CoT [15]    | 0.793             | 0.020 | 0.206 | 0.390 | 0.209 | 0.324 | 20 SD 1.5 [63] | 0.565 | 0.010 | 0.207 | 0.383 | 0.429 | 0.319 |
| 21 SDXL [57]              | 0.688     | 0.029 | 0.237 | 0.332 | 0.296 | 0.316 | 22 Show-o2-7B [83]   | 0.817             | 0.002 | 0.226 | 0.317 | 0.177 | 0.308 |                |       |       |       |       |       |       |
| 23 BLIP3-o [11]           | 0.711     | 0.013 | 0.223 | 0.361 | 0.229 | 0.307 | 24 Show-o2-1.5B [83] | 0.798             | 0.002 | 0.219 | 0.317 | 0.186 | 0.304 |                |       |       |       |       |       |       |
| 25 Janus-Pro [14]         | 0.553     | 0.001 | 0.139 | 0.276 | 0.365 | 0.267 |                      |                   |       |       |       |       |       |                |       |       |       |       |       |       |

表8 | OneIG-ZH [9] 上的定量评估结果。总体得分是五个维度的平均值。

| 排名 | 模型                      | 对齐    | 文本    | 推理    | 风格    | 多样性   | 总体    |
|----|-------------------------|-------|-------|-------|-------|-------|-------|
| 1  | Qwen-Image [76]         | 0.825 | 0.963 | 0.267 | 0.405 | 0.279 | 0.548 |
| 2  | Z-Image                 | 0.793 | 0.988 | 0.266 | 0.386 | 0.243 | 0.535 |
| 3  | Seedream 3.0 [21]       | 0.793 | 0.928 | 0.281 | 0.397 | 0.243 | 0.528 |
| 4  | Z-Image-Turbo           | 0.782 | 0.982 | 0.276 | 0.361 | 0.134 | 0.507 |
| 5  | GPT Image 1 [High] [55] | 0.812 | 0.650 | 0.300 | 0.449 | 0.159 | 0.474 |
| 6  | Kolors 2.0 [33]         | 0.738 | 0.502 | 0.226 | 0.331 | 0.333 | 0.426 |
| 7  | BAGEL [15]              | 0.672 | 0.365 | 0.186 | 0.357 | 0.268 | 0.370 |
| 8  | Cogview4 [97]           | 0.700 | 0.193 | 0.236 | 0.348 | 0.214 | 0.338 |
| 9  | HiDream-I1-Full [7]     | 0.620 | 0.205 | 0.256 | 0.304 | 0.300 | 0.337 |
| 10 | Lumina-Image 2.0 [58]   | 0.731 | 0.136 | 0.221 | 0.343 | 0.240 | 0.334 |
| 11 | BAGEL+CoT [15]          | 0.719 | 0.127 | 0.219 | 0.385 | 0.197 | 0.329 |
| 12 | BLIP3-o [11]            | 0.608 | 0.092 | 0.213 | 0.369 | 0.233 | 0.303 |
| 13 | Janus-Pro [14]          | 0.324 | 0.148 | 0.104 | 0.264 | 0.358 | 0.240 |

**GenEval**。如表9所示，我们使用 GenEval [23] 评估了以对象为中心的生成能力。Z-Image 取得了 0.84 的总体得分，与 Seedream 3.0 [21] 和 GPT Image 1 [High] [55] 并列第二，仅次于 Qwen-Image [76] (0.87)。值得注意的是，Z-Image-Turbo 以 0.82 的总体得分交付了极具竞争力的性能，与基础模型仅相差 2 个百分点。这些结果表明我们的模型拥有生成准确和清晰实体的稳健能力。

**DPG-Bench**。表10展示了在 DPG-Bench 基准 [30] 上的比较，该基准评估密集提示中的提示遵循能力。Z-Image 实现了强劲的全局性能，以 88.14 的得分总体排名第三，紧追 Seedream 3.0 [21] 和 Qwen-Image [76]。值得注意的是，我们的模型在属性维度 (93.16) 上展现出稳健的性能，超越了领先的 Qwen-Image (92.02) 和 Seedream 3.0 (91.36)。此外，我们的 8 步蒸馏模型 (Z-Image-Turbo) 在实现高效率的同时保持了竞争力的性能。

表9 | GenEval [23] 上的定量评估结果。

| 排名 | 模型                      | 单物体  | 双物体  | 计数   | 颜色   | 位置   | 属性绑定 | 总体   |
|----|-------------------------|------|------|------|------|------|------|------|
| 1  | Qwen-Image [76]         | 0.99 | 0.92 | 0.89 | 0.88 | 0.76 | 0.77 | 0.87 |
| 2  | Z-Image                 | 1.00 | 0.94 | 0.78 | 0.93 | 0.62 | 0.77 | 0.84 |
| 2  | Seedream 3.0 [21]       | 0.99 | 0.96 | 0.91 | 0.93 | 0.47 | 0.80 | 0.84 |
| 2  | GPT Image 1 [High] [55] | 0.99 | 0.92 | 0.85 | 0.92 | 0.75 | 0.61 | 0.84 |
| 5  | HiDream-I1-Full [7]     | 1.00 | 0.98 | 0.79 | 0.91 | 0.60 | 0.72 | 0.83 |
| 6  | Z-Image-Turbo           | 1.00 | 0.95 | 0.77 | 0.89 | 0.65 | 0.68 | 0.82 |
| 7  | Janus-Pro-7B [14]       | 0.99 | 0.89 | 0.59 | 0.90 | 0.79 | 0.66 | 0.80 |
| 8  | Lumina-Image 2.0 [58]   | 0.87 | 0.67 | --   | 0.62 | 0.73 |      |      |
| 9  | SD3.5-Large [18]        | 0.98 | 0.89 | 0.73 | 0.83 | 0.34 | 0.47 | 0.71 |
| 10 | FLUX.1 [Dev] [36]       | 0.98 | 0.81 | 0.74 | 0.79 | 0.22 | 0.45 | 0.66 |
| 11 | JanusFlow [51]          | 0.97 | 0.59 | 0.45 | 0.83 | 0.53 | 0.42 | 0.63 |
| 12 | SD3 Medium [18]         | 0.98 | 0.74 | 0.63 | 0.67 | 0.34 | 0.36 | 0.62 |
| 13 | Emu3-Gen [72]           | 0.98 | 0.71 | 0.34 | 0.81 | 0.17 | 0.21 | 0.54 |
| 14 | Show-o [82]             | 0.95 | 0.52 | 0.49 | 0.82 | 0.11 | 0.28 | 0.53 |
| 15 | PixArt-α [13]           | 0.98 | 0.50 | 0.44 | 0.80 | 0.08 | 0.07 | 0.48 |

表10 | DPG [30] 上的定量评估结果。

| 排名 | 模型                      | 全局    | 实体    | 属性    | 关系    | 其他    | 总体    |
|----|-------------------------|-------|-------|-------|-------|-------|-------|
| 1  | Qwen-Image [76]         | 91.32 | 91.56 | 92.02 | 94.31 | 92.73 | 88.32 |
| 2  | Seedream 3.0 [21]       | 94.31 | 92.65 | 91.36 | 92.78 | 88.24 | 88.27 |
| 3  | Z-Image                 | 93.39 | 91.22 | 93.16 | 92.22 | 91.52 | 88.14 |
| 4  | Lumina-Image 2.0 [58]   | 91.97 | 90.20 | 94.85 | --    | 87.20 | 5     |
| 5  | HiDream-I1-Full [7]     | 76.44 | 90.22 | 89.48 | 93.74 | 91.83 | 85.89 |
| 6  | GPT Image 1 [High] [55] | 88.89 | 88.94 | 89.84 | 92.63 | 90.96 | 85.15 |
| 7  | Z-Image-Turbo           | 91.29 | 89.59 | 90.14 | 92.16 | 88.68 | 84.86 |
| 8  | Janus-Pro-7B [14]       | 86.90 | 88.90 | 89.40 | 89.32 | 89.48 | 84.19 |
| 9  | SD3 Medium [18]         | 87.90 | 91.01 | 88.83 | 80.70 | 88.68 | 84.08 |
| 10 | FLUX.1 [Dev] [36]       | 74.35 | 90.00 | 88.96 | 90.87 | 88.33 | 83.84 |
| 11 | DALL-E 3 [4]            | 90.97 | 89.61 | 88.39 | 90.58 | 89.83 | 83.50 |
| 12 | Janus-Pro-1B [14]       | 87.58 | 88.63 | 88.17 | 88.98 | 88.30 | 82.63 |
| 13 | Emu3-Gen [72]           | 85.21 | 86.68 | 86.84 | 90.22 | 83.15 | 80.60 |
| 14 | PixArt-Σ [13]           | 86.89 | 82.89 | 88.94 | 86.59 | 87.68 | 80.54 |
| 15 | Janus [77]              | 82.33 | 87.38 | 87.70 | 85.46 | 86.41 | 79.68 |
| 16 | Hunyuan-DiT [40]        | 84.59 | 80.59 | 88.01 | 74.36 | 86.41 | 78.87 |
| 17 | Playground v2.5 [38]    | 83.06 | 82.59 | 81.20 | 84.08 | 83.50 | 75.47 |
| 18 | SDXL [57]               | 83.27 | 82.43 | 80.91 | 86.76 | 80.41 | 74.65 |
| 19 | Lumina-Next [99]        | 82.82 | 88.65 | 86.44 | 80.53 | 81.82 | 74.63 |
| 20 | PixArt-α [13]           | 74.97 | 79.32 | 78.60 | 82.57 | 76.96 | 71.11 |
| 21 | SD1.5 [63]              | 74.63 | 74.23 | 75.39 | 73.49 | 67.81 | 63.18 |

**TIIF**。表11详细展示了在 TIIF 基准 testmini [74] 上的性能，该系统性地评估指令遵循能力。Z-Image 和 Z-Image-Turbo 分别排名第 4 和第 5。这些结果表明，基础和蒸馏版本都具备在多样化类别中解释和执行复杂用户指令的卓越能力。

**PRISM-Bench**。我们在 PRISM-Bench [19] 上评估了我们的模型，这是一个由 VLM 驱动的基准，评估跨七个赛道的推理和美学。在英文赛道（表12）上，Z-Image-Turbo 排名第 3（77.4），优于基础模型和 Qwen-Image，突显了其卓越的效率和生成质量。在中文赛道（表13）上，Z-Image 排名第 2（75.3），在文本渲染（83.4）和构图（88.6）方面表现卓越，展示了稳健的多语言性能。

表11 | TIIF Bench testmini [74] 上的定量评估结果。

| 排<br>名                              | 模<br>型 | 总<br>体 | 基<br>础<br>遵<br>循 | 高<br>级<br>遵<br>循 | 设计者 |
|-------------------------------------|--------|--------|------------------|------------------|-----|
| （注：表11内容在PDF中为复杂跨页表格，此处略去详细数值，保留结构） |        |        |                  |                  |     |

表15 | GEdit-Bench [47] 上的定量评估结果。

| 排<br>名 | 模<br>型               | GEdit-<br>Bench-<br>EN | GEdit-Bench-CN G_SC G_PQ G_O G_SC G_PQ G_O |      |      |      |      |                        |                         |                          |      |      |      |      |                      |      |      |      |      |      |      |      |
|--------|----------------------|------------------------|--------------------------------------------|------|------|------|------|------------------------|-------------------------|--------------------------|------|------|------|------|----------------------|------|------|------|------|------|------|------|
|        |                      |                        | 1 UniWorld-V2 [42]                         | 8.39 | 8.02 | 7.83 | ---  | ---                    | ---                     | 2 Qwen-Image-Edit [2509] | 7.6  | 8.15 | 7.86 | 7.54 | 8.08                 | 7.89 | 7.54 |      |      |      |      |      |
| 3      | Z-Image-Edit         | 8.11                   | 7.72                                       | 7.57 | 8.03 | 7.80 | 7.54 | 4 Qwen-Image-Edit [76] | 8.00                    | 7.86                     | 7.56 | 7.82 | 7.79 | 7.52 | 5 GPT-Image-1 [High] | 55   | 7.85 | 7.62 | 7.53 | 7.67 | 7.56 | 7.30 |
| 6      | Step1X-Edit [47]     | 7.66                   | 7.35                                       | 6.97 | 7.20 | 6.87 | 6.86 | 7 BAGEL [15]           | 7.36                    | 6.83                     | 6.52 | 7.34 | 6.85 | 6.50 | 8 OmniGen2 [78]      | 7.16 | 6.77 | 6.41 | ---  | ---  | ---  | ---  |
| 9      | FLUX.1 Kontext [Pro] | 36                     | 7.02                                       | 7.60 | 6.56 | 1.11 | 7.36 | 1.23                   | 10 FLUX.1 Kontext [Dev] | 36                       | 6.52 | 7.38 | 6.00 | ---  | ---                  | ---  | ---  | ---  | ---  | ---  | ---  |      |
| 11     | OmniGen [80]         | 5.96                   | 5.89                                       | 5.06 | ---  | ---  | ---  | ---                    | 12 UniWorld-V1 [43]     | 4.93                     | 7.43 | 4.85 | ---  | ---  | ---                  | ---  | ---  | ---  | ---  | ---  | ---  |      |
| 13     | MagicBrush [92]      | 4.68                   | 5.66                                       | 4.52 | ---  | ---  | ---  | ---                    | 14 Instruct-Pix2Pix [5] | 3.58                     | 5.49 | 3.68 | ---  | ---  | ---                  | ---  | ---  | ---  | ---  | ---  | ---  |      |
| 15     | AnyEdit [90]         | 3.18                   | 5.82                                       | 3.21 | ---  | ---  | ---  | ---                    |                         |                          |      |      |      |      |                      |      |      |      |      |      |      |      |

5.2.2. 基于指令的图像编辑

**ImgEdit**。表14展示了 Z-Image-Edit 在 ImgEdit 基准 [87] 上的评估，其中度量结合了指令完成度和视觉质量。在 9 个常见编辑任务中，Z-Image-Edit 展现了与领先模型竞争的编辑性能，特别是在物体添加和提取方面。

**GEdit**。我们还在 GEdit-Bench [47] 上评估了 Z-Image-Edit，该基准评估视觉自然度（G\_PQ）和双语指令遵循（G\_SC）。GEdit-Bench-EN 和 GEdit-Bench-CN 分别在评估中采用英文和中文指令。如表15所示，Z-Image-Edit 排名第 3，展示了稳健的双语编辑能力。

5.3. 定性评估



为进一步展示 Z-Image 的视觉生成能力，我们首先与最先进的开源模型（Lumina-Image 2.0 [58]、Qwen-Image [76]、HunyuanImage 3.0 [8] 和 FLUX 2 dev [35]）和闭源模型（Imagen 4 Ultra [26]、Seedream 4.0 [64] 和 Nano Banana Pro [27]）进行定性比较。然后，我们评估 Z-Image-Edit 在四个核心维度上的表现：复杂指令遵循、局部交互编辑、相机视角控制和多图像身份一致性。最后，我们展示了由提示增强器实现的模型增强推理能力，以及其新兴的多语言和多元文化理解能力。

### 5.3.1. 卓越的照片级真实感生成

如图18和图19所示，Z-Image-Turbo 展现了出色的人物特写生成能力（例如，男性面部的皮肤细节和女孩的泪珠）。当被要求生成单人的多表情肖像时（图20），Z-Image-Turbo 可以生成更具美学吸引力和更真实表情的图像，而 Qwen-Image、HunyuanImage3.0、FLUX 2 dev 和 Seedream 4.0 有时会生成夸张和不真实的表情，从而缺乏真实感和美感。此外，当生成手机拍摄的场景时（图21和图22），Z-Image-Turbo 在人物和背景的真实感以及布局和姿态的美学吸引力方面展示了强大的性能，而 Qwen-Image、HunyuanImage3.0 和 FLUX 2 dev 会生成不真实的内容（例如，在大雨中完全未浸湿的衣物）。

### 5.3.2. 出色的双语文本渲染

图23和图24展示了中文和英文文本渲染的定性比较。如图23和图24所示，Z-Image-Turbo 在保持其他部分（例如，图23中面部的真实感和图24中场景的布局）的美学吸引力和真实感的同时，准确渲染了所需文本。值得注意的是，这与领先的闭源模型 Nano Banana Pro 相当，并超越其他候选模型。在海报设计中的文本渲染中（图25和图26），Z-Image-Turbo 不仅呈现了正确的文本渲染，还设计了更具美学吸引力和真实感的海报。例如，如图26所示，Qwen-Image、HunyuanImage3.0、FLUX 2 dev 和 Imagen 4 Ultra 在渲染非常小的字符时出错，Seedream4.0 和 Nano Banana Pro 出现重复渲染文本的错误，而 Z-Image-Turbo 获得了具有正确渲染文本和令人满意设计的海报。

### 5.3.3. 精确且交互式的局部编辑

Z-Image-Edit 在局部图像操作中表现出极其令人印象深刻的性能，支持特定元素的无缝添加、移除和替换，如图27所示。以静物设置为中心参考，我们的模型可以轻松执行局部物体替换，例如将蓝色围巾改为橙色，将木桌替换为大理石，或将玻璃瓶内的液体替换为牛奶。它还执行完美的物体移除（例如，移除所有红色花朵或移除包的银色配件）和逼真的添加（例如，将向日葵插入花瓶或将复古时钟放置在背景墙上）。

此外，Z-Image-Edit 支持由边界框和用户涂鸦引导的多模态交互编辑。如红色标记的缩略图所示，通过将修改映射到明确的空间坐标和草图笔触，用户可以直观地指导局部更改，例如通过红色边界框将特定的红色花朵替换为白色郁金香，或通过红色涂鸦添加紫色气球。在整个编辑过程中，我们的模型保持了卓越的“零接缝”融合和阴影协调，自动重新计算物理逼真的阴影、反射和光折射（例如，玻璃容器内的牛奶）以完美匹配原始环境光。

### 5.3.4. 先进的相机控制能力和空间一致性

Z-Image-Edit 展示了卓越的相机和视角控制能力，在剧烈的视角变化下保持严格的空间和几何一致性。如图28所示，我们的模型可以在连续相机轨迹下精确生成以物体为中心的场景（第1行）和复杂室内环境（第2行）的新颖视角。这包括广角水平偏航旋转（范围从  $-135^\circ$  到  $135^\circ$ ，甚至完整的  $180^\circ$  反向视角）以及垂直俯仰调整（从  $-75^\circ$  到  $75^\circ$ ）。

为验证生成视角序列的严格几何保真度，我们使用 VGGT 流程从生成的多视图图像重建 3D 稀疏点云并估计相机视锥。成功的 3D 重建和准确的相机对齐表明 Z-Image-Edit 以高空间完整性动态适应物体尺度、深度线索和背景视差，避免结构失真或纹理扭曲。

### 5.3.5. 稳健的多图像身份一致性

Z-Image-Edit 通过从参考图像提取稳健的身份嵌入并将其注入目标布局，克服了在风格和背景变换中保持角色身份（ID）的长期挑战。如图29所示，我们的模型以卓越的保真度处理了多样化的多图像合成范式。

具体来说，在背景移植（第1行）中，图1中身着冬装的角色被无缝融合到图2的风景湖景环境中。在风格和元素迁移（第2行）中，模型将写实肖像重绘为传统中国水墨画风格，同时精确提取和放置局部红色签名印章。此外，Z-Image-Edit 支持多主体合成（第3行），将两个独立身份统一到和谐的校园场景中，搭配匹配的毕业礼服。最后，它促进了复杂的主体-对象交互（第4行），使角色能够自然地坐在公园长椅上，同时持有第二张图像中的特定参考毛绒玩具。

### 5.3.6. 通过提示增强器增强推理能力和世界知识

如图15和图30-31所示，我们的提示增强器利用结构化推理链——包括核心主体分析、问题解决/世界知识注入、美学增强和全面描述——为模型配备逻辑推理和世界知识能力。这使模型能够处理多样化任务，从解决复杂逻辑难题（例如，鸡兔同笼问题）和解释用户意图（例如，可视化古典诗歌或从坐标推断场景）到执行文本渲染和问答。

在图像编辑的背景下，提示增强器对于解决模糊意图、注入世界知识和实现物理推理也至关重要，如图32-33所示。例如，在图32中，模糊的指令“设计一张海报”在没有 PE 的情况下产生了混乱、格式不佳的布局。提示增强器通过生成结构化计划来解决此问题，将产品移植到具有主题照明和干净商业排版的专业户外场景中。类似地，在图33中，没有 PE 的编辑缺乏泡茶的物理推理，未能展示水与茶包之间的互动。提示增强器通过引入倒水的茶壶、逼真的流体动力学和升起的蒸汽来纠正此问题。

### 5.3.7. 新兴的多语言和多元文化理解能力

在用双语数据训练后，我们惊讶地发现 Z-Image 已初步涌现出处理多语言输入的能力。如图34所示，Z-Image 不仅能理解多种语言的提示，还能生成与当地文化和地标相符的图像。

### 5.3.8. 新兴的复合指令理解能力

经过编辑训练后，Z-Image-Edit 涌现出更强的能力来理解和遵循以自然语言表达的复合指令。如图35所示，编辑结果反映了对完整指令更忠实的解释，而非孤立的属性更改。具体来说，前两行显示模型可以同时满足多个依赖的编辑意图——例如，为黑白照片着色同时将角色姿态转变为比心手势（第1行），或移除飞溅面粉等动态元素同时替换桌面物体和改变服装颜色（第2行）。

此外，Z-Image-Edit 展现出新兴的指令一致的身份保持和局部文本渲染能力。如底部两行所示，它可以将特写肖像移植到雪景背景中，同时引入新元素（萨摩耶和花朵）并严格保持面部身份（第3行）。它还与主体自然互动和视角匹配的方式在插入的屏幕上渲染风格化文本“Z-Image”（第4行）。

---

图18 | 特写肖像生成的比较，表明 Z-Image 在角色情感和皮肤纹理渲染方面表现出强大的能力。建议放大查看细微表情和皮肤纹理。

---

图19 | 特写肖像生成的比较，表明 Z-Image 在角色情感和皮肤纹理渲染方面表现出强大的能力。建议放大查看细微表情和皮肤纹理。

---

图20 | 复杂特写肖像生成的比较，表明 Z-Image-Turbo 在渲染角色表情和皮肤纹理以及生成美学图像方面具有强大的能力。建议放大查看细微表情。

---

图21 | 场景拍摄的比较，表明 Z-Image-Turbo 在人物和背景的真实感以及布局和姿态的美学吸引力方面展示了强大的性能。建议放大查看衣物和头发的纹理。

---

图22 | 场景拍摄的比较，表明 Z-Image-Turbo 在人物和背景的真实感以及布局和姿态的美学吸引力方面展示了强大的性能。建议放大查看细节。

---

图23 | 复杂中文文本渲染的比较。它显示只有 Z-Image-Turbo 和 Nano Banana Pro 能够准确生成预期的中文对联。建议放大查看渲染文本的正确性和人物的真实感。

---

图24 | 复杂英文文本渲染的比较。它显示只有 Z-Image-Turbo 和 Nano Banana Pro 能够准确生成预期的英文对联。建议放大查看渲染文本的正确性和场景的布局。

---

图25 | 海报设计中中文文本渲染的比较。Z-Image-Turbo 不仅呈现了正确的文本渲染，还设计了更具美学吸引力和真实感的海报。建议放大查看渲染文本的正确性和食物的保真度。

---

图26 | 海报设计中英文文本渲染的比较。只有 Z-Image-Turbo 呈现了正确的文本渲染，并配以令人愉悦和真实的海报。建议放大查看渲染文本的正确性和海报的细节。

---

图27 | Z-Image-Edit 的局部图像操作结果。以中央参考静物图像为中心辐射，十个不同的编辑结果展示了我们的模型在无缝添加、移除和替换方面的能力。模型自然支持交互式输入，如边界框（红色框）和用户涂鸦（红色曲线），同时保持严格的物理一致性，包括逼真的光照、阴影和玻璃折射。

---

图28 | Z-Image-Edit 的多视角相机控制和 3D 重建验证。我们展示了跨不同偏航和俯仰角度的视角控制生成。通过 VGGT 的 3D 重建验证了我们输出的几何一致性和精确空间对齐。

---

图29 | Z-Image-Edit 的多图像编辑和身份保持合成。从左到右：提示、主体来源（图1）、参考来源（图2）和我们的编辑结果。Z-Image-Edit 在背景交换（第1行）、风格迁移（第2行）、多主体合成（第3行）和对象交互（第4行）中实现了稳健的身份保持。

---

图30 | 逻辑推理提示增强器的展示。

---

图31 | 世界知识注入提示增强器的展示。给定诗题《登科后》，基线（左）缺乏文化背景。我们的方法（右）利用 LLM 先验检索特定历史细节（例如，奔腾的马、红色官袍）和著名对联“春风得意马蹄疾，一日看尽长安花。”推理模块（中）将这些文学语义转化为视觉线索，确保具有精确文本转录的文化忠实渲染。

---

图32 | 提示增强器（PE）在商业产品海报生成中的影响。左：输入图像（保温瓶）。中：没有 PE 的输出混乱且缺乏专业构图。右：通过 PE 的结构化推理和布局规划，输出成为精致的产品海报，具有主题环境和专业排版。

---

图33 | 提示增强器（PE）在物理推理编辑中的影响。左：输入图像（空杯中的干茶包）。中：没有 PE 的编辑仅复制内容，缺乏泡茶的物理动态。右：通过 PE 的世界知识和物理推理，输出包含了倒水、茶包浸泡、茶色扩散和升起的蒸汽，实现了逼真的“泡茶”编辑。

---

图34 | Z-Image-Turbo 新兴的多语言和多元文化理解能力。它显示 Z-Image-Turbo 不仅能理解多种语言的提示，还能利用其世界知识生成与当地文化和地标相符的图像。

---

图35 | Z-Image-Edit 新兴的复合指令理解能力。从左到右：输入提示（双语）、源图像和我们的编辑结果。Z-Image-Edit 擅长处理多属性修改、复杂的身份保持场景变换和局部文本渲染。

---

## 6. 结论

在本报告中，我们介绍了 Z-Image 系列，一套基于可扩展单流扩散 Transformer（S3-DiT）构建的高性能 6B 参数模型套件。挑战当前盛行的“不计成本地扩大

规模”范式，我们提出了一个由四大战略支柱支撑的整体端到端解决方案：(1) 精心策划的高效数据基础设施；(2) 可扩展的单流架构；(3) 精简的训练策略；(4) 用于高质量和高效推理的先进优化技术，包括 PE 感知的监督微调、少步蒸馏和奖励后训练。

这种协同作用使我们能够在 314K H800 GPU 小时内以低于 63 万美元的总成本完成整个工作流，交付顶级的照片级真实感合成和双语文本渲染。除了强大的基础模型外，我们的流程还产生了 Z-Image-Turbo，它可以在企业级 H800 GPU 上实现亚秒级推理 (<1s)，并舒适地适配 16G VRAM 消费级硬件。此外，我们开发了 Z-Image-Edit，一个通过全任务预训练范式高效衍生的编辑模型。通过这一流程，我们为社区提供了开发可访问、高性价比且最先进的生成模型的蓝图。

## 7. 作者

### 7.1. 核心贡献者

蔡焕洽 (Huanqia Cai)，曹思涵 (Sihan Cao)，杜若一 (Ruoyi Du)，高鹏 (Peng Gao)，郝爱民 (Aiming Hao)，Steven Hoi，侯兆辉 (Zhaohui Hou)，蒋登阳 (Dengyang Jiang)，蒋宇明 (Yuming Jiang)，金鑫 (Xin Jin)，李良琛 (Liangchen Li)，李臻 (Zhen Li)，李中宇 (Zhong-Yu Li)，刘大卫 (David Liu)，刘东阳 (Dongyang Liu)，吴启龙 (Qilong Wu)，余峰 (Feng Yu)，詹泽超 (Zechao Zhan)，张弛 (Chi Zhang)，张世峰 (Shifeng Zhang)，周瑞凯 (Ruikai Zhou)，周士林 (Shilin Zhou)

### 7.2. 贡献者

蔡程林 (Chenglin Cai)，窦玉静 (Yujing Dou)，高岩 (Yan Gao)，郭明昊 (Minghao Guo)，韩松志 (Songzhi Han)，胡伟 (Wei Hu)，胡秀寒 (Xiuhan Hu)，黄世杰 (Shijie Huang)，黄玉燕 (Yuyan Huang)，李浩南 (Haonan Li)，李旭 (Xu Li)，李泽夫 (Zefu Li)，林恒 (Heng Lin)，刘佳明 (Jiaming Liu)，罗林洪 (Linhong Luo)，毛青青 (Qingqing Mao)，MERJIC，倪静远 (Jingyuan Ni)，秦川 (Chuan Qin)，曲琳 (Lin Qu)，石俊涵 (Junhan Shi)，孙景华 (Jinghua Sun)，王鹏 (Peng Wang)，王平 (Ping Wang)，王珊珊 (Shanshan Wang)，王雪聪 (Xuecong Wang)，王毅 (Yi Wang)，王月 (Yue Wang)，温廷坤 (Tingkun Wen)，吴俊德 (Junde Wu)，吴明刚 (Minggang Wu)，吴雄伟 (Xiongwei Wu)，辛毅 (Yi Xin)，邢海波 (Haibo Xing)，徐靖杰 (Jingjie Xu)，徐晓晓 (Xiaoxiao Xu)，徐晓宇 (Xiaoyu Xu)，徐泽 (Ze Xu)，杨训亮 (Xunliang Yang)，叶文涛 (Wentao Ye)，余淑婷 (Shuting Yu)，赵宇晨 (Yucheng Zhao)，张健安 (Jianan Zhang)，张剑锋 (Jianfeng Zhang)，张嘉伟 (Jiawei Zhang)，张强 (Qiang Zhang)，赵旭东 (Xudong Zhao)，郑宇 (Yu Zheng)，周海建 (Haijian Zhou)，周含章 (Hanzhang Zhou)

---

(参考文献部分按原文保留，不翻译)