

ACE-Step v1.5：推动开源音乐生成的边界

Junnin Gong* Yulin Song† Wenxiao Zhao† Sen Wang† junmin@acestudio.ai keyxiao@acestudio.ai sean@acestudio.ai sayo@acestudio.ai ACE Studio ACE Studio ACE Studio ACE Studio Shengyuan Xu† Jing Guo† Xuerui Yang† shengyuan@acestudio.ai joe@acestudio.ai yangxuerui@stepfun.com ACE Studio ACE Studio Step Fun

摘要

我们提出了 ACE-Step v1.5，一个高度高效的开源音乐基础模型，将商业级生成能力带到消费级硬件上。在常用评估指标上，ACE-Step v1.5 的质量超越了大多数商业音乐模型，同时保持极快的速度——在 A100 上每首完整歌曲不到 2 秒，在 RTX 3090 上不到 10 秒。该模型可在本地运行，显存占用低于 4GB，并支持轻量级个性化：用户仅需几首歌曲即可训练一个 LoRA 来捕捉自己的风格。其核心是一种新颖的混合架构，其中语言模型（LM）充当全能规划器：它将简单的用户查询转化为全面的歌曲蓝图——从短循环扩展到 10 分钟作品——同时通过思维链合成元数据、歌词和描述，以指导扩散 Transformer（DiT）。独特的是，这种对齐仅通过依赖模型内部机制的内在强化学习实现，从而消除了外部奖励模型或人类偏好固有的偏差。除了标准合成之外，ACE-Step v1.5 还统一了精确的风格控制与多功能的编辑能力——例如翻唱生成、重绘和人声到背景音乐转换——同时在 50 多种语言中严格遵循提示。这为能够无缝集成到音乐艺术家、制作人和内容创作者创意工作流程中的强大工具铺平了道路。代码、模型权重和演示可在以下网址获取：<https://ace-step.github.io/ace-step-v1.5.github.io/>。

1 引言

神经音乐生成领域已经经历了范式转变，专有系统展现出卓越的保真度和结构连贯性。然而，闭源能力与开源替代方案之间仍存在显著差距。虽然我们的前代版本 ACE-Step v1.0 [1] 验证了在消费级硬件上进行基于扩散的文本到音乐生成的可行性，但它主要作为概念验证运行。关键的是，v1.0 凸显了可行与商业级之间的差距：声学保真度受限于梅尔频谱图表示；语义一致性未达到专业标准；而复杂的编辑需求——如音轨分离和翻唱生成——仍未得到解决。

在这项工作中，我们提出了 ACE-Step v1.5，一个旨在弥合实验原型与生产就绪标准之间差距的确定性框架。我们挑战了推理效率与生成质量之间的传统权衡，实现了一种精炼的混合推理-扩散架构，从根本上将可用性与声学渲染解耦。我们不是采用端到端黑盒，而是将语言模型（LM）定位为智能作曲家代理，将扩散 Transformer（DiT [2, 3]）定位为专门的声学渲染器。LM 作为高层规划器，明确地将模糊的用户提示重建为精确的结构蓝图（例如，格式化歌词、计算时长、扩展查询），以减轻 DiT 的语义模糊性。相反，DiT 被解放出来，专注于声学丰富度和乐器分离。通过整合一种新颖的蒸馏方法.....

- 通过蒸馏实现商业级效率：**我们引入了一种专门的蒸馏协议，将 DiT 推理轨迹压缩到 4-8 步。这一优化使得在消费级 GPU（<4GB VRAM）上能够亚秒级生成高保真音频，有效实现了专业音乐合成的民主化，而不牺牲乐器清晰度。
- 解耦的可用性-生成架构：**我们提出了一种结构性范式转变，其中 LM 和 DiT 解决不同的生成挑战。通过多任务训练将结构规划和提示理解卸载给 LM，我们确保 DiT 接收标准化、无歧义的条件，从而最大化其生成上限。
- 用于对齐控制的内在 RL：**为了在不引入外部偏差的情况下增强可控性，我们采用了一种强化学习流程，其驱动来自模型自身理解任务的内在奖励。这种方法确保了在 50 多种语言中的稳健对齐，并强制精确遵守风格和歌词约束。
- 统一全能任务框架：**超越简单的文本到音乐合成，ACE-Step v1.5 建立了一个用于复杂音乐操作的统一框架。该模型原生支持多功能工具包——包括翻唱生成、无缝重绘、音轨提取和人声到背景音乐转换——证明了一个单一、高效训练的模型可以满足现代音乐制作中多样化的长尾需求。

2 数据基础设施

ACE-Step v1.5 前所未有的保真度和可控性严格源于数据工程的范式转变：从数量优先到对齐优先。我们建立了一个全面的数据基础设施，旨在最大化每个训练样本的信息密度。

该基础设施的核心是一个复杂的自进化标注系统。我们最初设计了精确提示，利用 Gemini 2.5 Pro [4]——因其世界级推理能力和最小固有偏差而被选中——来标注一个包含 500 万音频样本的黄金集。使用这些高质量种子数据，我们微调了 Qwen2.5-Omni 以创建我们的专有专家模型：ACE-Captioner 和 ACE-Transcriber。为了进一步消除幻觉并提高遵循度，我们在 400 万合成负对上训练了特定的奖励模型，并应用强化学习来精炼标注器。最后，这个 RL 增强的流程标注了我们整个 2700 万样本的语料库，随后进行了严格的过滤步骤。

2.1 RL 驱动标注流程

为了弥合声学细节和文本描述之间的差距，我们构建了一个多阶段流程，实现了对 2000 多种音乐风格和 50 多种语言的细粒度描述。阶段 1（基础 SFT）利用 500 万 Gemini 标注样本对 Qwen2.5-Omni [5] 进行监督微调，产生基础的 ACE-Captioner 和 ACE-Transcriber。阶段 2（奖励建模）通过双轨启发式语义增强策略构建了 400 万对比对。我们通过微妙地破坏语义元素（例如，交换乐器或情绪标签）生成困难负例，并通过语义重写生成稳健正例。这迫使奖励模型区分超越表面文本模式的细粒度语义差异。在阶段 3（RL 精炼）中，我们应用 GRPO [6] 来针对这些奖励模型优化标注器。最后，阶段 4 部署这些模型来标注完整的 2700 万数据集，并重用奖励模型过滤掉低对齐配对。

2.2 语义-声学过滤与增强

为了缓解先前迭代中观察到的生成不稳定性，我们实施了一个由 ACE-Reward 模型驱动的严格过滤和增强协议。我们应用基于度量的过滤策略，积极丢弃表现出低音频-文本相关性的样本，从而去除导致模式崩溃的噪声。同时，认识到我们密集的训练描述与通常稀疏的用户提示之间的分布偏移，我们使用 Qwen3-30B-A3B [7] 进行查询重写。通过用多样化的输入变体——从单风格关键词到摘要描述——增强数据集，我们确保模型在不同提示复杂度和长度下保持稳健。

图 1：数据基础设施和 RL 驱动 的标注流程。

2.3 多语言和音色预处理

为了促进全球通用性和精确控制，我们引入了针对语言和声学特征的专门预处理策略。对于非罗马文字（例如，中文、日文、泰文），我们实施随机罗马化策略，在训练期间将 50% 的歌词转换为音素表示。这种方法使模型能够跨语言共享音韵表示，显著提高稀有 token 的发音准确性，而无需扩大词汇量。对于音色建模，我们通过应用语音掩码来分离人声或乐器干声，构建专用参考数据集。这些片段被拼接成连续流，并处理为固定的 30 秒上下文窗口，带有循环填充，使模型能够学习稳健的零样本音色克隆能力。

2.4 渐进式课程学习

我们采用三阶段课程学习策略，使用超过 2700 万个处理样本逐步解锁模型能力。训练方案从基础预训练开始，使用约 2000 万文本到音乐对的大规模语料库，重点捕获一般声学分布和广泛语言表示。随后是全能任务微调阶段，数据集通过保留质量最高的 50% 样本进行精炼，并增加 600 万分离音轨；此阶段针对高级编辑任务，如音轨提取和重绘。流程最后使用精选的 200 万样本子集进行高质量 SFT 阶段。通过分层高奖励过滤选出，这个最终阶段最大化指令遵循和.....

3 模型架构

图 2：ACE-Step 1.5 的模型框架。

3.1 高保真 1D VAE：超越梅尔频谱图

AceStep v1.0 依赖 2D 梅尔频谱图，这种表示常常受到相位损失和高频瞬态（如贝斯拨弦和打击乐）分辨率不足的困扰。为了规避这一声学瓶颈，我们实现了一种纯波形域 1D 变分自编码器（VAE）[8]。采用受 SongBloom [9] 启发的配置，我们的 VAE 将 48kHz 立体声音频压缩为 25Hz 的紧凑 64 维隐空间，实现了高达 1920 倍的压缩率，同时保持近乎无损的感知质量。

训练通过 Muon 优化器 [10] 进行优化，与标准 AdamW 相比，它在大型 1D 卷积层上展现出更优的收敛特性。该模型在 120 块 A100 GPU 上进行了 60 万步的对抗调优。关键的是，在最后 10 万步中，我们消除了 KL 散度惩罚，并将对抗损失权重从 0.1 增加到 0.5。这一策略显著锐化了声学纹理，使 1D VAE 在重建指标上超越 2D DCAE 基线，特别是在人声清晰度和乐器分离方面。

3.2 DiT 主干：高效条件生成

我们声学合成流程的核心是一个规模约为 20 亿参数的扩散 Transformer（DiT）。作为通用条件生成器设计，该主干平衡了计算效率与多任务通用性。为了协调长序列建模与结构连贯性，我们引入了混合注意力机制：奇数层使用滑动窗口注意力来捕获局部声学细微差别和瞬态，偶数层使用全局分组查询注意力（GQA）来保持长期节奏和旋律一致性。

该模型在统一条件栈上运行，其中 Qwen3-0.6B 描述嵌入与专用音色和歌词编码器拼接，并通过交叉注意力注入。为了连接连续隐空间与我们的离散 LM 规划器，我们实现了有限标量量化（FSQ [11]）tokenizer。该模块利用注意力池化将 25Hz 隐变量压缩为 5Hz 离散编码（码本约 64k），作为结构源隐变量。

最后，模型通过 patchify 层处理复合输入张量——组合源、加噪目标和掩码——有效地将序列长度减半至 12.5Hz，以实现最佳吞吐量。

图 3：由掩码生成框架实现的 ACE-Step 1.5 多模态应用。

3.3 全能任务表述

我们将音乐生成统一到一个灵活的掩码生成框架中，其中操纵源隐变量和掩码配置允许单个模型支持六种不同的模态。除了标准文本到音乐之外，该架构还通过量化隐变量在保留旋律骨架的同时重新合成音色，实现翻唱生成；以及用于无缝片段再生的重绘。此外，它泛化到复杂的结构任务，包括音轨提取、分层（向音轨添加互补乐器）和补全（围绕单一动机编排完整编曲）。这种方法不仅通过利用共享隐空间简化了训练过程，还提高了效率，因为模型可以适应多样化输入而无需任务特定微调。通过整合量化隐变量，该框架确保在转换过程中高保真地保留旋律和节奏等音乐元素，使其成为创意混音应用的理想选择。

3.4 语言模型：推理与规划

虽然 DiT 处理声学渲染，但逻辑规划被委托给基于 Qwen 的语言模型。利用 ChatML 模板，LM 被训练为充当“作曲家代理”，在输出内容之前以 YAML 格式生成结构化思维链（CoT）元数据——包括 BPM、调性、时长和结构。该架构实现了四种不同的交互范式：（1）规划器模式，模型将模糊的用户提示转化为具体的结构蓝图和音频编码；（2）聆听者模式，通过从音频编码反向工程描述和歌词来展示语义理解；（3）副驾驶模式，作为创意助手将简单查询扩展为完整歌曲结构；（4）精炼器模式，LM 标准化和优化风格化或原始用户输入，以最大化下游 DiT 的性能。CoT 推理的整合允许 LM 将复杂的音乐想法分解为逻辑步骤，提高生成输出的连贯性和艺术质量。

此外，通过以标准化 YAML 格式输出元数据，它促进了与音乐制作流程中其他工具或系统的无缝互操作性。

4 训练策略

图 4：ACE-Step v1.5 的训练流程。

我们采用渐进式训练范式，从基础生成先验演化到复杂的多任务微调，最终实现对抗蒸馏，使学生模型超越其教师。初始生成预训练阶段使用 2000 万样本基础数据集（源=静音）来建立音乐结构和声学分布的稳健先验。随后的全能任务混合阶段引入全能任务协议，使用 1700 万样本，采用不同的源和掩码条件来解耦风格属性与旋律内容，以进行精确编辑任务。最终高保真监督微调（SFT）阶段采用精选的 200 万样本高对齐子集，将目标从多样性转向最大化控制信号与输出之间的相关性，以实现稳健初始化。

4.1 对抗动态偏移蒸馏

为了实现亚秒级推理而不降低质量，我们采用基于解耦 DMD2 [12, 13] 的蒸馏框架，并增加了 GAN 目标和基于 ConvNeXt 的判别器 [14]，通过流匹配目标在隐空间中运行。为了克服固定时间步偏移限制去噪轨迹多样性的局限性，我们提出了一种动态偏移策略，偏移参数从 {1, 2, 3} 中随机采样。这使代理模型暴露于多样化的去噪状态，防止过拟合并确保稳定的对抗反馈。蒸馏模型将推理从 50 步减少到 8 步（偏移=3），无需无分类器引导，实现了 200 倍加速，在 NVIDIA A100 上约 1 秒内生成 240 秒音轨。学生模型通过减轻离散化误差并通过判别器锐化纹理，超越了教师模型，促进了自主生成的测试时扩展，并使用内在奖励对候选批次进行重新排序。

4.2 自监督内在对齐

为了在不引入外部偏差的情况下增强可控性，我们建立了一个统一的内在强化学习框架，将 DiffusionNTF [15] 应用于 DiT 主干，将组相对策略优化（GRPO）应用于语言模型，奖励来自内部几何和概率一致性。对于 DiT 对齐，我们假设低保真度生成与交叉注意力图中的高熵相关，并开发了注意力对齐分数（AAS），测量 Token 到帧和帧到 Token 注意力图之间的一致性。AAS 通过动态时间规整（DTW）聚合三个属性：（1）覆盖率，具有显著能量峰的歌词 token 比例；（2）单调性，惩罚注意力质心的非前向对齐；（3）路径置信度，沿对齐轨迹的平均能量密度。优化 AAS 减少了幻觉，并在歌词-音频同步方面实现了与人类判断 >95% 的相关性。对于 LM 对齐，我们将模型视为既是“作曲家”（文本到编码）又是“聆听者”（编码到文本），使用点互信息（PMI）构建奖励模型以评估语义遵循。与原始截然不同，PMI 惩罚通用描述，并奖励特定于生成音频编码的描述。最终奖励是动态加权，强调风格氛围（50%）、歌词内容（30%）和元数据约束（20%），引导 LM 优先考虑艺术细微差别，同时保持结构有效性。

表 1：与商业（上）和开源（下）音乐生成模型的比较。评估配置为 1.7B LM + 动态蒸馏 DiT（无 RL）。粗体=最佳，下划线=次佳。↑ 越高越好。

模型	AudioBox CU↑	AudioBox PC↑	AudioBox PQ↑	AudioBox Coh.↑	AudioBox Mus.↑	SongEval Mem.↑	SongEval Cla.↑	SongEval Nat.↑	SongEval Udio- v1.5↑	Style Align↑	Lyric Align↑
Suno-v4.5	7.45	7.65	6.15	8.03	4.15	3.96	4.09	3.93	3.86	34.9	24.8
Suno-v5	7.63	7.85	6.22	8.25	4.64	4.51	4.63	4.53	4.49	40.5	32.7
Mureka-V	7.69	7.87	6.51	8.29	4.72	4.62	4.71	4.63	4.56	46.8	34.2
MinMax-2.0	7.67	7.44	7.71	6.35	8.13	4.43	4.29	4.35	4.29	4.21	36.2
Yue [18]	7.71	7.95	6.42	8.38	4.61	4.51	4.59	4.50	4.41	43.1	29.5
ACE-Step 1.0	6.58	7.29	4.95	7.39	3.01	2.80	2.85	2.79	2.82	26.8	-4.6
LeVo [19]	7.22	7.52	6.50	7.76	3.99	3.73	3.85	3.78	3.68	28.5	0.9
DiffRhythm 2 [20]	7.61	7.78	5.92	8.31	3.55	3.35	3.32	3.31	3.20	29.4	-1.2
HeartMuLa [21]	7.25	7.61	6.33	7.99	3.99	3.79	3.97	3.82	3.66	32.1	3.8
ACE-Step 1.5	7.66	7.89	6.15	8.25	4.68	4.55	4.69	4.55	4.45	31.7	28.6
ACE-Step 1.5	7.42	8.09	6.47	8.35	4.72	4.67	4.72	4.66	4.59	39.1	26.3

5 评估

我们在三个层级进行全面评估：客观指标、主观人类偏好，以及针对真实部署场景的新颖可用性评估。

5.1 客观指标

我们在涵盖 20 种音乐风格和双语（中文/英文）提示的多样化测试集上评估，使用 Gemini 3 Pro 生成结构化提示和相应歌词。

指标来源。 AudioBox 分数来自 Meta 的美学评估框架 [16]；SongEval 指标通过 ASLP-lab 评估套件 [17] 计算。风格和歌词对齐使用我们专有的 ACE-Caption-Reward 和 ACE-Lyric-Reward 模型量化。

结果。 如表 1 所示，ACE-Step 1.5 实现了最高的 AudioBox CU（8.09）、次佳的 PQ（8.35）和并列最佳的 Coherence（4.72），同时展示了优越的时间一致性（Mem 4.72，Nat 4.59）。虽然像 Suno-v5 这样的商业模型在风格/歌词对齐方面保持优势（46.8/34.2），但 ACE-Step 1.5 在开源基线中展现出强大的竞争力（39.1/26.3），验证了我们的蒸馏保留了高保真声学渲染。

5.2 通过 Music Arena 进行主观评估

为了评估超越自动指标的感知质量，我们采用 Music Arena 协议。人类评估者在给定相同提示/歌词的情况下对成对模型输出进行盲 A/B 测试。聚合 Bradley-Terry 分数后，ACE-Step 1.5 的主观质量排名介于 Suno-v4.5 和 Suno-v5 之间，证实亚秒级生成不会损害美学保真度。

5.3 可用性：一种新的评估范式

我们认为，流行的基准不足以捕捉文本到音乐系统在生产工作流中的实际效用。因此，我们提出可用性作为整体效能指标，通过跨越六个关键维度的严格 17 点清单（表 2）形式化。

该框架将评估重点从孤立的质量分数转向专业创意生态系统中的系统能力，解决了标准基准经常忽视的部署障碍和工作流集成问题。

表 2：用于评估真实创意工作流中文本到音乐系统的 17 点可用性清单。

维度	ID	标准	要求/成功条件
1. 民主化与可及性	1	部署障碍	必须在消费级本地硬件上运行，而非局限于企业 API/集群。
	2	硬件无关性	可在广泛使用的 GPU（例如 <8GB VRAM）上运行，无需强制使用专用 H100。
	3	安装复杂性	用户就绪的打包解决方案（例如 pip/conda 可安装），而非碎片化的研究仓库。
2. 效率与“惊喜因素”	4	结果时间	生成延迟不得破坏用户的创作“心流状态”（亚秒级到几秒）。
	5	测试时扩展	推理速度支持大规模并行批处理，以进行高效的隐空间探索。
	6	意外发现系数	能够快速生成大量多样化候选，以最大化“意外之喜”。
3. 稳健性与规模	7	提示稳健性	对稀疏/模糊输入的韧性（“反抽卡”要求：弱提示下无模式崩溃）。
	8	时间可扩展性	无缝处理从 10 秒声音设计循环到 10 分钟渐进式作品。
	9	语言广度	覆盖全球语言的长尾（>50），避免盎格鲁中心偏差。
4. 专业集成	10	非破坏性编辑	精准的“重绘”能力，允许部分编辑而无需重新生成整个音轨。
	11	干声分离	输出孤立音轨（人声/鼓/贝斯/其他）以供下游混音和母带处理。
	12	参考控制	从任意音频参考进行零样本音色克隆和结构引导。
5. 创意共生	13	灵感解锁	作为“动机生成器”在创作者瓶颈时激发创造力。
	14	身份一致性	在多次生成/连续片段中保持一致的音色身份。
	15	探索可玩性	允许在结构化规划和非结构化即兴之间流畅切换的界面。
6. 知识与精确性	16	专业术语	严格遵守技术指令（例如“侧链压缩”、“弗里吉亚调式”、“TB-303 Acid Line”），将术语转化为准确的声学现象而非通用氛围。
	17	世界知识接地	对特定时代、地区风格和艺术家参考的广泛文化素养（例如“1920 年代上海爵士”、“赛博朋克 2077 音景”），而无时代错乱的幻觉。

6 结论

在这项工作中，我们提出了 ACE-Step v1.5，一个通过新颖的混合推理-扩散架构实现商业级音乐生成民主化的确定性框架。通过将结构规划与声学渲染解耦，我们在消费级硬件上实现了亚秒级推理而不损害保真度，实现了合成、翻唱生成和精确编辑的统一工具包。这种方法有效弥合了开源能力与专有系统之间的差距，为创意工作流提供了多功能基础。

然而，当前能力仍受限于消费级可及性所必需的参数约束。未来开发将专注于扩展模型规模和深化数据基础设施以解决这些限制。具体来说，我们旨在增强声学丰富度，扩展对多样化语言和音乐风格的支持，并整合更广泛的世界知识以实现专业级描述控制。此外，我们计划精炼精确歌词对齐并启用代理音频编辑工作流。我们相信，持续扩展与我们严格的数据工程管道相结合，将解决这些约束并进一步推动生成音乐的边界。

致谢

本项目由 ACE Studio 和 StepFun 联合领导。

我们衷心感谢 StepFun 慷慨提供计算能力和存储基础设施。没有这些关键支持，ACE-Step 的开发不可能实现。我们也深深感谢他们的团队组织并进行了我们模型的主观评估。

我们非常感谢 Jing Guo 和 Wenxiao Zhao 在有关 ACE-Step 训练和应用方面的决策和讨论中的密集参与。他们对权衡的细致考量在将 ACE-Step 塑造为如今的多功能基础模型方面发挥了重要作用。

我们真诚感谢 Sen Wang 和 Shengyuan Xu 在数据工程方面的宝贵支持。有效的数据管理是我们努力的基础，没有他们的专业知识，ACE-Step 不可能成功训练。我们也感谢 Yulin Song 在数据管道构建方面的合作以及他对强化学习奖励框架的具体贡献。

我们向 Junmin Gong 表达最深切的感谢，感谢他的广泛贡献，包括算法开发、框架设计、实验执行、模型训练和评估。此外，我们感谢他撰写报告、准备开源代码发布和创建项目网页。

最后，我们特别感谢 ACE-Step 社区的宝贵反馈和资源共享。ACE-Step 是一个社区驱动的模式，没有我们用户的持续参与和支持，我们不可能走到今天。