

用旋律和文本编辑音乐：使用ControlNet进行扩散Transformer

Siyuan Hou^{1,2}, Shansong Liu², Ruibin Yuan³, Wei Xue³, Ying Shan², Mangsuo Zhao¹, Chao Zhang^{1,*}¹ 清华大学,² 腾讯PCG ARC Lab,³ 香港科技大学 housty24@mails.tsinghua.edu.cn; shansongliu@tencent.com; cz277@tsinghua.edu.cn

摘要——尽管可控音乐生成与编辑取得了显著进展，但由于使用梅尔频谱图表示和基于UNet的模型结构，生成音乐的质量和长度仍面临挑战。为解决这些局限，我们提出了一种新方法，使用扩散Transformer (DiT) 并通过ControlNet增加一个额外的控制分支。这使得能够生成和编辑由文本和旋律提示控制的长格式、可变长度音乐。为了实现更精确和细粒度的旋律控制，我们引入了一种新颖的top- k 恒Q变换表示作为旋律提示，与先前的表示（如chroma）相比减少了歧义，特别是对于具有多音轨或宽音高范围的音乐。为了有效平衡来自文本和旋律提示的控制信号，我们采用了一种课程学习策略，逐步掩码旋律提示，从而实现更稳定的训练过程。我们使用开源器乐录音数据在文本到音乐生成和音乐风格迁移任务上进行了实验。结果表明，通过扩展StableAudio（一个预训练的文本控制DiT模型），我们的方法在保留良好文本到音乐生成性能的同时，实现了优越的旋律控制编辑。这些结果在基于文本的生成和编辑中的旋律保持方面均优于强大的MusicGen基线。音频示例可在<https://stable-audio-control.github.io> 找到。

1. 引言

随着深度生成模型的快速发展，跨多种模态的文本引导生成任务取得了显著进展，包括文本到图像、文本到音频和文本到视频。在文本到音乐生成领域，若干模型如MusicLM [1]、MusicGen [2]、JASCO [3]和JEN-1 [4]已展示出基于文本提示生成高质量音乐的能力，这些提示通常描述更抽象和高层次的全局属性，如风格、主题和流派 [5]。此外，一些模型在音乐生成任务中探索了更灵活的条件机制，如以音乐音频上下文为条件 [6]-[9]。最近，音乐编辑领域的努力已经出现，包括Coco-Mulla [10]和DITTO [11]，它们使用时序对齐的音乐提示来实现对生成音乐更精细属性的更大控制灵活性。

现有音乐生成模型面临两个局限。第一，使用基于UNet的扩散模型 [12]-[14]通过梅尔频谱图表示生成音乐会严重限制生成音乐的长度和质量。为适应2D卷积结构和下采样因子所需的固定长度频谱图输出，阻碍了精确、可变长度音频的生成。此外，通过单独训练的声码器将梅尔频谱图转换为波形通常会在转换过程中引入误差，进一步降低最终音频输出的质量。第二，许多现有方法使用的旋律提示未能包含完整的旋律信息，导致旋律保持效果差。例如，Music ControlNet [5]采用one-hot 12音级chromagram作为旋律提示，无法准确捕获跨多个八度的音高变化，也难以有效表示多音轨音乐的旋律。

为解决上述挑战，我们提出了一种改进的可控音乐编辑模型，旨在基于文本和旋律提示生成音乐。受StableAudio模型 [15], [16]启发，我们采用扩散Transformer (DiT) 模型结构，配合时间条件方法作为主要框架，实现可变长度音乐的生成。为实现精确的旋律控制，我们引入了一个基于ControlNet的控制分支，遵循Music ControlNet [5]中使用的方法，以适配DiT模型的扩散组件。与先前研究中常用的chroma特征不同，我们提出使用top- k 恒Q变换 (CQT) 特征来提供更灵活和准确的旋律表示。该特征有助于消除歧义并渲染具有多音轨或更宽音高范围的音乐。此外，受JEN-1作曲家 [17]启发，我们实施了一种渐进式课程掩码策略来改进旋律提示的学习，在训练期间实现文本和旋律提示之间更有效的平衡。因此，我们的模型不仅能够执行基于提示的音乐风格迁移，还能使用旋律提示更精确地渲染和生成音乐内容。实验结果表明，我们的模型在多种主观和客观指标上提供了有竞争力的性能，展示了增强的音乐编辑能力，同时在文本到音乐生成质量上没有显著损失。

我们的主要贡献如下：

- 据我们所知，我们是第一个将ControlNet [18]应用于DiT模型进行音乐任务的工作，实现了对旋律提示的精确、时变控制。
- 我们引入了top- k CQT，一种基于恒Q变换特征的灵活有效的旋律信息表示，保留了更详细的旋律信息并增强了模型保持旋律的能力。
- 我们提出了一种渐进式课程掩码策略来稳定训练并提高音乐编辑性能。

II. 背景

A. 扩散模型

扩散模型 [19]是一类基于概率模型的生成方法，其核心思想是将生成过程分解为一系列增量随机扩散步骤。通过学习逆转这个添加随机噪声的过程，扩散模型逐渐获得从噪声生成目标数据的能力。由于其高质量生成和稳定过程，扩散模型架构已被各种音频生成模型采用，包括Moûsai [20]、AudioLDM [21], [22]、MusicLDM [12], [23]和MusicMagus [24]。

在前向过程中，由马尔可夫链定义的随机过程越来越多地向干净数据 $\mathbf{x}_0$ 添加噪声。

$$\begin{aligned} q(\mathbf{x}_1 : T | \mathbf{x}_0) &= \prod_{t=1}^T q(\mathbf{x}_t | \mathbf{x}_{t-1}) \\ q(\mathbf{x}_t | \mathbf{x}_{t-1}) &= \mathcal{N}(\mathbf{x}_t; \sqrt{1 - \beta_t} \mathbf{x}_{t-1}, \beta_t \mathbf{I}), \end{aligned} \quad (1)$$

其中 $\beta_1, \dots, \beta_T$ 是一系列预定的噪声时间表，定义前向扩散过程中的噪声水平。

在训练期间，扩散模型学习具有可学习参数 θ 的逆过程，该过程迭代地将随机样本 $\mathbf{x}_T \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$ 去噪为数据样本 $\mathbf{x}_0 \sim p(\mathbf{x}_0)$ 。

$$\begin{aligned} p_\theta(\mathbf{x}_{0:T-1} | \mathbf{x}_T) &= \prod_{t=1}^T p_\theta(\mathbf{x}_{t-1} | \mathbf{x}_t) \\ p_\theta(\mathbf{x}_{t-1} | \mathbf{x}_t) &= \mathcal{N}(\mathbf{x}_{t-1}; \mu_\theta(\mathbf{x}_t, t), \Sigma_\theta(\mathbf{x}_t, t)). \end{aligned} \quad (2)$$

这个去噪过程可以通过最小化预测噪声 $\epsilon \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$ 的均方误差来训练。最近，v-objective扩散被提出 [25]，它通过最小化以下目标来估计模型 $\hat{\mathbf{v}}_t = f_\theta(\mathbf{x}_t, t)$ ：

$$\mathbb{E}_{t \sim [0,1]} \|\mathbf{x}_t\| f_\theta(\alpha_t \mathbf{x}_0 + \sigma_t \epsilon, t) - \mathbf{v}_t\|_2^2, \quad (3)$$

其中 $\mathbf{v}_t = d\mathbf{x}_t/dt = \alpha_t \epsilon - \sigma_t \mathbf{x}_0$, $t \sim [0, 1]$ 是噪声时间表， $\alpha_t = \cos(0.5\pi t)$ 且 $\sigma_t = \sin(0.5\pi t)$ 。

B. 扩散Transformer (DiT)

DiT [26]是一种将扩散模型与Transformer架构 [27]集成的生成模型。与依赖UNet架构 [28]的传统扩散模型不同，DiT使用Transformer编码器作为去噪网络。通过利用Transformer的自注意力机制，该机制擅长捕获数据中的长程依赖关系，它特别适合建模音乐的复杂结构，使其能够生成连贯一致的作品。StableAudio 2 [16]将DiT应用于音频生成，实现了高质量、长格式音乐生成。

III. 提出的方法

A. 带ControlNet的扩散Transformer

为了建模长格式和可变长度音乐，我们采用StableAudio Open [29]作为主干结构，它使用DiT模型。通过结合DiT的序列建模能力和音频编解码器的低延迟优势，该框架可以在文本提示引导下生成高达47秒的高质量立体声音频。此外，得益于StableAudio的时间条件机制 [15]，模型可以生成可变长度音乐，在音乐生成中提供更大的灵活性。

在此基础上，受Music ControlNet [5]启发，我们探索为扩散模型添加控制分支以实现时变旋律控制。Music ControlNet通过将ControlNet适配到音乐领域，实现对旋律和力度等音乐属性的控制。然而，由于Music ControlNet使用UNet结构的扩散模型，且ControlNet是为UNet架构设计的，原始ControlNet不能直接与我们采用的DiT结构兼容。例如，DiT缺乏UNet中存在的显式对称“编码器-解码器”结构，使得原始ControlNet所使用的跳跃连接等组件在此背景下不适用。

为解决此问题，我们从Pixart- δ [30]中使用的ControlNet-Transformer结构汲取灵感，并将其适配到StableAudio的DiT架构（如图1所示）。具体来说，ControlNet-Transformer复制前 N 个Transformer块作为控制分支。第 i 个可训练复制块的输出，经过额外的零初始化线性层后，与第 i 个冻结块的输出相结合，并用作第 $(i + 1)$ 个冻结块的输入。这种设计保持了DiT模型的原始连接结构，实现了ControlNet结构的无缝集成，同时保留了Transformer结构的核心优势。

B. 用于旋律信息的Top- k CQT表示

找到精确且灵活的旋律信息表示对于实现对音乐旋律的时变控制至关重要。先前的研究，如Music ControlNet [5]和DITTO [11], [31]，使用one-hot 12音级chromagram作为旋律控制条件，这有两个主要缺点。第一，它仅捕获单个八度内的音高变化，意味着模型难以保持涉及跨多个八度音高变化的旋律，也无法准确推断绝对音高信息。第二，该方法中使用的argmax操作仅记录每帧最突出的音级，限制了其在具有多个交织音轨的音乐中提取完整旋律信息的能力。结果，生成的旋律可能显著偏离原始旋律，仅捕获整体旋律包络而非完整和声细节。

为解决上述问题，我们提出了一种更精确和灵活的旋律表示（图1），通过将CQT [32]扩展为具有top- k 最突出的音高值。由于CQT的中心频率呈指数分布，这种表示与音阶的频率分布很好地对齐，使其在处理音乐信号时非常有效 [33], [34]。对于立体声音频输入，我们首先计算左右声道各128个频带的CQT，然后应用argmax操作保留每个声道每帧最突出的4个音高。这产生8个突出音高，交错堆叠，形成旋律提示 $\mathbf{c} \in \mathbb{R}^{8 \times T f_k}$ ，其中 T 是音频的秒数， f_k 是CQT计算后的帧率，每个像素 $\mathbf{c}_{i,j} \in 1, 2, \dots, 128$ 。与Music ControlNet一样，我们在计算CQT之前应用截止频率为中央C（261.2 Hz）的双二次高通滤波器。由于top- k CQT保留了绝对音高信息并捕获了多个音轨的旋律细节，它显著提高了旋律控制的精度。同时，top- k CQT保持了chroma表示的灵活性，因为它使用人类可理解的音高索引作为旋律提示。这不仅允许从音频中提取旋律，还可以将乐谱转换为旋律控制数据，或直接创建旋律表示作为模型输入。

为了进一步增强旋律信息的提取和表示，我们使用旋律提示 $\mathbf{c}$ 作为索引，通过音高特定的可训练嵌入将其从突出音级的表示转换为更高维的潜在旋律提示。接下来，应用一系列1D卷积层对旋律信息进行下采样，使其与ControlNet的输入形状对齐，从而实现对生成音乐中旋律的精确控制。

C. 渐进式课程掩码策略

虽然精确的旋律提示允许对音乐旋律进行更大的控制，但它也给模型的创作灵活性带来了挑战。一方面，过于精确的旋律提示可能将额外的音乐元素（如音色）纳入条件信息。在这种情况下，旋律表示更像目标音频的压缩版本，而非纯粹的旋律表示。另一方面，由于旋律提示与目标音频时间对齐，模型更可能学习旋律提示与音频之间的直接关系，而非依赖高层文本提示。由于这两个因素，模型可能变得擅长从精确旋律提示重建目标音频，但不太能够同时由旋律和文本提示引导生成音乐。

为解决此问题，需要在训练期间对旋律提示进行调整。受JEN-1作曲家 [17]启发，我们引入了一种渐进式课程掩码策略，逐步增强模型利用旋律提示进行音乐建模的能力。掩码在两个方向应用：帧方向和音级方向。最初，所有旋律提示都被掩码，允许模型学习使用空旋律提示进行音乐生成。随着训练进展，帧方向的掩码比例逐渐减小，使模型逐步学习纳入旋律提示。需要注意的是，掩码比例在训练期间并非单调递减，因为采样较小掩码比例的概率随时间增加，而采样较大掩码比例的小概率仍然存在。在初始全掩码阶段之后，保留top-1旋律提示，而top-2、top-3和top-4旋律提示被随机掩码和打乱。这种课程掩码策略帮助模型更稳健地学习使用旋律提示。

示，防止对简单重建任务过拟合，并避免丧失文本到音乐生成能力。最终，这种方法在文本和旋律提示控制生成之间取得平衡，确保模型在学习音乐编辑任务的同时保留文本到音乐生成能力。

IV. 实验设置

A. 数据

我们的训练数据来自四个公共音乐数据集：MTG [35]、FMA [36]、MTT [37]和Wikimute [38]。由于我们专注于生成和编辑器乐音乐（即无人声），我们使用PANNs [39]标记器对音轨进行分类并过滤掉有人声的部分。此外，由于这些数据集主要包含音乐标签而非自由形式描述，我们利用SALMONN-13B [40]为每个过滤后的音频样本生成多个描述。处理后，我们编译了一个包含59,955个录音、总计2,239.7小时高质量文本-音乐配对数据的数据集。对于评估，我们从Song Descriptor [41]数据集中选择无歌唱子集，这是stable audio评估 [15], [16], [29]中使用的相同基准。

B. 模型

对于我们的预训练扩散Transformer模型，我们使用StableAudio Open [29]的检查点，其中包括DiT模型和自编码器。ControlNet克隆预训练DiT的一半，创建一个总共12个Transformer块的控制分支。所有输入音频以44.1 kHz立体声格式重采样和处理。旋律提示使用CQT提取，hop长度为512，fmin对应MIDI音符编号0（8.18 Hz）。每个八度包含12个频带，总共128个频带，与128个MIDI音符完美对齐。

在训练期间，我们利用v-objective [25]方法，使模型能够从带噪真实数据预测噪声增量。使用AdamW优化器，学习率为 $5e-5$ ，配合InverseLR调度器，功率设置为0.5。DiT参数保持冻结，仅微调ControlNet和负责转换潜在旋律提示的层。训练由均方误差损失引导，持续到收敛，在4块V100 GPU上大约需要3天，每GPU的mini-batch大小为8。对于推理，我们采用250步DPM-Solver++ [42]采样，使用无分类器引导 [43]，尺度为7，仅应用于全局文本提示控制。

C. 评估

为了评估时变旋律可控性、对全局文本控制的遵循度以及整体音频真实感，我们结合使用主观和客观指标。对于客观指标，旋律准确率评估输入旋律控制的音级与从生成音频中提取的音级之间的逐帧对齐，反映模型在音乐编辑期间保持旋律的能力。我们使用 FD_{open1} 和 KL_{past} 评估模型生成音频与真实参考之间的差异。此外， $CLAP_{score}$ 用于评估生成音频与所提供文本提示之间的一致性。对于主观指标，我们采用5分制的平均意见分数（MOS）来评估生成音乐与文本提示的对齐度以及整体音频质量。共有20名来自不同年龄组的志愿者参与了评估。其中三分之一有过学习乐器或接受音乐教育的经历。

我们的实验评估两个任务：文本到音乐生成和音乐编辑。对于音乐编辑任务，我们基于两个条件生成音乐：从目标音频提取的音乐提示和相应的文本提示。我们选择MusicGen-stereo-melody作为基线，因为它是最有竞争力的立体声音乐生成和编辑开源模型之一。此外，我们进行消融研究，探索处理音乐提示的各种架构和不同的掩码策略。具体来说，我们通过将基于加法的信息注入替换为交叉注意力机制来检查替代的ControlNet结构。

V. 实验结果

A. 客观结果

表I中的客观结果表明，我们的模型成功平衡了文本到音乐生成和音乐编辑，在这两项任务中均提供了强劲性能。尽管与StableAudio Open相比，我们的模型为提高音乐编辑性能而降低了文本到音乐性能，但仍显著优于MusicGen。在音乐编辑任务中，我们的模型在全部四个评估指标上均表现出色，突显了其在音乐编辑方面的熟练程度，同时保留了坚实的文本到音乐生成能力。

表I: Song Describer数据集上的客观结果。对于文本到音乐任务，音乐基于文本提示生成。对于音乐编辑任务，音乐使用文本提示和从给定音频样本提取的旋律提示两者生成。最佳性能以粗体高亮，次佳性能以下划线标出。

模型	文本到音乐 FDopen1↓	文本到音乐 KL-past↓	文本到音乐 CLAPscore↑	文本到音乐 Melody acc↑	音乐编辑 FDopen1↓	音乐编辑 KL-past↓	音乐编辑 CLAPscore↑	音乐编辑 Melody acc↑
MusicGen-stereo-melody	218.82	0.811	0.249	42.3%	199.35	0.432	0.348	-
MusicGen-stereo-melody-large	201.53	0.707	0.279	44.7%	190.79	0.384	0.354	-
Ours w/ cross attention	116.71	0.531	0.417	9.37%	115.10	0.587	0.412	-
Ours w/o masking strategy	—	—	—	54.9%	86.060	0.232	0.393	-
Ours	158.53	0.623	0.375	56.6%	97.734	0.265	0.396	-

B. 主观结果

表II展示了文本-音乐一致性和音频质量的平均MOS分数。主观结果清楚表明，我们的模型在两个任务中均优于MusicGen，在音乐编辑任务中优势尤为显著。

表II: Song Describer数据集上的主观结果。TF和OVL分别代表文本契合度和整体质量。

模型	文本到音乐 TF	文本到音乐 OVL	音乐编辑 TF	音乐编辑 OVL
MusicGen-stereo-melody	2.8	2.5	3.2	3.3
MusicGen-stereo-melody-large	3.3	3.6	3.5	3.5
Ours	3.4	3.6	3.7	3.8

C. 消融研究

消融研究的结果表明，尽管通过交叉注意力注入提示更好地与Transformer结构对齐并提高了生成音乐的质量，但它几乎消除了模型的音乐编辑能力，且难以平衡两类提示，基本上作为一个纯文本到音乐模型运行，这反映在较低的旋律准确率上。

关于掩码策略，没有它，模型无法有效同时保持文本到音乐生成和音乐编辑能力。没有掩码策略时，模型始终在完整旋律提示上训练，这阻碍了其执行仅依赖文本提示而无旋律提示的文本到音乐任务的能力。尽管模型在

音乐编辑指标上表现合理，但这并不意味着它具有强大的音乐编辑能力。如前所述，在训练期间没有掩码策略时，模型更像是在基于旋律提示重建目标音频，而非执行真正的音乐编辑。

因此，即使消融研究中的这两个模型在许多指标上表现出顶级性能，它们也未能正确平衡文本提示和旋律提示的控制效果。

VI. 结论

在本文中，我们提出了一种新颖的音乐生成和编辑方法，旨在支持长格式和可变长度音乐以及文本和旋律提示。为实现这一目标，我们将ControlNet集成到DiT结构中，并引入了一种新颖的top- k CQT表示作为旋律提示，提供更精确和细粒度的旋律控制。主观和客观结果均表明，我们的模型在保持强大文本到音乐生成能力的同时，在音乐编辑方面表现出色，并在文本和旋律提示之间实现了更平衡的控制。